Otimização

1.1 Problemas de otimização e modelação

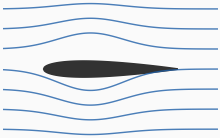
José Firmino Aguilar Madeira

Definição e estrutura geral

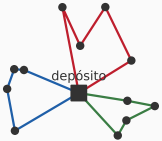
Qual é a melhor?

Otimizar é escolher a melhor alternativa admissível.

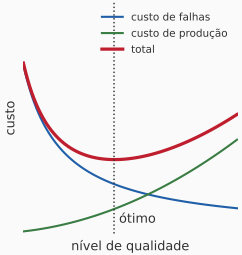
forma que minimiza o arrasto



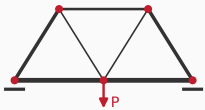
rotas de custo mínimo



compromisso custo / qualidade



estrutura de peso mínimo

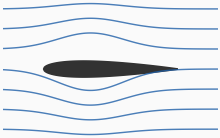


Qual é a melhor?

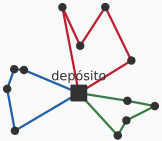
Otimizar é escolher a melhor alternativa admissível.

Mas o que quer dizer melhor? E quais são as alternativas admissíveis?

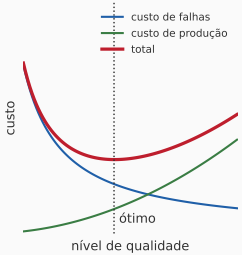
forma que minimiza o arrasto



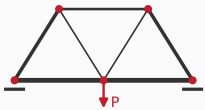
rotas de custo mínimo



compromisso custo / qualidade



estrutura de peso mínimo

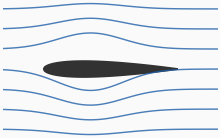


Qual é a melhor?

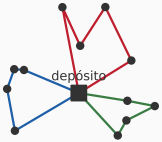
Otimizar é escolher a melhor alternativa admissível.

Mas o que quer dizer melhor? E quais são as alternativas admissíveis?

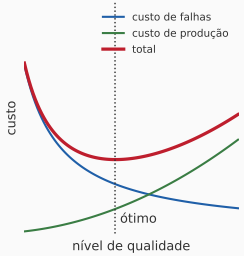
forma que minimiza o arrasto



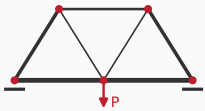
rotas de custo mínimo



compromisso custo / qualidade



estrutura de peso mínimo



Em todos os casos há **decisões** a tomar, um **critério** para as comparar e **limites** que não podem ser ultrapassados.

Nesta aula

1. O que é um problema de otimização?
2. Como se transforma um problema real num modelo matemático?
3. Que tipos de problemas existem?
4. Como se escolhe um método para o resolver?

Um problema concreto: as bicicletas Gira

Há N bicicletas e n estações, a estação i com C_i docas. Quantas bicicletas pôr em cada estação?

Um problema concreto: as bicicletas Gira

Há N bicicletas e n estações, a estação i com C_i docas. Quantas bicicletas pôr em cada estação?

- **O que decidimos:** x_i = número de bicicletas na estação i, $\quad i = 1, \ldots, n$.

Um problema concreto: as bicicletas Gira

Há N bicicletas e n estações, a estação i com C_i docas. Quantas bicicletas pôr em cada estação?

- **O que decidimos:** x_i = número de bicicletas na estação i, $i = 1, \ldots, n$.
- **O que é "melhor":** menos falhas de serviço — pedidos numa estação vazia, devoluções numa estação cheia — estimadas a partir da procura prevista em cada estação.

Um problema concreto: as bicicletas Gira

Há N bicicletas e n estações, a estação i com C_i docas. Quantas bicicletas pôr em cada estação?

- **O que decidimos:** x_i = número de bicicletas na estação i, $\quad i = 1, \ldots, n$.
- **O que é "melhor":** menos falhas de serviço — pedidos numa estação vazia, devoluções numa estação cheia — estimadas a partir da procura prevista em cada estação.
- **O que é permitido:** $x_1 + \cdots + x_n = N$ (não há mais bicicletas); $\quad 0 \leq x_i \leq C_i$ (docas); x_i inteiro.

Um problema concreto: as bicicletas Gira

Há N bicicletas e n estações, a estação i com C_i docas. Quantas bicicletas pôr em cada estação?

- **O que decidimos:** x_i = número de bicicletas na estação i, $\quad i = 1, \ldots, n$.
- **O que é "melhor":** menos falhas de serviço — pedidos numa estação vazia, devoluções numa estação cheia — estimadas a partir da procura prevista em cada estação.
- **O que é permitido:** $x_1 + \cdots + x_n = N$ (não há mais bicicletas); $\quad 0 \leq x_i \leq C_i$ (docas); x_i inteiro.

Isto já é um problema de otimização.

Versão simplificada, para a aula; o trabalho real inclui também a redistribuição ao longo do dia.

A mesma estrutura noutros problemas reais



Bicicletas partilhadas Gira
Câmara Municipal de Lisboa

Quantas bicicletas colocar em cada estação, e como redistribuí-las, para minimizar estações vazias ou cheias. (Trabalho de aluna da UC.)



Logística marítima
GALP/ENACOL
Cabo Verde

Configuração e capacidade dos navios, e logística de distribuição de combustíveis entre ilhas, minimizando custos e roturas de abastecimento.



Bright Optimizer
competição internacional de estudantes

Otimização estrutural: dimensionar uma estrutura de peso mínimo que resista às cargas impostas.
`brightoptimizer.com`

Quanto vale otimizar?

Resultados publicados de estudos de investigação operacional (Hillier & Lieberman), poupança anual:

Continental Airlines	**Samsung Electronics**	**China**
reafetação de tripulações	tempos de fabrico e inventário	grandes projetos energéticos
40 M$	200 M$	425 M$

Outros na mesma fonte: gestão da água nos Países Baixos (15 M$), refinarias Citgo (70 M$), patrulhas da polícia de São Francisco (11 M$).

O ganho vem de decidir melhor, não de produzir mais:
as mesmas máquinas, pessoas e rotas, organizadas de outra forma.

O que é um problema de otimização

Um problema de otimização consiste em encontrar os melhores valores para um conjunto de variáveis de decisão de modo a:

- **minimizar** ou **maximizar** uma função objetivo;
- respeitar um conjunto de restrições.

No problema real		No modelo
o que decidimos	$\rightarrow$	variáveis de decisão $\mathbf{x} = (x_1, \ldots, x_n)$
o que quer dizer "melhor"	$\rightarrow$	função objetivo $f(\mathbf{x})$: custo, lucro, peso, ...
"isto é permitido?"	$\rightarrow$	restrições: condições que a solução tem de cumprir

Nas bicicletas: x_i, as falhas de serviço, e $\sum_i x_i = N$, $0 \leq x_i \leq C_i$.

Restrições

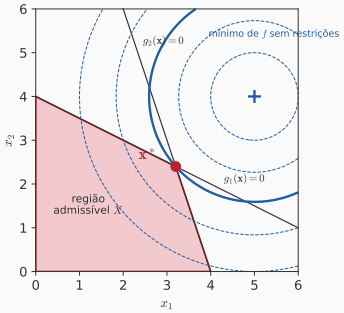
- **Desigualdade:** $g_j(\mathbf{x}) \geq 0$, $j = 1, \ldots, J$ — limites que não podem ser excedidos (capacidade, tensão máxima, orçamento). Um limite "$c(\mathbf{x}) \leq b$" escreve-se $g(\mathbf{x}) = b - c(\mathbf{x}) \geq 0$.
- **Igualdade:** $h_\ell(\mathbf{x}) = 0$, $\ell = 1, \ldots, K$ — condições que têm de ser satisfeitas exatamente (balanço de massa, procura a satisfazer, volume fixo).
- **Limites das variáveis:** $x_i^{(L)} \leq x_i \leq x_i^{(U)}$, $i = 1, \ldots, n$ — o intervalo fisicamente admissível de cada variável.

Convenção da UC, usada em todos os capítulos: desigualdades na forma $g_j(\mathbf{x}) \geq 0$ ($g \leq 0 \iff -g \geq 0$) e sempre *minimizar* ($\max f \iff \min(-f)$).

Formulação geral

$$\begin{aligned} \underset{\mathbf{x}\in\mathbb{R}^n}{\text{minimizar}} \quad & f(\mathbf{x}) \\ \text{sujeito a} \quad & g_j(\mathbf{x}) \geq 0, && j = 1, \ldots, J \\ & h_\ell(\mathbf{x}) = 0, && \ell = 1, \ldots, K \\ & x_i^{(L)} \leq x_i \leq x_i^{(U)}, && i = 1, \ldots, n \end{aligned}$$

- Região admissível X: conjunto dos $\mathbf{x}$ que satisfazem todas as restrições.
- Solução ótima $\mathbf{x}^* \in X$: $f(\mathbf{x}^*) \leq f(\mathbf{x})$ para todo o $\mathbf{x} \in X$.
- Uma restrição diz-se ativa em $\mathbf{x}^*$ se aí vale com igualdade.

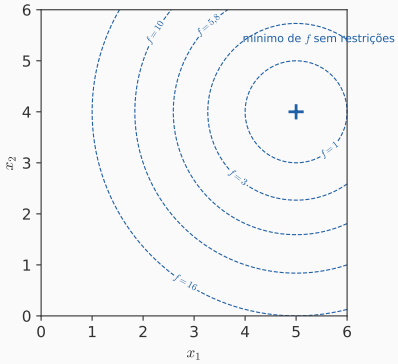


Na figura, g_1 e g_2 são ambas ativas em $\mathbf{x}^*$.

A geometria do problema

min $f(\mathbf{x}) = (x_1 - 5)^2 + (x_2 - 4)^2$
s.a. $g_1 = 8 - x_1 - 2x_2 \geq 0$, $g_2 = 12 - 3x_1 - x_2 \geq 0$,
$\mathbf{x} \geq \mathbf{0}$.

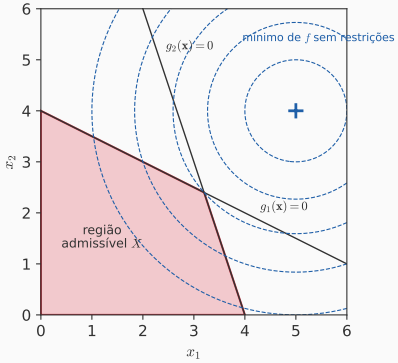
1. Curvas de nível de f: sem restrições, o mínimo seria $(5; 4)$.



A geometria do problema

min $f(\mathbf{x}) = (x_1 - 5)^2 + (x_2 - 4)^2$
s.a. $g_1 = 8 - x_1 - 2x_2 \geq 0$, $g_2 = 12 - 3x_1 - x_2 \geq 0$,
$\mathbf{x} \geq \mathbf{0}$.

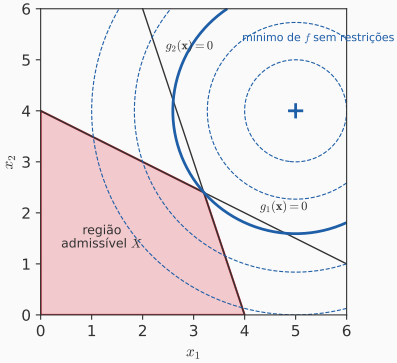
1. Curvas de nível de f: sem restrições, o mínimo seria $(5; 4)$.
2. Região admissível X: só podemos escolher aqui — e $(5; 4) \notin X$.



A geometria do problema

min $f(\mathbf{x}) = (x_1 - 5)^2 + (x_2 - 4)^2$
s.a. $g_1 = 8 - x_1 - 2x_2 \geq 0$, $g_2 = 12 - 3x_1 - x_2 \geq 0$,
$\mathbf{x} \geq \mathbf{0}$.

1. Curvas de nível de f: sem restrições, o mínimo seria $(5; 4)$.
2. Região admissível X: só podemos escolher aqui — e $(5; 4) \notin X$.
3. Descer nas curvas de nível até à mais baixa que ainda toca X.

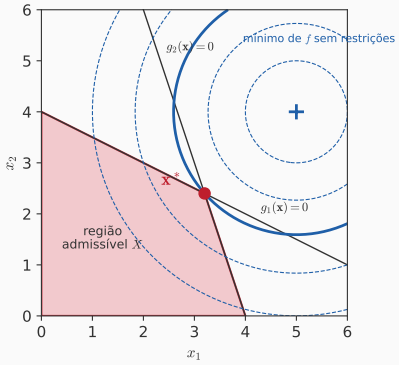


A geometria do problema

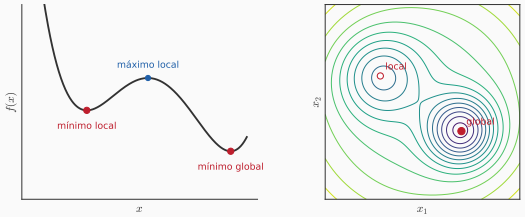
min $f(\mathbf{x}) = (x_1 - 5)^2 + (x_2 - 4)^2$
s.a. $g_1 = 8 - x_1 - 2x_2 \geq 0$, $g_2 = 12 - 3x_1 - x_2 \geq 0$,
$\mathbf{x} \geq \mathbf{0}$.

1. Curvas de nível de f: sem restrições, o mínimo seria $(5; 4)$.
2. Região admissível X: só podemos escolher aqui — e $(5; 4) \notin X$.
3. Descer nas curvas de nível até à mais baixa que ainda toca X.
4. O contacto: $\mathbf{x}^* = (3{,}2;\ 2{,}4)$, $f^* = 5{,}8$, com g_1, g_2 ativas.

O ótimo é o mínimo de f entre as soluções admissíveis — não necessariamente o mínimo sem restrições. Esta ideia volta em 4.1–4.2 (Lagrange, KKT) e em 6.2 (Pareto).

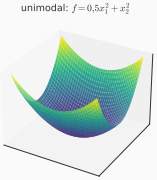


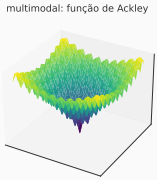
Mínimo local e mínimo global



- $\mathbf{x}^* \in X$ é mínimo global se $f(\mathbf{x}^*) \leq f(\mathbf{x})$ para todo o $\mathbf{x} \in X$.
- $\mathbf{x}^* \in X$ é mínimo local se existe $\delta > 0$ com $f(\mathbf{x}^*) \leq f(\mathbf{x})$ para todo o $\mathbf{x} \in X$ com $\|\mathbf{x} - \mathbf{x}^*\| < \delta$ (estrito: $<$ para $\mathbf{x} \neq \mathbf{x}^*$). Todo o mínimo global é local.
- A maioria dos métodos (caps. 2–4) procura mínimos locais (em rigor, no melhor caso e sob hipóteses, pontos estacionários/KKT); os de otimização global (cap. 5) procuram escapar deles. Se o problema é *convexo*, todo o mínimo local é global.

Funções unimodais e multimodais



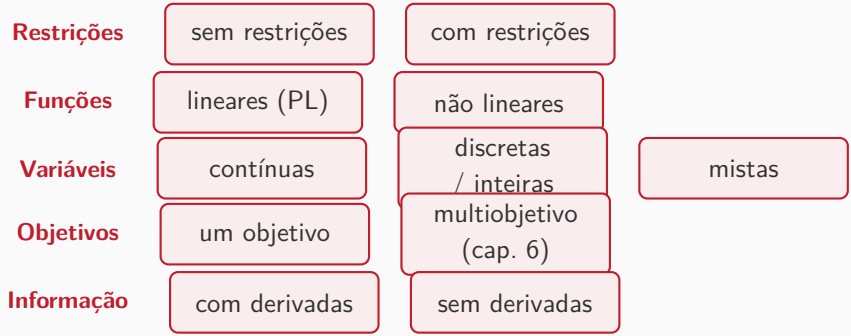


- **Unimodal** (definição rigorosa em 2.1): um único mínimo local, que é global; os métodos de descida dos caps. 2–3 encontram-no, sob as hipóteses de cada um.
- **Multimodal**: vários mínimos locais; o resultado depende do ponto inicial. Motiva os métodos de otimização global (cap. 5).

Teorema de Weierstrass

Uma função contínua num conjunto fechado e limitado (compacto) tem máximo e mínimo nesse conjunto — garante que há solução, não diz como encontrá-la.

Classificação de problemas



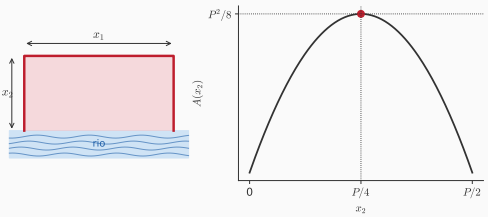
O núcleo teórico da UC é a otimização contínua, não linear, com e sem restrições, com um ou vários objetivos; no cap. 5 vê-se também como algumas metaheurísticas se estendem naturalmente a variáveis discretas e combinatórias.

Exemplos de problemas de otimização

Exemplo 1 — cerca junto ao rio

Maximizar a área de um recinto retangular com um lado encostado a um rio (sem cerca nesse lado), dispondo de P metros de cerca.

- **Variáveis:** x_1 (comprimento), x_2 (largura)
- **Objetivo:** maximizar $A(x_1, x_2) = x_1 x_2$
- **Restrições:** $x_1 + 2x_2 \leq P$; $\quad x_1, x_2 \geq 0$



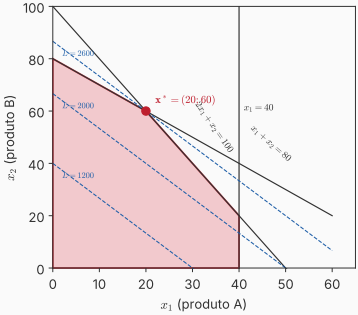
Resolução

A cerca será toda usada, logo $x_1 = P - 2x_2$ e $A(x_2) = Px_2 - 2x_2^2$. De $A'(x_2) = P - 4x_2 = 0$ vem $x_2^* = P/4$, $x_1^* = P/2$ e $A_{\max} = P^2/8$ ($A'' = -4 < 0$: é máximo).

Exemplo 2 — plano de produção

Uma empresa fabrica dois produtos com lucro unitário de 40 € (A) e 30 € (B). Por unidade, A gasta 2 h de máquina e 1 h de mão de obra; B gasta 1 h de cada. Há 100 h de máquina, 80 h de mão de obra e a procura de A não excede 40 unidades.

$$
\begin{aligned}
\max \quad & L = 40x_1 + 30x_2 \\
\text{s.a.} \quad & 2x_1 + x_2 \leq 100 \quad \text{(máquina)} \\
& x_1 + x_2 \leq 80 \quad \text{(mão de obra)} \\
& x_1 \leq 40 \quad \text{(procura)}, \qquad x_1, x_2 \geq 0
\end{aligned}
$$



Problema linear: a região admissível é um polígono e o ótimo está num vértice. As retas de nível $L = \text{const}$ deslizam até ao último ponto admissível: $\mathbf{x}^* = (20; 60)$, $L^* = 2600$ €.
Restrições ativas: máquina e mão de obra.

Exemplo 3 — lata de volume dado: modelar

Fabricar uma lata cilíndrica com $V = 330\,\text{cm}^3$ gastando o mínimo de material.

Antes de ver a resposta: quais são (1) as variáveis, (2) o objetivo, (3) as restrições?

Exemplo 3 — lata de volume dado: modelar

Fabricar uma lata cilíndrica com $V = 330\,\text{cm}^3$ gastando o mínimo de material.

Antes de ver a resposta: quais são (1) as variáveis, (2) o objetivo, (3) as restrições?

- **Variáveis:** o raio r e a altura h.

Exemplo 3 — lata de volume dado: modelar

Fabricar uma lata cilíndrica com $V = 330\,\text{cm}^3$ gastando o mínimo de material.

Antes de ver a resposta: quais são (1) as variáveis, (2) o objetivo, (3) as restrições?

- **Variáveis:** o raio r e a altura h.
- **Objetivo:** minimizar a área da chapa, $A(r, h) = 2\pi r^2 + 2\pi rh$ (fundo, tampa e lado).

Exemplo 3 — lata de volume dado: modelar

Fabricar uma lata cilíndrica com $V = 330\,\text{cm}^3$ gastando o mínimo de material.

Antes de ver a resposta: quais são (1) as variáveis, (2) o objetivo, (3) as restrições?

- **Variáveis:** o raio r e a altura h.
- **Objetivo:** minimizar a área da chapa, $A(r, h) = 2\pi r^2 + 2\pi rh$ (fundo, tampa e lado).
- **Restrições:** $\pi r^2 h = V$ (o volume é dado); $r, h > 0$.

Exemplo 3 — lata de volume dado: modelar

Fabricar uma lata cilíndrica com $V = 330\,\text{cm}^3$ gastando o mínimo de material.

Antes de ver a resposta: quais são (1) as variáveis, (2) o objetivo, (3) as restrições?

- **Variáveis:** o raio r e a altura h.
- **Objetivo:** minimizar a área da chapa, $A(r, h) = 2\pi r^2 + 2\pi rh$ (fundo, tampa e lado).
- **Restrições:** $\pi r^2 h = V$ (o volume é dado); $r, h > 0$.

$$\min_{r,h} \; 2\pi r^2 + 2\pi rh \qquad \text{s.a.} \quad \pi r^2 h = V, \;\; r, h > 0$$

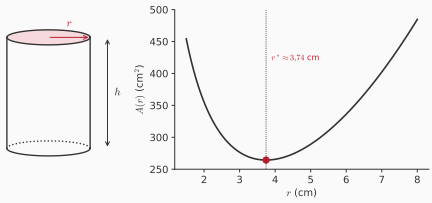
Exemplo 3 — lata de volume dado: resolver

Problema não linear com uma restrição de igualdade. Eliminando $h = V/(\pi r^2)$:

$$A(r) = 2\pi r^2 + \frac{2V}{r}, \qquad A'(r) = 4\pi r - \frac{2V}{r^2} = 0$$

$$\Rightarrow \quad r^* = \sqrt[3]{V/(2\pi)} \approx 3{,}74\,\text{cm}.$$

$A''(r) = 4\pi + 4V/r^3 > 0 \Rightarrow$ mínimo;
$A^* \approx 264{,}4\,\text{cm}^2$. Logo $h^* = 2r^* \approx 7{,}5\,\text{cm}$: a lata ótima é tão alta como larga (as reais não são — há outros custos e restrições fora deste modelo).



O que os exemplos têm em comum

	Cerca	Produção	Lata
Variáveis	x_1, x_2	x_1, x_2	r, h
Objetivo	$\max x_1 x_2$	$\max 40x_1 + 30x_2$	$\min 2\pi r^2 + 2\pi rh$
Restrições	$x_1 + 2x_2 \leq P$	3 desigualdades	$\pi r^2 h = V$
Tipo	não linear	linear	não linear
Resolução	eliminar + derivar	gráfica (vértice)	eliminar + derivar

Com mais variáveis, ou funções que não se derivam à mão, estes truques deixam de servir: é para isso que existem os métodos numéricos dos capítulos seguintes.

O exemplo 2 num *solver*: o que o computador devolve

```
% max 40x1+30x2  ->  min -(40x1+30x2); restricoes A*x <= b
c = [-40; -30];
A = [2 1; 1 1; 1 0];   b = [100; 80; 40];
lb = [0; 0];
[x, L, ~, ~, lambda] = linprog(c, A, b, [], [], lb);
x, -L                      % x = (20, 60),  -L = 2600
lambda.ineqlin             % precos-sombra: 10, 20, 0
```

- Os preços-sombra: uma hora extra de máquina vale 10 €, uma de mão de obra 20 €; a restrição de procura, inativa, vale 0. É a informação que o solver dá *além* da solução — 4.2.
- Verifique à mão: nas duas restrições ativas, $2\lambda_1 + \lambda_2 = 40$ e $\lambda_1 + \lambda_2 = 30$ dão $\lambda_1 = 10$, $\lambda_2 = 20$.

O MESMO EM PYTHON

```
from scipy.optimize import linprog
res = linprog(c=[-40,-30],
    A_ub=[[2,1],[1,1],[1,0]],
    b_ub=[100,80,40], bounds=[(0,None)]*2)
res.x, -res.fun          # (20,60), 2600
res.ineqlin.marginals    # -10, -20, 0
```

A mesma formulação matemática em duas linguagens; o *solver* interno pode ser diferente. Os `marginals` do SciPy vêm com sinal negativo por convenção (minimização de $-L$): -10 e -20 são os 10 e 20 do MATLAB.

Modelação matemática de problemas

Duas perguntas diferentes

1. Qual é o problema? — *modelação*

realidade $\longrightarrow$ $\mathbf{x}$, f, g_j, h_ℓ

2. Como o resolvemos? — *otimização*

$(\mathbf{x}, f, g_j, h_\ell)$ $\longrightarrow$ algoritmo $\longrightarrow$ $\mathbf{x}^*$

Um algoritmo excelente aplicado ao modelo errado
resolve muito bem o problema errado.

Esta UC é sobretudo sobre a pergunta 2; mas cada capítulo começa pela 1.

Da situação real ao modelo

1. **Identificar as variáveis de decisão.** O que podemos escolher? Quantidades, dimensões, posições, sim/não. Fixar unidades.
2. **Formular a função objetivo.** Uma única métrica, nas mesmas unidades, escrita em função das variáveis. Se há vários critérios: agregá-los ou tratar como multiobjetivo (cap. 6).
3. **Escrever as restrições.** Recursos limitados, leis físicas, procura, segurança, sinais das variáveis. Verificar que cada uma é expressa só com as variáveis e dados conhecidos.

Dois erros frequentes

Tratar um *dado* como variável (ou vice-versa); somar na função objetivo grandezas com unidades diferentes (euros com horas).

Exemplo completo — rede de transporte

Uma empresa distribui mercadoria de armazéns $i \in \{1, \ldots, I\}$ para clientes $c \in \{1, \ldots, C\}$. Cada armazém tem oferta s_i, cada cliente procura d_c, e transportar uma unidade de i para c custa p_{ic} (*dados*).

Passo 1 — variáveis

$x_{ic} \geq 0$: quantidade enviada de i para c.

Passo 2 — objetivo

$\min \sum_{i=1}^{I} \sum_{c=1}^{C} p_{ic}\, x_{ic}$ (custo total, em €)

Passo 3 — restrições

$\sum_c x_{ic} \leq s_i$ (não exceder a oferta), $\sum_i x_{ic} = d_c$ (satisfazer a procura), $x_{ic} \leq q_{ic}$ (capacidade da rota).

Exemplo completo — e depois do modelo?

- **Verificar** se o modelo é admissível: $\sum_i s_i \geq \sum_c d_c$ é condição necessária (suficiente só sem capacidades de rota).
- **Classificar**: linear, contínuo, com restrições — resolve-se com o método do simplex ou pontos interiores, mesmo com milhares de variáveis.
- **Resolver** numericamente e **interpretar**: quais as restrições ativas? Quanto vale relaxar cada uma (preços-sombra)?
- **Validar** com dados reais e refinar o modelo (tempos de entrega, veículos inteiros, várias mercadorias, ...).

Um modelo é sempre uma simplificação; a qualidade da decisão depende mais do modelo do que do algoritmo que o resolve.

O mesmo modelo, à escala real

OTIMIZAÇÃO NA PRÁTICA — logística marítima de combustíveis entre ilhas (GALP/ENACOL, Cabo Verde)

Decisão	que navios usar (e com que capacidade), que rotas e calendário entre as ilhas, e quanto de cada combustível descarregar em cada porto.
Variáveis	quantidades por viagem, porto e produto (contínuas) *e* escolhas de navio, rota e sequência de portos (discretas).
Objetivo	minimizar o custo de distribuição e as roturas de abastecimento.
Restrições	procura de cada ilha, capacidade dos tanques em terra e dos navios, condições dos portos, prazos.
Porque é difícil	é a rede de transporte das páginas anteriores com decisões inteiras, vários produtos e a dimensão temporal: o resultado não é uma solução, é um *sistema de apoio à decisão* que se volta a usar sempre que os dados mudam.
Métodos	modelos de programação linear (inteira) mista, integrados num sistema de apoio à decisão. A formulação — o que é variável, dado ou restrição — é a parte decisiva.

Problema académico vs. problema real

	cerca, produção, lata	problemas reais (p. ex. parque eólico, estrutura)
f conhece-se?	fórmula explícita	sai de uma simulação, de um modelo de elementos finitos ou de dados
custo de avaliar f	desprezável	segundos a horas por avaliação
derivadas	à mão, exatas	muitas vezes indisponíveis ou pouco fiáveis
variáveis	2, contínuas	dezenas a milhares; contínuas, inteiras, mistas
restrições	1–3, simples	muitas, algumas só verificáveis a posteriori
objetivos	um	frequentemente vários, em conflito
ruído	nenhum	medições, simulações estocásticas

Os exemplos académicos servem para perceber os métodos. Os problemas reais explicam porque existe uma área científica chamada otimização: quase todas as linhas da coluna da direita são uma razão para um capítulo desta UC; variáveis inteiras e ruído ficam fora do núcleo.

Panorama da UC

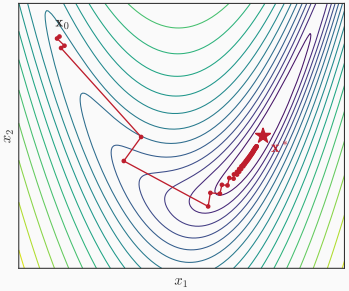
Como se resolve numericamente

Quase todos os métodos são iterativos:

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \lambda_k \mathbf{S}_k, \qquad k = 0, 1, 2, \ldots$$

- $\mathbf{x}_0$: ponto inicial; $\mathbf{x}_k$: o ponto após k iterações
- $\mathbf{S}_k$: direção de pesquisa (cap. 3)
- $\lambda_k > 0$: comprimento do passo ao longo da direção (cap. 2)
- parar quando $\|\nabla f(\mathbf{x}_k)\|$, o passo ou a variação de f forem pequenos

Os capítulos seguintes diferem em *como* escolhem $\mathbf{S}_k$ e λ_k, em que informação sobre f usam, e em como tratam as restrições.



Iterações de um método do gradiente sobre as curvas de nível de f.

A pergunta que atravessa a UC

Que informação temos sobre f? Quanto custa obtê-la? O que conseguimos garantir com ela?

	informação sobre f	custo típico	o que se garante
só valores de f (ordem 0)	comparações $f(\mathbf{x}) < f(\mathbf{x}')$	muitas avaliações (n_f)	NM: sem garantia geral; pesquisa direta formalizada (p. ex. GLODS, 5.1): estacionariedade sob hipóteses adequadas
gradiente (ordem 1)	para onde f desce	$n_g = 1$ (analítico) ou $2n$ avaliações de f (centrais)	estacionariedade no limite, de qualquer $\mathbf{x}_0$ (sob regularidade + pesq. em linha adequada; 3.3.1)
Hessiana (ordem 2)	curvatura	$n_H = 1$ (analítica) ou $O(n^2)$ avaliações de f	convergência rápida, perto da solução
estrutura (linear, convexa)	forma global de f e de X	—	ótimo global

Contamos à parte n_f (avaliações de f), n_g (de f'; em $\mathbb{R}^n$, gradientes) e n_H (de f''; Hessianas). Cada capítulo responde com um compromisso diferente entre informação, custo e garantia. Antes de resolver é preciso decidir *o que são as variáveis, o que significa "melhor", o que é permitido e quanto custa avaliar uma decisão*.

Como escolher um método: perguntas antes do algoritmo

Pergunta	Cap.	Métodos
Uma variável?	2	secção áurea, Powell, bisseção, Newton–Raphson
Várias variáveis, sem restrições?	3	sem derivadas: pesquisa aleatória, pesquisa em grelha, Nelder–Mead, Box, Hooke–Jeeves; com derivadas: gradiente, Newton, gradientes conjugados
Há restrições?	4	Lagrange, KKT, penalização exterior e interior
Há vários mínimos locais?	5	GLODS, *simulated annealing*, algoritmos genéticos
Há vários objetivos?	6	Pareto, agregação, ε-constrangimento, DMS, NSGA-II
Temos derivadas?	2–3	com ou sem derivadas (ordem 0, 1, 2)
f é cara ou caixa negra?	todos	o recurso crítico passa a ser o número de avaliações de f

Não existe "o melhor algoritmo de otimização".

Existe o método adequado à informação disponível e à estrutura do problema.

A seguir (1.2): onde se usa otimização.

Referências e recursos

Referências Lista completa: *Bibliografia da UC*, no fim do PDF da UC.

- Hillier, F. S., Lieberman, G. J., *Introduction to Operations Research*, 2024 Release, McGraw-Hill, 2024 — casos de estudo citados no deck.
- Arora, J. S., *Introduction to Optimum Design*, 3.ª ed., Academic Press, 2011 — cap. 2, formulação.

Recursos

- MATLAB: `linprog` (Optimization Toolbox), preços-sombra em `lambda.ineqlin`.
- Python: `scipy.optimize.linprog`, preços-sombra em `res.ineqlin.marginals`. Ligação: `brightoptimizer.com`.