

Otimização

1.1 Problemas de otimização e modelação


José Firmino Aguilar Madeira

Definição e estrutura geral


Qual é a melhor?

Otimizar é escolher a melhor alternativa admissível.


forma que minimiza o arrasto




rotas de custo mínimo



compromisso custo / qualidade



estrutura de peso mínimo




Qual é a melhor?

Otimizar é **escolher a melhor alternativa admissível**.

Mas o que quer dizer **melhor**? E quais são as alternativas **admissíveis**?


forma que minimiza o arrasto




rotas de custo mínimo



compromisso custo / qualidade



estrutura de peso mínimo




Qual é a melhor?


Otimizar é **escolher a melhor alternativa admissível**.

Mas o que quer dizer **melhor**? E quais são as alternativas **admissíveis**?


forma que minimiza o arrasto




rotas de custo mínimo



compromisso custo / qualidade



estrutura de peso mínimo



Em todos os casos há **decisões** a tomar, um **critério** para as comparar e **limites** que não podem ser ultrapassados.

1. O que é um problema de otimização?
2. Como se transforma um problema real num modelo matemático?
3. Que tipos de problemas existem?
4. Como se escolhe um método para o resolver?

Um problema concreto: as bicicletas Gira

Há N bicicletas e n estações, a estação i com C_i docas. Quantas bicicletas pôr em cada estação?

Um problema concreto: as bicicletas Gira

Há N bicicletas e n estações, a estação i com C_i docas. Quantas bicicletas pôr em cada estação?

- **O que decidimos:** x_i = número de bicicletas na estação i , $i = 1, \dots, n$.

Um problema concreto: as bicicletas Gira

Há N bicicletas e n estações, a estação i com C_i docas. Quantas bicicletas pôr em cada estação?

- **O que decidimos:** x_i = número de bicicletas na estação i , $i = 1, \dots, n$.
- **O que é “melhor”:** menos falhas de serviço — pedidos numa estação vazia, devoluções numa estação cheia — estimadas a partir da procura prevista em cada estação.

Um problema concreto: as bicicletas Gira

Há N bicicletas e n estações, a estação i com C_i docas. Quantas bicicletas pôr em cada estação?

- **O que decidimos:** x_i = número de bicicletas na estação i , $i = 1, \dots, n$.
- **O que é “melhor”:** menos falhas de serviço — pedidos numa estação vazia, devoluções numa estação cheia — estimadas a partir da procura prevista em cada estação.
- **O que é permitido:** $x_1 + \dots + x_n = N$ (não há mais bicicletas); $0 \leq x_i \leq C_i$ (docas); x_i inteiro.

Um problema concreto: as bicicletas Gira

Há N bicicletas e n estações, a estação i com C_i docas. Quantas bicicletas pôr em cada estação?

- **O que decidimos:** x_i = número de bicicletas na estação i , $i = 1, \dots, n$.
- **O que é “melhor”:** menos falhas de serviço — pedidos numa estação vazia, devoluções numa estação cheia — estimadas a partir da procura prevista em cada estação.
- **O que é permitido:** $x_1 + \dots + x_n = N$ (não há mais bicicletas); $0 \leq x_i \leq C_i$ (docas); x_i inteiro.

Isto já é um problema de otimização.

Versão simplificada, para a aula; o trabalho real inclui também a redistribuição ao longo do dia.

Quanto vale otimizar?

Resultados publicados de estudos de investigação operacional (Hillier & Lieberman), poupança anual:

Continental Airlines	Samsung Electronics	China
reafetação de tripulações	tempos de fabrico e inventário	grandes projetos energéticos
40 M\$	200 M\$	425 M\$

Outros na mesma fonte: gestão da água nos Países Baixos (15 M\$), refinarias Citgo (70 M\$), patrulhas da polícia de São Francisco (11 M\$).

O ganho vem de **decidir melhor**, não de produzir mais:
as mesmas máquinas, pessoas e rotas, organizadas de outra forma.

O que é um problema de otimização

Um **problema de otimização** consiste em encontrar os melhores valores para um conjunto de variáveis de decisão de modo a:

- **minimizar** ou **maximizar** uma função objetivo;
- respeitar um conjunto de restrições.

No problema real	No modelo
o que decidimos	→ variáveis de decisão $\mathbf{x} = (x_1, \dots, x_n)$
o que quer dizer “melhor”	→ função objetivo $f(\mathbf{x})$: custo, lucro, peso, ...
“isto é permitido?”	→ restrições : condições que a solução tem de cumprir

Nas bicicletas: x_i , as falhas de serviço, e $\sum_i x_i = N$, $0 \leq x_i \leq C_i$.

- **Desigualdade:** $g_j(\mathbf{x}) \geq 0$, $j = 1, \dots, J$ — limites que não podem ser excedidos (capacidade, tensão máxima, orçamento). Um limite “ $c(\mathbf{x}) \leq b$ ” escreve-se $g(\mathbf{x}) = b - c(\mathbf{x}) \geq 0$.
- **Igualdade:** $h_\ell(\mathbf{x}) = 0$, $\ell = 1, \dots, K$ — condições que têm de ser satisfeitas exatamente (balanço de massa, procura a satisfazer, volume fixo).
- **Limites das variáveis:** $x_i^{(L)} \leq x_i \leq x_i^{(U)}$, $i = 1, \dots, n$ — o intervalo fisicamente admissível de cada variável.

Convenção da UC, usada em todos os capítulos: desigualdades na forma $g_j(\mathbf{x}) \geq 0$ ($g \leq 0 \iff -g \geq 0$) e sempre *minimizar* ($\max f \iff \min(-f)$).

Formulação geral


minimizar $f(\mathbf{x})$
 $\mathbf{x} \in \mathbb{R}^n$

sujeito a $g_j(\mathbf{x}) \geq 0, \quad j = 1, \dots, J$

$h_\ell(\mathbf{x}) = 0, \quad \ell = 1, \dots, K$

$x_i^{(L)} \leq x_i \leq x_i^{(U)}, \quad i = 1, \dots, n$

- **Região admissível** X : conjunto dos $\mathbf{x}$ que satisfazem todas as restrições.
- **Solução ótima** $\mathbf{x}^* \in X$: $f(\mathbf{x}^*) \leq f(\mathbf{x})$ para todo $\mathbf{x} \in X$.
- Uma restrição diz-se **ativa** em $\mathbf{x}^*$ se aí vale com igualdade.



Na
figura, g_1 e g_2 são ambas ativas em $\mathbf{x}^*$.


A geometria do problema

$$\min f(\mathbf{x}) = (x_1 - 5)^2 + (x_2 - 4)^2$$

$$\text{s.a. } g_1 = 8 - x_1 - 2x_2 \geq 0, \quad g_2 = 12 - 3x_1 - x_2 \geq 0,$$

$$\mathbf{x} \geq \mathbf{0}.$$

1. Curvas de nível de f : sem restrições, o mínimo seria $(5, 4)$.




A geometria do problema

$$\min f(\mathbf{x}) = (x_1 - 5)^2 + (x_2 - 4)^2$$

$$\text{s.a. } g_1 = 8 - x_1 - 2x_2 \geq 0, \quad g_2 = 12 - 3x_1 - x_2 \geq 0,$$

$$\mathbf{x} \geq \mathbf{0}.$$

1. Curvas de nível de f : sem restrições, o mínimo seria $(5, 4)$.
2. Região admissível X : só podemos escolher aqui — e $(5, 4) \notin X$.




A geometria do problema

$$\min f(\mathbf{x}) = (x_1 - 5)^2 + (x_2 - 4)^2$$

$$\text{s.a. } g_1 = 8 - x_1 - 2x_2 \geq 0, \quad g_2 = 12 - 3x_1 - x_2 \geq 0,$$

$$\mathbf{x} \geq \mathbf{0}.$$

1. Curvas de nível de f : sem restrições, o mínimo seria $(5, 4)$.
2. Região admissível X : **só podemos escolher aqui** — e $(5, 4) \notin X$.
3. Descer nas curvas de nível até à mais baixa que ainda **toca** X .




A geometria do problema


$$\begin{aligned} \min \quad & f(\mathbf{x}) = (x_1 - 5)^2 + (x_2 - 4)^2 \\ \text{s.a.} \quad & g_1 = 8 - x_1 - 2x_2 \geq 0, \quad g_2 = 12 - 3x_1 - x_2 \geq 0, \\ & \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

1. Curvas de nível de f : sem restrições, o mínimo seria $(5, 4)$.
2. Região admissível X : **só podemos escolher aqui** — e $(5, 4) \notin X$.
3. Descer nas curvas de nível até à mais baixa que ainda **toca** X .
4. O contacto: $\mathbf{x}^* = (3, 2)$, $f^* = 5,8$, com g_1 , g_2 ativas.

O ótimo é o mínimo de f entre as soluções admissíveis — não necessariamente o mínimo sem restrições. Esta ideia volta em 4.1–4.2 (Lagrange, KKT) e em 6.2 (Pareto).




Mínimo local e mínimo global




- $\mathbf{x}^* \in X$ é **mínimo global** se $f(\mathbf{x}^*) \leq f(\mathbf{x})$ para todo o $\mathbf{x} \in X$.
- $\mathbf{x}^* \in X$ é **mínimo local** se existe $\delta > 0$ com $f(\mathbf{x}^*) \leq f(\mathbf{x})$ para todo o $\mathbf{x} \in X$ com $\|\mathbf{x} - \mathbf{x}^*\| < \delta$ (**estrito**: $<$ para $\mathbf{x} \neq \mathbf{x}^*$). Todo o mínimo global é local.
- A maioria dos métodos (caps. 2–4) procura mínimos locais (em rigor, no melhor caso e sob hipóteses, pontos estacionários/KKT); os de otimização global (cap. 5) procuram escapar deles. Se o problema é *convexo*, todo o mínimo local é global.

Funções unimodais e multimodais

unimodal: $f = 0,5x_1^2 + x_2^2$



multimodal: função de Ackley



- **Unimodal** (definição rigorosa em 2.1): um único mínimo local, que é global; os métodos de descida dos caps. 2–3 encontram-no, sob as hipóteses de cada um.
- **Multimodal**: vários mínimos locais; o resultado depende do ponto inicial. Motiva os métodos de otimização global (cap. 5).

Teorema de Weierstrass

Uma função contínua num conjunto fechado e limitado (compacto) tem máximo e mínimo nesse conjunto — garante que há solução, não diz como encontrá-la.

Classificação de problemas

Restrições	sem restrições	com restrições	
Funções	lineares (PL)	não lineares	
Variáveis	contínuas	discretas / inteiras	mistas
Objetivos	um objetivo	multiobjetivo (cap. 6)	
Informação	com derivadas	sem derivadas	



O núcleo teórico da UC é a otimização **contínua**, não linear, com e sem restrições, com um ou vários objetivos; no cap. 5 vê-se também como algumas metaheurísticas se estendem naturalmente a variáveis discretas e combinatórias.

Exemplos de problemas de otimização

Exemplo 1 — cerca junto ao rio

Maximizar a área de um recinto retangular com um lado encostado a um rio (sem cerca nesse lado), dispondo de P metros de cerca.

- **Variáveis:** x_1 (comprimento), x_2 (largura)
- **Objetivo:** maximizar $A(x_1, x_2) = x_1 x_2$
- **Restrições:** $x_1 + 2x_2 \leq P$; $x_1, x_2 \geq 0$



Resolução

A cerca será toda usada, logo $x_1 = P - 2x_2$ e $A(x_2) = Px_2 - 2x_2^2$. De $A'(x_2) = P - 4x_2 = 0$ vem $x_2^* = P/4$, $x_1^* = P/2$ e $A_{\max} = P^2/8$ ($A'' = -4 < 0$: é máximo).


Exemplo 2 — plano de produção

Uma empresa fabrica dois produtos com lucro unitário de 40 € (A) e 30 € (B). Por unidade, A gasta 2 h de máquina e 1 h de mão de obra; B gasta 1 h de cada. Há 100 h de máquina, 80 h de mão de obra e a procura de A não excede 40 unidades.

$$\begin{aligned} \max \quad & L = 40x_1 + 30x_2 \\ \text{s.a.} \quad & 2x_1 + x_2 \leq 100 \quad (\text{máquina}) \\ & x_1 + x_2 \leq 80 \quad (\text{mão de obra}) \\ & x_1 \leq 40 \quad (\text{procura}), \quad x_1, x_2 \geq 0 \end{aligned}$$

Problema **linear**: a região admissível é um polígono e o ótimo está num vértice. As retas de nível $L = \text{const}$ deslizam até ao último ponto admissível: $\mathbf{x}^* = (20, 60)$, $L^* = 2600$ €.

Restrições ativas: máquina e mão de obra.



Exemplo 3 — lata de volume dado: modelar

Fabricar uma lata cilíndrica com $V = 330 \text{ cm}^3$ gastando o mínimo de material.

Antes de ver a resposta: quais são (1) as variáveis, (2) o objetivo, (3) as restrições?

Exemplo 3 — lata de volume dado: modelar

Fabricar uma lata cilíndrica com $V = 330 \text{ cm}^3$ gastando o mínimo de material.

Antes de ver a resposta: quais são (1) as variáveis, (2) o objetivo, (3) as restrições?

- **Variáveis:** o raio r e a altura h .

Exemplo 3 — lata de volume dado: modelar

Fabricar uma lata cilíndrica com $V = 330 \text{ cm}^3$ gastando o mínimo de material.

Antes de ver a resposta: quais são (1) as variáveis, (2) o objetivo, (3) as restrições?

- **Variáveis:** o raio r e a altura h .
- **Objetivo:** minimizar a área da chapa, $A(r, h) = 2\pi r^2 + 2\pi rh$ (fundo, tampa e lado).

Exemplo 3 — lata de volume dado: modelar

Fabricar uma lata cilíndrica com $V = 330 \text{ cm}^3$ gastando o mínimo de material.

Antes de ver a resposta: quais são (1) as variáveis, (2) o objetivo, (3) as restrições?

- **Variáveis:** o raio r e a altura h .
- **Objetivo:** minimizar a área da chapa, $A(r, h) = 2\pi r^2 + 2\pi rh$ (fundo, tampa e lado).
- **Restrições:** $\pi r^2 h = V$ (o volume é dado); $r, h > 0$.

Exemplo 3 — lata de volume dado: modelar

Fabricar uma lata cilíndrica com $V = 330 \text{ cm}^3$ gastando o mínimo de material.

Antes de ver a resposta: quais são (1) as variáveis, (2) o objetivo, (3) as restrições?

- **Variáveis:** o raio r e a altura h .
- **Objetivo:** minimizar a área da chapa, $A(r, h) = 2\pi r^2 + 2\pi rh$ (fundo, tampa e lado).
- **Restrições:** $\pi r^2 h = V$ (o volume é dado); $r, h > 0$.

$$\min_{r, h} 2\pi r^2 + 2\pi rh \quad \text{s.a.} \quad \pi r^2 h = V, \quad r, h > 0$$

Exemplo 3 — lata de volume dado: resolver


Problema **não linear** com uma restrição de igualdade. Eliminando $h = V/(\pi r^2)$:

$$A(r) = 2\pi r^2 + \frac{2V}{r}, \quad A'(r) = 4\pi r - \frac{2V}{r^2} = 0$$

$$\Rightarrow r^* = \sqrt[3]{V/(2\pi)} \approx 3,74 \text{ cm.}$$

$A''(r) = 4\pi + 4V/r^3 > 0 \Rightarrow$ mínimo;

$A^* \approx 264,4 \text{ cm}^2$. Logo $h^* = 2r^* \approx 7,5 \text{ cm}$: a lata ótima é tão alta como larga (as reais não são — há outros custos e restrições fora deste modelo).



O que os exemplos têm em comum

	Cerca	Produção	Lata
Variáveis	x_1, x_2	x_1, x_2	r, h
Objetivo	$\max x_1 x_2$	$\max 40x_1 + 30x_2$	$\min 2\pi r^2 + 2\pi rh$
Restrições	$x_1 + 2x_2 \leq P$	3 desigualdades	$\pi r^2 h = V$
Tipo	não linear	linear	não linear
Resolução	eliminar + derivar	gráfica (vértice)	eliminar + derivar

Com mais variáveis, ou funções que não se derivam à mão, estes truques deixam de servir: é para isso que existem os **métodos numéricos** dos capítulos seguintes.

O exemplo 2 num *solver*: o que o computador devolve

```
% max 40x1+30x2 -> min -(40x1+30x2); restricoes A*x <= b
c = [-40; -30];
A = [2 1; 1 1; 1 0]; b = [100; 80; 40];
lb = [0; 0];
[x, L, ~, ~, lambda] = linprog(c, A, b, [], [], lb);
x, -L % x = (20, 60), -L = 2600
lambda.ineqlin % precos-sombra: 10, 20, 0
```

- Os **preços-sombra**: uma hora extra de máquina vale 10 €, uma de mão de obra 20 €; a restrição de procura, inativa, vale 0. É a informação que o solver dá *além* da solução — 4.2.
- Verifique à mão: nas duas restrições ativas, $2\lambda_1 + \lambda_2 = 40$ e $\lambda_1 + \lambda_2 = 30$ dão $\lambda_1 = 10$, $\lambda_2 = 20$.

O MESMO EM PYTHON

```
from scipy.optimize import linprog
res = linprog(c=[-40,-30],
              A_ub=[[2,1],[1,1],[1,0]],
              b_ub=[100,80,40], bounds=[(0,None)]*2)
res.x, -res.fun # (20,60), 2600
res.ineqlin.marginals # -10, -20, 0
```

A mesma formulação matemática em duas linguagens; o *solver* interno pode ser diferente. Os marginals do SciPy vêm com sinal negativo por convenção (minimização de $-L$): -10 e -20 são os 10 e 20 do MATLAB.

Modelação matemática de problemas

Duas perguntas diferentes

1. Qual é o problema? — *modelação*

realidade $\longrightarrow \mathbf{x}, f, g_j, h_\ell$

2. Como o resolvemos? — *otimização*

$(\mathbf{x}, f, g_j, h_\ell) \longrightarrow \text{algoritmo} \longrightarrow \mathbf{x}^*$

Um algoritmo excelente aplicado ao modelo errado
resolve muito bem o **problema errado**.

Esta UC é sobretudo sobre a pergunta 2; mas cada capítulo começa pela 1.

Da situação real ao modelo

1. **Identificar as variáveis de decisão.** O que podemos escolher? Quantidades, dimensões, posições, sim/não. Fixar unidades.
2. **Formular a função objetivo.** Uma única métrica, nas mesmas unidades, escrita em função das variáveis. Se há vários critérios: agregá-los ou tratar como multiobjetivo (cap. 6).
3. **Escrever as restrições.** Recursos limitados, leis físicas, procura, segurança, sinais das variáveis. Verificar que cada uma é expressa só com as variáveis e dados conhecidos.

Dois erros frequentes

Tratar um *dado* como variável (ou vice-versa); somar na função objetivo grandezas com unidades diferentes (euros com horas).

Exemplo completo — rede de transporte

Uma empresa distribui mercadoria de armazéns $i \in \{1, \dots, I\}$ para clientes $c \in \{1, \dots, C\}$. Cada armazém tem oferta s_i , cada cliente procura d_c , e transportar uma unidade de i para c custa p_{ic} (*dados*).

Passo 1 — variáveis

$x_{ic} \geq 0$: quantidade enviada de i para c .

Passo 2 — objetivo

$\min \sum_{i=1}^I \sum_{c=1}^C p_{ic} x_{ic}$ (custo total, em €)

Passo 3 — restrições

$\sum_c x_{ic} \leq s_i$ (não exceder a oferta), $\sum_i x_{ic} = d_c$ (satisfazer a procura), $x_{ic} \leq q_{ic}$ (capacidade da rota).

Exemplo completo — e depois do modelo?

- **Verificar** se o modelo é admissível: $\sum_i s_i \geq \sum_c d_c$ é condição necessária (suficiente só sem capacidades de rota).
- **Classificar**: linear, contínuo, com restrições — resolve-se com o método do simplex ou pontos interiores, mesmo com milhares de variáveis.
- **Resolver** numericamente e **interpretar**: quais as restrições ativas? Quanto vale relaxar cada uma (preços-sombra)?
- **Validar** com dados reais e refinar o modelo (tempos de entrega, veículos inteiros, várias mercadorias, ...).

Um modelo é sempre uma simplificação; a qualidade da decisão depende mais do modelo do que do algoritmo que o resolve.

OTIMIZAÇÃO NA PRÁTICA — logística marítima de combustíveis entre ilhas (GALP/ENACOL, Cabo Verde)

Decisão que navios usar (e com que capacidade), que rotas e calendário entre as ilhas, e quanto de cada combustível descarregar em cada porto.

Variáveis quantidades por viagem, porto e produto (contínuas) e escolhas de navio, rota e sequência de portos (discretas).

Objetivo minimizar o custo de distribuição e as roturas de abastecimento.

Restrições procura de cada ilha, capacidade dos tanques em terra e dos navios, condições dos portos, prazos.

Porque é difícil é a rede de transporte das páginas anteriores com decisões inteiras, vários produtos e a dimensão temporal: o resultado não é uma solução, é um *sistema de apoio à decisão* que se volta a usar sempre que os dados mudam.

Métodos modelos de programação linear (inteira) mista, integrados num sistema de apoio à decisão. A formulação — o que é variável, dado ou restrição — é a parte decisiva.

Problema académico vs. problema real

	cerca, produção, lata	problemas reais (p. ex. parque eólico, estrutura)
f conhece-se?	fórmula explícita	sai de uma simulação, de um modelo de elementos finitos ou de dados
custo de avaliar f	desprezável	segundos a horas por avaliação
derivadas	à mão, exatas	muitas vezes indisponíveis ou pouco fiáveis
variáveis	2, contínuas	dezenas a milhares; contínuas, inteiras, mistas
restrições	1–3, simples	muitas, algumas só verificáveis a posteriori
objetivos	um	frequentemente vários, em conflito
ruído	nenhum	medições, simulações estocásticas

Os exemplos académicos servem para perceber os métodos. Os problemas reais explicam **porque existe uma área científica chamada otimização**: quase todas as linhas da coluna da direita são uma razão para um capítulo desta UC; variáveis inteiras e ruído ficam fora do núcleo.

Panorama da UC


Como se resolve numericamente

Quase todos os métodos são **iterativos**:

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \lambda_k \mathbf{S}_k, \quad k = 0, 1, 2, \dots$$

- $\mathbf{x}_0$: ponto inicial; $\mathbf{x}_k$: o ponto após k iterações
- $\mathbf{S}_k$: direção de pesquisa (cap. 3)
- $\lambda_k > 0$: comprimento do passo ao longo da direção (cap. 2)
- parar quando $\|\nabla f(\mathbf{x}_k)\|$, o passo ou a variação de f forem pequenos

Os capítulos seguintes diferem em *como* escolhem $\mathbf{S}_k$ e λ_k , em que informação sobre f usam, e em como tratam as restrições.



Iterações de um método do gradiente sobre as curvas de nível de f .

A pergunta que atravessa a UC

Que informação temos sobre f ? Quanto custa obtê-la? O que conseguimos garantir com ela?

	informação sobre f	custo típico	o que se garante
só valores de f (ordem 0)	comparações $f(\mathbf{x}) < f(\mathbf{x}')$	muitas avaliações (n_f)	NM: sem garantia geral; pesquisa direta formalizada (p. ex. GLODS, 5.1): estacionariedade sob hipóteses adequadas
gradiente (ordem 1)	para onde f desce	$n_g = 1$ (analítico) ou $2n$ avaliações de f (centrais)	estacionariedade no limite, de qualquer $\mathbf{x}_0$ (sob regularidade + pesq. em linha adequada; 3.3.1)
Hessiana (ordem 2)	curvatura	$n_H = 1$ (analítica) ou $O(n^2)$ avaliações de f	convergência rápida, perto da solução
estrutura (linear, convexa)	forma global de f e de X	—	ótimo global

Contamos à parte n_f (avaliações de f), n_g (de f' ; em $\mathbb{R}^n$, gradientes) e n_H (de f'' ; Hessianas). Cada capítulo responde com um compromisso diferente entre informação, custo e garantia. Antes de resolver é preciso decidir *o que são as variáveis, o que significa “melhor”, o que é permitido e quanto custa avaliar uma decisão.*

Como escolher um método: perguntas antes do algoritmo

Pergunta	Cap.	Métodos
Uma variável?	2	secção áurea, Powell, bissecção, Newton–Raphson
Várias variáveis, sem restrições?	3	sem derivadas: pesquisa aleatória, pesquisa em grelha, Nelder–Mead, Box, Hooke–Jeeves; com derivadas: gradiente, Newton, gradientes conjugados
Há restrições?	4	Lagrange, KKT, penalização exterior e interior
Há vários mínimos locais?	5	GLODS, <i>simulated annealing</i> , algoritmos genéticos
Há vários objetivos?	6	Pareto, agregação, ε -constrangimento, DMS, NSGA-II
Temos derivadas?	2–3	com ou sem derivadas (ordem 0, 1, 2)
f é cara ou caixa negra?	todos	o recurso crítico passa a ser o número de avaliações de f

Não existe “o melhor algoritmo de otimização”.

Existe o método adequado à informação disponível e à estrutura do problema.

A seguir (1.2): onde se usa otimização.

Referências Lista completa: *Bibliografia da UC*, no fim do PDF da UC.

- Hillier, F. S., Lieberman, G. J., *Introduction to Operations Research*, 2024 Release, McGraw-Hill, 2024 — casos de estudo citados no deck.
- Arora, J. S., *Introduction to Optimum Design*, 3.^a ed., Academic Press, 2011 — cap. 2, formulação.

Recursos

- MATLAB: `linprog` (Optimization Toolbox), preços-sombra em `lambda.ineqlin`.
- Python: `scipy.optimize.linprog`, preços-sombra em `res.ineqlin.marginals`. Ligação: brightoptimizer.com.