# Otimização

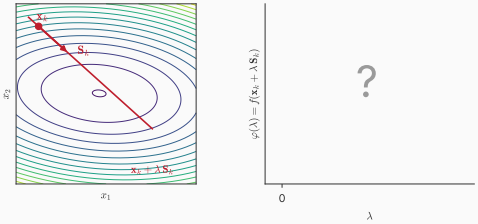
## 2.1 Otimização unidimensional: definição, classificação e notas gerais

José Firmino Aguilar Madeira

# Capítulo 2. Otimização unidimensional — porquê uma só variável?

Os problemas que nos interessam têm *n* variáveis. Porque estudar otimização numa *só*?

Quase todos os métodos do cap. 3 fazem, em cada iteração, $\mathbf{x}_{k+1} = \mathbf{x}_k + \lambda_k \mathbf{S}_k$: escolhem uma direção $\mathbf{S}_k$ e depois quanto andar, $\lambda_k$.



# Capítulo 2. Otimização unidimensional — porquê uma só variável?

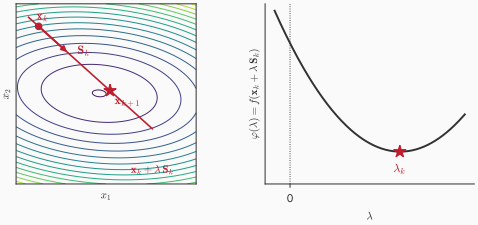
Os problemas que nos interessam têm *n* variáveis. Porque estudar otimização numa *só*?

Quase todos os métodos do cap. 3 fazem, em cada iteração, $\mathbf{x}_{k+1} = \mathbf{x}_k + \lambda_k \mathbf{S}_k$: escolhem uma direção $\mathbf{S}_k$ e depois quanto andar, $\lambda_k$.

Com $\mathbf{x}_k$ e $\mathbf{S}_k$ fixos, $\mathbf{x}_k + \lambda \mathbf{S}_k$ é uma reta, e ao longo dela

$$\varphi(\lambda) = f(\mathbf{x}_k + \lambda \mathbf{S}_k)$$

é uma função de uma variável. Escolher $\lambda_k$ é minimizar $\varphi$: a pesquisa em linha (*line search*).



# Capítulo 2. Otimização unidimensional — porquê uma só variável?

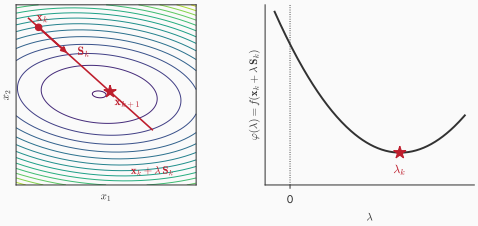
Os problemas que nos interessam têm *n* variáveis. Porque estudar otimização numa *só*?

Quase todos os métodos do cap. 3 fazem, em cada iteração, $\mathbf{x}_{k+1} = \mathbf{x}_k + \lambda_k \mathbf{S}_k$: escolhem uma direção $\mathbf{S}_k$ e depois quanto andar, $\lambda_k$.

Com $\mathbf{x}_k$ e $\mathbf{S}_k$ fixos, $\mathbf{x}_k + \lambda \mathbf{S}_k$ é uma reta, e ao longo dela

$$\varphi(\lambda) = f(\mathbf{x}_k + \lambda \mathbf{S}_k)$$

é uma função de uma variável. Escolher $\lambda_k$ é minimizar $\varphi$: a pesquisa em linha (*line search*).




Em 1D decidimos quanto andar. Em *n*D temos primeiro de decidir para onde andar (cap. 3).
E a pesquisa em linha repete-se em cada iteração: no cap. 3 é muitas vezes a maior parte do custo.

# O problema: valor mínimo e minimizante

Um problema de otimização unidimensional: $\min_{a \le x \le b} f(x)$ (a única restrição é o intervalo).

Há duas respostas possíveis:

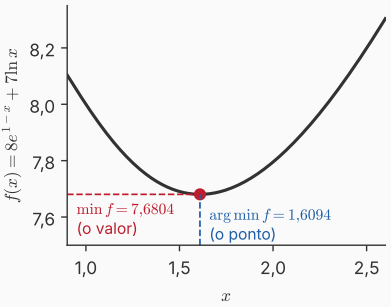
$$\text{valor mínimo:} \quad f^* = \min_{a \le x \le b} f(x)$$

$$\text{minimizante:} \quad x^* = \arg\min_{a \le x \le b} f(x)$$

$f^*$ é um valor de $f$; $x^*$ é o ponto onde ele é atingido: $f(x^*) = f^*$. No exemplo: $\min f = 7{,}6804$, $\arg\min f = 1{,}6094$.

Na pesquisa em linha interessa o ponto: $\lambda_k = \arg\min_{\lambda > 0} \varphi(\lambda)$.

Se houver vários minimizantes, arg min designa o conjunto deles; neste capítulo haverá um só.




$f(x) = 8e^{1-x} + 7\ln x$ em $[1, 2]$: o exemplo que acompanha o capítulo (1.º teste de 2019).

# O que podemos saber sobre $f$?

Que informação temos? Quanto custa obtê-la? O que conseguimos garantir com ela?
(a pergunta que atravessa a UC)

| | | | |
|---|---|---|---|
| só $f(x)$ | ordem 0 | $\longrightarrow$ | 2.2 secção áurea: *eliminar* intervalo; 2.3 Powell: *interpolar* |
| $f(x)$ e $f'(x)$ | ordem 1 | $\longrightarrow$ | 2.4 bisseção: *localizar* o zero de $f'$ |
| $f$, $f'$ e $f''$ | ordem 2 | $\longrightarrow$ | 2.5 Newton: *linearizar* $f'$ |
| só $f$, mas queremos $f'$, $f''$ | | $\longrightarrow$ | 2.6 diferenças finitas: *aproximar* $f'$, $f''$ |

Mais informação: potencialmente mais depressa (linear, superlinear, quadrática)

mas custa: derivadas caras, ou pouco fiáveis se as avaliações têm ruído; e pode tornar o método menos robusto (sem enquadramento garantido)

O custo de um método mede-se em avaliações de $f$ (e de $f'$, $f''$), não em operações aritméticas. Contamos à parte $n_f$ (avaliações de $f$), $n_g$ (de $f'$; em $\mathbb{R}^n$, gradientes) e $n_H$ (de $f''$; Hessianas).

# Métodos iterativos: quando parar?

Salvo casos triviais, o mínimo não se obtém num só passo. Um método iterativo:

1. parte de uma aproximação inicial $x_0$ (ou de um intervalo $[a_0, b_0]$);
2. gera uma sucessão $x_1, x_2, \ldots$ em que cada termo usa informação de $f$ nos anteriores — só em $x_k$ (Newton), ou em vários (Powell usa três pontos);
3. para quando um critério é satisfeito.

## Critérios de paragem habituais

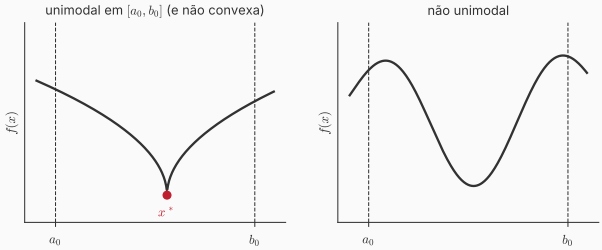
$$\frac{|x_{k+1} - x_k|}{\max(1, |x_k|)} \leq \varepsilon_x, \quad |f(x_{k+1}) - f(x_k)| \leq \varepsilon_f, \quad |f'(x_k)| \leq \varepsilon_g, \quad b_k - a_k \leq \varepsilon_x, \quad k \geq k_{\max}.$$

Usar sempre $k_{\max}$ (protege contra métodos que não convergem). Dividir por $\max(1, |x_k|)$ torna o critério relativo quando $|x_k|$ é grande e absoluto perto de zero; na secção áurea usa-se o comprimento $b_k - a_k$; na bisseção (2.4), $|f'(z)| \leq \varepsilon$.

# Funções unimodais

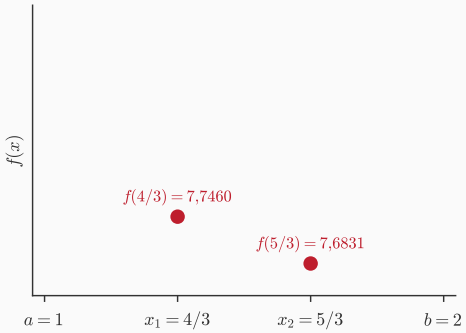
## Definição

$f$ é unimodal em $[a_0, b_0]$ se tem um e um só mínimo local $x^*$ nesse intervalo: é estritamente decrescente em $[a_0, x^*]$ e estritamente crescente em $[x^*, b_0]$.




Não exige continuidade, derivadas nem convexidade — basta a forma "desce, depois sobe". Toda a função estritamente convexa é unimodal; a recíproca é falsa (à esquerda: unimodal, não convexa e sem derivada em $x^*$).

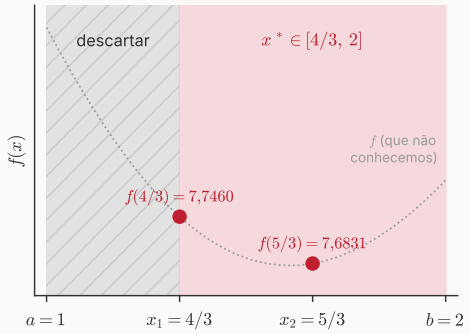
# Só dois valores de $f$: o que podemos deitar fora?




$f$ é unimodal em $[1, 2]$, mas não a conhecemos: só temos $f(4/3) = 7{,}7460$ e $f(5/3) = 7{,}6831$.

De que parte do intervalo temos a certeza de que não precisamos?

# Só dois valores de $f$: o que podemos deitar fora?

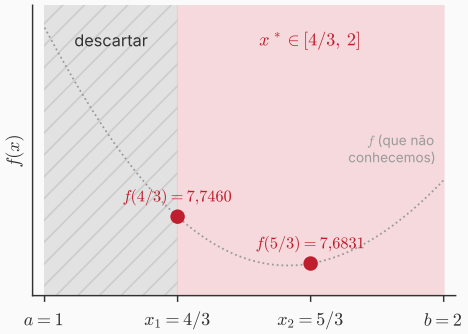



$f$ é unimodal em $[1, 2]$, mas não a conhecemos: só temos $f(4/3) = 7{,}7460$ e $f(5/3) = 7{,}6831$.

De que parte do intervalo temos a certeza de que não precisamos?

Como $f(4/3) > f(5/3)$, o mínimo não está em $[1,\ 4/3)$: se estivesse, $f$ subiria de $4/3$ para $5/3$. Logo $x^* \in [4/3,\ 2]$ — um terço do intervalo descartado com duas avaliações e *sem derivadas*.

# Só dois valores de $f$: o que podemos deitar fora?




$f$ é unimodal em $[1, 2]$, mas não a conhecemos: só temos $f(4/3) = 7{,}7460$ e $f(5/3) = 7{,}6831$.

De que parte do intervalo temos a certeza de que não precisamos?

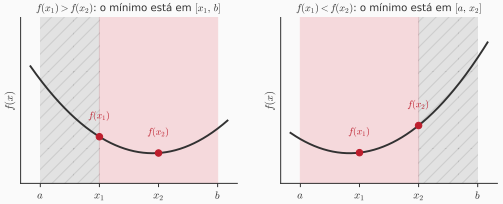
Como $f(4/3) > f(5/3)$, o mínimo não está em $[1,\ 4/3)$: se estivesse, $f$ subiria de $4/3$ para $5/3$. Logo $x^* \in [4/3,\ 2]$ — um terço do intervalo descartado com duas avaliações e *sem derivadas*.

E $x_2 = 5/3$ fica dentro do novo intervalo, com $f$ já calculada.

Se vamos repetir isto muitas vezes, onde colocar $x_1, x_2$ para reutilizar uma avaliação? → 2.2

# A regra geral: eliminar intervalo

Com $f$ unimodal em $[a, b]$ e dois pontos interiores $x_1 < x_2$:

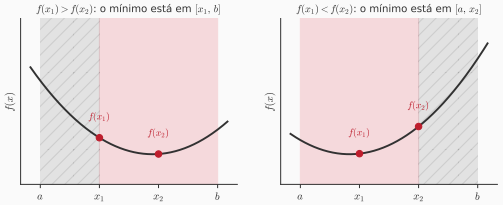



$$f(x_1) > f(x_2) \;\Rightarrow\; x^* \in [x_1, b], \qquad f(x_1) < f(x_2) \;\Rightarrow\; x^* \in [a, x_2], \qquad f(x_1) = f(x_2) \;\Rightarrow\; x^* \in [x_1, x_2].$$

**Robusto (enquadramento garantido)**: o intervalo contém sempre $x^*$, e encolhe de forma previsível. Só se usa a ordem dos dois valores ($<$ ou $>$).

# A regra geral: eliminar intervalo

Com $f$ unimodal em $[a, b]$ e dois pontos interiores $x_1 < x_2$:




$$f(x_1) > f(x_2) \;\Rightarrow\; x^* \in [x_1, b], \qquad f(x_1) < f(x_2) \;\Rightarrow\; x^* \in [a, x_2], \qquad f(x_1) = f(x_2) \;\Rightarrow\; x^* \in [x_1, x_2].$$

**Robusto (enquadramento garantido)**: o intervalo contém sempre $x^*$, e encolhe de forma previsível. Só se usa a ordem dos dois valores ($<$ ou $>$).

E se usássemos também a sua *magnitude*? Com três valores de $f$ pode ajustar-se uma parábola e estimar onde está o mínimo → 2.3 (Powell).

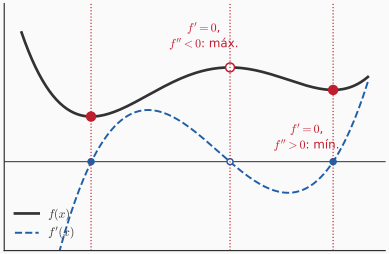
# Com derivadas: procurar o zero de $f'$

Se $f$ é diferenciável, num mínimo interior $f'(x^*) = 0$ (condição necessária); se além disso $f''(x^*) > 0$, $x^*$ é mínimo local estrito (condição suficiente).

Em vez de minimizar $f$, podemos procurar o zero de $f'$:

- **bisseção** sobre $f'$ (2.4): o *sinal* de $f'$ diz de que lado está o zero. Mantém um intervalo com $f'(a) < 0 < f'(b)$ ($f'$ contínua);
- **Newton** sobre $f'$ (2.5): a inclinação de $f'$, isto é $f''$, permite *estimar onde* está o zero: $x_{k+1} = x_k - \dfrac{f'(x_k)}{f''(x_k)}$.

Atenção: $f' = 0$ também em máximos e inflexões — verificar $f''$ ($f'' = 0$ é inconclusivo).

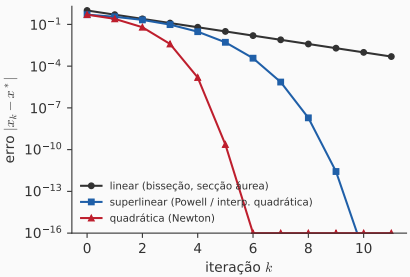


# Velocidade de convergência

Seja $e_k = |x_k - x^*|$. Diz-se que a convergência é

- **linear** se $e_{k+1} \leq c\, e_k$, $0 < c < 1$ — ganha um número fixo de dígitos por iteração. Nos métodos de intervalo é o *comprimento* $L_k$ que se reduz linearmente ($L_{k+1} = 0{,}5 L_k$ na bisseção, $0{,}618 L_k$ na secção áurea) e $e_k \leq L_k/2$;
- **superlinear** se $e_{k+1}/e_k \to 0$ (interpolação quadrática: ordem $\approx 1{,}3$);
- **quadrática** se $e_{k+1} \leq c\, e_k^2$ — perto de $x^*$, o número de dígitos corretos *tende a duplicar* por iteração (Newton).

O preço da velocidade: Newton precisa de $f''$ e de $x_0$ próximo; com as respetivas hipóteses, bisseção e secção áurea têm convergência garantida.



# Mapa do capítulo: cinco ideias

| Método | Informação | Ideia | Garantia / velocidade |
|---|---|---|---|
| 2.2 Secção áurea | $f$ | eliminar intervalo | robusta ($f$ unimodal); linear, 0,618 por avaliação |
| 2.3 Powell | $f$ | interpolar uma parábola | rápida perto do mínimo (superlinear); sozinha, sem garantia |
| 2.4 Bisseção | $f'$ | localizar o zero de $f'$ | robusta (zero único enquadrado); linear, 0,5 |
| 2.5 Newton | $f'$, $f''$ | linearizar $f'$ | quadrática local; pode divergir |
| 2.6 Diferenças finitas | $f$ | aproximar $f'$, $f''$ | erro de truncatura + erro de arredondamento |

Na prática combinam-se: um método robusto (enquadramento garantido) localiza o mínimo, um rápido refina-o.

secção áurea + interpolação parabólica → `fminbnd`

→ pesquisa em linha do cap. 3 (gradiente, Newton amortecido, GC)

O cap. 2 não é só "matéria anterior": explica uma peça que trabalha *dentro* dos algoritmos do cap. 3.

# O QUE DEVE FICAR — 2.1

1. Em $\mathbb{R}^n$, nos métodos baseados em direções, escolhe-se uma direção e depois quanto andar: $\lambda_k = \arg\min_{\lambda>0} \varphi(\lambda)$, com $\varphi(\lambda) = f(\mathbf{x}_k + \lambda \mathbf{S}_k)$ — um problema de uma variável.
2. $\min f$ é o *valor* mínimo; $\arg\min f$ é o *ponto* onde é atingido.
3. Os métodos distinguem-se pela informação que usam (só $f$, $f'$, $f''$), pelo que ela custa e pelo que garante: mais informação pode dar convergência mais rápida (linear $\rightarrow$ superlinear $\rightarrow$ quadrática), mas custa e pode tornar o método menos robusto (sem enquadramento garantido).
4. Com $f$ unimodal, dois valores de $f$ chegam para descartar parte do intervalo (só se usa a sua ordem); com derivadas, minimizar $f$ passa a procurar o zero de $f'$ ($f' = 0$ também em máximos: verificar $f''$).

A seguir (2.2): onde colocar $x_1$ e $x_2$ para que cada redução do intervalo custe uma só avaliação de $f$?

# Referências e recursos

**Referências** Lista completa: *Bibliografia da UC*, no fim do PDF da UC.


- Deb, K., *Optimization for Engineering Design: Algorithms and Examples*, 2.ª ed., PHI Learning, 2012 — cap. 2.
- Nocedal, J., Wright, S. J., *Numerical Optimization*, 2.ª ed., Springer, 2006 — cap. 3, pesquisa em linha.


**Recursos**

- MATLAB: `fminbnd`.