

Otimização


3.1 Otimização multidimensional: definição e notas gerais

José Firmino Aguilar Madeira

Do capítulo 2 para o 3: o que mudou?


Capítulo 3. Otimização multidimensional sem restrições

Cap. 2: $x \in \mathbb{R}$



Em 1D, a escolha da direção reduz-se a **dois sentidos**, $\leftarrow$ e $\rightarrow$; escolhido o sentido (ou o intervalo de pesquisa), resta decidir **quanto andar**.

Cap. 3: $\mathbf{x} = (x_1, \dots, x_n)^T \in \mathbb{R}^n$




Em n D, há **infinitas** direções possíveis a partir de $\mathbf{x}_k$.

Do capítulo 2 para o 3: o que mudou?

Capítulo 3. Otimização multidimensional sem restrições


Cap. 2: $x \in \mathbb{R}$



Em 1D, a escolha da direção reduz-se a **dois sentidos**, $\leftarrow$ e $\rightarrow$; escolhido o sentido (ou o intervalo de pesquisa), resta decidir **quanto andar**.

1.ª pergunta: para onde devemos andar?

Cap. 3: $\mathbf{x} = (x_1, \dots, x_n)^T \in \mathbb{R}^n$




Em n D, há **infinitas** direções possíveis a partir de $\mathbf{x}_k$.

Do capítulo 2 para o 3: o que mudou?

Capítulo 3. Otimização multidimensional sem restrições


Cap. 2: $x \in \mathbb{R}$



Em 1D, a escolha da direção reduz-se a **dois sentidos**, $\leftarrow$ e $\rightarrow$; escolhido o sentido (ou o intervalo de pesquisa), resta decidir **quanto andar**.

1.ª pergunta: para onde devemos andar?

Cap. 3: $\mathbf{x} = (x_1, \dots, x_n)^T \in \mathbb{R}^n$




Em n D, há **infinitas** direções possíveis a partir de $\mathbf{x}_k$.

2.ª pergunta: quanto devemos andar nessa direção?

Do capítulo 2 para o 3: o que mudou?


Capítulo 3. Otimização multidimensional sem restrições

Cap. 2: $x \in \mathbb{R}$



Em 1D, a escolha da direção reduz-se a **dois sentidos**, $\leftarrow$ e $\rightarrow$; escolhido o sentido (ou o intervalo de pesquisa), resta decidir **quanto andar**.

Cap. 3: $\mathbf{x} = (x_1, \dots, x_n)^T \in \mathbb{R}^n$



Em n D, há **infinitas** direções possíveis a partir de $\mathbf{x}_k$.

1.ª pergunta: para onde devemos andar?

2.ª pergunta: quanto devemos andar nessa direção?

$\mathbf{S}_k = \text{direção}$

$\lambda_k > 0 = \text{passo}$

$\Rightarrow$

$\mathbf{x}_{k+1} = \mathbf{x}_k + \lambda_k \mathbf{S}_k$

O problema multidimensional: direção e passo

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}), \quad \mathbf{x} = (x_1, \dots, x_n)^T,$$



sem restrições (ficam para o cap. 4).

Maximizar f é minimizar $-f$.

Os métodos do cap. 2 não desaparecem

Escolhida $\mathbf{S}_k$, o passo resolve um problema **unidimensional**:

$\min_{\lambda > 0} \varphi(\lambda) = f(\mathbf{x}_k + \lambda \mathbf{S}_k)$ — a **pesquisa em linha** (secção áurea, Powell, Newton...).



o cap. 3 escolhe a **direção**

o cap. 2 pode escolher o **passo**

Esta forma é a dos métodos baseados em direções (3.3; em parte, Hooke–Jeeves); a pesquisa aleatória, o Nelder–Mead e o Box progridem de outra maneira (3.2).


Gradiente: para onde sobe mais depressa?

$$\nabla f(\mathbf{x}) = \begin{pmatrix} \partial f / \partial x_1 \\ \vdots \\ \partial f / \partial x_n \end{pmatrix} \quad (\text{R})$$

Ao longo de uma direção unitária $\mathbf{S}$, f varia à taxa $\nabla f(\mathbf{x})^T \mathbf{S} \leq \|\nabla f(\mathbf{x})\|$ (Cauchy–Schwarz), com igualdade para $\mathbf{S} = \nabla f / \|\nabla f\|$.

∇f é normal à curva de nível

∇f aponta para o maior crescimento local



$f(\mathbf{x}) = \frac{1}{2}x_1^2 + 2x_2^2$: o gradiente em seis pontos.

Gradiente: para onde sobe mais depressa?

$$\nabla f(\mathbf{x}) = \begin{pmatrix} \partial f / \partial x_1 \\ \vdots \\ \partial f / \partial x_n \end{pmatrix} \quad (\text{R})$$


Ao longo de uma direção unitária $\mathbf{S}$, f varia à taxa $\nabla f(\mathbf{x})^T \mathbf{S} \leq \|\nabla f(\mathbf{x})\|$ (Cauchy–Schwarz), com igualdade para $\mathbf{S} = \nabla f / \|\nabla f\|$.

∇f é normal à curva de nível

∇f aponta para o maior crescimento local

Para *descer*? O sentido contrário: $-\nabla f(\mathbf{x})$

(É a ideia do método do gradiente, 3.3.1.)



$f(\mathbf{x}) = \frac{1}{2}x_1^2 + 2x_2^2$: o gradiente em seis pontos.

O que é uma direção de descida?

Taylor de 1.ª ordem (f diferenciável), para $\lambda > 0$:

$$f(\mathbf{x} + \lambda \mathbf{S}) = f(\mathbf{x}) + \lambda \nabla f(\mathbf{x})^T \mathbf{S} + o(\lambda),$$


com $o(\lambda)/\lambda \rightarrow 0$ quando $\lambda \rightarrow 0^+$.

Se $\nabla f(\mathbf{x})^T \mathbf{S} < 0$, o termo linear prevalece para λ pequeno: $f(\mathbf{x} + \lambda \mathbf{S}) < f(\mathbf{x})$.

Direção de descida

$\mathbf{S}$ é direção de descida em $\mathbf{x}$ se $\nabla f(\mathbf{x})^T \mathbf{S} < 0$:
o ângulo entre $\mathbf{S}$ e ∇f é **maior do que 90°** .

Pergunta: qual destas setas é direção de descida em $\mathbf{x}_k$?



O que é uma direção de descida?

Taylor de 1.ª ordem (f diferenciável), para $\lambda > 0$:

$$f(\mathbf{x} + \lambda \mathbf{S}) = f(\mathbf{x}) + \lambda \nabla f(\mathbf{x})^T \mathbf{S} + o(\lambda),$$


com $o(\lambda)/\lambda \rightarrow 0$ quando $\lambda \rightarrow 0^+$.

Se $\nabla f(\mathbf{x})^T \mathbf{S} < 0$, o termo linear prevalece para λ pequeno: $f(\mathbf{x} + \lambda \mathbf{S}) < f(\mathbf{x})$.

Direção de descida

$\mathbf{S}$ é direção de descida em $\mathbf{x}$ se $\nabla f(\mathbf{x})^T \mathbf{S} < 0$:
o ângulo entre $\mathbf{S}$ e ∇f é **maior do que 90°** .

A ($-\nabla f$) e **B**: sim. **C**: tangente à curva de nível, $\nabla f^T \mathbf{S} = 0$ — *não* é direção de descida (a 1.ª ordem não decide). **D**: $\nabla f^T \mathbf{S} > 0$, sobe.



E quando já não conseguimos descer?

Seja $\mathbf{x}^*$ um mínimo local (sem restrições). Se fosse $\nabla f(\mathbf{x}^*) \neq \mathbf{0}$, a direção $\mathbf{S} = -\nabla f(\mathbf{x}^*)$ daria

$$\nabla f(\mathbf{x}^*)^T \mathbf{S} = -\|\nabla f(\mathbf{x}^*)\|^2 < 0,$$


isto é, uma direção de descida — e $\mathbf{x}^*$ não seria mínimo. Logo:

Condição necessária de 1.^a ordem

$$\begin{aligned} f \text{ diferenciável em } \mathbf{x}^* \text{ e } \mathbf{x}^* \text{ mínimo local} \\ \implies \nabla f(\mathbf{x}^*) = \mathbf{0}. \end{aligned}$$

Os pontos com $\nabla f = \mathbf{0}$ chamam-se **pontos estacionários**.



É por isso que $\|\nabla f(\mathbf{x}_k)\| \leq \varepsilon_g$ é critério de paragem. Com restrições (cap. 4) muda: no mínimo pode haver direções de descida que saem da região admissível.



Setas: $-\nabla f$. Longe do mínimo há sempre para onde descer; no mínimo, não.



Mas estacionário $\neq$ mínimo

$$f(\mathbf{x}) = x_1^3 - 3x_1 + x_2^2: \quad \nabla f = \begin{pmatrix} 3x_1^2 - 3 \\ 2x_2 \end{pmatrix} = \mathbf{0} \iff \mathbf{x} \in \{(1, 0), (-1, 0)\}.$$



Mas estacionário $\neq$ mínimo



$$f(\mathbf{x}) = x_1^3 - 3x_1 + x_2^2: \quad \nabla f = \begin{pmatrix} 3x_1^2 - 3 \\ 2x_2 \end{pmatrix} = \mathbf{0} \iff \mathbf{x} \in \{(1, 0), (-1, 0)\}.$$



Visualmente: $(1, 0)$ é um **mínimo**; $(-1, 0)$ é um **ponto de sela** — sobe ao longo de x_2 , desce ao longo de x_1 .

Mas estacionário $\neq$ mínimo

$$f(\mathbf{x}) = x_1^3 - 3x_1 + x_2^2: \quad \nabla f = \begin{pmatrix} 3x_1^2 - 3 \\ 2x_2 \end{pmatrix} = \mathbf{0} \iff \mathbf{x} \in \{(1, 0), (-1, 0)\}.$$



Visualmente: $(1, 0)$ é um **mínimo**; $(-1, 0)$ é um **ponto de sela** — sobe ao longo de x_2 , desce ao longo de x_1 . **Como distinguimos os dois?** O gradiente já não ajuda (é nulo nos dois): é preciso a **curvatura** $\Rightarrow$ a Hessiana.

Hessiana: a curvatura

$$\nabla^2 f(\mathbf{x}) = \left[\frac{\partial^2 f}{\partial x_i \partial x_j} \right]_{i,j=1}^n$$

simétrica se $f \in C^2(\mathbb{R})$. Taylor de 2.ª ordem:

$$\begin{aligned} f(\mathbf{x}^* + \mathbf{s}) &\approx f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)^T \mathbf{s} \\ &\quad + \frac{1}{2} \mathbf{s}^T \nabla^2 f(\mathbf{x}^*) \mathbf{s}. \end{aligned}$$

Hessiana: a curvatura

$$\nabla^2 f(\mathbf{x}) = \left[\frac{\partial^2 f}{\partial x_i \partial x_j} \right]_{i,j=1}^n$$

simétrica se $f \in C^2(\mathbb{R})$. Taylor de 2.ª ordem:

$$f(\mathbf{x}^* + \mathbf{s}) \approx f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)^T \mathbf{s} + \frac{1}{2} \mathbf{s}^T \nabla^2 f(\mathbf{x}^*) \mathbf{s}.$$

Num ponto estacionário o termo linear desaparece:

$$f(\mathbf{x}^* + \mathbf{s}) - f(\mathbf{x}^*) \approx \frac{1}{2} \mathbf{s}^T \nabla^2 f(\mathbf{x}^*) \mathbf{s}$$

— $\mathbf{s}^T \nabla^2 f \mathbf{s}$ é a **curvatura** de f ao longo de $\mathbf{s}$.

Hessiana: a curvatura

$$\nabla^2 f(\mathbf{x}) = \left[\frac{\partial^2 f}{\partial x_i \partial x_j} \right]_{i,j=1}^n$$

simétrica se $f \in C^2(\mathbb{R})$. Taylor de 2.ª ordem:

$$f(\mathbf{x}^* + \mathbf{s}) \approx f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)^T \mathbf{s} + \frac{1}{2} \mathbf{s}^T \nabla^2 f(\mathbf{x}^*) \mathbf{s}.$$

Num ponto estacionário o termo linear desaparece:

$$f(\mathbf{x}^* + \mathbf{s}) - f(\mathbf{x}^*) \approx \frac{1}{2} \mathbf{s}^T \nabla^2 f(\mathbf{x}^*) \mathbf{s}$$

— $\mathbf{s}^T \nabla^2 f \mathbf{s}$ é a **curvatura** de f ao longo de $\mathbf{s}$.

O **sinal** desta quantidade, para *todas* as direções $\mathbf{s}$, decide a forma local.

Hessiana: a curvatura

$$\nabla^2 f(\mathbf{x}) = \left[\frac{\partial^2 f}{\partial x_i \partial x_j} \right]_{i,j=1}^n$$

simétrica se $f \in C^2(\mathbb{R})$. Taylor de 2.ª ordem:

$$f(\mathbf{x}^* + \mathbf{s}) \approx f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)^T \mathbf{s} + \frac{1}{2} \mathbf{s}^T \nabla^2 f(\mathbf{x}^*) \mathbf{s}.$$

Num ponto estacionário o termo linear desaparece:

$f(\mathbf{x}^* + \mathbf{s}) - f(\mathbf{x}^*) \approx \frac{1}{2} \mathbf{s}^T \nabla^2 f(\mathbf{x}^*) \mathbf{s}$
— $\mathbf{s}^T \nabla^2 f \mathbf{s}$ é a **curvatura** de f ao longo de $\mathbf{s}$.

O **sinal** desta quantidade, para *todas* as direções $\mathbf{s}$, decide a forma local.

$\nabla^2 f(\mathbf{x}^*)$	curvatura	$\mathbf{x}^*$ é
def. positiva (v. p. > 0)	para cima em todas as direções	mínimo local estrito
def. negativa (v. p. < 0)	para baixo em todas as direções	máximo local estrito
indefinida (sinais mistos)	sobe numa direção, desce noutra	ponto de sela
semidef. positiva ($\lambda_{\min} = 0 < \lambda_{\max}$)	nula em alguma direção	não é máximo (inconclusivo quanto a mínimo)
todos os v. p. nulos	nula em todas as direções	inconclusivo



Condições de 2.ª ordem ($f \in C^2$). Necessária: mínimo local $\Rightarrow \nabla^2 f(\mathbf{x}^*)$ semidef. positiva. Suficiente: $\nabla f(\mathbf{x}^*) = \mathbf{0}$ e $\nabla^2 f(\mathbf{x}^*)$ def. positiva $\Rightarrow$ mínimo local estrito.
Verificar: valores próprios ou Sylvester ($\mathbb{R}$).

Exemplo completo: mínimo ou sela?

$$f(\mathbf{x}) = x_1^3 - 3x_1 + x_2^2, \quad \nabla^2 f(\mathbf{x}) = \begin{pmatrix} 6x_1 & 0 \\ 0 & 2 \end{pmatrix}.$$

- $(1, 0)$: $\begin{pmatrix} 6 & 0 \\ 0 & 2 \end{pmatrix}$, valores próprios $6, 2 > 0$
 $\Rightarrow$ **mínimo local estrito**, $f = -2$.
- $(-1, 0)$: $\begin{pmatrix} -6 & 0 \\ 0 & 2 \end{pmatrix}$, valores próprios $-6, 2$
 $\Rightarrow$ **ponto de sela**, $f = 2$.

Nos cortes ao lado, a curvatura de cada corte é o elemento da diagonal $(\mathbf{e}_i^T \nabla^2 f \mathbf{e}_i)$.





Exemplo completo: mínimo ou sela?

$$f(\mathbf{x}) = x_1^3 - 3x_1 + x_2^2, \quad \nabla^2 f(\mathbf{x}) = \begin{pmatrix} 6x_1 & 0 \\ 0 & 2 \end{pmatrix}.$$

- $(1, 0)$: $\begin{pmatrix} 6 & 0 \\ 0 & 2 \end{pmatrix}$, valores próprios $6, 2 > 0$
 $\Rightarrow$ **mínimo local estrito**, $f = -2$.
- $(-1, 0)$: $\begin{pmatrix} -6 & 0 \\ 0 & 2 \end{pmatrix}$, valores próprios $-6, 2$
 $\Rightarrow$ **ponto de sela**, $f = 2$.

Nos cortes ao lado, a curvatura de cada corte é o elemento da diagonal $(\mathbf{e}_i^T \nabla^2 f \mathbf{e}_i)$.



Não há mínimo global: $f(x_1, 0) \rightarrow -\infty$ quando $x_1 \rightarrow -\infty$.

As condições de otimalidade são **locais**: dizem o que acontece numa vizinhança, não no domínio todo. Procurar o mínimo *global* é outro problema (cap. 5).

Como escolhemos então S_k ? O mapa dos métodos

Sem derivadas (3.2) — só valores $f(\mathbf{x})$

3.2.1 pesquisa aleatória; 3.2.2 pesquisa em grelha;
3.2.3 Nelder–Mead; 3.2.4 Box; 3.2.5 Hooke–Jeeves.

Constroem o progresso comparando valores de f (o que não os torna automaticamente robustos ao ruído, 3.2).

Com derivadas (3.3) — ∇f , eventualmente $\nabla^2 f$

3.3.1 gradiente: $\mathbf{S} = -\nabla f$

3.3.2 Newton: $\mathbf{S} = -(\nabla^2 f)^{-1} \nabla f$


3.3.3 gradientes conjugados: $-\nabla f$ corrigido pela direção anterior

Quanto custa a informação? Por diferenças centrais (2.6), um gradiente custa $2n$ avaliações de f (progressivas: n , além de $f(\mathbf{x})$) e uma Hessiana $O(n^2)$.

Que informação temos sobre f ? Quanto custa obtê-la? O que conseguimos garantir?

Em cada método: o que usa, como escolhe a direção, quanto custa (n_f , n_g , n_H , contados à parte, 2.1) e como se comporta no vale de Rosenbrock. No fim (3.3.3), os sete no mesmo problema, com o mesmo ponto inicial e o mesmo critério.

Rosenbrock e Himmelblau: pistas de ensaio



Rosenbrock, $f(\mathbf{x}) = (1 - x_1)^2 + 100(x_2 - x_1^2)^2$: um só mínimo, $(1, 1)$, no fundo de um vale **estreito e curvo** — castiga métodos que andam ao longo dos eixos ou do gradiente.

Himmelblau, $f(\mathbf{x}) = (x_1^2 + x_2 - 11)^2 + (x_1 + x_2^2 - 7)^2$: quatro mínimos globais, todos com $f = 0$ — o resultado **depende do ponto inicial**.

Não são exemplos para “resolver”: são **pistas de ensaio** para ver como os algoritmos se comportam.

O QUE DEVE FICAR — 3.1

1. Nos métodos baseados em direções, cada iteração tem **duas decisões**: a direção $\mathbf{S}_k$ e o passo λ_k ; o cap. 2 pode escolher o passo.
2. $\mathbf{S}$ é **direção de descida** se $\nabla f(\mathbf{x})^T \mathbf{S} < 0$; se $\nabla f(\mathbf{x}) \neq \mathbf{0}$, $-\nabla f(\mathbf{x})$ é sempre uma.
3. Num mínimo local (sem restrições, f diferenciável), $\nabla f(\mathbf{x}^*) = \mathbf{0}$ — mas isto só identifica **pontos estacionários**.
4. Num ponto estacionário, a **Hessiana** classifica localmente: definida positiva $\Rightarrow$ mínimo local estrito; indefinida $\Rightarrow$ sela.
5. A escolha do método depende da **informação disponível**: sem derivadas $\rightarrow$ 3.2; com derivadas $\rightarrow$ 3.3.

A seguir (3.2): **se não conhecermos ∇f , como escolhemos para onde andar?**

Referências Lista completa: *Bibliografia da UC*, no fim do PDF da UC.

- Nocedal, J., Wright, S. J., *Numerical Optimization*, 2.^a ed., Springer, 2006 — cap. 2.
- Dennis, J. E., Jr., Schnabel, R. B., *Numerical Methods for Unconstrained Optimization and Nonlinear Equations*, SIAM (Classics in Applied Mathematics 16), 1996.

Recursos: —