Otimização

3.2.4 Método de Box — versão simplificada de EVOP (*evolutionary operation*)

José Firmino Aguilar Madeira

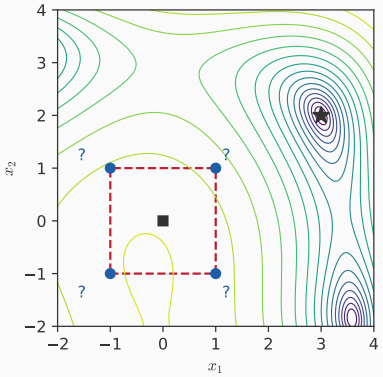
Do simplex que muda de forma para uma caixa que não muda

O Nelder–Mead adapta a forma do simplex usando os valores de f. E se mantivermos sempre o mesmo padrão geométrico?

Em 2D, à volta do ponto atual $\mathbf{x}$, os quatro vértices de uma caixa:

$$\mathbf{x} + \tfrac{1}{2}(\pm\Delta_1,\ \pm\Delta_2).$$

Aqui $\mathbf{x} = (0; 0)$, $\Delta = (2; 2)$, no Himmelblau.



Do simplex que muda de forma para uma caixa que não muda

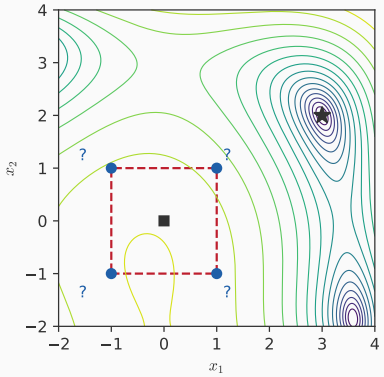
O Nelder–Mead adapta a forma do simplex usando os valores de f. E se mantivermos sempre o mesmo padrão geométrico?

Em 2D, à volta do ponto atual $\mathbf{x}$, os quatro vértices de uma caixa:

$$\mathbf{x} + \tfrac{1}{2}(\pm\Delta_1,\ \pm\Delta_2).$$

Aqui $\mathbf{x} = (0; 0)$, $\Delta = (2; 2)$, no Himmelblau.

Qual deles escolheríamos?



Do simplex que muda de forma para uma caixa que não muda

O Nelder–Mead adapta a forma do simplex usando os valores de f. E se mantivermos sempre o mesmo padrão geométrico?

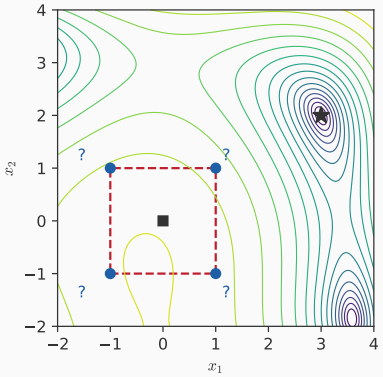
Em 2D, à volta do ponto atual $\mathbf{x}$, os quatro vértices de uma caixa:

$$\mathbf{x} + \tfrac{1}{2}(\pm\Delta_1,\ \pm\Delta_2).$$

Aqui $\mathbf{x} = (0; 0)$, $\Delta = (2; 2)$, no Himmelblau.

Qual deles escolheríamos?

$\rightarrow$ o de menor f — se melhorar o centro.



Do simplex que muda de forma para uma caixa que não muda

O Nelder–Mead adapta a forma do simplex usando os valores de f. E se mantivermos sempre o mesmo padrão geométrico?

Em 2D, à volta do ponto atual $\mathbf{x}$, os quatro vértices de uma caixa:

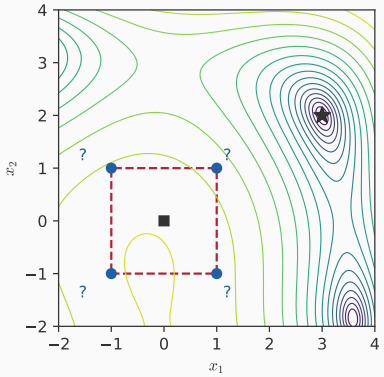
$$\mathbf{x} + \tfrac{1}{2}(\pm\Delta_1,\ \pm\Delta_2).$$

Aqui $\mathbf{x} = (0; 0)$, $\Delta = (2; 2)$, no Himmelblau.

Qual deles escolheríamos?

$\rightarrow$ o de menor f — se melhorar o centro.

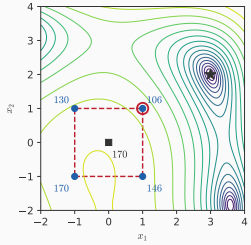
pesquisa aleatória (3.2.1)	pontos sem estrutura
grelha (3.2.2)	estrutura fixa, no domínio todo
Nelder–Mead (3.2.3)	geometria adaptativa, que se move
Box (3.2.4)	padrão fixo, que se move



Uma iteração à mão

$f(\mathbf{x}) = (x_1^2 + x_2 - 11)^2 + (x_1 + x_2^2 - 7)^2, \quad \mathbf{x} = (0; 0),$
$f(\mathbf{x}) = 170, \quad \Delta = (2; 2).$

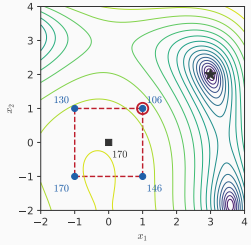
vértice	f
$(-1; -1)$	170
$(1; -1)$	146
$(-1; 1)$	130
$(1; 1)$	106



Uma iteração à mão

$f(\mathbf{x}) = (x_1^2 + x_2 - 11)^2 + (x_1 + x_2^2 - 7)^2, \quad \mathbf{x} = (0;0),$
$f(\mathbf{x}) = 170, \quad \Delta = (2;2).$

vértice	f
$(-1;-1)$	170
$(1;-1)$	146
$(-1;1)$	130
$(1;1)$	106

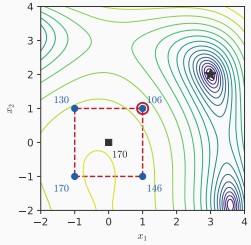


O melhor, $f(1,1) = 106 < 170$: fazer $\mathbf{x} = (1;1)$, e Δ fica igual.

Uma iteração à mão

$f(\mathbf{x}) = (x_1^2 + x_2 - 11)^2 + (x_1 + x_2^2 - 7)^2, \quad \mathbf{x} = (0; 0),$
$f(\mathbf{x}) = 170, \quad \Delta = (2; 2).$

vértice	f
$(-1; -1)$	170
$(1; -1)$	146
$(-1; 1)$	130
$(1; 1)$	106



O melhor, $f(1, 1) = 106 < 170$: fazer $\mathbf{x} = (1; 1)$, e Δ fica igual.

E se nenhum dos quatro fosse melhor? fazer $\Delta = \Delta/2$

Uma iteração à mão

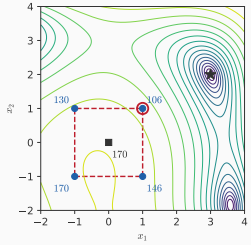
$f(\mathbf{x}) = (x_1^2 + x_2 - 11)^2 + (x_1 + x_2^2 - 7)^2, \quad \mathbf{x} = (0; 0),$
$f(\mathbf{x}) = 170, \quad \Delta = (2; 2).$

vértice	f
$(-1; -1)$	170
$(1; -1)$	146
$(-1; 1)$	130
$(1; 1)$	106

O melhor, $f(1, 1) = 106 < 170$: fazer $\mathbf{x} = (1; 1)$, e Δ fica igual.

E se nenhum dos quatro fosse melhor? fazer $\Delta = \Delta/2$

Acabámos de construir o algoritmo inteiro.



Origem

G. E. P. Box (1957), *Evolutionary Operation*: afinar processos industriais *em produção* (Box trabalhava na ICI), com pequenas variações em torno das condições atuais; cada avaliação era um lote. O EVOP original é experimental e estatístico; aqui usa-se uma versão determinística simplificada (não confundir com o método *Complex* de M. J. Box, 1965 — outro autor, outro algoritmo).

O algoritmo, e o seu custo

Box: ponto inicial $\mathbf{x}_0$, lados Δ_i, tolerância ε_x

Passo 1 Fazer $\mathbf{x} = \mathbf{x}_0$; calcular $f(\mathbf{x})$.
Passo 2 Se $\|\boldsymbol{\Delta}\| < \varepsilon_x$, **parar**: a solução é $\mathbf{x}$.
Passo 3 Gerar os 2^n vértices $\mathbf{x} + \frac{1}{2}(\pm\Delta_1, \ldots, \pm\Delta_n)$.
Passo 4 Avaliar f nos vértices; seja $\mathbf{x}'$ o melhor.
Passo 5 Se $f(\mathbf{x}') < f(\mathbf{x})$, fazer $\mathbf{x} = \mathbf{x}'$ (mover).
Senão, fazer $\boldsymbol{\Delta} = \boldsymbol{\Delta}/2$ (encolher).
Voltar ao passo 2.

- Os Δ_i podem ser diferentes por coordenada; paragem quando a caixa fica menor do que ε_x.
- Uma implementação com *cache* pode reaproveitar pontos já avaliados; nas contagens deste deck avaliam-se sempre os 2^n vértices.

$$n_f = 2^n \text{ por iteração}$$

n	2	3	10	20
vértices	4	8	1 024	$\approx 10^6$

O algoritmo, e o seu custo

Box: ponto inicial $\mathbf{x}_0$, lados Δ_i, tolerância ε_x

Passo 1 Fazer $\mathbf{x} = \mathbf{x}_0$; calcular $f(\mathbf{x})$.
Passo 2 Se $\|\boldsymbol{\Delta}\| < \varepsilon_x$, **parar**: a solução é $\mathbf{x}$.
Passo 3 Gerar os 2^n vértices $\mathbf{x} + \frac{1}{2}(\pm\Delta_1, \ldots, \pm\Delta_n)$.
Passo 4 Avaliar f nos vértices; seja $\mathbf{x}'$ o melhor.
Passo 5 Se $f(\mathbf{x}') < f(\mathbf{x})$, fazer $\mathbf{x} = \mathbf{x}'$ (mover).
Senão, fazer $\boldsymbol{\Delta} = \boldsymbol{\Delta}/2$ (encolher).
Voltar ao passo 2.

- Os Δ_i podem ser diferentes por coordenada; paragem quando a caixa fica menor do que ε_x.
- Uma implementação com *cache* pode reaproveitar pontos já avaliados; nas contagens deste deck avaliam-se sempre os 2^n vértices.

$$n_f = 2^n \text{ por iteração}$$

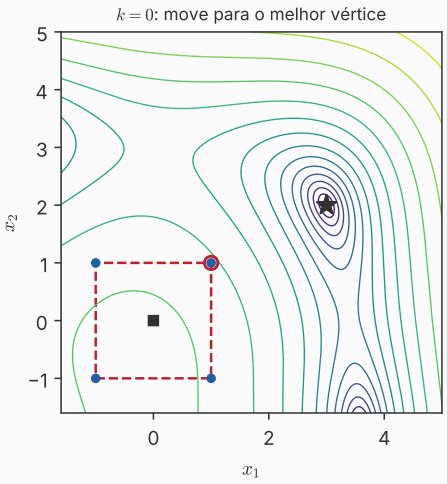
n	2	3	10	20
vértices	4	8	1 024	$\approx 10^6$

A maldição da dimensão outra vez — por uma razão diferente:

- pesquisa aleatória e grelha (3.2.1–3.2.2): o volume a cobrir;
- Box: o número de vértices a testar.

Mesma consequência: a dimensão custa muito.

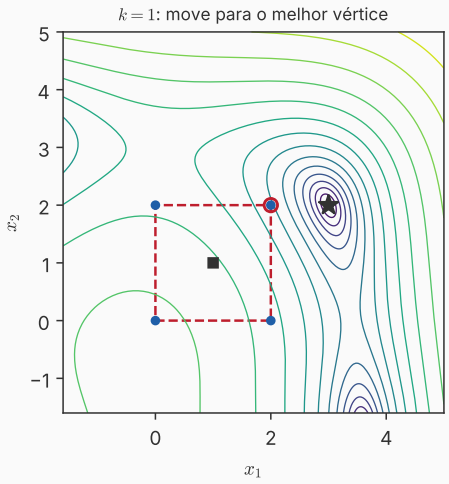
Himmelblau a partir de $(0;0)$: mover ou encolher



$\Delta = (2;2)$, $\varepsilon_x = 10^{-4}$. Em cada linha, o centro $\mathbf{x}_k$ e a decisão tomada a partir dele.

k	$\mathbf{x}_k$	Δ	$f(\mathbf{x}_k)$	decisão	f novo
0	(0,000; 0,000)	2,000	170,000	move	106,000

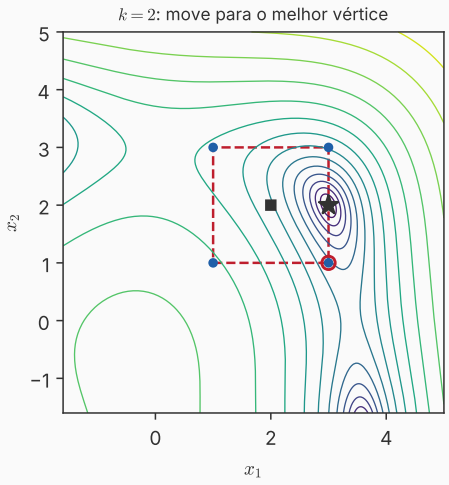
Himmelblau a partir de $(0; 0)$: mover ou encolher



$\Delta = (2; 2)$, $\varepsilon_x = 10^{-4}$. Em cada linha, o centro $\mathbf{x}_k$ e a decisão tomada a partir dele.

k	$\mathbf{x}_k$	Δ	$f(\mathbf{x}_k)$	decisão	f novo
0	(0,000; 0,000)	2,000	170,000	move	106,000
1	(1,000; 1,000)	2,000	106,000	move	26,000

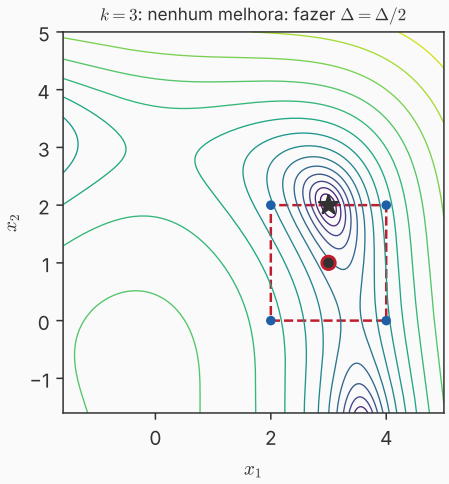
Himmelblau a partir de $(0;0)$: mover ou encolher



$\Delta = (2;2)$, $\varepsilon_x = 10^{-4}$. Em cada linha, o centro $\mathbf{x}_k$ e a decisão tomada a partir dele.

k	$\mathbf{x}_k$	Δ	$f(\mathbf{x}_k)$	decisão	f novo
0	(0,000; 0,000)	2,000	170,000	move	106,000
1	(1,000; 1,000)	2,000	106,000	move	26,000
2	(2,000; 2,000)	2,000	26,000	move	10,000

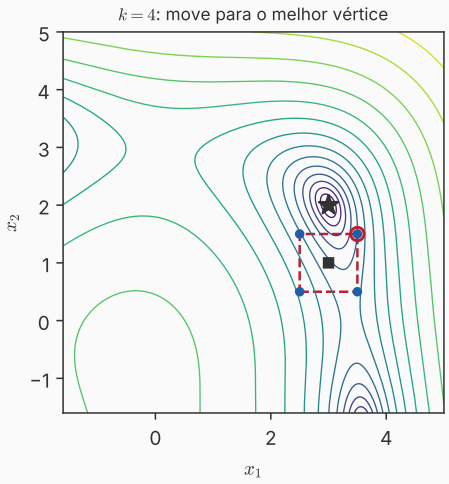
Himmelblau a partir de $(0; 0)$: mover ou encolher



$\Delta = (2; 2)$, $\varepsilon_x = 10^{-4}$. Em cada linha, o centro $\mathbf{x}_k$ e a decisão tomada a partir dele.

k	$\mathbf{x}_k$	Δ	$f(\mathbf{x}_k)$	decisão	f novo
0	(0,000; 0,000)	2,000	170,000	move	106,000
1	(1,000; 1,000)	2,000	106,000	move	26,000
2	(2,000; 2,000)	2,000	26,000	move	10,000
3	(3,000; 1,000)	2,000	10,000	$\Delta = \Delta/2$	10,000

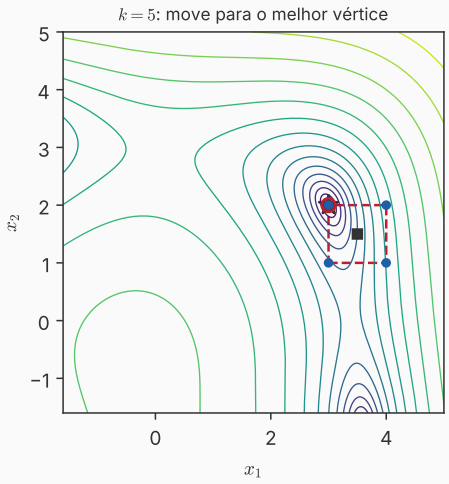
Himmelblau a partir de $(0;0)$: mover ou encolher



$\Delta = (2;2)$, $\varepsilon_x = 10^{-4}$. Em cada linha, o centro $\mathbf{x}_k$ e a decisão tomada a partir dele.

k	$\mathbf{x}_k$	Δ	$f(\mathbf{x}_k)$	decisão	f novo
0	(0,000; 0,000)	2,000	170,000	move	106,000
1	(1,000; 1,000)	2,000	106,000	move	26,000
2	(2,000; 2,000)	2,000	26,000	move	10,000
3	(3,000; 1,000)	2,000	10,000	$\Delta = \Delta/2$	10,000
4	(3,000; 1,000)	1,000	10,000	move	9,125

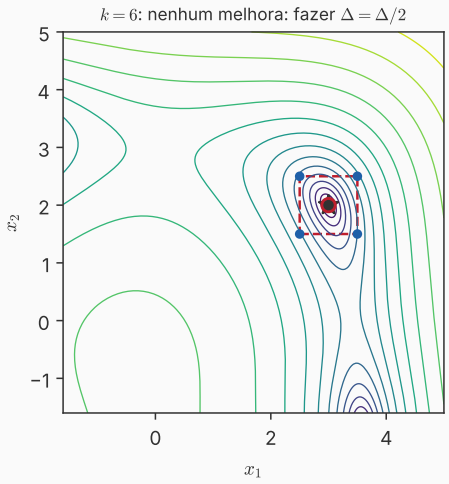
Himmelblau a partir de $(0;0)$: mover ou encolher



$\Delta = (2;2)$, $\varepsilon_x = 10^{-4}$. Em cada linha, o centro $\mathbf{x}_k$ e a decisão tomada a partir dele.

k	$\mathbf{x}_k$	Δ	$f(\mathbf{x}_k)$	decisão	f novo
0	(0,000; 0,000)	2,000	170,000	move	106,000
1	(1,000; 1,000)	2,000	106,000	move	26,000
2	(2,000; 2,000)	2,000	26,000	move	10,000
3	(3,000; 1,000)	2,000	10,000	$\Delta = \Delta/2$	10,000
4	(3,000; 1,000)	1,000	10,000	move	9,125
5	(3,500; 1,500)	1,000	9,125	move	0,000

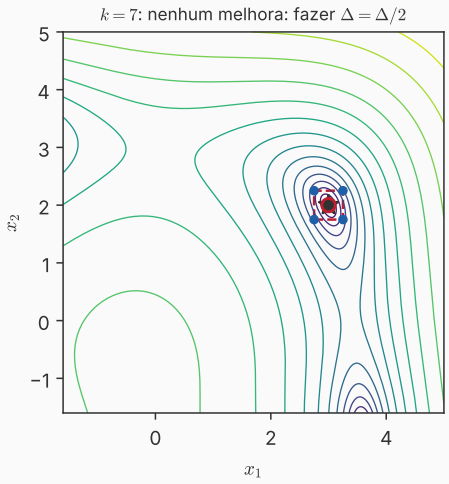
Himmelblau a partir de $(0;0)$: mover ou encolher



$\Delta = (2;2)$, $\varepsilon_x = 10^{-4}$. Em cada linha, o centro $\mathbf{x}_k$ e a decisão tomada a partir dele.

k	$\mathbf{x}_k$	Δ	$f(\mathbf{x}_k)$	decisão	f novo
0	(0,000; 0,000)	2,000	170,000	move	106,000
1	(1,000; 1,000)	2,000	106,000	move	26,000
2	(2,000; 2,000)	2,000	26,000	move	10,000
3	(3,000; 1,000)	2,000	10,000	$\Delta = \Delta/2$	10,000
4	(3,000; 1,000)	1,000	10,000	move	9,125
5	(3,500; 1,500)	1,000	9,125	move	0,000
6	(3,000; 2,000)	1,000	0,000	$\Delta = \Delta/2$	0,000

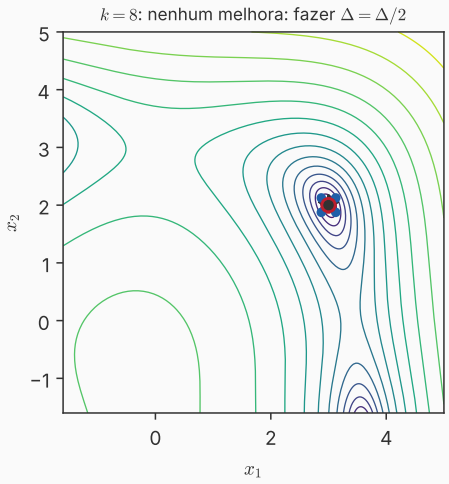
Himmelblau a partir de $(0; 0)$: mover ou encolher



$\Delta = (2; 2)$, $\varepsilon_x = 10^{-4}$. Em cada linha, o centro $\mathbf{x}_k$ e a decisão tomada a partir dele.

k	$\mathbf{x}_k$	Δ	$f(\mathbf{x}_k)$	decisão	f novo
0	(0,000; 0,000)	2,000	170,000	move	106,000
1	(1,000; 1,000)	2,000	106,000	move	26,000
2	(2,000; 2,000)	2,000	26,000	move	10,000
3	(3,000; 1,000)	2,000	10,000	$\Delta = \Delta/2$	10,000
4	(3,000; 1,000)	1,000	10,000	move	9,125
5	(3,500; 1,500)	1,000	9,125	move	0,000
6	(3,000; 2,000)	1,000	0,000	$\Delta = \Delta/2$	0,000
7	(3,000; 2,000)	0,500	0,000	$\Delta = \Delta/2$	0,000

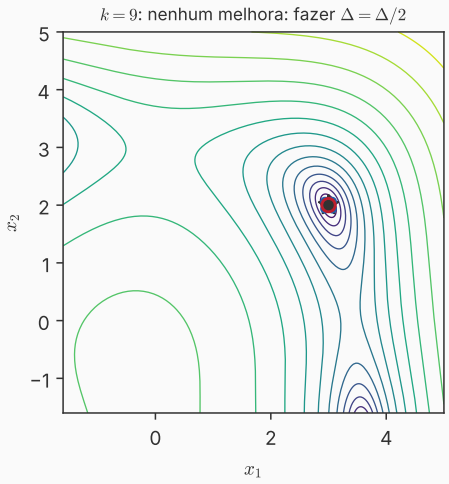
Himmelblau a partir de $(0; 0)$: mover ou encolher



$\Delta = (2; 2)$, $\varepsilon_x = 10^{-4}$. Em cada linha, o centro $\mathbf{x}_k$ e a decisão tomada a partir dele.

k	$\mathbf{x}_k$	Δ	$f(\mathbf{x}_k)$	decisão	f novo
0	(0,000; 0,000)	2,000	170,000	move	106,000
1	(1,000; 1,000)	2,000	106,000	move	26,000
2	(2,000; 2,000)	2,000	26,000	move	10,000
3	(3,000; 1,000)	2,000	10,000	$\Delta = \Delta/2$	10,000
4	(3,000; 1,000)	1,000	10,000	move	9,125
5	(3,500; 1,500)	1,000	9,125	move	0,000
6	(3,000; 2,000)	1,000	0,000	$\Delta = \Delta/2$	0,000
7	(3,000; 2,000)	0,500	0,000	$\Delta = \Delta/2$	0,000
8	(3,000; 2,000)	0,250	0,000	$\Delta = \Delta/2$	0,000

Himmelblau a partir de $(0;0)$: mover ou encolher

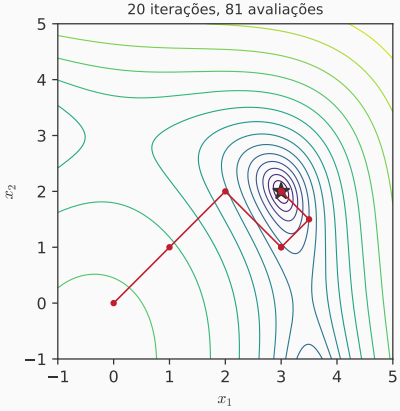


$\Delta = (2;2)$, $\varepsilon_x = 10^{-4}$. Em cada linha, o centro $\mathbf{x}_k$ e a decisão tomada a partir dele.

k	$\mathbf{x}_k$	Δ	$f(\mathbf{x}_k)$	decisão	f novo
0	(0,000; 0,000)	2,000	170,000	move	106,000
1	(1,000; 1,000)	2,000	106,000	move	26,000
2	(2,000; 2,000)	2,000	26,000	move	10,000
3	(3,000; 1,000)	2,000	10,000	$\Delta = \Delta/2$	10,000
4	(3,000; 1,000)	1,000	10,000	move	9,125
5	(3,500; 1,500)	1,000	9,125	move	0,000
6	(3,000; 2,000)	1,000	0,000	$\Delta = \Delta/2$	0,000
7	(3,000; 2,000)	0,500	0,000	$\Delta = \Delta/2$	0,000
8	(3,000; 2,000)	0,250	0,000	$\Delta = \Delta/2$	0,000
9	(3,000; 2,000)	0,125	0,000	$\Delta = \Delta/2$	0,000

A caixa desloca-se com tamanho fixo, $(0;0) \to (1,1) \to (2,2) \to (3,1)$; em $(3;1)$ nenhum vértice melhora e encolhe (Δ: $2 \to 1$); depois $(3;1) \to (3{,}5;1{,}5) \to (3,2)$ e só encolhe.

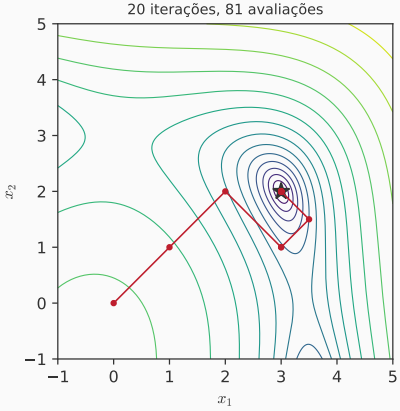
O percurso completo: o que a caixa está a fazer



20 iterações, $n_f = 4 \times 20 + 1 = 81$ até $\|\boldsymbol{\Delta}\| < 10^{-4}$.

- Enquanto há melhoria, o centro salta de vértice em vértice: todas as coordenadas mudam $\pm\Delta_i/2$, logo o passo tem comprimento fixo $\frac{1}{2}\,\|\boldsymbol{\Delta}\|$. Só quando estagna é que diminui.
- Chega a $(3;2)$ *exatamente* porque o mínimo está sobre a grelha de passos $\Delta/2$.

O percurso completo: o que a caixa está a fazer

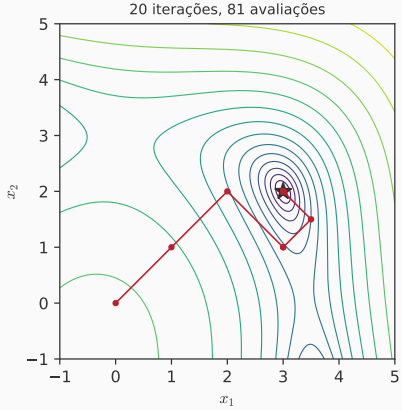


20 iterações, $n_f = 4 \times 20 + 1 = 81$ até $\|\mathbf{\Delta}\| < 10^{-4}$.

- Enquanto há melhoria, o centro salta de vértice em vértice: todas as coordenadas mudam $\pm\Delta_i/2$, logo o passo tem comprimento fixo $\frac{1}{2}\|\mathbf{\Delta}\|$. Só quando estagna é que diminui.
- Chega a $(3;2)$ *exatamente* porque o mínimo está sobre a grelha de passos $\Delta/2$.

Se Δ é muito pequeno, sabemos que estamos perto de $\mathbf{x}^*$?

O percurso completo: o que a caixa está a fazer



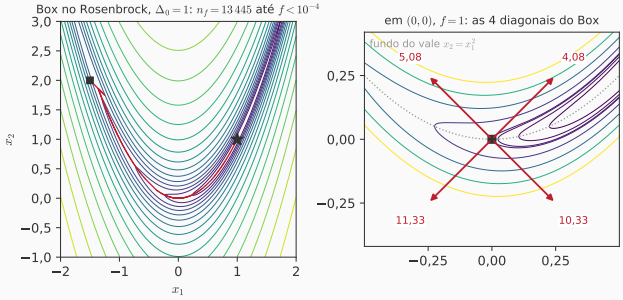
20 iterações, $n_f = 4 \times 20 + 1 = 81$ até $\|\boldsymbol{\Delta}\| < 10^{-4}$.

- Enquanto há melhoria, o centro salta de vértice em vértice: todas as coordenadas mudam $\pm\Delta_i/2$, logo o passo tem comprimento fixo $\frac{1}{2}\,\|\boldsymbol{\Delta}\|$. Só quando estagna é que diminui.
- Chega a $(3;2)$ *exatamente* porque o mínimo está sobre a grelha de passos $\Delta/2$.

Se Δ é muito pequeno, sabemos que estamos perto de $\mathbf{x}^*$?

Não. Sabemos apenas que, naquele padrão e àquela escala, nenhum vértice testado melhorou. Uma caixa pequena não certifica estacionariedade a Δ finito, nem mínimo local, nem $\|\mathbf{x} - \mathbf{x}^*\| = O(\varepsilon_x)$.

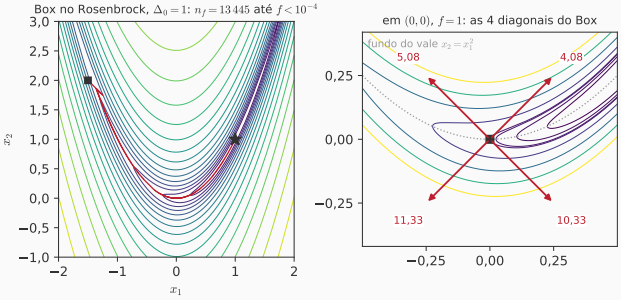
Porque falha em vales curvos?



Qual é o problema de mudar todas as coordenadas ao mesmo tempo? No Rosenbrock, a partir de $(-1{,}5; 2)$ com $\Delta_0 = 1$, a caixa tem de encolher de 1 até $\approx 6 \cdot 10^{-5}$ para conseguir progredir no vale, e depois avança em passos minúsculos: $n_f = 13\,445$ até $f < 10^{-4}$ (com $\varepsilon_x = 10^{-6}$).

Em $(0; 0)$, $\Delta = (0{,}5; 0{,}5)$ (vértices $\pm 0{,}25$): nenhuma diagonal $(\pm 1; \pm 1)$ melhora $f = 1$ (4,08 a 11,33).

Porque falha em vales curvos?

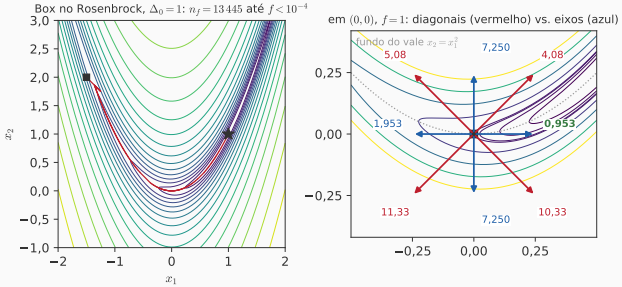


Qual é o problema de mudar todas as coordenadas ao mesmo tempo? No Rosenbrock, a partir de $(-1{,}5; 2)$ com $\Delta_0 = 1$, a caixa tem de encolher de 1 até $\approx 6 \cdot 10^{-5}$ para conseguir progredir no vale, e depois avança em passos minúsculos: $n_f = 13\,445$ até $f < 10^{-4}$ (com $\varepsilon_x = 10^{-6}$).

Em $(0; 0)$, $\Delta = (0{,}5; 0{,}5)$ (vértices $\pm 0{,}25$): nenhuma diagonal $(\pm 1; \pm 1)$ melhora $f = 1$ (4,08 a 11,33).

O Box concluiu que não há melhoria. Será que realmente não há uma direção de descida?

Porque falha em vales curvos?



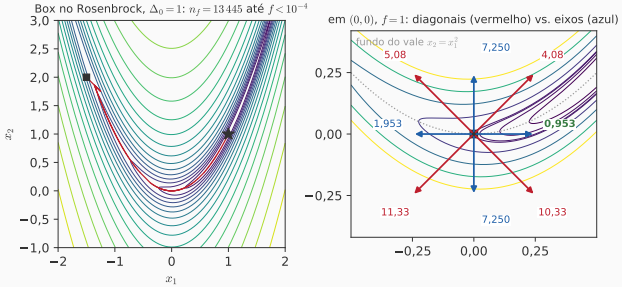
Qual é o problema de mudar todas as coordenadas ao mesmo tempo? No Rosenbrock, a partir de $(-1{,}5; 2)$ com $\Delta_0 = 1$, a caixa tem de encolher de 1 até $\approx 6 \cdot 10^{-5}$ para conseguir progredir no vale, e depois avança em passos minúsculos: $n_f = 13\,445$ até $f < 10^{-4}$ (com $\varepsilon_x = 10^{-6}$).

Em $(0; 0)$, $\Delta = (0{,}5; 0{,}5)$ (vértices $\pm 0{,}25$): nenhuma diagonal ($\pm 1; \pm 1$) melhora $f = 1$ (4,08 a 11,33).

O Box concluiu que não há melhoria. Será que realmente não há uma direção de descida?

Há: o eixo $+\mathbf{e}_1$ melhora, $f(0{,}25; 0) = 0{,}953$. O vale é horizontal aí; as diagonais saem dele.

Porque falha em vales curvos?



Qual é o problema de mudar todas as coordenadas ao mesmo tempo? No Rosenbrock, a partir de $(-1{,}5; 2)$ com $\Delta_0 = 1$, a caixa tem de encolher de 1 até $\approx 6 \cdot 10^{-5}$ para conseguir progredir no vale, e depois avança em passos minúsculos: $n_f = 13\,445$ até $f < 10^{-4}$ (com $\varepsilon_x = 10^{-6}$).

Em $(0; 0)$, $\Delta = (0{,}5; 0{,}5)$ (vértices $\pm 0{,}25$): nenhuma diagonal $(\pm 1; \pm 1)$ melhora $f = 1$ (4,08 a 11,33).

O Box concluiu que não há melhoria. Será que realmente não há uma direção de descida?

Há: o eixo $+\mathbf{e}_1$ melhora, $f(0{,}25; 0) = 0{,}953$. O vale é horizontal aí; as diagonais saem dele.

diagonais $(\pm 1, \ldots, \pm 1)$ vs. eixos $\pm \mathbf{e}_i$

O preço do Box; no computador

Vantagens

ordem zero; determinístico; muito simples; escala Δ_i controlável por variável; as avaliações dos 2^n vértices podem ser feitas em paralelo.

Limitações

- 2^n avaliações por iteração;
- só as 2^n direções diagonais $D = \{(\pm 1, \ldots, \pm 1)\}$: depende da orientação das coordenadas;
- ineficiente em vales estreitos e curvos; local;
- caixa pequena $\not\Rightarrow$ estacionariedade (a Δ finito);
- o ruído pode alterar a escolha do melhor vértice.

No Rosenbrock a partir de $(-1{,}5; 2)$, até $f < 10^{-4}$: Box ($\Delta_0 = 1$) $n_f = 13\,445$; Nelder–Mead $n_f = 244$ (mesmo problema, mesmo ponto inicial, mesmo critério; com estes parâmetros).

O núcleo, em MATLAB:

```
S = dec2bin(0:2^n-1) - '0';
S = 2*S - 1;                % linhas de +-1
V  = x + 0.5*S.*Delta;      % vertices
Fv = arrayfun(@(i) f(V(i,:)), 1:2^n);
[fmin, i] = min(Fv);
if fmin < fx
    x = V(i,:);  fx = fmin;   % mover
else
    Delta = Delta/2;          % encolher
end
```

Em 2D, `S` tem as 4 linhas $(-1,-1)$, $(-1,1)$, $(1,-1)$, $(1,1)$.

A função completa (`BoxEvo`, com `info.nfev`) está no código complementar da UC.

O QUE DEVE FICAR — 3.2.4

1. O Box usa uma caixa centrada no ponto atual e testa todas as 2^n combinações diagonais.
2. Melhoria $\Rightarrow$ mover para o melhor vértice; insucesso $\Rightarrow$ fazer $\Delta = \Delta/2$.
3. Só usa valores de f, mas o custo, 2^n por iteração, cresce exponencialmente com a dimensão: testar todas as diagonais é caro e rígido.
4. Uma caixa pequena não certifica estacionariedade a Δ finito. Para esta versão simplificada do Box não apresentamos aqui uma garantia geral de estacionariedade.
5. O NM não tem garantia geral; o HJ está na origem da pesquisa em padrão, cujas versões formalizadas (GPS) têm, sob hipóteses adequadas, $\liminf \|\nabla f(\mathbf{x}_k)\| = 0$ (3.2.5).

A seguir (3.2.5): precisamos mesmo das 2^n diagonais? E se explorarmos uma coordenada de cada vez, com apenas $2n$ direções, e depois aproveitarmos a direção do progresso? — o método de Hooke–Jeeves.

Referências e recursos

Referências Lista completa: *Bibliografia da UC*, no fim do PDF da UC.

- Box, G. E. P., *Evolutionary operation: a method for increasing industrial productivity*, Journal of the Royal Statistical Society, Series C (Applied Statistics) 6(2):81–101, 1957.
- Deb, K., *Optimization for Engineering Design: Algorithms and Examples*, 2.ª ed., PHI Learning, 2012 — cap. 3.

Recursos

- Código complementar: `BoxEvo` (`info.nfev`).