

Otimização

3.3.2 Método de Newton


José Firmino Aguilar Madeira

Podemos usar a curvatura?

A pergunta que o 3.3.1 deixou. A mesma quadrática: $f(\mathbf{x}) = \frac{1}{2}(x_1^2 + 9x_2^2)$, $\mathbf{x}_0 = (9, 1)$,

$$\mathbf{g}(\mathbf{x}) = \begin{pmatrix} x_1 \\ 9x_2 \end{pmatrix}, \quad H = \begin{pmatrix} 1 & 0 \\ 0 & 9 \end{pmatrix}, \quad \mathbf{g}_0 = (9, 9).$$

Gradiente: $\mathbf{d} = -\mathbf{g}_0 = (-9, -9)$ aponta para a “parede”: 74 iterações.



Podemos usar a curvatura?

A pergunta que o 3.3.1 deixou. A mesma quadrática: $f(\mathbf{x}) = \frac{1}{2}(x_1^2 + 9x_2^2)$, $\mathbf{x}_0 = (9, 1)$,


$$\mathbf{g}(\mathbf{x}) = \begin{pmatrix} x_1 \\ 9x_2 \end{pmatrix}, \quad H = \begin{pmatrix} 1 & 0 \\ 0 & 9 \end{pmatrix}, \quad \mathbf{g}_0 = (9, 9).$$

Gradiente: $\mathbf{d} = -\mathbf{g}_0 = (-9, -9)$ aponta para a “parede”: 74 iterações.

Newton: resolver $H\mathbf{d} = -\mathbf{g}_0$:

$$\mathbf{d}_0 = (-9, -1), \quad \mathbf{x}_1 = \mathbf{x}_0 + \mathbf{d}_0 = (0, 0).$$

Uma iteração.



Podemos usar a curvatura?

A pergunta que o 3.3.1 deixou. A mesma quadrática: $f(\mathbf{x}) = \frac{1}{2}(x_1^2 + 9x_2^2)$, $\mathbf{x}_0 = (9, 1)$,


$$\mathbf{g}(\mathbf{x}) = \begin{pmatrix} x_1 \\ 9x_2 \end{pmatrix}, \quad H = \begin{pmatrix} 1 & 0 \\ 0 & 9 \end{pmatrix}, \quad \mathbf{g}_0 = (9, 9).$$

Gradiente: $\mathbf{d} = -\mathbf{g}_0 = (-9, -9)$ aponta para a “parede”: 74 iterações.

Newton: resolver $H\mathbf{d} = -\mathbf{g}_0$:

$$\mathbf{d}_0 = (-9, -1), \quad \mathbf{x}_1 = \mathbf{x}_0 + \mathbf{d}_0 = (0, 0).$$

Uma iteração.



Porque é que Newton “sabe” ir direto ao mínimo?

De onde vem Newton? A quadrática de Taylor

Em $\mathbf{x}_k$, aproximar f pela sua quadrática de Taylor (como em 2.5, agora em $\mathbb{R}^n$):

$$f(\mathbf{x}_k + \mathbf{s}) \approx q(\mathbf{s}) = f(\mathbf{x}_k) + \mathbf{g}_k^T \mathbf{s} + \frac{1}{2} \mathbf{s}^T H_k \mathbf{s}, \quad H_k = \nabla^2 f(\mathbf{x}_k).$$

Procuramos o mínimo do **modelo**, não diretamente de f : $\nabla q(\mathbf{s}) = \mathbf{g}_k + H_k \mathbf{s} = \mathbf{0}$, logo

$$\boxed{H_k \mathbf{d}_k = -\mathbf{g}_k} \quad (\text{formalmente } \mathbf{d}_k = -H_k^{-1} \mathbf{g}_k), \quad \mathbf{x}_{k+1} = \mathbf{x}_k + \mathbf{d}_k.$$

- No computador **nunca se calcula** H_k^{-1} : resolve-se o sistema $H_k \mathbf{d}_k = -\mathbf{g}_k$ (Cholesky, eliminação de Gauss).
- Se f é quadrática com $H \succ 0$, o modelo é *exato*: o mínimo do modelo é o mínimo de f — **uma iteração**, seja qual for $\mathbf{x}_0$. Foi o que se viu na página anterior.
- Em geral o modelo só é bom perto de $\mathbf{x}_k$: daí as perguntas das páginas seguintes.

Gradiente vs. Newton: inclinação vs. curvatura

	Gradiente (3.3.1)	Newton (3.3.2)
usa	$\mathbf{g}$	$\mathbf{g}$ e H
direção	$\mathbf{d} = -\mathbf{g}$	$H\mathbf{d} = -\mathbf{g}$
geometria	inclinação	inclinação + curvatura
quadrática SPD	zigzag (linear)	1 iteração
custo por iteração	baixo	elevado (Hessiana + sistema)

Do 3.3 («Do 3.1...»): $\mathbf{d} = -M\mathbf{g}$ com $M \succ 0$ é de descida; o gradiente usa $M = I$; quando $H \succ 0$, Newton usa $M = H^{-1} \succ 0$.

H^{-1} reescala e roda o gradiente de acordo com a curvatura.

No exemplo: $H^{-1} = \text{diag}(1, \frac{1}{9})$ encolhe a componente x_2 (a direção de curvatura forte) nove vezes:
 $(-9, -9) \rightarrow (-9, -1)$.

Quando é a direção de Newton uma direção de descida?

$$\mathbf{g}_k^T \mathbf{d}_k = -\mathbf{g}_k^T H_k^{-1} \mathbf{g}_k.$$

- Se $H_k \succ 0$ (então $H_k^{-1} \succ 0$): $\mathbf{g}_k^T \mathbf{d}_k < 0$ para todo o $\mathbf{g}_k \neq \mathbf{0}$ — descida garantida.
- Se H_k é indefinida ou definida negativa: não há garantia de descida.
- Perto de um mínimo estrito não degenerado ($H(\mathbf{x}^*) \succ 0$), por continuidade $H_k \succ 0$: a garantia é local. (Um mínimo estrito pode ter $H(\mathbf{x}^*)$ singular: $f(x) = x^4$ em 0.)

O que pode realmente acontecer quando H_k não é definida positiva? — daqui a pouco, no Himmelblau.

Newton puro: o algoritmo

Newton puro: $\mathbf{x}_0, \varepsilon_g, k_{\max}$


```
1: for  $k = 0, 1, \dots, k_{\max}$  do  
2:    $\mathbf{g}_k \leftarrow \nabla f(\mathbf{x}_k)$ ; if  $\|\mathbf{g}_k\| \leq \varepsilon_g$  return  $\mathbf{x}_k$   
3:    $H_k \leftarrow \nabla^2 f(\mathbf{x}_k)$   
4:   resolver  $H_k \mathbf{d}_k = -\mathbf{g}_k$   
5:    $\mathbf{x}_{k+1} \leftarrow \mathbf{x}_k + \mathbf{d}_k$   $\triangleright$  passo completo,  $\alpha = 1$   
6: end for
```

- Sem pesquisa em linha: o próprio modelo diz quanto andar.
- Convergência **local quadrática**, sob regularidade e com $H(\mathbf{x}^*) \succ 0$: perto da solução, o número de algarismos corretos tende a duplicar em cada iteração.
- Quadrática SPD: uma iteração, de qualquer $\mathbf{x}_0$.
- Longe da solução: **nenhuma garantia** — nem de descida, nem de convergência.

Rosenbrock: muito rápido, mas não monótono

Newton puro a partir de $(-1,5; 2)$.


k	$\mathbf{x}_k$	$f(\mathbf{x}_k)$	$\ \nabla f\ $
0	$(-1,5000; 2,0000)$	12,500000	$1,63 \cdot 10^2$
1	$(-1,4510; 2,1029)$	6,007882	$6,31 \cdot 10^0$



Rosenbrock: muito rápido, mas não monótono

Newton puro a partir de $(-1,5; 2)$.


k	$\mathbf{x}_k$	$f(\mathbf{x}_k)$	$\ \nabla f\ $
0	$(-1,5000; 2,0000)$	12,500000	$1,63 \cdot 10^2$
1	$(-1,4510; 2,1029)$	6,007882	$6,31 \cdot 10^0$
2	$(0,2044; -2,6986)$	751,610005	$5,92 \cdot 10^2$



Rosenbrock: muito rápido, mas não monótono

Newton puro a partir de $(-1,5; 2)$.


k	$\mathbf{x}_k$	$f(\mathbf{x}_k)$	$\ \nabla f\ $
0	$(-1,5000; 2,0000)$	12,500000	$1,63 \cdot 10^2$
1	$(-1,4510; 2,1029)$	6,007882	$6,31 \cdot 10^0$
2	$(0,2044; -2,6986)$	751,610005	$5,92 \cdot 10^2$
3	$(0,2059; 0,0424)$	0,630622	$1,59 \cdot 10^0$



Rosenbrock: muito rápido, mas não monótono

Newton puro a partir de $(-1,5; 2)$.


k	$\mathbf{x}_k$	$f(\mathbf{x}_k)$	$\ \nabla f\ $
0	$(-1,5000; 2,0000)$	12,500000	$1,63 \cdot 10^2$
1	$(-1,4510; 2,1029)$	6,007882	$6,31 \cdot 10^0$
2	$(0,2044; -2,6986)$	751,610005	$5,92 \cdot 10^2$
3	$(0,2059; 0,0424)$	0,630622	$1,59 \cdot 10^0$
4	$(0,9997; 0,3692)$	39,701728	$2,82 \cdot 10^2$



Rosenbrock: muito rápido, mas não monótono

Newton puro a partir de $(-1,5; 2)$.


k	$\mathbf{x}_k$	$f(\mathbf{x}_k)$	$\ \nabla f\ $
0	$(-1,5000; 2,0000)$	12,500000	$1,63 \cdot 10^2$
1	$(-1,4510; 2,1029)$	6,007882	$6,31 \cdot 10^0$
2	$(0,2044; -2,6986)$	751,610005	$5,92 \cdot 10^2$
3	$(0,2059; 0,0424)$	0,630622	$1,59 \cdot 10^0$
4	$(0,9997; 0,3692)$	39,701728	$2,82 \cdot 10^2$
5	$(0,9997; 0,9993)$	$1,09 \cdot 10^{-7}$	$6,61 \cdot 10^{-4}$



Rosenbrock: muito rápido, mas não monótono

Newton puro a partir de $(-1,5; 2)$.

k	$\mathbf{x}_k$	$f(\mathbf{x}_k)$	$\ \nabla f\ $
0	$(-1,5000; 2,0000)$	12,500000	$1,63 \cdot 10^2$
1	$(-1,4510; 2,1029)$	6,007882	$6,31 \cdot 10^0$
2	$(0,2044; -2,6986)$	751,610005	$5,92 \cdot 10^2$
3	$(0,2059; 0,0424)$	0,630622	$1,59 \cdot 10^0$
4	$(0,9997; 0,3692)$	39,701728	$2,82 \cdot 10^2$
5	$(0,9997; 0,9993)$	$1,09 \cdot 10^{-7}$	$6,61 \cdot 10^{-4}$
6	$(1,0000; 1,0000)$	$1,20 \cdot 10^{-12}$	$4,89 \cdot 10^{-5}$




Rosenbrock: muito rápido, mas não monótono

Newton puro a partir de $(-1,5; 2)$.

k	$\mathbf{x}_k$	$f(\mathbf{x}_k)$	$\ \nabla f\ $
0	$(-1,5000; 2,0000)$	12,500000	$1,63 \cdot 10^2$
1	$(-1,4510; 2,1029)$	6,007882	$6,31 \cdot 10^0$
2	$(0,2044; -2,6986)$	751,610005	$5,92 \cdot 10^2$
3	$(0,2059; 0,0424)$	0,630622	$1,59 \cdot 10^0$
4	$(0,9997; 0,3692)$	39,701728	$2,82 \cdot 10^2$
5	$(0,9997; 0,9993)$	$1,09 \cdot 10^{-7}$	$6,61 \cdot 10^{-4}$
6	$(1,0000; 1,0000)$	$1,20 \cdot 10^{-12}$	$4,89 \cdot 10^{-5}$
7	$(1,0000; 1,0000)$	0	0


Pelo caminho, f sobe para 751 e para 40: o passo completo **não é monótono** — e mesmo assim converge, com a aceleração quadrática no fim.



Gradiente: 3000 it., ainda $f \approx 2,4 \cdot 10^{-4}$.
Newton puro: **7 iterações**, $f < 10^{-16}$.

Mas comparar iterações não chega: uma iteração de Newton é muito mais cara (Hessiana + sistema).

Newton procura $g = 0$ — não necessariamente mínimos



Himmelblau a partir de $(0, 0)$: $\lambda(H_0) = (-42; -26)$, H_0 definida negativa. A direção de Newton aponta para cima; o método puro converge em 4 iterações — para o máximo local $(-0.27; -0.92)$, $f = 181.6$.

O amortecido deteta $\mathbf{g}^T \mathbf{d} \geq 0$, usa $-\mathbf{g}$ com pesquisa em linha, e chega ao mínimo $(3, 2)$ em 5 iterações.

$$\text{Newton procura } \nabla f(\mathbf{x}) = \mathbf{0}$$

Newton puro resolve as condições de 1.ª ordem — e $\nabla f = \mathbf{0}$ inclui mínimos, máximos e selas (3.1: estacionário $\neq$ mínimo). Só com $H_k \succ 0$ o modelo tem um único mínimo e a direção é de descida.

Newton amortecido: longe proteger, perto deixar correr

1. calcular $\mathbf{g}_k$, H_k ;
2. testar $H_k \succ 0$ (Cholesky);
3. se falhar: modificar, $H_k + \mu I$ com $\mu > 0$ suficiente, ou usar $-\mathbf{g}_k$;
4. resolver $H_k \mathbf{d}_k = -\mathbf{g}_k$;
5. garantir $\mathbf{g}_k^T \mathbf{d}_k < 0$ (senão, $\mathbf{d}_k = -\mathbf{g}_k$);
6. pesquisa em linha: $\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$, com decréscimo suficiente (Armijo/Wolfe), começando em $\alpha = 1$.

longe: proteger

perto: $\alpha_k \rightarrow 1$, deixar Newton correr

Propriedade (Newton globalizado)

Com pesquisa em linha do tipo Armijo/Wolfe a começar em $\alpha = 1$, sob condições adequadas, quando os iterandos ficam suficientemente perto da solução o **passo completo** $\alpha_k = 1$ **passa a ser aceite** — e recupera-se a convergência quadrática.

Nas experiências desta UC (salvaguarda do passo 5 + minimização unidimensional muito precisa): Rosenbrock, puro 7 iterações (não monótono), amortecido 14 (monótono); os últimos minimizantes da linha foram 0,91; 0,98; 1,00 — uma **ilustração numérica** compatível com a propriedade, não uma demonstração. No Himmelblau, o amortecido evita o máximo local.

O preço de Newton; no computador

O preço da curvatura, por iteração

- $n_g = 1$, $n_H = 1$ ($2n^2 + 1$ avaliações de f se numéricos, em conjunto);
- sistema **denso** $n \times n$: $O(n^3)$ (esparso/estruturado: pode ser muito menos);
- **memória** $O(n^2)$ para guardar H — contra $O(n)$ no gradiente.

Com milhões de variáveis, o Newton clássico não é a escolha natural.

Newton: curvatura **exata**, cara

quasi-Newton (BFGS): curvatura **aproximada** a partir de gradientes

fora do programa; usada por defeito no `fminunc`

O núcleo, em MATLAB:

```
g = grad(x);  H = hess(x);  
d = -(H \ g);      % H*d = -g  
if g'*d >= 0  
    d = -g;        % salvaguarda  
end  
alpha = ...;      % pesquisa em linha  
x = x + alpha*d;
```

$[\sim, p] = \text{chol}(H)$: $p = 0$ se $H \succ 0$.

A função completa (`NewtonND`, puro/amortecido, com `info.nfev`, `ngev`, `nhev`) está no código complementar da UC.

O QUE DEVE FICAR — 3.3.2

1. Newton minimiza localmente a quadrática de Taylor: $H_k \mathbf{d}_k = -\mathbf{g}_k$ (resolve-se o sistema, não se inverte H_k).
2. Se f é quadrática SPD, chega ao mínimo em **uma iteração**.
3. Newton puro procura $\nabla f = \mathbf{0}$, **não mínimos**: se $H_k \neq 0$, a direção pode não ser de descida e o método pode convergir para máximos ou selas.
4. Newton puro é local; na prática usa-se modificação da Hessiana, salvaguardas e pesquisa em linha. Perto de um mínimo com $H(\mathbf{x}^*) \succ 0$, com pesquisa em linha a começar em $\alpha = 1$ (Armijo/Wolfe), $\alpha_k \rightarrow 1$ e, sob regularidade, recupera-se a convergência **quadrática**.
5. O preço da curvatura: Hessiana ($O(n^2)$ memória) + sistema denso ($O(n^3)$).

A seguir (3.3.3): **podemos evitar o ziguezague do gradiente sem calcular nem guardar a Hessiana?** — gradientes conjugados.

Referências Lista completa: *Bibliografia da UC*, no fim do PDF da UC.

- Nocedal, J., Wright, S. J., *Numerical Optimization*, 2.^a ed., Springer, 2006 — cap. 3.
- Dennis, J. E., Jr., Schnabel, R. B., *Numerical Methods for Unconstrained Optimization and Nonlinear Equations*, SIAM (Classics in Applied Mathematics 16), 1996 — cap. 6.

Recursos

- Código complementar: `NewtonND` (puro/amortecido; `info.nfev`, `ngev`, `nhev`).
- MATLAB: `chol`; `fminunc` (quasi-Newton BFGS por defeito, fora do programa).