

Otimização

3.3.2 Método de Newton


José Firmino Aguilar Madeira

Podemos usar a curvatura?

A pergunta que o 3.3.1 deixou. A mesma quadrática: $f(\mathbf{x}) = \frac{1}{2}(x_1^2 + 9x_2^2)$, $\mathbf{x}_0 = (9, 1)$,

$$\mathbf{g}(\mathbf{x}) = \begin{pmatrix} x_1 \\ 9x_2 \end{pmatrix}, \quad H = \begin{pmatrix} 1 & 0 \\ 0 & 9 \end{pmatrix}, \quad \mathbf{g}_0 = (9, 9).$$

Gradiente: $\mathbf{d} = -\mathbf{g}_0 = (-9, -9)$ aponta para a “parede”: 74 iterações.



Podemos usar a curvatura?

A pergunta que o 3.3.1 deixou. A mesma quadrática: $f(\mathbf{x}) = \frac{1}{2}(x_1^2 + 9x_2^2)$, $\mathbf{x}_0 = (9, 1)$,


$$\mathbf{g}(\mathbf{x}) = \begin{pmatrix} x_1 \\ 9x_2 \end{pmatrix}, \quad H = \begin{pmatrix} 1 & 0 \\ 0 & 9 \end{pmatrix}, \quad \mathbf{g}_0 = (9, 9).$$

Gradiente: $\mathbf{d} = -\mathbf{g}_0 = (-9, -9)$ aponta para a “parede”: 74 iterações.

Newton: resolver $H\mathbf{d} = -\mathbf{g}_0$:

$$\mathbf{d}_0 = (-9, -1), \quad \mathbf{x}_1 = \mathbf{x}_0 + \mathbf{d}_0 = (0, 0).$$

Uma iteração.



Podemos usar a curvatura?

A pergunta que o 3.3.1 deixou. A mesma quadrática: $f(\mathbf{x}) = \frac{1}{2}(x_1^2 + 9x_2^2)$, $\mathbf{x}_0 = (9, 1)$,


$$\mathbf{g}(\mathbf{x}) = \begin{pmatrix} x_1 \\ 9x_2 \end{pmatrix}, \quad H = \begin{pmatrix} 1 & 0 \\ 0 & 9 \end{pmatrix}, \quad \mathbf{g}_0 = (9, 9).$$

Gradiente: $\mathbf{d} = -\mathbf{g}_0 = (-9, -9)$ aponta para a “parede”: 74 iterações.

Newton: resolver $H\mathbf{d} = -\mathbf{g}_0$:

$$\mathbf{d}_0 = (-9, -1), \quad \mathbf{x}_1 = \mathbf{x}_0 + \mathbf{d}_0 = (0, 0).$$

Uma iteração.



Porque é que Newton “sabe” ir direto ao mínimo?

De onde vem Newton? A quadrática de Taylor

Em $\mathbf{x}_k$, aproximar f pela sua quadrática de Taylor (como em 2.5, agora em $\mathbb{R}^n$):

$$f(\mathbf{x}_k + \mathbf{s}) \approx q(\mathbf{s}) = f(\mathbf{x}_k) + \mathbf{g}_k^T \mathbf{s} + \frac{1}{2} \mathbf{s}^T H_k \mathbf{s}, \quad H_k = \nabla^2 f(\mathbf{x}_k).$$

Procuramos o mínimo do **modelo**, não diretamente de f : $\nabla q(\mathbf{s}) = \mathbf{g}_k + H_k \mathbf{s} = \mathbf{0}$, logo

$$\boxed{H_k \mathbf{d}_k = -\mathbf{g}_k} \quad (\text{formalmente } \mathbf{d}_k = -H_k^{-1} \mathbf{g}_k), \quad \mathbf{x}_{k+1} = \mathbf{x}_k + \mathbf{d}_k.$$

- No computador **nunca se calcula** H_k^{-1} : resolve-se o sistema $H_k \mathbf{d}_k = -\mathbf{g}_k$ (Cholesky, eliminação de Gauss).
- Se f é quadrática com $H \succ 0$, o modelo é *exato*: o mínimo do modelo é o mínimo de f — **uma iteração**, seja qual for $\mathbf{x}_0$. Foi o que se viu na página anterior.
- Em geral o modelo só é bom perto de $\mathbf{x}_k$: daí as perguntas das páginas seguintes.

Gradiente vs. Newton: inclinação vs. curvatura

	Gradiente (3.3.1)	Newton (3.3.2)
usa	$\mathbf{g}$	$\mathbf{g}$ e H
direção	$\mathbf{d} = -\mathbf{g}$	$H\mathbf{d} = -\mathbf{g}$
geometria	inclinação	inclinação + curvatura
quadrática SPD	zigzague (linear)	1 iteração
custo por iteração	baixo	elevado (Hessiana + sistema)

Do 3.3 («Do 3.1...»): $\mathbf{d} = -M\mathbf{g}$ com $M \succ 0$ é de descida; o gradiente usa $M = I$; quando $H \succ 0$, Newton usa $M = H^{-1} \succ 0$.

H^{-1} reescala e roda o gradiente de acordo com a curvatura.

No exemplo: $H^{-1} = \text{diag}(1, \frac{1}{9})$ encolhe a componente x_2 (a direção de curvatura forte) nove vezes:
 $(-9, -9) \rightarrow (-9, -1)$.

Quando é a direção de Newton uma direção de descida?

$$\mathbf{g}_k^T \mathbf{d}_k = -\mathbf{g}_k^T H_k^{-1} \mathbf{g}_k.$$

- Se $H_k \succ 0$ (então $H_k^{-1} \succ 0$): $\mathbf{g}_k^T \mathbf{d}_k < 0$ para todo o $\mathbf{g}_k \neq \mathbf{0}$ — descida garantida.
- Se H_k é indefinida ou definida negativa: não há garantia de descida.
- Perto de um mínimo estrito não degenerado ($H(\mathbf{x}^*) \succ 0$), por continuidade $H_k \succ 0$: a garantia é local. (Um mínimo estrito pode ter $H(\mathbf{x}^*)$ singular: $f(x) = x^4$ em 0.)

O que pode realmente acontecer quando H_k não é definida positiva? — daqui a pouco, no Himmelblau.

Newton puro: o algoritmo

Newton puro: $\mathbf{x}_0, \varepsilon_g, k_{\max}$


```
1: for  $k = 0, 1, \dots, k_{\max}$  do  
2:    $\mathbf{g}_k \leftarrow \nabla f(\mathbf{x}_k)$ ; if  $\|\mathbf{g}_k\| \leq \varepsilon_g$  return  $\mathbf{x}_k$   
3:    $H_k \leftarrow \nabla^2 f(\mathbf{x}_k)$   
4:   resolver  $H_k \mathbf{d}_k = -\mathbf{g}_k$   
5:    $\mathbf{x}_{k+1} \leftarrow \mathbf{x}_k + \mathbf{d}_k$   $\triangleright$  passo completo,  $\alpha = 1$   
6: end for
```

- Sem pesquisa em linha: o próprio modelo diz quanto andar.
- Convergência **local quadrática**, sob regularidade e com $H(\mathbf{x}^*) \succ 0$: perto da solução, o número de algarismos corretos tende a duplicar em cada iteração.
- Quadrática SPD: uma iteração, de qualquer $\mathbf{x}_0$.
- Longe da solução: **nenhuma garantia** — nem de descida, nem de convergência.

Rosenbrock: muito rápido, mas não monótono

Newton puro a partir de $(-1,5; 2)$.


k	$\mathbf{x}_k$	$f(\mathbf{x}_k)$	$\ \nabla f\ $
0	$(-1,5000; 2,0000)$	12,500000	$1,63 \cdot 10^2$
1	$(-1,4510; 2,1029)$	6,007882	$6,31 \cdot 10^0$



Rosenbrock: muito rápido, mas não monótono

Newton puro a partir de $(-1,5; 2)$.


k	$\mathbf{x}_k$	$f(\mathbf{x}_k)$	$\ \nabla f\ $
0	$(-1,5000; 2,0000)$	12,500000	$1,63 \cdot 10^2$
1	$(-1,4510; 2,1029)$	6,007882	$6,31 \cdot 10^0$
2	$(0,2044; -2,6986)$	751,610005	$5,92 \cdot 10^2$



Rosenbrock: muito rápido, mas não monótono

Newton puro a partir de $(-1,5; 2)$.


k	$\mathbf{x}_k$	$f(\mathbf{x}_k)$	$\ \nabla f\ $
0	$(-1,5000; 2,0000)$	12,500000	$1,63 \cdot 10^2$
1	$(-1,4510; 2,1029)$	6,007882	$6,31 \cdot 10^0$
2	$(0,2044; -2,6986)$	751,610005	$5,92 \cdot 10^2$
3	$(0,2059; 0,0424)$	0,630622	$1,59 \cdot 10^0$



Rosenbrock: muito rápido, mas não monótono

Newton puro a partir de $(-1,5; 2)$.


k	$\mathbf{x}_k$	$f(\mathbf{x}_k)$	$\ \nabla f\ $
0	$(-1,5000; 2,0000)$	12,500000	$1,63 \cdot 10^2$
1	$(-1,4510; 2,1029)$	6,007882	$6,31 \cdot 10^0$
2	$(0,2044; -2,6986)$	751,610005	$5,92 \cdot 10^2$
3	$(0,2059; 0,0424)$	0,630622	$1,59 \cdot 10^0$
4	$(0,9997; 0,3692)$	39,701728	$2,82 \cdot 10^2$



Rosenbrock: muito rápido, mas não monótono

Newton puro a partir de $(-1,5; 2)$.


k	$\mathbf{x}_k$	$f(\mathbf{x}_k)$	$\ \nabla f\ $
0	$(-1,5000; 2,0000)$	12,500000	$1,63 \cdot 10^2$
1	$(-1,4510; 2,1029)$	6,007882	$6,31 \cdot 10^0$
2	$(0,2044; -2,6986)$	751,610005	$5,92 \cdot 10^2$
3	$(0,2059; 0,0424)$	0,630622	$1,59 \cdot 10^0$
4	$(0,9997; 0,3692)$	39,701728	$2,82 \cdot 10^2$
5	$(0,9997; 0,9993)$	$1,09 \cdot 10^{-7}$	$6,61 \cdot 10^{-4}$



Rosenbrock: muito rápido, mas não monótono

Newton puro a partir de $(-1,5; 2)$.

k	$\mathbf{x}_k$	$f(\mathbf{x}_k)$	$\ \nabla f\ $
0	$(-1,5000; 2,0000)$	12,500000	$1,63 \cdot 10^2$
1	$(-1,4510; 2,1029)$	6,007882	$6,31 \cdot 10^0$
2	$(0,2044; -2,6986)$	751,610005	$5,92 \cdot 10^2$
3	$(0,2059; 0,0424)$	0,630622	$1,59 \cdot 10^0$
4	$(0,9997; 0,3692)$	39,701728	$2,82 \cdot 10^2$
5	$(0,9997; 0,9993)$	$1,09 \cdot 10^{-7}$	$6,61 \cdot 10^{-4}$
6	$(1,0000; 1,0000)$	$1,20 \cdot 10^{-12}$	$4,89 \cdot 10^{-5}$




Rosenbrock: muito rápido, mas não monótono

Newton puro a partir de $(-1,5; 2)$.

k	$\mathbf{x}_k$	$f(\mathbf{x}_k)$	$\ \nabla f\ $
0	$(-1,5000; 2,0000)$	12,500000	$1,63 \cdot 10^2$
1	$(-1,4510; 2,1029)$	6,007882	$6,31 \cdot 10^0$
2	$(0,2044; -2,6986)$	751,610005	$5,92 \cdot 10^2$
3	$(0,2059; 0,0424)$	0,630622	$1,59 \cdot 10^0$
4	$(0,9997; 0,3692)$	39,701728	$2,82 \cdot 10^2$
5	$(0,9997; 0,9993)$	$1,09 \cdot 10^{-7}$	$6,61 \cdot 10^{-4}$
6	$(1,0000; 1,0000)$	$1,20 \cdot 10^{-12}$	$4,89 \cdot 10^{-5}$
7	$(1,0000; 1,0000)$	0	0


Pelo caminho, f sobe para 751 e para 40: o passo completo **não é monótono** — e mesmo assim converge, com a aceleração quadrática no fim.



Gradiente: 3000 it., ainda $f \approx 2,4 \cdot 10^{-4}$.
Newton puro: **7 iterações**, $f < 10^{-16}$.

Mas comparar iterações não chega: uma iteração de Newton é muito mais cara (Hessiana + sistema).

Newton procura $g = 0$ — não necessariamente mínimos



Himmelblau a partir de $(0, 0)$: $\lambda(H_0) = (-42; -26)$, H_0 definida negativa. A direção de Newton aponta para cima; o método puro converge em 4 iterações — para o máximo local $(-0.27; -0.92)$, $f = 181.6$.

O amortecido deteta $\mathbf{g}^T \mathbf{d} \geq 0$, usa $-\mathbf{g}$ com pesquisa em linha, e chega ao mínimo $(3, 2)$ em 5 iterações.

$$\text{Newton procura } \nabla f(\mathbf{x}) = \mathbf{0}$$

Newton puro resolve as condições de 1.ª ordem — e $\nabla f = \mathbf{0}$ inclui mínimos, máximos e selas (3.1: estacionário $\neq$ mínimo). Só com $H_k \succ 0$ o modelo tem um único mínimo e a direção é de descida.

Newton amortecido: longe proteger, perto deixar correr

1. calcular $\mathbf{g}_k$, H_k ;
2. testar $H_k \succ 0$ (Cholesky);
3. se falhar: modificar, $H_k + \mu I$ com $\mu > 0$ suficiente, ou usar $-\mathbf{g}_k$;
4. resolver $H_k \mathbf{d}_k = -\mathbf{g}_k$;
5. garantir $\mathbf{g}_k^T \mathbf{d}_k < 0$ (senão, $\mathbf{d}_k = -\mathbf{g}_k$);
6. pesquisa em linha: $\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$, com decréscimo suficiente (Armijo/Wolfe, a seguir), começando em $\alpha = 1$.

longe: proteger

perto: $\alpha_k \rightarrow 1$, deixar Newton correr

Propriedade (Newton globalizado)

Com pesquisa em linha do tipo Armijo/Wolfe a começar em $\alpha = 1$, sob condições adequadas, quando os iterandos ficam suficientemente perto da solução o **passo completo** $\alpha_k = 1$ **passa a ser aceite** — e recupera-se a convergência quadrática.

Nas experiências desta UC (salvaguarda do passo 5 + minimização unidimensional muito precisa): Rosenbrock, puro 7 iterações (não monótono), amortecido 14 (monótono); os últimos minimizantes da linha foram 0,91; 0,98; 1,00 — uma **ilustração numérica** compatível com a propriedade, não uma demonstração. No Himmelblau, o amortecido evita o máximo local.

Que α aceitar? A condição de Armijo

Minimizar $\varphi(\alpha)$ com precisão é caro: no Rosenbrock, o amortecido do slide anterior gastou **cerca de 360 avaliações de f** em 14 iterações. Na prática basta um **decréscimo suficiente**.

Condição de Armijo


$$f(\mathbf{x}_k + \alpha \mathbf{d}_k) \leq f(\mathbf{x}_k) + c_1 \alpha \mathbf{g}_k^T \mathbf{d}_k, \quad 0 < c_1 < 1$$

(tipicamente $c_1 = 10^{-4}$)

Recuo: $\alpha = 1, \frac{1}{2}, \frac{1}{4}, \dots$ até verificar. Começar em $\alpha = 1$ deixa Newton correr.

Em $k = 1$: $f(\mathbf{x}_1) = 6,008$, $\mathbf{g}_1^T \mathbf{d}_1 = -8,12$; $\alpha = 1, \frac{1}{2}, \frac{1}{4}$ rejeitados; $\alpha = \frac{1}{8}$ **aceite** (4 avaliações).

Rosenbrock com Armijo: **22 iterações**, $n_f = 29$, f sempre a descer; $\alpha = 1$ nas últimas 7. Mais iterações, muito menos avaliações.



Rosenbrock, $\mathbf{x}_1 = (-1,451; 2,103)$ (Newton puro), direção de Newton $\mathbf{d}_1$. A reta de Armijo é quase horizontal: basta descer um pouco.

Wolfe acrescenta uma condição sobre $\varphi'(\alpha)$, que impede passos demasiado curtos (essencial no BFGS).

E se H_k não é definida positiva?

1. Trocar a direção

$\mathbf{d}_k = -\mathbf{g}_k$ quando $\mathbf{g}_k^T \mathbf{d}_k \geq 0$.

Simplex; perde a curvatura nessa iteração. Foi o que se fez no Himmelblau.

Himmelblau de $(0, 0)$, $\lambda(H_0) = (-42; -26)$, com Armijo:

	iterações	n_f
1. $-\mathbf{g}$ na 1.ª iteração	6	14
2. $H + \mu I$	8	10

Os dois chegam ao mínimo $(3, 2)$.

2. Modificar a Hessiana

$(H_k + \mu I)\mathbf{d}_k = -\mathbf{g}_k$, com $\mu > 0$ até Cholesky passar.

μ pequeno: quase Newton; μ grande: $\mathbf{d}_k \approx -\mathbf{g}_k/\mu$, quase gradiente. (A mesma ideia em Levenberg–Marquardt, nos mínimos quadrados.)

3. Regiões de confiança

$\min_{\mathbf{s}} q(\mathbf{s})$ s.a. $\|\mathbf{s}\| \leq \Delta_k$.

Na bola o problema tem solução mesmo com H_k indefinida.

$\rho_k = \frac{f(\mathbf{x}_k) - f(\mathbf{x}_k + \mathbf{s})}{q(0) - q(\mathbf{s})}$: grande $\Rightarrow$ aceitar e alargar Δ ; pequeno $\Rightarrow$ rejeitar e encolher Δ .

Pesquisa em linha: primeiro a **direção**, depois o comprimento.

Região de confiança: primeiro o **tamanho** Δ_k , depois a direção.

Regiões de confiança: fora do programa (Nocedal–Wright, cap. 4).

O preço de Newton e o que nasce daqui: quasi-Newton

Preço por iteração: $n_g = 1$, $n_H = 1$ ($2n^2 + 1$ avaliações de f se numéricos); sistema denso $O(n^3)$; memória $O(n^2)$. Com milhões de variáveis, o Newton clássico não é a escolha natural.

Ideia: aproximar a curvatura com os gradientes que já temos. Com $\mathbf{s}_k = \mathbf{x}_{k+1} - \mathbf{x}_k$ e $\mathbf{y}_k = \mathbf{g}_{k+1} - \mathbf{g}_k$, pedir $B_{k+1} \mathbf{s}_k = \mathbf{y}_k$ (equação da secante; em 1D, a reta secante).

- **BFGS:** atualização simples de B_k (ou da inversa) que a mantém definida positiva se $\mathbf{y}_k^T \mathbf{s}_k > 0$ (Wolfe garante-o); sem segundas derivadas; convergência **superlinear**.
- **L-BFGS:** guarda só os últimos m pares $(\mathbf{s}, \mathbf{y})$, $m \approx 5\text{--}20$: memória $O(mn)$.

método	memória	custo/it.*	conv. local
gradiente (3.3.1)	$O(n)$	$O(n)$	linear
grad. conj. (3.3.3)	$O(n)$	$O(n)$	linear**
L-BFGS	$O(mn)$	$O(mn)$	linear
BFGS	$O(n^2)$	$O(n^2)$	superlinear
Newton (3.3.2)	$O(n^2)$	$O(n^3)$	quadrática

* além das avaliações de f , $\mathbf{g}$ (e H). ** n iterações nas quadráticas SPD (3.3.3).

No software: MATLAB `fminunc` ('quasi-newton', BFGS, por omissão; 'trust-region', com gradiente fornecido); SciPy `minimize` ('BFGS', 'L-BFGS-B', 'trust-exact', ...).

Quasi-Newton e regiões de confiança: **fora do programa** — é aqui que a matéria continua.

- Resolver $Hd = -g$ com $H \setminus g$, nunca com $\text{inv}(H)$.
- Testar $H \succ 0$ com Cholesky: $[\sim, p] = \text{chol}(H)$, $p = 0$ se $H \succ 0$.
- A pesquisa em linha do código complementar: minimizante da linha (Brent, por omissão) ou recuo de Armijo (`opts.ls = 'armijo'`); $H + \mu I$ com `opts.modify = true`.

Newton: curvatura **exata**, cara

BFGS: curvatura **aproximada**

O núcleo, em MATLAB:

```
g = grad(x);  H = hess(x);  
d = -(H \ g);           % H*d = -g  
if g'*d >= 0  
    d = -g;              % salvaguarda  
end  
alpha = ...;            % pesquisa em linha  
x = x + alpha*d;
```

A função completa (`NewtonND`, puro/amortecido, com `info.nfev`, `ngev`, `nhev`) está no código complementar da UC.

O QUE DEVE FICAR — 3.3.2

1. Newton minimiza localmente a quadrática de Taylor: $H_k \mathbf{d}_k = -\mathbf{g}_k$ (resolve-se o sistema, não se inverte H_k).
2. Se f é quadrática SPD, chega ao mínimo em **uma iteração**.
3. Newton puro procura $\nabla f = \mathbf{0}$, **não mínimos**: se $H_k \neq 0$, a direção pode não ser de descida e o método pode convergir para máximos ou selas.
4. Newton puro é local; na prática: $H + \mu I$, salvaguardas e pesquisa em linha com **decréscimo suficiente** (Armijo, a partir de $\alpha = 1$). Perto de um mínimo com $H(\mathbf{x}^*) \succ 0$, $\alpha_k \rightarrow 1$ e recupera-se a convergência **quadrática** (sob regularidade).
5. O preço: Hessiana ($O(n^2)$ memória) + sistema ($O(n^3)$). Daqui nascem os **quasi-Newton** (BFGS: curvatura a partir dos gradientes) e as **regiões de confiança**.

A seguir (3.3.3): **podemos evitar o ziguezague do gradiente sem calcular nem guardar a Hessiana?** — gradientes conjugados.

Referências Lista completa: *Bibliografia da UC*, no fim do PDF da UC.

- Nocedal, J., Wright, S. J., *Numerical Optimization*, 2.^a ed., Springer, 2006 — caps. 3 (pesquisa em linha, Armijo/Wolfe), 4 (regiões de confiança), 6 (quasi-Newton) e 7 (L-BFGS).
- Dennis, J. E., Jr., Schnabel, R. B., *Numerical Methods for Unconstrained Optimization and Nonlinear Equations*, SIAM (Classics in Applied Mathematics 16), 1996 — caps. 6 e 9 (secante).
- Conn, A. R., Gould, N. I. M., Toint, Ph. L., *Trust-Region Methods*, SIAM (MPS-SIAM Series on Optimization 1), 2000.
- Armijo, L., *Minimization of functions having Lipschitz continuous first partial derivatives*, Pacific Journal of Mathematics 16(1):1–3, 1966.

Recursos

- Código complementar: NewtonND (puro/amortecido; Brent ou Armijo; $H + \mu I$; info.nfev, ngev, nhev).
- MATLAB: chol; fminunc (BFGS por omissão; 'trust-region'). SciPy: minimize.