

Otimização

4.2 Condições de Karush–Kuhn–Tucker (KKT)

José Firmino Aguilar Madeira

De 4.1 para 4.2: o que muda?


4.1: uma **igualdade** $h(\mathbf{x}) = 0$ prende-nos à superfície. 4.2: uma **desigualdade** $g(\mathbf{x}) \geq 0$ só proíbe um lado.

$\min (x_1 - 1)^2 + (x_2 - 1)^2$ s.a. $g(\mathbf{x}) \geq 0$ — a **restrição** influencia a solução?

De 4.1 para 4.2: o que muda?

4.1: uma **igualdade** $h(\mathbf{x}) = 0$ prende-nos à superfície. 4.2: uma **desigualdade** $g(\mathbf{x}) \geq 0$ só proíbe um lado.

$\min (x_1 - 1)^2 + (x_2 - 1)^2$ s.a. $g(\mathbf{x}) \geq 0$ — a restrição influencia a solução?




Círculo largo, $g = 4 - x_1^2 - x_2^2$. O mínimo livre $(1, 1)$ é admissível: $g(\mathbf{x}^*) = 4 - 1 - 1 = 2 > 0$. **Inativa**: $\lambda^* = 0$ e $\nabla f(\mathbf{x}^*) = \mathbf{0}$ — é **como se não existisse**.


De 4.1 para 4.2: o que muda?

4.1: uma **igualdade** $h(\mathbf{x}) = 0$ prende-nos à superfície. 4.2: uma **desigualdade** $g(\mathbf{x}) \geq 0$ só proíbe um lado.

$\min (x_1 - 1)^2 + (x_2 - 1)^2$ s.a. $g(\mathbf{x}) \geq 0$ — a restrição influencia a solução?



Círculo largo, $g = 4 - x_1^2 - x_2^2$. O mínimo livre $(1, 1)$ é admissível: $g(\mathbf{x}^*) = 4 - 1 - 1 = 2 > 0$. **Inativa**: $\lambda^* = 0$ e $\nabla f(\mathbf{x}^*) = \mathbf{0}$ — é **como se não existisse**.




Círculo apertado, $g = 1 - x_1^2 - x_2^2$. $(1, 1)$ já não é admissível; $\mathbf{x}^* = (\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}})$, $g(\mathbf{x}^*) = 0$. **Ativa**: $\nabla f = \lambda \nabla g$, $2(\frac{1}{\sqrt{2}} - 1)(1, 1) = \lambda(-\sqrt{2})(1, 1)$, $\lambda^* = \sqrt{2} - 1 > 0$.


De 4.1 para 4.2: o que muda?

4.1: uma **igualdade** $h(\mathbf{x}) = 0$ prende-nos à superfície. 4.2: uma **desigualdade** $g(\mathbf{x}) \geq 0$ só proíbe um lado.

$\min (x_1 - 1)^2 + (x_2 - 1)^2$ s.a. $g(\mathbf{x}) \geq 0$ — a restrição influencia a solução?



Círculo largo, $g = 4 - x_1^2 - x_2^2$. O mínimo livre $(1, 1)$ é admissível: $g(\mathbf{x}^*) = 4 - 1 - 1 = 2 > 0$. **Inativa**: $\lambda^* = 0$ e $\nabla f(\mathbf{x}^*) = \mathbf{0}$ — é **como se não existisse**.



Círculo apertado, $g = 1 - x_1^2 - x_2^2$. $(1, 1)$ já não é admissível; $\mathbf{x}^* = (\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}})$, $g(\mathbf{x}^*) = 0$. **Ativa**: $\nabla f = \lambda \nabla g$, $2(\frac{1}{\sqrt{2}} - 1)(1, 1) = \lambda(-\sqrt{2})(1, 1)$, $\lambda^* = \sqrt{2} - 1 > 0$.

Mesma f : **basta mover a fronteira**. Ativa, é como uma igualdade que só “empurra” para dentro.

O problema geral

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) \quad \text{s.a.} \quad g_j(\mathbf{x}) \geq 0, \quad j = 1, \dots, J; \quad h_\ell(\mathbf{x}) = 0, \quad \ell = 1, \dots, K.$$

- Convenção da UC (Deb, e 1.1): desigualdades na forma $g_j \geq 0$. Uma restrição $c(\mathbf{x}) \leq b$ escreve-se $g = b - c(\mathbf{x}) \geq 0$.
- **Região admissível** X : todos os $\mathbf{x}$ que cumprem todas as restrições.
- Em $\mathbf{x} \in X$, g_j está **ativa** se $g_j(\mathbf{x}) = 0$ (na fronteira) e **inativa** se $g_j(\mathbf{x}) > 0$. **Conjunto ativo**: $I(\mathbf{x}) = \{j : g_j(\mathbf{x}) = 0\}$.
- As igualdades h_ℓ entram como em 4.1, com multiplicador β_ℓ ($= -\lambda_\ell$ de 4.1).

Notas: os limites $x_i^{(L)} \leq x_i \leq x_i^{(U)}$ escrevem-se $x_i - x_i^{(L)} \geq 0$ e $x_i^{(U)} - x_i \geq 0$ e ficam incluídos em $\mathbf{g}$. Muitos livros e o `fmincon` usam $c(\mathbf{x}) \leq 0$: a geometria é a mesma, mas os sinais escrevem-se de outra forma.

A partir daqui g_j (e $\mathbf{g} = (g_1, \dots, g_J)$) são restrições; o gradiente escreve-se sempre ∇f .


Geometria (1): porque é que o ótimo vai para a fronteira?

Exemplo 1. $\min (x_1 - 2)^2 + 2(x_2 - 1)^2$ s.a.

$g_1 = 3 - x_1 - 4x_2 \geq 0$, $g_2 = x_1 - x_2 \geq 0$.

- O mínimo livre $(2, 1)$ **viola** g_1 :

$$g_1(2, 1) = -3 < 0.$$




Geometria (1): porque é que o ótimo vai para a fronteira?

Exemplo 1. $\min (x_1 - 2)^2 + 2(x_2 - 1)^2$ s.a.

$$g_1 = 3 - x_1 - 4x_2 \geq 0, \quad g_2 = x_1 - x_2 \geq 0.$$

- O mínimo livre $(2, 1)$ **viola** g_1 :
 $g_1(2, 1) = -3 < 0$.
- Dentro de X , f desce até à curva de nível $f = 1$, que **toca** a fronteira $g_1 = 0$ em $\mathbf{x}^* = (\frac{5}{3}, \frac{1}{3})$. Descer mais obrigaria a sair de X .




Geometria (1): porque é que o ótimo vai para a fronteira?

Exemplo 1. $\min (x_1 - 2)^2 + 2(x_2 - 1)^2$ s.a.

$$g_1 = 3 - x_1 - 4x_2 \geq 0, \quad g_2 = x_1 - x_2 \geq 0.$$


- O mínimo livre $(2, 1)$ **viola** g_1 :
 $g_1(2, 1) = -3 < 0$.
- Dentro de X , f desce até à curva de nível $f = 1$, que **toca** a fronteira $g_1 = 0$ em $\mathbf{x}^* = (\frac{5}{3}, \frac{1}{3})$. Descer mais obrigaria a sair de X .
- Em $\mathbf{x}^*$: $g_1 = 0$ — **ativa**; $g_2 = \frac{4}{3} > 0$ — **inativa**, é como se não existisse.

O mesmo exemplo tem os dois casos: uma restrição que “trabalha” e outra que não.



Geometria (2): porque é que $\lambda \geq 0$?


- ∇g_1 aponta para onde g_1 **cresce**, isto é, para o lado admissível $g_1 > 0$ — para dentro de X .
- No ótimo de fronteira, f não pode descer para dentro de X : f cresce para dentro, logo ∇f também aponta para dentro — **o mesmo sentido** que ∇g_1 .
- Logo o coeficiente que os relaciona é não negativo:
 $\nabla f(\mathbf{x}^*) = \lambda_1 \nabla g_1(\mathbf{x}^*)$: $\left(-\frac{2}{3}, -\frac{8}{3}\right) = \frac{2}{3}(-1, -4)$,
 $\lambda_1 = \frac{2}{3} \geq 0$.



Geometria (2): porque é que $\lambda \geq 0$?

- ∇g_1 aponta para onde g_1 **cresce**, isto é, para o lado admissível $g_1 > 0$ — para dentro de X .
- No ótimo de fronteira, f não pode descer para dentro de X : f cresce para dentro, logo ∇f também aponta para dentro — **o mesmo sentido** que ∇g_1 .
- Logo o coeficiente que os relaciona é não negativo: $\nabla f(\mathbf{x}^*) = \lambda_1 \nabla g_1(\mathbf{x}^*)$: $(-\frac{2}{3}, -\frac{8}{3}) = \frac{2}{3}(-1, -4)$, $\lambda_1 = \frac{2}{3} \geq 0$.
- Se fosse $\lambda < 0$: no círculo largo de «De 4.1 para 4.2», o ponto $(\sqrt{2}, \sqrt{2})$ da fronteira tem $\nabla f = \lambda \nabla g$ com $\lambda = \frac{1}{\sqrt{2}} - 1 < 0$. Aí ∇f aponta para fora, $-\nabla f$ para dentro — desce-se **entrando em X** (até $(1, 1)$): não é mínimo.

Com a convenção $c(\mathbf{x}) \leq 0$, ∇c aponta para fora e escreve-se $\nabla f = -\mu \nabla c$, $\mu \geq 0$: a mesma geometria.



Caso 1 — inativa: $g_j(\mathbf{x}^*) > 0 \Rightarrow \lambda_j = 0$.

Da geometria às condições KKT

Caso 1 — inativa: $g_j(\mathbf{x}^*) > 0 \Rightarrow \lambda_j = 0$.

Caso 2 — ativa: $g_j(\mathbf{x}^*) = 0, \quad \lambda_j \geq 0$.

Da geometria às condições KKT

Caso 1 — inativa: $g_j(\mathbf{x}^*) > 0 \Rightarrow \lambda_j = 0$.

Caso 2 — ativa: $g_j(\mathbf{x}^*) = 0, \quad \lambda_j \geq 0$.

Pergunta

Como escrever os dois casos numa única equação?

Da geometria às condições KKT

Caso 1 — inativa: $g_j(\mathbf{x}^*) > 0 \Rightarrow \lambda_j = 0$.

Caso 2 — ativa: $g_j(\mathbf{x}^*) = 0, \quad \lambda_j \geq 0$.

Pergunta

Como escrever os dois casos numa única equação?

$$\lambda_j g_j(\mathbf{x}^*) = 0, \quad \lambda_j \geq 0$$

(**complementaridade**). Em cada j , pelo menos um dos dois é zero. No exemplo 1:

$$\lambda_1 g_1 = \frac{2}{3} \cdot 0 = 0, \quad \lambda_2 g_2 = 0 \cdot \frac{4}{3} = 0.$$

Cuidado: ativa não implica $\lambda > 0$

$\min x^2$ s.a. $g = x \geq 0$: $x^* = 0$, $g(x^*) = 0$ (ativa), mas $2x - \lambda = 0 \Rightarrow \lambda^* = 0$. Inativa $\Rightarrow \lambda = 0$; mas $\lambda = 0$ **não implica** inativa.

Da geometria às condições KKT

Caso 1 — inativa: $g_j(\mathbf{x}^*) > 0 \Rightarrow \lambda_j = 0$.

Caso 2 — ativa: $g_j(\mathbf{x}^*) = 0, \quad \lambda_j \geq 0$.

Pergunta

Como escrever os dois casos numa única equação?

$$\lambda_j g_j(\mathbf{x}^*) = 0, \quad \lambda_j \geq 0$$

(**complementaridade**). Em cada j , pelo menos um dos dois é zero. No exemplo 1:
 $\lambda_1 g_1 = \frac{2}{3} \cdot 0 = 0, \quad \lambda_2 g_2 = 0 \cdot \frac{4}{3} = 0$.

Cuidado: ativa não implica $\lambda > 0$

$\min x^2$ s.a. $g = x \geq 0$: $x^* = 0, g(x^*) = 0$ (ativa), mas $2x - \lambda = 0 \Rightarrow \lambda^* = 0$. Inativa $\Rightarrow \lambda = 0$; mas $\lambda = 0$ **não implica** inativa.

Juntando tudo, em $\mathbf{x}^*$ (com as igualdades de 4.1):

$$\text{estacionariedade } \nabla f = \sum_j \lambda_j \nabla g_j + \sum_\ell \beta_\ell \nabla h_\ell$$

$$\text{admissibilidade } g_j \geq 0, \quad h_\ell = 0$$

$$\text{complementaridade } \lambda_j g_j = 0$$

$$\text{sinal } \lambda_j \geq 0 \quad (\beta_\ell \text{ livres})$$

Com $\mathcal{L} = f - \lambda^T \mathbf{g} - \beta^T \mathbf{h}$, a 1.ª linha é $\nabla_{\mathbf{x}} \mathcal{L} = \mathbf{0}$ (convenção das aulas).

KKT = Lagrange + sinal + complementaridade. Sem desigualdades, é exatamente 4.1.

Condições necessárias de 1.ª ordem

Se $\mathbf{x}^*$ é mínimo local, com $f, g_j, h_\ell \in C^1$ perto de $\mathbf{x}^*$, e os gradientes das restrições ativas em $\mathbf{x}^*$ — $\nabla g_j, j \in I(\mathbf{x}^*)$, e todos os ∇h_ℓ — são **linearmente independentes** (LICQ), então existem $\lambda \in \mathbb{R}^J$ e $\beta \in \mathbb{R}^K$ tais que

$$\nabla f(\mathbf{x}^*) = \sum_j \lambda_j \nabla g_j(\mathbf{x}^*) + \sum_\ell \beta_\ell \nabla h_\ell(\mathbf{x}^*), \quad g_j(\mathbf{x}^*) \geq 0, \quad h_\ell(\mathbf{x}^*) = 0, \quad \lambda_j g_j(\mathbf{x}^*) = 0, \quad \lambda_j \geq 0.$$

- Um ponto que cumpre as quatro condições chama-se **ponto KKT**.
- A hipótese LICQ é a de 4.1 alargada às desigualdades *ativas*; sem ela pode não haver multiplicadores (ver adiante).
- São condições **necessárias**: dizem onde procurar, não garantem que se encontrou um mínimo (ver adiante).

Receita

1. Escrever $\mathcal{L}$ e as condições. 2. Escolher um caso: cada g_j ativa ($g_j = 0$) ou com $\lambda_j = 0$. 3. Resolver o sistema. 4. Verificar admissibilidade e $\lambda_j \geq 0$. 5. Classificar os pontos KKT.

Exemplo 1. $\mathcal{L} = (x_1 - 2)^2 + 2(x_2 - 1)^2 - \lambda_1(3 - x_1 - 4x_2) - \lambda_2(x_1 - x_2)$:

$$2(x_1 - 2) + \lambda_1 - \lambda_2 = 0, \quad 4(x_2 - 1) + 4\lambda_1 + \lambda_2 = 0, \quad \lambda_1 g_1 = 0, \quad \lambda_2 g_2 = 0, \quad \lambda_1, \lambda_2 \geq 0.$$

caso	hipótese	solução do sistema linear	verificação
1	$\lambda_1 = \lambda_2 = 0$	$\mathbf{x} = (2, 1)$	$g_1 = -3 < 0$: inadmissível ✗

Resolver KKT: receita e 2^J casos

Receita

1. Escrever $\mathcal{L}$ e as condições. 2. Escolher um caso: cada g_j ativa ($g_j = 0$) ou com $\lambda_j = 0$. 3. Resolver o sistema. 4. Verificar admissibilidade e $\lambda_j \geq 0$. 5. Classificar os pontos KKT.

Exemplo 1. $\mathcal{L} = (x_1 - 2)^2 + 2(x_2 - 1)^2 - \lambda_1(3 - x_1 - 4x_2) - \lambda_2(x_1 - x_2)$:

$$2(x_1 - 2) + \lambda_1 - \lambda_2 = 0, \quad 4(x_2 - 1) + 4\lambda_1 + \lambda_2 = 0, \quad \lambda_1 g_1 = 0, \quad \lambda_2 g_2 = 0, \quad \lambda_1, \lambda_2 \geq 0.$$

caso	hipótese	solução do sistema linear	verificação
1	$\lambda_1 = \lambda_2 = 0$	$\mathbf{x} = (2, 1)$	$g_1 = -3 < 0$: inadmissível ✗
2	$\lambda_1 = 0, g_2 = 0$	$\mathbf{x} = (\frac{4}{3}, \frac{4}{3}), \lambda_2 = -\frac{4}{3}$	$\lambda_2 < 0$ ✗

Resolver KKT: receita e 2^J casos

Receita

1. Escrever $\mathcal{L}$ e as condições. 2. Escolher um caso: cada g_j ativa ($g_j = 0$) ou com $\lambda_j = 0$. 3. Resolver o sistema. 4. Verificar admissibilidade e $\lambda_j \geq 0$. 5. Classificar os pontos KKT.

Exemplo 1. $\mathcal{L} = (x_1 - 2)^2 + 2(x_2 - 1)^2 - \lambda_1(3 - x_1 - 4x_2) - \lambda_2(x_1 - x_2)$:

$$2(x_1 - 2) + \lambda_1 - \lambda_2 = 0, \quad 4(x_2 - 1) + 4\lambda_1 + \lambda_2 = 0, \quad \lambda_1 g_1 = 0, \quad \lambda_2 g_2 = 0, \quad \lambda_1, \lambda_2 \geq 0.$$

caso	hipótese	solução do sistema linear	verificação
1	$\lambda_1 = \lambda_2 = 0$	$\mathbf{x} = (2, 1)$	$g_1 = -3 < 0$: inadmissível ✗
2	$\lambda_1 = 0, g_2 = 0$	$\mathbf{x} = (\frac{4}{3}, \frac{4}{3}), \lambda_2 = -\frac{4}{3}$	$\lambda_2 < 0$ ✗
3	$g_1 = 0, \lambda_2 = 0$	$\mathbf{x} = (\frac{5}{3}, \frac{1}{3}), \lambda_1 = \frac{2}{3}$	$g_2 = \frac{4}{3} > 0, \lambda_1 \geq 0$ ✓

Resolver KKT: receita e 2^J casos

Receita

1. Escrever $\mathcal{L}$ e as condições. 2. Escolher um caso: cada g_j ativa ($g_j = 0$) ou com $\lambda_j = 0$. 3. Resolver o sistema. 4. Verificar admissibilidade e $\lambda_j \geq 0$. 5. Classificar os pontos KKT.

Exemplo 1. $\mathcal{L} = (x_1 - 2)^2 + 2(x_2 - 1)^2 - \lambda_1(3 - x_1 - 4x_2) - \lambda_2(x_1 - x_2)$:

$$2(x_1 - 2) + \lambda_1 - \lambda_2 = 0, \quad 4(x_2 - 1) + 4\lambda_1 + \lambda_2 = 0, \quad \lambda_1 g_1 = 0, \quad \lambda_2 g_2 = 0, \quad \lambda_1, \lambda_2 \geq 0.$$

caso	hipótese	solução do sistema linear	verificação
1	$\lambda_1 = \lambda_2 = 0$	$\mathbf{x} = (2, 1)$	$g_1 = -3 < 0$: inadmissível ✗
2	$\lambda_1 = 0, g_2 = 0$	$\mathbf{x} = (\frac{4}{3}, \frac{4}{3}), \lambda_2 = -\frac{4}{3}$	$\lambda_2 < 0$ ✗
3	$g_1 = 0, \lambda_2 = 0$	$\mathbf{x} = (\frac{5}{3}, \frac{1}{3}), \lambda_1 = \frac{2}{3}$	$g_2 = \frac{4}{3} > 0, \lambda_1 \geq 0$ ✓
4	$g_1 = g_2 = 0$	$\mathbf{x} = (\frac{3}{5}, \frac{3}{5}), \lambda_1 = \frac{22}{25}, \lambda_2 = -\frac{48}{25}$	$\lambda_2 < 0$ ✗

Sobrevive o caso 3 — o que a figura já mostrava (g_1 ativa, g_2 inativa): $\mathbf{x}^* = (\frac{5}{3}, \frac{1}{3}), f^* = 1$. Com J restrições são 2^J casos: à mão só em problemas pequenos; os algoritmos (4.3) evitam esta enumeração.

Duas restrições ativas: do *span* ao cone

Exemplo 2: verificar um candidato.


$\min (x_1 - 3)^2 + (x_2 - 2)^2$ s.a. $g_1 = 5 - x_1^2 - x_2^2 \geq 0$,
 $g_2 = 4 - x_1 - 2x_2 \geq 0$, $g_3 = x_1 \geq 0$, $g_4 = x_2 \geq 0$.

Candidato $\mathbf{x} = (2, 1)$: admissível, ativas $I = \{1, 2\}$
($g_1 = g_2 = 0$; $g_3 = 2$, $g_4 = 1$), logo $\lambda_3 = \lambda_4 = 0$.

$$\nabla f = (-2, -2), \quad \nabla g_1 = (-4, -2), \quad \nabla g_2 = (-1, -2):$$

$$\begin{pmatrix} -2 \\ -2 \end{pmatrix} = \lambda_1 \begin{pmatrix} -4 \\ -2 \end{pmatrix} + \lambda_2 \begin{pmatrix} -1 \\ -2 \end{pmatrix} \Rightarrow \lambda_1 = \frac{1}{3}, \quad \lambda_2 = \frac{2}{3}.$$

Ambos ≥ 0 e $\nabla g_1, \nabla g_2$ independentes (LICQ): $(2, 1)$ é ponto KKT, $f = 2$ — e mínimo global (página seguinte).



Do span ao cone

- 4.1: com igualdades, ∇f está no **espaço gerado** pelas normais, com coeficientes de qualquer sinal.
- 4.2: com desigualdades ativas, ∇f está no **cone** gerado pelas normais ativas: coeficientes $\lambda_j \geq 0$.

KKT dá candidatos; quando bastam?

Em geral

mínimo local (com LICQ) $\Rightarrow$ ponto KKT
ponto KKT $\nRightarrow$ mínimo

$\min -x^2$ s.a. $g_1 = x + 1 \geq 0$, $g_2 = 2 - x \geq 0$: **três** pontos KKT.


- $x = -1$ (g_1 ativa, $\lambda_1 = 2$): mínimo local, $f = -1$.
- $x = 0$ (ambas inativas, $\lambda = 0$, $f' = 0$): **máximo**.
- $x = 2$ (g_2 ativa, $\lambda_2 = 4$): mínimo global, $f = -4$.

KKT produz candidatos; depois é preciso classificá-los — como em 4.1.

No caso convexo

f convexa, g_j côncavas, h_ℓ afins $\Rightarrow$

ponto KKT $\Rightarrow$ mínimo global



Porquê g_j côncavas? Com $g_j \geq 0$, é a concavidade que torna $\{x : g_j(x) \geq 0\}$ convexo (com $c \leq 0$ seriam as c convexas). Os exemplos 1 e 2 são convexas: os seus pontos KKT são mínimos globais.

Limitações das condições KKT

Como procedimento de resolução

Não são um algoritmo

Dizem o que uma solução deve satisfazer, não como a encontrar. Enumerar conjuntos ativos: até 2^J casos — só para problemas pequenos. Os algoritmos (4.3) existem para evitar isto.

Como condições

Não garantem mínimo

Fora do caso convexo, um ponto KKT pode ser mínimo local, máximo ou ponto de sela.

Precisam de regularidade

Sem uma qualificação das restrições, um mínimo pode **não ser** ponto KKT → «Quando KKT falha».

São locais e diferenciáveis

Num problema não convexo pode haver outro ponto admissível melhor (cap. 5). Exigem derivadas: discretas, não suaves ou caixa negra pedem outras ferramentas.


Então para que servem? Caracterizar soluções, verificar candidatos, interpretar restrições (multiplicadores) e fundamentar os algoritmos numéricos.

O que medem os multiplicadores

Relaxe-se a restrição j : $g_j(\mathbf{x}) + \delta \geq 0$ (a região cresce). O ótimo varia como

$$\frac{df^*}{d\delta} = -\lambda_j^* \quad (\text{sob regularidade}).$$

- λ_j^* é o **preço-sombra** da restrição: quanto se ganha por unidade de relaxação.
- Inativa: $\lambda_j^* = 0$, relaxar não ajuda. Ativa com λ_j^* grande: é a restrição que mais “custa” (com as restrições na mesma escala).
- No exemplo 1: $x_1 + 4x_2 \leq b$, $b = 3 \rightarrow 3,1$: f^* passa de 1 a $\approx 1 - \frac{2}{3} \cdot 0,1 = 0,933$ (valor exato: 0,934).
- Na produção do 1.1 (PL): “uma hora extra de máquina vale 10 €” — os preços-sombra da máquina e da mão de obra são exatamente estes λ_j ; é a informação que o linprog devolve em lambda.



Quando KKT falha: LICQ


$$\min -x_1 \quad \text{s.a.} \quad g_1 = (1 - x_1)^3 - x_2 \geq 0, \quad g_2 = x_2 \geq 0.$$

- A região é a “cunha” entre a cúbica e o eixo; o mínimo é o bico $\mathbf{x}^* = (1, 0)$, $f^* = -1$.
- Aí ambas ativas: $\nabla g_1 = (0, -1)$, $\nabla g_2 = (0, 1)$ — **dependentes** (a cúbica chega ao eixo com tangente horizontal).
- $\nabla f = (-1, 0)$ não é combinação de $(0, \mp 1)$: **não existem** λ_1, λ_2 . $\mathbf{x}^*$ é mínimo mas não é ponto KKT.

LICQ

Gradientes das igualdades e das desigualdades **ativas** linearmente independentes em $\mathbf{x}^*$.

Sem uma qualificação das restrições, um mínimo pode **não admitir multiplicadores** KKT.



Como em 4.1 («Porque falha»): as normais dependentes deixam de descrever as direções em que se pode andar.

Nota: com restrições todas afins (PL, exemplo 1), KKT é necessária sem qualificação; há qualificações mais fracas do que a LICQ (MFCQ; Slater, em problemas convexos).

1. $\min -\ln(x_1 + 1) - x_2$ s.a. $3 - 2x_1 - x_2 \geq 0$, $x_1 \geq 0$, $x_2 \geq 0$. $\mathbf{x}^* = (0, 3)$; ativas: a 1.ª e $x_1 \geq 0$.

2. $\min x_1^2 + x_2^2$ s.a. $5 - x_1^2 - x_2^2 \geq 0$, $x_1 + 2x_2 = 4$, $x_1, x_2 \geq 0$. $\mathbf{x}^* = (\frac{4}{5}, \frac{8}{5})$, $\beta = \frac{8}{5}$; só a igualdade é ativa.

3. Escreva as condições KKT para $\min -\mathbf{c}^T \mathbf{x}$ s.a. $\mathbf{b} - A\mathbf{x} \geq 0$, $\mathbf{x} \geq 0$ (PL) e interprete os multiplicadores.

$$A^T \boldsymbol{\lambda} - \mathbf{w} = \mathbf{c}, \boldsymbol{\lambda}, \mathbf{w} \geq 0, \boldsymbol{\lambda}^T (\mathbf{b} - A\mathbf{x}) = 0, \mathbf{w}^T \mathbf{x} = 0: \text{ é o dual.}$$

4. Para a lata de 4.1 (h = altura), acrescente $h \leq 6$ cm, isto é, $g = 6 - h \geq 0$. Mostre que a solução muda e calcule o novo λ .

$$h^* = 6 \text{ cm}, r^* = 4,18 \text{ cm}, A^* = 267,7 \text{ cm}^2; \lambda^* \approx 5,19 \text{ cm}^2/\text{cm}.$$

Em MATLAB

`[x,fval,exitflag,output,lambda] = fmincon(f, x0, A, b, Aeq, beq, lb, ub, nonlcon)`
resolve o problema e devolve os multiplicadores: `lambda.ineqnonlin`, `lambda.eqnonlin`,
`lambda.lower`, `lambda.upper`.

O MESMO EM PYTHON

`r = scipy.optimize.minimize(f, x0, method='trust-constr',
constraints=[NonlinearConstraint(g, 0, np.inf)]);` os multiplicadores vêm em `r.v`.

- **Convenções de sinal diferentes:** o `fmincon` usa $c(\mathbf{x}) \leq 0$ e $c_{eq}(\mathbf{x}) = 0$; o SciPy tem a sua. Desigualdades ($c = -g$): `lambda.ineqnonlin` são os λ_j daqui. Igualdades: sinal trocado, `lambda.eqnonlin` = $-\beta_\ell$ (o `fmincon` soma: $\mathcal{L} = f + \dots + \lambda_{eq}^T c_{eq}$, como em 4.1).
- Regra prática: **verificar contra KKT à mão** num exemplo pequeno (p. ex. o exemplo 2: $\lambda_1 = \frac{1}{3}$, $\lambda_2 = \frac{2}{3}$) antes de interpretar.
- Por defeito o `fmincon` usa um método de *pontos interiores*, cuja ideia veremos em 4.3.2.

O QUE DEVE FICAR — 4.2

1. Cada desigualdade, no ótimo, ou está **inativa** ($\lambda_j = 0$: é como se não existisse) ou **ativa** (igualdade que só empurra para dentro: $\lambda_j \geq 0$); numa equação, **complementaridade** $\lambda_j g_j = 0$ (ativa com $\lambda_j = 0$ também é possível).
2. **KKT = Lagrange + sinal + complementaridade**: $\nabla f = \sum_j \lambda_j \nabla g_j + \sum_\ell \beta_\ell \nabla h_\ell$; com desigualdades ativas, ∇f está no cone das suas normais.
3. **Necessárias** sob uma qualificação (LICQ; sem ela, um mínimo pode não ter multiplicadores); **suficientes no caso convexo** (f convexa, g_j côncavas, h_ℓ afins): ponto KKT $\Rightarrow$ mínimo global. Fora disso, candidatos a classificar.
4. λ_j é o **preço-sombra**: quanto desce f^* por unidade de relaxação da restrição j .

A seguir (4.3): KKT diz *o que* é uma solução, não *como* a encontrar — transformar o problema com restrições numa sequência de problemas sem restrições, resolvidos com os métodos do cap. 3.

Referências Lista completa: *Bibliografia da UC*, no fim do PDF da UC.

- Nocedal, J., Wright, S. J., *Numerical Optimization*, 2.^a ed., Springer, 2006 — cap. 12.
- Fletcher, R., *Practical Methods of Optimization*, 2.^a ed., Wiley, 1987.
- Deb, K., *Optimization for Engineering Design: Algorithms and Examples*, 2.^a ed., PHI Learning, 2012 — convenção $g_j \geq 0$.

Recursos

- MATLAB: `fmincon (lambda.ineqnonlin, .eqnonlin, .lower, .upper)`, `linprog` (Optimization Toolbox).
- Python: `scipy.optimize.minimize(..., method='trust-constr', constraints=[NonlinearConstraint(g, 0, np.inf)])`, multiplicadores em r.v.