


Otimização

5.2 *Simulated annealing*

José Firmino Aguilar Madeira


De GLODS para SA: e se tivermos apenas um ponto?



A função de referência do capítulo. De $x_0 = 6$, um método local (caps. 2–4) termina em $x \approx 5.99$ ($f \approx 1.25$), não em $x^* = 2.47$: para lá chegar é preciso **subir** duas barreiras (a mais alta em $x \approx 3.68$).

5.1 (GLODS): várias pesquisas, para encontrar outras bacias.

De GLODS para SA: e se tivermos apenas um ponto?




A função de referência do capítulo. De $x_0 = 6$, um método local (caps. 2–4) termina em $x \approx 5.99$ ($f \approx 1.25$), não em $x^* = 2.47$: para lá chegar é preciso **subir** duas barreiras (a mais alta em $x \approx 3.68$).

5.1 (GLODS): várias pesquisas, para encontrar outras bacias.

Pergunta: e se mantivermos **apenas um ponto**, mas lhe permitirmos **atravessar barreiras**?

De GLODS para SA: e se tivermos apenas um ponto?



A função de referência do capítulo. De $x_0 = 6$, um método local (caps. 2–4) termina em $x \approx 5.99$ ($f \approx 1.25$), não em $x^* = 2.47$: para lá chegar é preciso **subir** duas barreiras (a mais alta em $x \approx 3.68$).


5.1 (GLODS): várias pesquisas, para encontrar outras bacias.

Pergunta: e se mantivermos apenas um ponto, mas lhe permitirmos **atravessar barreiras**?

A ideia do *simulated annealing*


Sair de um mínimo local exige **aceitar, por vezes, subir**.

Aceitar uma subida? O critério de Metropolis



Pergunta: o vizinho é pior. Aceitamos?


Aceitar uma subida? O critério de Metropolis



Pergunta: o vizinho é pior. Aceitamos?

Um método local: $\Delta f > 0 \Rightarrow$ **não**. *Simulated annealing*: $\Delta f > 0 \Rightarrow$ **talvez**.

Aceitar uma subida? O critério de Metropolis




Pergunta: o vizinho é pior. Aceitamos?

Um método local: $\Delta f > 0 \Rightarrow$ **não**. *Simulated annealing*: $\Delta f > 0 \Rightarrow$ **talvez**.

Critério de Metropolis

Aceita-se sempre se $\Delta f = f(x') - f(x_k) \leq 0$; se


$\Delta f > 0$, com probabilidade $P(\text{aceitar}) = e^{-\Delta f/T}$.



A mesma subida $\Delta f = 1$: aceite com prob. 0,82 a $T = 5$, 0,37 a $T = 1$, 0,007 a $T = 0,2$.

T não é uma temperatura física: é um parâmetro na escala de f .

Aceitar uma subida? O critério de Metropolis




Pergunta: o vizinho é pior. Aceitamos?

Um método local: $\Delta f > 0 \Rightarrow$ **não**. *Simulated annealing*: $\Delta f > 0 \Rightarrow$ **talvez**.

Critério de Metropolis

Aceita-se sempre se $\Delta f = f(x') - f(x_k) \leq 0$; se

$\Delta f > 0$, com probabilidade $P(\text{aceitar}) = e^{-\Delta f/T}$.



A mesma subida $\Delta f = 1$: aceite com prob. 0,82 a $T = 5$, 0,37 a $T = 1$, 0,007 a $T = 0,2$.

T não é uma temperatura física: é um parâmetro na escala de f .

De onde vem o nome: um metal aquecido e **arrefecido lentamente** cristaliza num estado de energia mínima; arrefecido depressa fica num estado de energia mais alta. Kirkpatrick, Gelatt e Vecchi (1983) transpuseram a ideia para otimização com o critério de Metropolis (1953).

Quente → frio: exploração → refinamento

T alta

$P(\text{aceitar subida}) \approx 1$: passeia entre bacias
— exploração.




T intermédia

aceita algumas subidas — transição:
instala-se numa bacia, com excursões.



T baixa

$P(\text{aceitar subida}) \approx 0$: só desce —
refinamento.



Uma corrida na função de referência: aceites (azul) e rejeitados (cinzento); em baixo, T por patamares, em escala log.

exploração → refinamento — a linguagem da abertura do capítulo, num só parâmetro que desce.

Simulated annealing (como nas aulas)

- Passo 1** Escolher $\mathbf{x}_0$, $T = T_0$ (alta), n (aceites por temperatura), $\alpha \in [0,5; 0,99]$ e T_s ; fazer $t = 0$.
- Passo 2** Gerar um vizinho aleatório $\mathbf{x}'$ de $\mathbf{x}_t$ (aqui $\mathbf{x}_t + \sigma\zeta$, $\zeta \sim N(\mathbf{0}, I)$, projetado em X).
- Passo 3** $\Delta f = f(\mathbf{x}') - f(\mathbf{x}_t)$. Se $\Delta f < 0$, aceitar: $\mathbf{x}_{t+1} = \mathbf{x}'$, $t = t + 1$. Senão, gerar $r \sim U(0, 1)$: se $r < e^{-\Delta f/T}$, aceitar; senão, **voltar ao passo 2**.
- Passo 4** Se $T < T_s$, **terminar**. Senão, se $t \bmod n = 0$, fazer $T = \alpha T$. Voltar ao passo 2.

Deb (2012), cap. 6.

t conta os pontos **aceites**; n_f conta todas as propostas. A T baixa quase tudo é rejeitado e cada patamar custa **cada vez mais avaliações**.

na prática: guardar também o melhor visitado $\mathbf{x}_{\text{best}}$

O algoritmo devolve o ponto final $\mathbf{x}_t$, que pode ter piorado *de propósito*. Só valores de f .

Variáveis discretas

$x_i \in \{1, \dots, 5\}$ (espessura, tipo, componente): mudar uma variável ao acaso para a categoria adjacente, $(2, 4, 1, 3) \rightarrow (2, 4, 2, 3)$. Permutações: trocar duas posições, $(1, 2, 3, 4, 5) \rightarrow (1, 4, 3, 2, 5)$. **Sem distância contínua nem derivadas: basta saber gerar um vizinho.**

Depressa demais

T cai antes de o ponto ter explorado:
comporta-se **rapidamente como um método local** e fica na primeira bacia.

Devagar demais

Explora melhor, mas **custa muitas avaliações**:
os patamares frios são os mais caros.

Nas aulas: patamares de n aceites, depois $T = \alpha T$.
Variante: $T = c T$ a cada proposta, com orçamento $N_{\max}$.

Geman, S., Geman, D., IEEE Trans. Pattern Anal. Mach. Intell. 6(6):721–741, 1984.


Hajek, B., *Cooling schedules for optimal annealing*, Math. Oper. Res. 13(2):311–329, 1988.

Teoria (Geman & Geman, 1984; Hajek, 1988)

Num espaço finito, com arrefecimento **logarítmico** $T_k = d / \ln(1 + k)$, $k \geq 1$, e $d \geq d^*$ (profundidade do mínimo local não global mais fundo), a probabilidade de estar num ótimo global tende para 1.


A garantia teórica exige um arrefecimento demasiado lento para ser normalmente usado na prática. Os esquemas práticos (geométricos) não têm essa garantia (o melhor ponto visitado tem pelo menos a garantia da pesquisa aleatória, 3.2.1 — igualmente lenta).

Uma execução passo a passo: $x_0 = 6$, $T_0 = 3$, $\alpha = 0,8$, $n = 10$, $T_s = 0,05$, $\sigma = 0,5$




- $n_f = 60$, $T \approx 1,2$: já na bacia de 4,7 (mínimo local, $f = 0,89$), mas sobe e desce muito.

Uma execução passo a passo: $x_0 = 6$, $T_0 = 3$, $\alpha = 0,8$, $n = 10$, $T_s = 0,05$, $\sigma = 0,5$




- $n_f = 60$, $T \approx 1,2$: já na bacia de 4,7 (mínimo local, $f = 0,89$), mas sobe e desce muito.
- $n_f = 150$, $T \approx 0,32$: instalado nessa bacia, com excursões; cada patamar já pede ≈ 30 propostas.

Uma execução passo a passo: $x_0 = 6$, $T_0 = 3$, $\alpha = 0,8$, $n = 10$, $T_s = 0,05$, $\sigma = 0,5$



- $n_f = 60$, $T \approx 1,2$: já na bacia de 4,7 (mínimo local, $f = 0,89$), mas sobe e desce muito.
- $n_f = 150$, $T \approx 0,32$: instalado nessa bacia, com excursões; cada patamar já pede ≈ 30 propostas.
- $n_f = 300$, $T \approx 0,11$: excursões raras e curtas.


Uma execução passo a passo: $x_0 = 6$, $T_0 = 3$, $\alpha = 0,8$, $n = 10$, $T_s = 0,05$, $\sigma = 0,5$



- $n_f = 60$, $T \approx 1,2$: já na bacia de 4,7 (mínimo local, $f = 0,89$), mas sobe e desce muito.
- $n_f = 150$, $T \approx 0,32$: instalado nessa bacia, com excursões; cada patamar já pede ≈ 30 propostas.
- $n_f = 300$, $T \approx 0,11$: excursões raras e curtas.

Pergunta: acham que vai conseguir escapar? (É estocástico: *pode ou não.*)

Uma execução passo a passo: $x_0 = 6$, $T_0 = 3$, $\alpha = 0,8$, $n = 10$, $T_s = 0,05$, $\sigma = 0,5$




- $n_f = 60$, $T \approx 1,2$: já na bacia de 4,7 (mínimo local, $f = 0,89$), mas sobe e desce muito.
- $n_f = 150$, $T \approx 0,32$: instalado nessa bacia, com excursões; cada patamar já pede ≈ 30 propostas.
- $n_f = 300$, $T \approx 0,11$: excursões raras e curtas.

Pergunta: acham que vai conseguir escapar? (*É estocástico: pode ou não.*)

Em $n_f = 325$ ($T = 0,084$) uma proposta cai **do outro lado da barreira**, num ponto mais baixo, e é aceite ($4,59 \rightarrow 2,92$). Termina com $T = 0,043 < T_s$ em $x_t = 2,457$: $n_f = 507$, 191 aceites. Uma só corrida (semente 3): **correu bem desta vez.**

Como se atravessa uma barreira?



Da bacia de 4,72 para a de 2,47: barreira de altura $H \approx 4,8$.

O SA não sabe onde está a bacia melhor. Há duas maneiras de lá chegar:

Uma sequência de subidas aceites

A T aproximadamente constante, subidas com elevação total H têm um fator de aceitação $e^{-H/T}$: 0,20 a $T = 3$, 0,008 a $T = 1$, 6×10^{-6} a $T = 0,4$. **T baixa prende.**

Um salto

Uma proposta cai diretamente do outro lado, num ponto mais baixo — aceite como descida. Foi o que aconteceu na execução anterior ($n_f = 325$: de 4,59 para 2,92, a $3,3\sigma$). **σ pequeno torna estes saltos raros.**

Mais orçamento: mais tentativas.

Uma execução não chega: 100 corridas

Sucesso ($|x - x^*| < 0,3$) em 100 corridas, sempre de $x_0 = 6$, com $T_s = 0,05$:

σ	T_0	α	n	n_f [Q1; Q3]	sucesso	
					x_t final	melhor
0,5	3,0	0,80	10	693 [525; 828]	60%	63%
0,5	3,0	0,50	10	148 [136; 168]	11%	11%
0,5	3,0	0,95	10	3318 [3187; 3470]	69%	93%
0,5	0,3	0,80	10	404 [368; 440]	15%	15%
1,0	3,0	0,80	10	1518 [1445; 1578]	60%	92%
0,5	3,0	0,80	50	3942 [3669; 4125]	64%	93%

Com os parâmetros da execução anterior, **60%**. A execução bem-sucedida era uma entre muitas possíveis: **uma execução de SA não é uma conclusão experimental.**

Algoritmo estocástico $\Rightarrow$ várias corridas

Reportar **taxa de sucesso**, **mediana** e **dispersão** sobre ≥ 20 –30 corridas, com sementes fixas.

Com exploração longa ($\alpha = 0,95$, $\sigma = 1$, $n = 50$) o ponto final pode ficar na bacia de $-1,08$ ($f = -4,05$, quase tão baixa como a do global): **guardar o melhor visitado** compensa.

O que fazem os parâmetros?

parâmetro	demasiado pequeno	demasiado grande
T_0	começa quase local ($T_0 = 0,3$: 15%)	aceita quase tudo; gasta avaliações a vaguear
σ	não atravessa barreiras	propostas distantes, mais rejeitadas ($\sigma = 1$: n_f duplica)
α	arrefece depressa ($\alpha = 0,5$: 11%)	exploração longa ($\alpha = 0,95$: $n_f \approx 3300$)
n	pouco tempo a cada temperatura	maior custo ($n = 50$: $n_f \approx 3900$)
T_s	patamares frios muito caros	termina antes de refinar

T : o que aceitamos

tolerância a piorar


σ : onde propomos

exploração geométrica — compatível com a escala das bacias (aqui, $\sigma = 1$: 92% com o melhor visitado)


T e σ têm papéis diferentes; o arrefecimento (T_0 , α , n , T_s) equilibra exploração e refinamento.

Em duas dimensões: Rastrigin

$f(\mathbf{x}) = 20 + \sum_{i=1}^2 (x_i^2 - 10 \cos 2\pi x_i)$ em $[-5,12; 5,12]^2$: 121 mínimos locais numa grelha; global $f = 0$ em $\mathbf{0}$.



Aqui o arrefecimento rápido também resulta ($\alpha = 0,3$: 97%); o efeito do arrefecimento vê-se na função 1D.



- $T_0 = 20$, $\alpha = 0,5$, $n = 10$, $T_s = 0,1$, $\sigma = 0,5$, de $(4, -4)$: termina em $f = 0,18$ (bacia do global) com $n_f = 5421$ e **só 81 aceites**: quase todas as avaliações vão para os patamares frios.
- 30 corridas de pontos aleatórios, sucesso $f < 1$: 90% (melhor visitado: 100%), $n_f \approx 4800$; com $\alpha = 0,8$, 97%, mas $n_f \approx 18600$. Noutra amostra (a do 5.3): Nelder–Mead **3%** ($n_f \approx 90$), SA 97% ($n_f \approx 5300$).
- Precisão final modesta ($f \sim 10^{-1}$): terminar com uma descida local (cap. 3).

O preço do *simulated annealing*

Vantagens

- Extremamente simples.
- Só valores de f .
- Consegue escapar de mínimos locais.
- Adapta-se a variáveis discretas e permutações através da vizinhança.
- Uma avaliação por proposta.

SA → método local

O SA encontra uma boa bacia; um método local (caps. 2–3) refina. No exemplo: de $x_{SA} = 2,457$, uma pesquisa direta chega a $|x - x^*| < 10^{-6}$ com **38 avaliações** (o SA usou 507).

Limitações

- Muitas avaliações.
- Resultado aleatório.
- T_0 , α , n , σ pesam muito no desempenho.
- Mais eficaz a explorar do que a refinar com alta precisão.
- A garantia global é assintótica, com esquemas impraticavelmente lentos.

Explorar globalmente e refinar localmente são tarefas diferentes — e podem ser feitas por métodos diferentes (a filosofia do GLODS, vista de outra maneira).

O SA não “sabe” que encontrou o global: devolve o ponto final (ou o melhor visitado), sem certificado de globalidade.

GLODS e SA: o que mudou?

	GLODS (5.1)	SA (5.2)
Estado	vários pontos	um ponto
Como escapa	o <i>search</i> encontra outras regiões	aceita subidas
Pesquisa local	pesquisa direta (<i>poll</i>)	não explícita (passeio aleatório)
Memória	lista de mínimos / pesquisas	ponto corrente (+ $\mathbf{x}_{\text{best}}$)
Aleatório?	depende do <i>search</i>	sim
Saída natural	vários mínimos	o ponto final (ou $\mathbf{x}_{\text{best}}$)

Não é “qual é melhor”: são duas respostas diferentes à mesma pergunta do capítulo.

No computador: implementação em MATLAB

```
% nucleo de SimulatedAnnealing(f, x0, T0, alpha, n, Ts, sigma, lb, ub)
x = x0; fx = f(x); T = T0; t = 0;
while true
    xn = min(max(x + sigma*randn(size(x)), lb), ub); % passo 2
    fn = f(xn); df = fn - fx;
    if df < 0 || rand < exp(-df/T) % passo 3
        x = xn; fx = fn; t = t + 1;
        if T < Ts, break, end % passo 4
        if mod(t, n) == 0, T = alpha*T; end
    end
end
```

A função completa (SimulatedAnnealing) guarda também
info.xbest, conta info.nfev e tem um limite nfmax.

```
f = @(x) 20 + sum(x.^2 - 10*cos(2*pi*x));
for s = 1:30 % 30 corridas
    rng(s); x0 = -5.12 + 10.24*rand(1,2);
    [x, fx, info] = SimulatedAnnealing(f, x0, ...
        20, 0.5, 10, 0.1, 0.5, -5.12, 5.12);
    fs(s) = fx; nf(s) = info.nfev;
end
median(fs), prctile(fs, [25 75]), mean(fs < 1)
```

rng(s) torna cada corrida reproduzível; o
resultado reporta-se com mediana, quartis
e taxa de sucesso. Projetar nos limites
(min/max) é só uma opção simples.

O QUE DEVE FICAR — 5.2

1. **Exploração global:** um único ponto que aceita, por vezes, piorar.
2. T controla a aceitação de subidas; σ , a vizinhança. Nas aulas: n aceites a cada T , $T = \alpha T$, até $T < T_s$; na prática, guardar o melhor visitado.
3. **Informação e custo:** só valores de f ; uma avaliação por proposta, muitas propostas.
4. **Aleatoriedade:** uma execução não basta — várias corridas; taxa de sucesso, mediana e dispersão.
5. **Garantia:** ponto corrente: só assintótica (espaço finito, arrefecimento logarítmico); melhor visitado: a da pesquisa aleatória (3.2.1). Com orçamento finito, sem certificado de ótimo global.

GLODS: vários pontos que exploram diferentes bacias. **SA:** um ponto que pode subir.

E se explorássemos várias regiões em simultâneo e deixássemos as boas soluções trocar informação?

→ população → 5.3 Algoritmos genéticos.

Referências e recursos

Referências Lista completa: *Bibliografia da UC*, no fim do PDF da UC.

- Deb, K., *Optimization for Engineering Design*, 2.^a ed., PHI Learning, 2012 — cap. 6 (o algoritmo das aulas).
- Kirkpatrick, S., Gelatt Jr., C. D., Vecchi, M. P., *Optimization by simulated annealing*, Science 220(4598):671–680, 1983.
- Hajek, B., *Cooling schedules for optimal annealing*, Mathematics of Operations Research 13(2):311–329, 1988.
- Hillier, F. S., Lieberman, G. J., *Introduction to Operations Research*, 2024 Release, McGraw-Hill, 2024 — metaheurísticas.

Recursos

- Código complementar: `SimulatedAnnealing (info.nfev, info.xbest)`. MATLAB: `rng(s); simulannealbnd` (Global Optimization Toolbox).
- Trabalhos de alunos (estágios na Tecmic, dados reais): Santos, J. R. (2022) e Costa, M. O. (2023), alocação de serviços de transporte; Jin, C. (2024), afetação de veículos da Carris, com SA e NSGA-II; Macau, R. O. (2026), escalonamento de motoristas, com SA, pesquisa tabu e greedy comparados. Referências completas na *Bibliografia da UC*.