


Otimização

5.2 *Simulated annealing*

José Firmino Aguilar Madeira


De GLODS para SA: e se tivermos apenas um ponto?



A função de referência do capítulo. De $x_0 = 6$, um método local (caps. 2–4) termina em $x \approx 5,99$ ($f \approx 1,25$), não em $x^* = 2,47$: para lá chegar é preciso **subir** duas barreiras (a mais alta em $x \approx 3,68$).

5.1 (GLODS): várias pesquisas, para encontrar outras bacias.

De GLODS para SA: e se tivermos apenas um ponto?




A função de referência do capítulo. De $x_0 = 6$, um método local (caps. 2–4) termina em $x \approx 5.99$ ($f \approx 1.25$), não em $x^* = 2.47$: para lá chegar é preciso **subir** duas barreiras (a mais alta em $x \approx 3.68$).

5.1 (GLODS): várias pesquisas, para encontrar outras bacias.

Pergunta: e se mantivermos **apenas um ponto**, mas lhe permitirmos **atravessar barreiras**?

De GLODS para SA: e se tivermos apenas um ponto?



A função de referência do capítulo. De $x_0 = 6$, um método local (caps. 2–4) termina em $x \approx 5,99$ ($f \approx 1,25$), não em $x^* = 2,47$: para lá chegar é preciso **subir** duas barreiras (a mais alta em $x \approx 3,68$).


5.1 (GLODS): várias pesquisas, para encontrar outras bacias.

Pergunta: e se mantivermos **apenas um ponto**, mas lhe permitirmos **atravessar barreiras**?

A ideia do *simulated annealing*


Sair de um mínimo local exige **aceitar, por vezes, subir**.

Aceitar uma subida? O critério de Metropolis



Pergunta: o vizinho é pior. Aceitamos?


Aceitar uma subida? O critério de Metropolis



Pergunta: o vizinho é pior. Aceitamos?

Um método local: $\Delta f > 0 \Rightarrow$ **não**. *Simulated annealing*: $\Delta f > 0 \Rightarrow$ **talvez**.

Aceitar uma subida? O critério de Metropolis




Pergunta: o vizinho é pior. Aceitamos?

Um método local: $\Delta f > 0 \Rightarrow$ **não**. *Simulated annealing*: $\Delta f > 0 \Rightarrow$ **talvez**.

Critério de Metropolis

Aceita-se sempre se $\Delta f = f(x') - f(x_k) \leq 0$; se


$\Delta f > 0$, com probabilidade $P(\text{aceitar}) = e^{-\Delta f/T}$.



A mesma subida $\Delta f = 1$: aceite com prob. 0,82 a $T = 5$, 0,37 a $T = 1$, 0,07 a $T = 0,2$.

T não é uma temperatura física: é um parâmetro na escala de f .

Aceitar uma subida? O critério de Metropolis




Pergunta: o vizinho é pior. Aceitamos?

Um método local: $\Delta f > 0 \Rightarrow$ **não**. *Simulated annealing*: $\Delta f > 0 \Rightarrow$ **talvez**.

Critério de Metropolis

Aceita-se sempre se $\Delta f = f(x') - f(x_k) \leq 0$; se $\Delta f > 0$, com probabilidade $P(\text{aceitar}) = e^{-\Delta f/T}$.



A mesma subida $\Delta f = 1$: aceite com prob. 0,82 a $T = 5$, 0,37 a $T = 1$, 0,007 a $T = 0,2$.

T não é uma temperatura física: é um parâmetro na escala de f .

De onde vem o nome: um metal aquecido e **arrefecido lentamente** cristaliza num estado de energia mínima; arrefecido depressa fica num estado de energia mais alta. Kirkpatrick, Gelatt e Vecchi (1983) transpuseram a ideia para otimização com o critério de Metropolis (1953).

Quente → frio: exploração → refinamento

T alta

$P(\text{aceitar subida}) \approx 1$: passeia entre bacias
— exploração.




T intermédia

aceita algumas subidas — transição:
instala-se numa bacia, com excursões.



T baixa

$P(\text{aceitar subida}) \approx 0$: só desce —
refinamento.



Uma corrida na função de referência: aceites (azul) e rejeitados (cinzento); em baixo, T_k em escala log.

exploração → refinamento — a linguagem da abertura do capítulo, num só parâmetro que desce.

Simulated annealing: $x_0, T_0, c \in (0, 1)$, passo

$\sigma, N_{\max}$

```
1:  $x \leftarrow x_0; f_x \leftarrow f(x); x_{\text{best}} \leftarrow x; f_{\text{best}} \leftarrow f_x; T \leftarrow T_0$ 
2: for  $k = 1, \dots, N_{\max}$  do
3:    $x' \leftarrow x + \sigma \zeta, \zeta \sim N(0, I)$ , projetado em  $X$   $\triangleright$  vizinho aleatório
4:    $f' \leftarrow f(x'); \Delta f \leftarrow f' - f_x$   $\triangleright$  a única avaliação da iteração
5:   if  $\Delta f \leq 0$  or  $\xi < e^{-\Delta f/T}, \xi \sim U(0, 1)$  then  $x \leftarrow x'; f_x \leftarrow f'$ 
6:   end if
7:   if  $f_x < f_{\text{best}}$  then  $x_{\text{best}} \leftarrow x; f_{\text{best}} \leftarrow f_x$ 
8:   end if
9:    $T \leftarrow c T$   $\triangleright$  arrefecimento geométrico
10: end for
11: return  $x_{\text{best}}$ 
```

$x_{\text{best}} \neq x_k$ necessariamente

Devolve-se o **melhor visitado**: o ponto corrente pode ter piorado *de propósito* (nos métodos de descida anteriores — pesquisa em linha, pesquisa direta — f no iterando nunca aumenta). Uma avaliação de f por iteração, $n_f = N_{\max} + 1$; só valores de f .

Variáveis discretas

$x_i \in \{1, \dots, 5\}$ (espessura, tipo, componente): mudar uma variável ao acaso para a categoria adjacente, $(2, 4, 1, 3) \rightarrow (2, 4, 2, 3)$. Permutações: trocar duas posições, $(1, 2, 3, 4, 5) \rightarrow (1, 4, 3, 2, 5)$. **Sem distância contínua nem derivadas: basta saber gerar um vizinho.**

Depressa demais

T cai antes de o ponto ter explorado:
comporta-se **rapidamente como um método local** e fica na primeira bacia.

Devagar demais

Explora melhor, mas **custa muitas avaliações**;
com $N_{\max}$ fixo pode nem chegar a refinar.

Esquemas usuais: geométrico $T_{k+1} = c T_k$
($c \approx 0,9-0,999$), ou por patamares (n_T iterações a cada T).

Geman, S., Geman, D., IEEE Trans. Pattern Anal. Mach. Intell. 6(6):721–741, 1984.


Hajek, B., *Cooling schedules for optimal annealing*, Math. Oper. Res. 13(2):311–329, 1988.

Teoria (Geman & Geman, 1984; Hajek, 1988)

Num espaço finito, com arrefecimento **logarítmico** $T_k = d / \ln(1 + k)$, $k \geq 1$, e $d \geq d^*$ (profundidade do mínimo local não global mais fundo), a probabilidade de estar num ótimo global tende para 1.


A garantia teórica exige um arrefecimento demasiado lento para ser normalmente usado na prática. Os esquemas práticos (geométricos) não têm essa garantia (o melhor ponto visitado tem pelo menos a garantia da pesquisa aleatória, 3.2.1 — igualmente lenta).

Uma execução passo a passo: $x_0 = 6$, $T_0 = 3$, $c = 0,98$, $\sigma = 0,5$, $N_{\max} = 400$




- $k = 30$, $T \approx 1,7$: ainda quente; sobe e desce com elevada taxa de aceitação em torno de x_0 .

Uma execução passo a passo: $x_0 = 6$, $T_0 = 3$, $c = 0,98$, $\sigma = 0,5$, $N_{\max} = 400$




- $k = 30$, $T \approx 1,7$: ainda quente; sobe e desce com elevada taxa de aceitação em torno de x_0 .
- $k = 100$, $T = 0,4$: instalou-se na bacia de $x = 4,7$ (mínimo local, $f = 0,89$), com excursões.

Uma execução passo a passo: $x_0 = 6$, $T_0 = 3$, $c = 0,98$, $\sigma = 0,5$, $N_{\max} = 400$



- $k = 30$, $T \approx 1,7$: ainda quente; sobe e desce com elevada taxa de aceitação em torno de x_0 .
- $k = 100$, $T = 0,4$: instalou-se na bacia de $x = 4,7$ (mínimo local, $f = 0,89$), com excursões.
- $k = 200$, $T = 0,05$: continua na bacia de $4,7$; as excursões são já raras e curtas.


Uma execução passo a passo: $x_0 = 6$, $T_0 = 3$, $c = 0,98$, $\sigma = 0,5$, $N_{\max} = 400$



- $k = 30$, $T \approx 1,7$: ainda quente; sobe e desce com elevada taxa de aceitação em torno de x_0 .
- $k = 100$, $T = 0,4$: instalou-se na bacia de $x = 4,7$ (mínimo local, $f = 0,89$), com excursões.
- $k = 200$, $T = 0,05$: continua na bacia de $4,7$; as excursões são já raras e curtas.

Pergunta: achas que vai conseguir escapar? (É estocástico: *pode ou não.*)

Uma execução passo a passo: $x_0 = 6$, $T_0 = 3$, $c = 0,98$, $\sigma = 0,5$, $N_{\max} = 400$




- $k = 30$, $T \approx 1,7$: ainda quente; sobe e desce com elevada taxa de aceitação em torno de x_0 .
- $k = 100$, $T = 0,4$: instalou-se na bacia de $x = 4,7$ (mínimo local, $f = 0,89$), com excursões.
- $k = 200$, $T = 0,05$: continua na bacia de $4,7$; as excursões são já raras e curtas.

Pergunta: achas que vai conseguir escapar? (É estocástico: *pode ou não.*)

Em $k = 315$ uma proposta cai **do outro lado da barreira**, num ponto mais baixo, e é aceite: $x = 2,464$, na bacia do ótimo global ($x^* = 2,468$).

Uma só corrida (semente 3 do script Python das figuras), $n_f = 401$. **Correu bem desta vez.**

Como se atravessa uma barreira?



Da bacia de 4,72 para a de 2,47: barreira de altura $H \approx 4,8$.

O SA não sabe onde está a bacia melhor. Há duas maneiras de lá chegar:

Uma sequência de subidas aceites

A T aproximadamente constante, subidas com elevação total H têm um fator de aceitação $e^{-H/T}$: 0,20 a $T = 3$, 0,008 a $T = 1$, 6×10^{-6} a $T = 0,4$. **T baixa prende.**

Um salto

Uma proposta cai diretamente do outro lado, num ponto mais baixo — aceite como descida. Foi o que aconteceu na execução anterior ($k = 315$: de 4,73 para 3,07, a $3,3\sigma$). **σ pequeno torna estes saltos raros.**

Mais orçamento: mais tentativas.

Uma execução não chega: 100 corridas

Sucesso ($|x - x^*| < 0,3$) em 100 corridas, sempre de $x_0 = 6$:

σ	T_0	c	$N_{\max}$	$T_{N_{\max}}$	sucesso
0,5	3,0	0,980	400	$9,3 \times 10^{-4}$	35%
0,5	3,0	0,900	400	$1,5 \times 10^{-18}$	19%
0,5	3,0	0,995	400	$4,0 \times 10^{-1}$	74%
0,5	0,3	0,980	400	$9,3 \times 10^{-5}$	20%
1,0	3,0	0,980	400	$9,3 \times 10^{-4}$	88%
0,5	3,0	0,980	2000	$8,5 \times 10^{-18}$	73%

Com os parâmetros da execução anterior, só **35%**. A execução bem-sucedida era uma entre muitas possíveis: **uma execução de SA não é uma conclusão experimental.**

Algoritmo estocástico $\Rightarrow$ várias corridas

Reportar **taxa de sucesso**, **mediana** e **dispersão** sobre ≥ 20 –30 corridas, com sementes fixas.

O mesmo vale para os algoritmos genéticos (5.3).

O que fazem os parâmetros?

parâmetro	demasiado pequeno	demasiado grande
T_0	começa quase local ($T_0 = 0,3$: 20%)	aceita quase tudo; gasta iterações a vaguear
σ	não atravessa barreiras	propostas demasiado distantes, poucas aceites
c	arrefece depressa ($c = 0,9$: 19%)	exploração longa; pode não chegar a refinar
$N_{\max}$ (orçamento)	orçamento insuficiente	maior custo ($N_{\max} = 2000$: 73%)

T : o que aceitamos

tolerância a piorar


σ : onde propomos

exploração geométrica — compatível com a escala das bacias (aqui, $\sigma = 1$: 88%)


T e σ têm papéis diferentes; o arrefecimento (T_0 , c , $N_{\max}$) equilibra exploração e refinamento.

Em duas dimensões: Rastrigin

$f(\mathbf{x}) = 10n + \sum_i (x_i^2 - 10 \cos 2\pi x_i)$, $n = 2$, em $[-5,12; 5,12]^2$: 121 mínimos locais numa grelha; global $f = 0$ em $\mathbf{0}$.



Neste problema, mesmo sem aceitar subidas ($T \approx 0$), dá 97% (30 corridas); o efeito do arrefecimento vê-se na função 1D (19% com $c = 0,9$).



- $T_0 = 20$, $c = 0,995$, $\sigma = 0,5$, $N_{\max} = 3000$, de $(4, -4)$: $f = 0,068$, $|\mathbf{x}| \approx 0,02$ (bacia do global). Primeiro um passeio pela grelha de mínimos; depois de $T \lesssim 1$ fixa-se.
- 30 corridas de pontos aleatórios: sucesso ($f < 1$) 100% com $c = 0,995$; 97% com 0,9–0,99; 90% com 0,999 ($T_{3000} \approx 1$: não chegou a arrefecer). Noutra amostra de 30 pontos (a do 5.3): Nelder–Mead 7% ($n_f \approx 87$), SA 100% ($n_f = 3001$).
- Precisão final modesta ($f \sim 10^{-2}$): terminar com uma descida local (cap. 3) a partir de $\mathbf{x}_{\text{best}}$.

O preço do *simulated annealing*

Vantagens

- Extremamente simples.
- Só valores de f .
- Consegue escapar de mínimos locais.
- Adapta-se a variáveis discretas e permutações através da vizinhança.
- Uma avaliação por iteração.

SA → método local

O SA encontra uma boa bacia; um método local (caps. 2–3) refina. No exemplo: de $x_{SA} = 2,464$, uma pesquisa direta chega a $|x - x^*| < 10^{-6}$ com **37 avaliações** (o SA usou 401).

Limitações

- Muitas iterações.
- Resultado aleatório.
- T_0 , c , σ influenciam fortemente o desempenho.
- Mais eficaz a explorar do que a refinar com alta precisão.
- A garantia global é assintótica, com esquemas impraticavelmente lentos.

Explorar globalmente e refinar localmente são tarefas diferentes — e podem ser feitas por métodos diferentes (a filosofia do GLODS, vista de outra maneira).

O SA não “sabe” que encontrou o global: devolve o melhor ponto visitado, sem certificado de globalidade.

GLODS e SA: o que mudou?

	GLODS (5.1)	SA (5.2)
Estado	vários pontos	um ponto
Como escapa	o <i>search</i> encontra outras regiões	aceita subidas
Pesquisa local	pesquisa direta (<i>poll</i>)	não explícita (passeio aleatório)
Memória	lista de mínimos / pesquisas	ponto corrente + melhor visitado
Aleatório?	depende do <i>search</i>	sim
Saída natural	vários mínimos	o melhor visitado

Não é “qual é melhor”: são duas respostas diferentes à mesma pergunta do capítulo.

No computador: implementação em MATLAB

```
% nucleo de SimulatedAnnealing(f, x0, T0, c, sigma, Nmax, lb, ub)
for k = 1:Nmax
    xn = x + sigma*randn(size(x));           % vizinho
    xn = min(max(xn, lb), ub);               % projetar em X
    fn = f(xn); df = fn - fx;
    if df <= 0 || rand < exp(-df/T)          % Metropolis
        x = xn; fx = fn;
        if fx < fbest, xbest = x; fbest = fx; end
    end
    T = c*T;                                % arrefecer
end
```

A função completa (SimulatedAnnealing, com info.nfev e info.nacc) está no código complementar da UC.

```
f = @(x) 20 + sum(x.^2 - 10*cos(2*pi*x));
for s = 1:30                                % 30 corridas
    rng(s); x0 = -5.12 + 10.24*rand(1,2);
    [x, fx, info] = SimulatedAnnealing(f, x0, ...
        20, 0.995, 0.5, 3000, -5.12, 5.12);
    fs(s) = fx;                             % info.nfev = 3001
end
median(fs), prctile(fs, [25 75]), mean(fs < 1)
```

rng(s) torna cada corrida reproduzível; o resultado reporta-se com mediana, quartis e taxa de sucesso. O MATLAB tem simulannealbnd (Global Optimization Toolbox), com arrefecimento e passo adaptativos e reaquecimentos. Projetar nos limites (min/max) altera a distribuição dos vizinhos junto à fronteira: é só uma opção simples.

O QUE DEVE FICAR — 5.2

1. **Exploração global:** um único ponto que aceita ocasionalmente piorar, para atravessar barreiras.
2. T controla a **aceitação** de subidas (alta: exploração; baixa: refinamento); σ , a **vizinhança**.
3. **Informação e custo:** só valores de f ; uma avaliação por iteração, muitas iterações.
4. **Aleatoriedade:** uma execução não basta — várias corridas; taxa de sucesso, mediana e dispersão.
5. **Garantia:** ponto corrente: só assintótica (espaço finito, arrefecimento logarítmico — impraticável); melhor visitado: a da pesquisa aleatória (3.2.1), igualmente lenta. Com orçamento finito, **sem certificado de ótimo global**.

GLODS: vários pontos que exploram diferentes bacias. **SA:** um ponto que pode subir.

E se explorássemos várias regiões em simultâneo e deixássemos as boas soluções trocar informação?

→ população → 5.3 Algoritmos genéticos.

Referências Lista completa: *Bibliografia da UC*, no fim do PDF da UC.

- Kirkpatrick, S., Gelatt Jr., C. D., Vecchi, M. P., *Optimization by simulated annealing*, Science 220(4598):671–680, 1983.
- Hajek, B., *Cooling schedules for optimal annealing*, Mathematics of Operations Research 13(2):311–329, 1988.
- Hillier, F. S., Lieberman, G. J., *Introduction to Operations Research*, 2024 Release, McGraw-Hill, 2024 — metaheurísticas.

Recursos

- Código complementar: `SimulatedAnnealing` (`info.nfev`, `info.nacc`). MATLAB: `rng(s); simulannealbnd` (Global Optimization Toolbox).