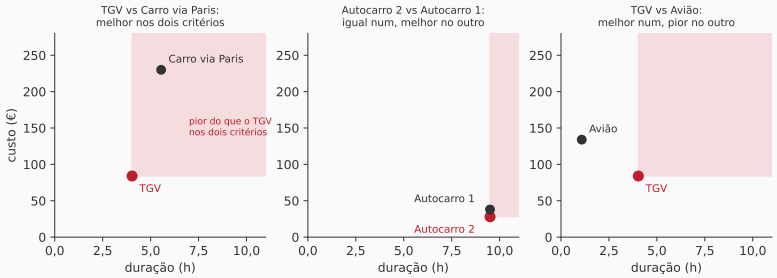
Otimização

6.2 Frente de Pareto

José Firmino Aguilar Madeira

Da intuição à definição: qual é a regra?

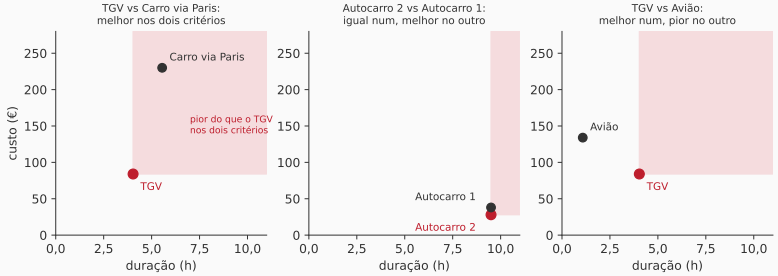
O 6.1 terminou com a pergunta: como se define que uma solução é inequivocamente pior do que outra? Três pares de Nantes–Lille:



Em quais destes casos podemos eliminar uma alternativa sem conhecer as preferências do decisor?

Da intuição à definição: qual é a regra?

O 6.1 terminou com a pergunta: como se define que uma solução é inequivocamente pior do que outra? Três pares de Nantes–Lille:



Nos dois primeiros, sim: o TGV é melhor em tudo; o autocarro 2 demora *o mesmo* e custa menos — empatar num critério e ganhar no outro também chega.

No terceiro, não: o avião é mais rápido e o TGV mais barato. Nenhum é melhor nos dois: sem preferências adicionais, não se pode ordenar.

Dominância de Pareto

Para $\mathbf{z}, \mathbf{z}' \in \mathbb{R}^m$ (minimização):

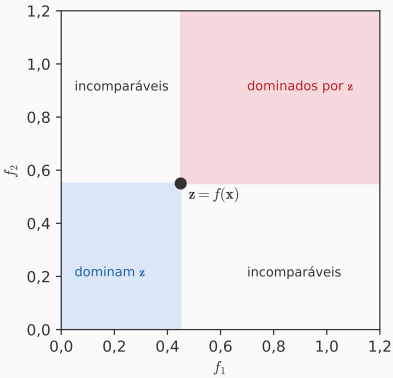
Definição

$\mathbf{z}$ domina $\mathbf{z}'$, $\mathbf{z} \prec \mathbf{z}'$, se

$$z_i \leq z'_i \text{ para todo o } i \quad \textbf{e} \quad z_j < z'_j \text{ para algum } j :$$

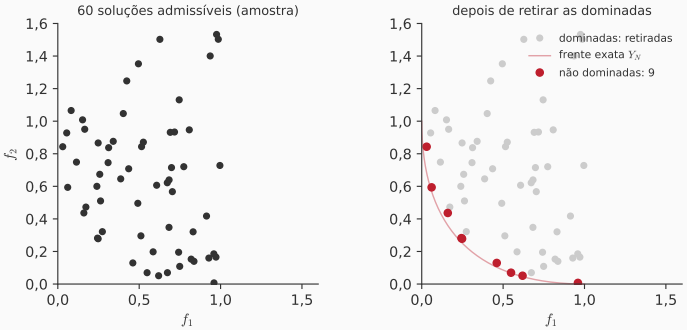
não é pior em nenhum objetivo e é melhor em pelo menos um.

- $\mathbf{x}$ domina $\mathbf{x}'$ se $\mathbf{f}(\mathbf{x}) \prec \mathbf{f}(\mathbf{x}')$.
- TGV $\prec$ carro via Paris; autocarro 2 $\prec$ autocarro 1; TGV e avião: incomparáveis.
- É uma ordem parcial: há pares que não conseguimos ordenar. Quem decide entre eles é o decisor.



Em relação a $\mathbf{z}$: a sudoeste, quem o domina; a nordeste, quem ele domina; nos outros dois quadrantes, os incomparáveis.

Retirar os dominados: aparece a frente



60 soluções admissíveis do exemplo do 6.1; retiradas as dominadas, sobram 9, todas junto à curva vermelha. Com *todas* as soluções admissíveis, o que sobra tem um nome: a frente de Pareto.

A frente é o que resta de Y depois de retirar tudo o que é dominado.

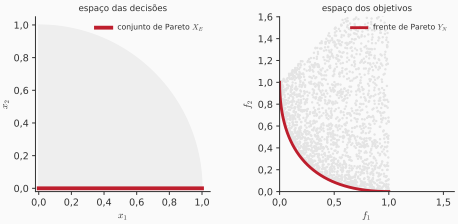
Conjunto de Pareto e frente de Pareto

$\mathbf{x}^* \in X$ é eficiente se nenhuma solução admissível a domina:

$$\mathbf{x}^* \in X_E \iff \nexists\, \mathbf{x} \in X : \ \mathbf{f}(\mathbf{x}) \prec \mathbf{f}(\mathbf{x}^*).$$

- **Nas decisões**: $X_E \subset X$, o conjunto de Pareto — os projetos eficientes.
- **Nos objetivos**: $Y_N = \mathbf{f}(X_E)$, a frente de Pareto — o desempenho desses projetos.

No exemplo: $X_E = \{(x_1, 0) : 0 \le x_1 \le 1\}$; Y_N: $f_2 = (1 - \sqrt{f_1})^2$.



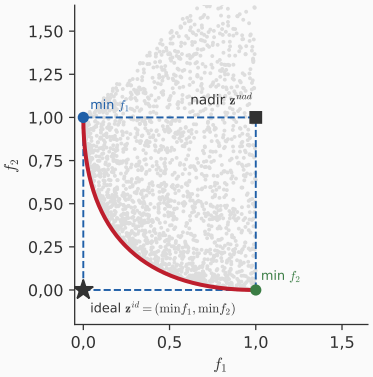
conjunto de Pareto $\neq$ frente de Pareto

Para mais tarde (6.3, 6.4): $\mathbf{x}^*$ é *fracamente eficiente* se não existe solução estritamente melhor em *todos* os objetivos.

Ideal e nadir: a caixa que contém a frente

Ideal. Se pudéssemos escolher o melhor de cada objetivo *separadamente*: $z_i^{id} = \min_{\mathbf{x} \in X} f_i(\mathbf{x})$.

Em geral nenhuma solução atinge todos esses valores ao mesmo tempo: $\boxed{\mathbf{z}^{id} \text{ é geralmente inatingível.}}$ Aqui, $(0; 0)$ não é imagem de nenhum $\mathbf{x}$.



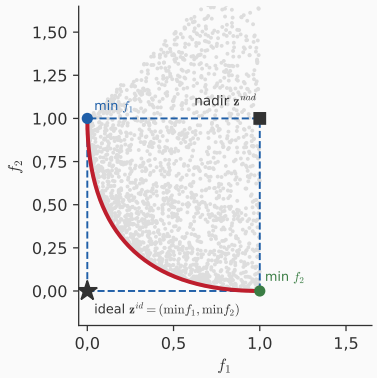
Na prática usa-se muitas vezes uma estimativa $\hat{\mathbf{z}}^{nad}$ (por exemplo, sobre a frente aproximada).

Ideal e nadir: a caixa que contém a frente

Ideal. Se pudéssemos escolher o melhor de cada objetivo *separadamente*: $z_i^{id} = \min_{\mathbf{x} \in X} f_i(\mathbf{x})$.

Em geral nenhuma solução atinge todos esses valores ao mesmo tempo: $\boxed{\mathbf{z}^{id} \text{ é geralmente inatingível.}}$ Aqui, $(0; 0)$ não é imagem de nenhum $\mathbf{x}$.

Nadir. O pior valor de cada objetivo *entre as soluções eficientes*: $z_i^{nad} = \max_{\mathbf{x} \in X_E} f_i(\mathbf{x})$.



Na prática usa-se muitas vezes uma estimativa $\hat{\mathbf{z}}^{nad}$ (por exemplo, sobre a frente aproximada).

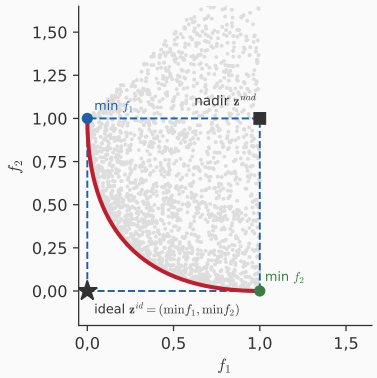
Ideal e nadir: a caixa que contém a frente

Ideal. Se pudéssemos escolher o melhor de cada objetivo *separadamente*: $z_i^{id} = \min_{\mathbf{x} \in X} f_i(\mathbf{x})$.

Em geral nenhuma solução atinge todos esses valores ao mesmo tempo: $\boxed{\mathbf{z}^{id} \text{ é geralmente inatingível.}}$ Aqui, $(0; 0)$ não é imagem de nenhum $\mathbf{x}$.

Nadir. O pior valor de cada objetivo *entre as soluções eficientes*: $z_i^{nad} = \max_{\mathbf{x} \in X_E} f_i(\mathbf{x})$.

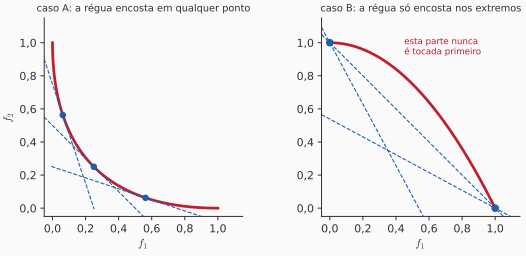
Servem para delimitar a região relevante e para normalizar objetivos com escalas diferentes (6.3).



Na prática usa-se muitas vezes uma estimativa $\hat{\mathbf{z}}^{nad}$ (por exemplo, sobre a frente aproximada).

A geometria do problema: convexo ou não?

Porque precisamos de saber? Porque vai determinar que pontos a soma ponderada consegue encontrar (6.3).



Uma régua (reta) encostada à frente, vinda de baixo e da esquerda.

Caso A: consegue tocar primeiro em qualquer ponto.

Caso B (o exemplo não convexo, abaixo): há uma região que nenhuma régua consegue tocar primeiro. (A frente também pode ser descontínua ou discreta.)

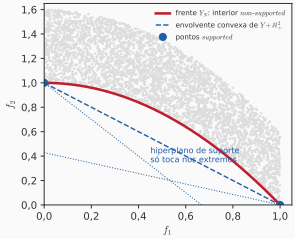
Exemplo não convexo do capítulo: $\min\left(x_1,\ 1 - x_1^2 + x_2\right)$, $\mathbf{x} \in [0,1] \times [0;\ 0{,}6]$;
$X_E = \{(x_1, 0) : 0 \leq x_1 \leq 1\}$; Y_N: $f_2 = 1 - f_1^2$.

Rigorosamente, "convexo" refere-se à imagem superior $Y + \mathbb{R}^m_+$, não à curva Y_N isolada.

Pontos eficientes *supported* e *non-supported*

Uma régua com inclinação dada pelos pesos (w_1, w_2): desloca-se desde baixo e da esquerda até tocar na região possível.

- Onde toca: ponto *supported*.
- A parte da frente que a régua nunca consegue tocar primeiro: *non-supported*.



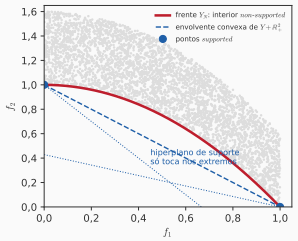
Pontos eficientes *supported* e *non-supported*

Uma régua com inclinação dada pelos pesos (w_1, w_2): desloca-se desde baixo e da esquerda até tocar na região possível.

- Onde toca: ponto *supported*.
- A parte da frente que a régua nunca consegue tocar primeiro: *non-supported*.

Definição

$\mathbf{z} \in Y_N$ é *supported* se minimiza $\mathbf{w}^T\mathbf{z}'$ sobre Y para alguns pesos $w_i > 0$, $\sum_i w_i = 1$. Senão, *non-supported*.



Na frente não convexa (acima) só os dois extremos são *supported*. Num problema convexo são-no todos os eficientes, exceto eventualmente pontos-limite que exigem um peso nulo (os extremos do exemplo convexo).

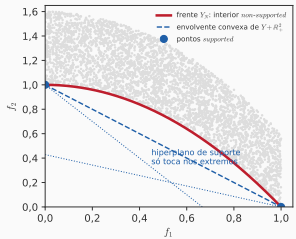
Pontos eficientes *supported* e *non-supported*

Uma régua com inclinação dada pelos pesos (w_1, w_2): desloca-se desde baixo e da esquerda até tocar na região possível.

- Onde toca: ponto *supported*.
- A parte da frente que a régua nunca consegue tocar primeiro: *non-supported*.

Definição

$\mathbf{z} \in Y_N$ é *supported* se minimiza $\mathbf{w}^T\mathbf{z}'$ sobre Y para alguns pesos $w_i > 0$, $\sum_i w_i = 1$. Senão, *non-supported*.

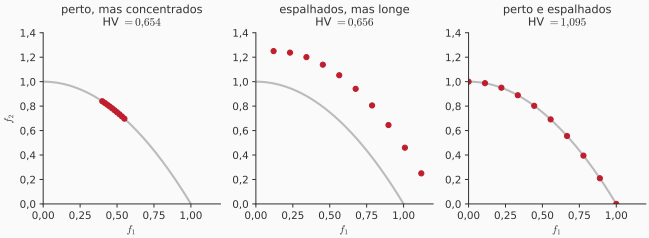


Na frente não convexa (acima) só os dois extremos são *supported*. Num problema convexo são-no todos os eficientes, exceto eventualmente pontos-limite que exigem um peso nulo (os extremos do exemplo convexo).

Porque importa

A soma ponderada (6.3) só encontra pontos *supported*; o ε-constrangimento (6.4) chega também aos *non-supported*.

Duas metas diferentes: convergência e diversidade



HV (hipervolume, página seguinte, com $\mathbf{r} = (1{,}1;\ 1{,}65)$): 0,654, 0,656 e 1,095, da esquerda para a direita.

Um método *a posteriori* devolve um conjunto finito de pontos. Queremos:

convergência: chegar perto da frente;

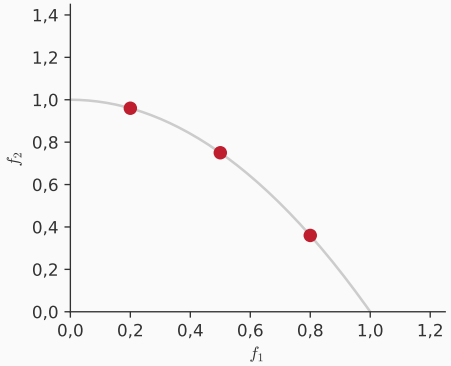
diversidade: cobri-la bem.

As duas primeiras aproximações falham cada uma numa das metas; a terceira cumpre as duas.

É isto que o DMS procura com a lista e a ordenação (6.5), e o NSGA-II com o *rank* e o *crowding* (6.6).

Medir a qualidade: o hipervolume

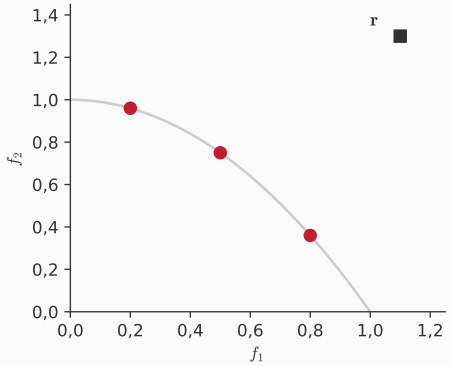
Três pontos não dominados.



$\mathbf{r} = (1{,}1;\ 1{,}3)$, escolhido para ilustração. Outros indicadores: GD, IGD, *spread*.

Medir a qualidade: o hipervolume

Um ponto de referência **r**, pior do que todos.



$\mathbf{r} = (1{,}1;\ 1{,}3)$, escolhido para ilustração. Outros indicadores: GD, IGD, *spread*.

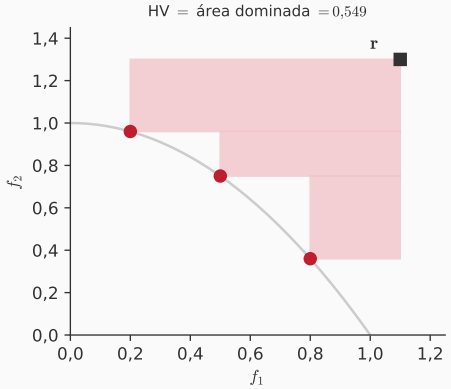
Medir a qualidade: o hipervolume

A região dominada pelos pontos e limitada por **r**:

HV = área dominada (em 2D)

- melhor convergência tende a aumentar a área;
- melhor cobertura da frente tende a aumentar a área.

O hipervolume combina informação sobre as duas metas.



r = (1,1; 1,3), escolhido para ilustração. Outros indicadores: GD, IGD, *spread*.

Medir a qualidade: o hipervolume

A região dominada pelos pontos e limitada por **r**:

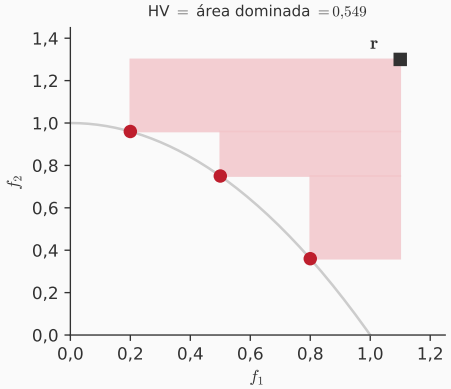
HV = área dominada (em 2D)

- melhor convergência tende a aumentar a área;
- melhor cobertura da frente tende a aumentar a área.

O hipervolume combina informação sobre as duas metas.

Para comparar métodos

Mesmo problema, mesmo **r**, mesmo orçamento n_f (n_f = avaliações do vetor **f**); estocásticos com várias corridas, mediana e quartis (3.2.1; cap. 5). O valor depende de **r** e da escala dos objetivos.



r = (1,1; 1,3), escolhido para ilustração. Outros indicadores: GD, IGD, *spread*.

Então, o que significa "resolver" um problema multiobjetivo?

Um objetivo	**Vários objetivos**
$\boxed{\mathbf{x}^*}$	$\boxed{Y_N}$ ou, numericamente, $\boxed{A \approx Y_N}$
um minimizante	um conjunto finito de pontos

Uma boa aproximação A: $\boxed{\text{convergência} + \text{diversidade}}$

O QUE DEVE FICAR — 6.2

1. **Dominância:** $\mathbf{z} \prec \mathbf{z}'$ se não é pior em nenhum objetivo e é melhor em pelo menos um. Há pares incomparáveis.
2. **Frente de Pareto:** o que resta depois de retirar todos os dominados. Conjunto de Pareto X_E (decisões) $\neq$ frente Y_N (objetivos).
3. **Ideal e nadir:** a caixa que contém a frente; servem para normalizar.
4. ***Supported* vs. *non-supported*:** numa frente não convexa há pontos que nenhuma soma ponderada alcança.
5. **Convergência e diversidade** são metas diferentes; o hipervolume combina as duas num único indicador.

Já sabemos qual é o objeto a calcular: a frente. Como a calculamos?

Primeira ideia: transformar vários objetivos outra vez num só $\rightarrow$ **6.3 Agregação**

Referências e recursos

Referências Lista completa: *Bibliografia da UC*, no fim do PDF da UC.

- Miettinen, K., *Nonlinear Multiobjective Optimization*, Kluwer Academic Publishers, 1999.
- Jahn, J., *Vector Optimization: Theory, Applications, and Extensions*, 2.ª ed., Springer, 2011 — cap. 4.

Recursos: —