


Otimização

6.2 Frente de Pareto

José Firmino Aguilar Madeira

Da intuição à definição: qual é a regra?


O 6.1 terminou com a pergunta: **como se define que uma solução é inequivocamente pior do que outra?** Três pares de Nantes–Lille:



Em quais destes casos podemos eliminar uma alternativa sem conhecer as preferências do decisor?

Da intuição à definição: qual é a regra?

O 6.1 terminou com a pergunta: **como se define que uma solução é inequivocamente pior do que outra?** Três pares de Nantes–Lille:



Nos dois primeiros, sim: o TGV é melhor em tudo; o autocarro 2 demora *o mesmo* e custa menos — empatar num critério e ganhar no outro também chega.

No terceiro, não: o avião é mais rápido e o TGV mais barato. **Nenhum é melhor nos dois:** sem preferências adicionais, não se pode ordenar.

Dominância de Pareto

Para $z, z' \in \mathbb{R}^m$ (minimização):


Definição

z **domina** z' , $z \prec z'$, se

$z_i \leq z'_i$ para todo o i e $z_j < z'_j$ para algum j :



não é pior em nenhum objetivo e é melhor em pelo menos um.

- x domina x' se $f(x) \prec f(x')$.
- TGV $\prec$ carro via Paris; autocarro 2 $\prec$ autocarro 1; TGV e avião: **incomparáveis**.
- É uma **ordem parcial**: há pares que não conseguimos ordenar. Quem decide entre eles é o decisor.



Em relação a z : a **sudoeste**, quem o domina; a **nordeste**, quem ele domina; nos outros dois quadrantes, os incomparáveis.

Retirar os dominados: aparece a frente



60 soluções admissíveis do exemplo do 6.1; retiradas as dominadas, sobram 9, todas junto à curva vermelha. Com *todas* as soluções admissíveis, o que sobra tem um nome: a **frente de Pareto**.

A frente é o que resta de Y depois de retirar tudo o que é dominado.

Conjunto de Pareto e frente de Pareto


$\mathbf{x}^* \in X$ é **eficiente** se nenhuma solução admissível a domina:

$$\mathbf{x}^* \in X_E \iff \nexists \mathbf{x} \in X : \mathbf{f}(\mathbf{x}) \prec \mathbf{f}(\mathbf{x}^*).$$

- **Nas decisões:** $X_E \subset X$, o **conjunto de Pareto** — os projetos eficientes.
- **Nos objetivos:** $Y_N = \mathbf{f}(X_E)$, a **frente de Pareto** — o desempenho desses projetos.

No exemplo: $X_E = \{(x_1, 0) : 0 \leq x_1 \leq 1\}$; Y_N :
 $f_2 = (1 - \sqrt{f_1})^2$.

Para mais tarde (6.3, 6.4): $\mathbf{x}^*$ é *fracamente eficiente* se não existe solução estritamente melhor em *todos* os objetivos.




conjunto de Pareto $\neq$ frente de Pareto

Ideal e nadir: a caixa que contém a frente

Ideal. Se pudéssemos escolher o melhor de cada objetivo *separadamente*: $z_i^{id} = \min_{\mathbf{x} \in X} f_i(\mathbf{x})$.

Em geral nenhuma solução atinge todos esses valores ao mesmo tempo: z^{id} é geralmente inatingível. Aqui, $(0,0)$ não é imagem de nenhum $\mathbf{x}$.




Na prática usa-se muitas vezes uma estimativa $\hat{z}^{nad}$ (por exemplo, sobre a frente aproximada).

Ideal e nadir: a caixa que contém a frente

Ideal. Se pudéssemos escolher o melhor de cada objetivo *separadamente*: $z_i^{id} = \min_{\mathbf{x} \in X} f_i(\mathbf{x})$.

Em geral nenhuma solução atinge todos esses valores ao mesmo tempo: z^{id} é geralmente inatingível. Aqui, $(0,0)$ não é imagem de nenhum $\mathbf{x}$.

Nadir. O pior valor de cada objetivo *entre as soluções eficientes*: $z_i^{nad} = \max_{\mathbf{x} \in X_E} f_i(\mathbf{x})$.



Na prática usa-se muitas vezes uma estimativa $\hat{z}^{nad}$ (por exemplo, sobre a frente aproximada).


Ideal e nadir: a caixa que contém a frente

Ideal. Se pudéssemos escolher o melhor de cada objetivo *separadamente*: $z_i^{id} = \min_{\mathbf{x} \in X} f_i(\mathbf{x})$.

Em geral nenhuma solução atinge todos esses valores ao mesmo tempo: $\mathbf{z}^{id}$ é geralmente inatingível. Aqui, $(0,0)$ não é imagem de nenhum $\mathbf{x}$.

Nadir. O pior valor de cada objetivo *entre as soluções eficientes*: $z_i^{nad} = \max_{\mathbf{x} \in X_E} f_i(\mathbf{x})$.



Servem para **delimitar** a região relevante e para **normalizar** objetivos com escalas diferentes (6.3).



Na prática usa-se muitas vezes uma estimativa $\hat{\mathbf{z}}^{nad}$ (por exemplo, sobre a frente aproximada).

A geometria do problema: convexo ou não?

Porque precisamos de saber? Porque vai determinar que pontos a soma ponderada consegue encontrar (6.3).



Uma régua (reta) encostada à frente, vinda de baixo e da esquerda.

Caso A: consegue tocar primeiro em **qualquer** ponto.

Caso B (o exemplo não convexo, abaixo): há uma região que **nenhuma régua consegue tocar primeiro**. (A frente também pode ser descontínua ou discreta.)


Exemplo não convexo do capítulo: $\min(x_1, 1 - x_1^2 + x_2)$, $\mathbf{x} \in [0, 1] \times [0, 0,6]$;
 $X_E = \{(x_1, 0) : 0 \leq x_1 \leq 1\}$; $Y_N: f_2 = 1 - f_1^2$.

Rigorosamente, "convexo" refere-se à imagem superior $Y + \mathbb{R}_+^m$, não à curva Y_N isolada.

Pontos eficientes *supported* e *non-supported*

Uma régua com inclinação dada pelos pesos (w_1, w_2) : desloca-se desde baixo e da esquerda até tocar na região possível.

- Onde toca: ponto *supported*.
- A parte da frente que a régua nunca consegue tocar primeiro: *non-supported*.




Pontos eficientes *supported* e *non-supported*

Uma régua com inclinação dada pelos pesos (w_1, w_2) : desloca-se desde baixo e da esquerda até tocar na região possível.

- Onde toca: ponto *supported*.
- A parte da frente que a régua nunca consegue tocar primeiro: *non-supported*.

Definição

$\mathbf{z} \in Y_N$ é *supported* se minimiza $\mathbf{w}^T \mathbf{z}'$ sobre Y para alguns pesos $w_i > 0$, $\sum_i w_i = 1$. Senão, *non-supported*.



Na frente não convexa (acima) só os dois extremos são *supported*. Num problema convexo são-no todos os eficientes, exceto eventualmente pontos-limite que exigem um peso nulo (os extremos do exemplo convexo).


Pontos eficientes *supported* e *non-supported*

Uma régua com inclinação dada pelos pesos (w_1, w_2) : desloca-se desde baixo e da esquerda até tocar na região possível.

- Onde toca: ponto *supported*.
- A parte da frente que a régua nunca consegue tocar primeiro: *non-supported*.

Definição

$\mathbf{z} \in Y_N$ é *supported* se minimiza $\mathbf{w}^T \mathbf{z}'$ sobre Y para alguns pesos $w_i > 0$, $\sum_i w_i = 1$. Senão, *non-supported*.




Na frente não convexa (acima) só os dois extremos são *supported*. Num problema convexo são-no todos os eficientes, exceto eventualmente pontos-limite que exigem um peso nulo (os extremos do exemplo convexo).

Porque importa

A *soma ponderada* (6.3) só encontra pontos *supported*; o *ε -constrangimento* (6.4) chega também aos *non-supported*.

Duas metas diferentes: convergência e diversidade



HV (hipervolume, página seguinte, com $r = (1,1; 1,65)$): 0,654, 0,656 e 1,095, da esquerda para a direita.

Um método *a posteriori* devolve um conjunto finito de pontos. Queremos:

convergência: chegar **perto** da frente;


diversidade: **cobri-la** bem.

As duas primeiras aproximações falham cada uma numa das metas; a terceira cumpre as duas.

É isto que o DMS procura com a lista e a ordenação (6.5), e o NSGA-II com o *rank* e o *crowding* (6.6).

Medir a qualidade: o hipervolume


Três pontos não dominados.



$\mathbf{r} = (1,1; 1,3)$, escolhido para ilustração. Outros indicadores: GD, IGD, *spread*.

Medir a qualidade: o hipervolume

Um ponto de referência r , pior do que todos.



$r = (1,1; 1,3)$, escolhido para ilustração. Outros indicadores: GD, IGD, *spread*.


Medir a qualidade: o hipervolume

A região dominada pelos pontos e limitada por r :

$$HV = \text{área dominada (em 2D)}$$

- melhor **convergência** tende a aumentar a área;
- melhor **cobertura** da frente tende a aumentar a área.

O hipervolume **combina informação sobre as duas metas**.



$r = (1,1; 1,3)$, escolhido para ilustração. Outros indicadores: GD, IGD, *spread*.

Medir a qualidade: o hipervolume

A região dominada pelos pontos e limitada por $\mathbf{r}$:


$$HV = \text{área dominada (em 2D)}$$

- melhor **convergência** tende a aumentar a área;
- melhor **cobertura** da frente tende a aumentar a área.

O hipervolume **combina informação sobre as duas metas**.

Para comparar métodos

Mesmo problema, mesmo $\mathbf{r}$, mesmo orçamento n_f (n_f = avaliações do vetor $\mathbf{f}$); estocásticos com várias corridas, mediana e quartis (3.2.1; cap. 5). O valor depende de $\mathbf{r}$ e da escala dos objetivos.



$\mathbf{r} = (1,1; 1,3)$, escolhido para ilustração. Outros indicadores: GD, IGD, *spread*.

Então, o que significa “resolver” um problema multiobjetivo?

Um objetivo

$$\mathbf{x}^*$$

um minimizante

Vários objetivos

$$Y_N$$

ou, numericamente,

$$A \approx Y_N$$

um conjunto finito de pontos

Uma boa aproximação A :

convergência + diversidade

O QUE DEVE FICAR — 6.2

1. **Dominância:** $\mathbf{z} \prec \mathbf{z}'$ se não é pior em nenhum objetivo e é melhor em pelo menos um. Há pares incomparáveis.
2. **Frente de Pareto:** o que resta depois de retirar todos os dominados. Conjunto de Pareto X_E (decisões) $\neq$ frente Y_N (objetivos).
3. **Ideal e nadir:** a caixa que contém a frente; servem para normalizar.
4. **Supported vs. non-supported:** numa frente não convexa há pontos que nenhuma soma ponderada alcança.
5. **Convergência e diversidade** são metas diferentes; o **hipervolume** combina as duas num único indicador.

Já sabemos qual é o objeto a calcular: a frente. **Como a calculamos?**

Primeira ideia: transformar vários objetivos outra vez num só → **6.3 Agregação**

Referências Lista completa: *Bibliografia da UC*, no fim do PDF da UC.

- Miettinen, K., *Nonlinear Multiobjective Optimization*, Kluwer Academic Publishers, 1999.
- Jahn, J., *Vector Optimization: Theory, Applications, and Extensions*, 2.^a ed., Springer, 2011 — cap. 4.

Recursos: —