

Otimização

6.3 Métodos de agregação de objetivos

José Firmino Aguilar Madeira

A ideia mais simples: voltar a ter um objetivo

Temos $\min_{x \in X} (f_1(x), f_2(x))$. Porque não escolher a importância de cada objetivo e resolver

$$\min_{x \in X} w_1 f_1(x) + w_2 f_2(x)$$

com $w_1, w_2 \geq 0$, $w_1 + w_2 = 1$?

A ideia mais simples: voltar a ter um objetivo

Temos $\min_{x \in X} (f_1(x), f_2(x))$. Porque não escolher a importância de cada objetivo e resolver

$$\min_{x \in X} w_1 f_1(x) + w_2 f_2(x)$$

com $w_1, w_2 \geq 0$, $w_1 + w_2 = 1$?

Voltámos a um problema com um só objetivo:
podemos usar tudo o que aprendemos nos caps.
2–5.

A ideia mais simples: voltar a ter um objetivo

Temos $\min_{x \in X} (f_1(x), f_2(x))$. Porque não escolher a importância de cada objetivo e resolver

$$\min_{x \in X} w_1 f_1(x) + w_2 f_2(x)$$

com $w_1, w_2 \geq 0$, $w_1 + w_2 = 1$?

Voltámos a um problema com um só objetivo:
podemos usar tudo o que aprendemos nos caps. 2–5.

Já o fizemos no 6.1

Nantes–Lille, “uma hora vale 30 €”:

$$\text{custo} + 30 \times \text{duração}$$

é uma **soma ponderada** dos dois critérios.

Gass e Saaty (1955); com m objetivos,
 $\min \sum_i w_i f_i, \sum_i w_i = 1$.



O que fazem os pesos?

No exemplo do capítulo:

$$\min w_1(x_1^2 + x_2^2) + w_2[(x_1 - 1)^2 + x_2^2].$$

Derivando: $x_2^* = 0$, $x_1^* = w_2$.

w	x^*
(1; 0)	(0; 0)
(0,5; 0,5)	(0,5; 0)
(0; 1)	(1; 0)



O que fazem os pesos?



No exemplo do capítulo:

$$\min w_1(x_1^2 + x_2^2) + w_2[(x_1 - 1)^2 + x_2^2].$$

Derivando: $x_2^* = 0$, $x_1^* = w_2$.


w	x^*
$(1; 0)$	$(0; 0)$
$(0,5; 0,5)$	$(0,5; 0)$
$(0; 1)$	$(1; 0)$

Se variarmos os pesos, percorremos a **frente?** Neste exemplo, sim: $x_1^* = w_2$ percorre todo o segmento X_E .



Primeira surpresa: pesos uniformes $\neq$ pontos uniformes

w_1	w_2	x_1^*	f_1	f_2
0,0	1,0	1,000	1,000	0,000
0,1	0,9	0,900	0,810	0,010
0,2	0,8	0,800	0,640	0,040
0,3	0,7	0,700	0,490	0,090
0,4	0,6	0,600	0,360	0,160
0,5	0,5	0,500	0,250	0,250
0,6	0,4	0,400	0,160	0,360
0,7	0,3	0,300	0,090	0,490
0,8	0,2	0,200	0,040	0,640
0,9	0,1	0,100	0,010	0,810
1,0	0,0	0,000	0,000	1,000



Nas decisões $x_1^* = w_2$ é uniforme; nos objetivos, $f_1 = w_2^2$, $f_2 = (1 - w_2)^2$: os pontos **concentram-se nos extremos**.

Os pesos controlam a escalarização; **não controlam diretamente a posição na frente**.

Com $m \geq 3$, ainda menos previsível. Custo aqui: 11 pontos, $n_f = 75$ (SLSQP, gradientes progressivos do solver, arranque a quente).

Segunda surpresa: a escala importa

Três projetos (números ilustrativos): f_1 = massa (kg), f_2 = custo (€).

	massa	custo
A	1,5	800
B	0,9	850
C	0,5	1000

Com $w = (0,9; 0,1)$ — “90% massa” — sem normalizar: $A = 81,4$, $B = 85,8$, $C = 100,5$: **ganha A, o mais pesado**. O custo, na casa das centenas, domina a soma.

Segunda surpresa: a escala importa

Três projetos (números ilustrativos): f_1 = massa (kg), f_2 = custo (€).

	massa	custo
A	1,5	800
B	0,9	850
C	0,5	1000

Com $w = (0,9; 0,1)$ — “90% massa” — sem normalizar: $A = 81,4$, $B = 85,8$, $C = 100,5$: **ganha A, o mais pesado**. O custo, na casa das centenas, domina a soma.

Normalizar com ideal e nadir (6.2)

$$\hat{f}_i(x) = \frac{f_i(x) - z_i^{id}}{\hat{z}_i^{nad} - z_i^{id}} \in [0, 1] \text{ nos eficientes;}$$
$$\min \sum_i w_i \hat{f}_i(x).$$

Aqui $z^{id} = (0,5; 800)$, $\hat{z}^{nad} = (1,5; 1000)$:

w	(0,9; 0,1)	(0,5; 0,5)	(0,1; 0,9)
escolhe	C	B	A

Antes de interpretar os pesos como importância relativa, **normalizar** objetivos com escalas diferentes.

O que podemos garantir?

Propriedade

Se $w_i > 0$ para todo o i e x^* minimiza $\sum_i w_i f_i$ em X , então x^* é **eficiente**.

O que podemos garantir?

Propriedade

Se $w_i > 0$ para todo o i e x^* minimiza $\sum_i w_i f_i$ em X , então x^* é **eficiente**.

Prova numa linha. Se existisse $x \in X$ que dominasse x^* — $f_i(x) \leq f_i(x^*)$ para todo o i e $<$ para algum —, então, como todos os pesos são positivos,

$$\sum_i w_i f_i(x) < \sum_i w_i f_i(x^*),$$

contra a minimalidade de x^* .



O que podemos garantir?

Propriedade

Se $w_i > 0$ para todo o i e x^* minimiza $\sum_i w_i f_i$ em X , então x^* é **eficiente**.

Prova numa linha. Se existisse $x \in X$ que dominasse x^* — $f_i(x) \leq f_i(x^*)$ para todo o i e $<$ para algum —, então, como todos os pesos são positivos,

$$\sum_i w_i f_i(x) < \sum_i w_i f_i(x^*),$$


contra a minimalidade de x^* . □

Com algum $w_i = 0$ esse objetivo deixa de contar: em geral só se garante eficiência *fraca*. Por isso, no que se segue, $w_i > 0$ (como na definição de *supported*, 6.2).

A limitação fundamental: uma frente côncava

$x \in [0, 1]$, $f_1(x) = x$, $f_2(x) = 1 - x^2$ (o exemplo não convexo do 6.2, com $x_2 = 0$). Frente: $f_2 = 1 - f_1^2$, côncava.

Todos estes pontos são eficientes. Se variarmos w_1 de 0 a 1, conseguimos encontrá-los todos?




A limitação fundamental: uma frente côncava

$x \in [0, 1]$, $f_1(x) = x$, $f_2(x) = 1 - x^2$ (o exemplo não convexo do 6.2, com $x_2 = 0$). Frente: $f_2 = 1 - f_1^2$, côncava.

Experimentamos $w_1 = 0,2$; $0,5$; $0,8$: as retas de nível selecionam sempre **um extremo**.

11 pesos $\rightarrow$ 2 pontos. 100 pesos $\rightarrow$ 2 pontos.

10 000 pesos $\rightarrow$ 2 pontos.



A limitação fundamental: uma frente côncava


$x \in [0, 1]$, $f_1(x) = x$, $f_2(x) = 1 - x^2$ (o exemplo não convexo do 6.2, com $x_2 = 0$). Frente: $f_2 = 1 - f_1^2$, côncava.

Porquê? Com $w_1, w_2 > 0$,

$$\tilde{f}(x) = w_1 x + w_2(1 - x^2), \quad \boxed{\tilde{f}''(x) = -2w_2 < 0}.$$

$\tilde{f}$ é **côncava**: num intervalo, o mínimo está num dos extremos, $x^* \in \{0, 1\}$, isto é, $(0, 1)$ ou $(1, 0)$.

Todos os pontos com $0 < x < 1$ são eficientes, mas *non-supported*.



A limitação fundamental: uma frente côncava


$x \in [0, 1]$, $f_1(x) = x$, $f_2(x) = 1 - x^2$ (o exemplo não convexo do 6.2, com $x_2 = 0$). Frente: $f_2 = 1 - f_1^2$, côncava.

Porquê? Com $w_1, w_2 > 0$,

$$\tilde{f}(x) = w_1 x + w_2(1 - x^2), \quad \boxed{\tilde{f}''(x) = -2w_2 < 0}.$$

$\tilde{f}$ é **côncava**: num intervalo, o mínimo está num dos extremos, $x^* \in \{0, 1\}$, isto é, $(0, 1)$ ou $(1, 0)$.

Todos os pontos com $0 < x < 1$ são eficientes, mas *non-supported*.



Não é um problema de escolher poucos pesos: **nenhum peso positivo encontra os pontos interiores.**

Soma ponderada: o quadro completo

$$\min_{x \in X} \sum_{i=1}^m w_i f_i(x), \quad w_i > 0, \quad \sum_i w_i = 1.$$

Sempre o minimizante **global** é **eficiente**.

Problema convexo todo o eficiente minimiza a soma para algum $w \geq 0$, $w \neq 0$; os propriamente eficientes (taxas de troca limitadas), para algum $w > 0$ (Geoffrion, 1968) (pontos-limite como os extremos do exemplo convexo podem exigir um peso nulo).

Problema não convexo **apenas os pontos *supported***.

Os três casos já os vimos acontecer nas páginas anteriores.

Outra agregação: Tchebycheff ponderado

A **distância ponderada ao ideal** na norma do máximo:

$$\min_{x \in X} \max_i w_i (f_i(x) - z_i^{id}).$$


Geometricamente: soma ponderada $\rightarrow$ **retas**;

Tchebycheff $\rightarrow$ **cantos em L** cujos vértices estão na semirreta que parte do ideal na direção $(1/w_1, 1/w_2)$, que conseguem tocar também as regiões *non-supported*.

A limitação *non-supported* é da soma ponderada, não de todas as escalarizações.

	soma ponderada	Tchebycheff
problema escalar	soma	máximo
pontos <i>non-supported</i>	não	sim
posição na frente	difícil de controlar	difícil de controlar
diferenciável	se as f_i o forem	não diretamente

Tchebycheff ponderado: níveis em "L", apanha a frente toda



Notas

Versão aumentada, $+\rho \sum_i (f_i - z_i^{id})$ com $\rho > 0$ pequeno: evita soluções só fracamente eficientes. Sem o max (4.2): min θ s.a. $w_i(f_i - z_i^{id}) \leq \theta$. Outras agregações: *goal programming*, lexicográfica.

O preço da agregação

Vantagens

- muito simples;
- reutiliza qualquer método dos caps. 2–5 e a sua teoria;
- incorpora preferências do decisor;
- uma otimização dá uma solução.

Limitações

- uma otimização **por ponto**;
- os pesos dependem da escala;
- pesos uniformes não dão cobertura uniforme;
- posição na frente difícil de controlar;
- a soma ponderada perde os *non-supported*.

Para construir uma frente, temos de **repetir a otimização** — uma vez por ponto.

O QUE DEVE FICAR — 6.3

1. A agregação transforma vários objetivos num problema escalar: $\min \sum_i w_i f_i$.
2. Com $w_i > 0$, um minimizante **global** da soma ponderada é **eficiente**.
3. Objetivos com escalas diferentes devem ser **normalizados** antes de interpretar os pesos.
4. Pesos uniformes $\neq$ pontos uniformes na frente; em problemas não convexos, a soma ponderada **não encontra** pontos *non-supported*.
5. Outras escalarizações (Tchebycheff) alcançam os *non-supported*, mas continuam a dar **um ponto por otimização**.

E se, em vez de combinar os objetivos numa soma, mantivermos um como objetivo e transformarmos os outros em restrições?



6.4 ϵ -constrangimento

Referências Lista completa: *Bibliografia da UC*, no fim do PDF da UC.

- Miettinen, K., *Nonlinear Multiobjective Optimization*, Kluwer Academic Publishers, 1999.
- Geoffrion, A. M., *Proper efficiency and the theory of vector maximization*, Journal of Mathematical Analysis and Applications 22(3):618–630, 1968.
- Jahn, J., *Vector Optimization: Theory, Applications, and Extensions*, 2.^a ed., Springer, 2011 — cap. 5.

Recursos: custos calculados com SLSQP (SciPy); código da soma ponderada (fmincon) no 6.4.