

Otimização

6.5 *Direct MultiSearch* (DMS)

José Firmino Aguilar Madeira

De um ponto para uma lista

O 6.4 terminou com a pergunta: **podemos construir uma aproximação da frente numa única execução?**

Pesquisa direta (3.2.5; 5.1): um iterando

$$\mathbf{x}_k$$

DMS (*Direct MultiSearch*): uma **lista** de pontos não dominados

$$L_k = \{\mathbf{x}^1, \dots, \mathbf{x}^q\}$$

De um ponto para uma lista

O 6.4 terminou com a pergunta: **podemos construir uma aproximação da frente numa única execução?**

Pesquisa direta (3.2.5; 5.1): um iterando

$$\mathbf{x}_k$$

DMS (*Direct MultiSearch*): uma **lista** de pontos não dominados

$$L_k = \{\mathbf{x}^1, \dots, \mathbf{x}^q\}$$

Como se faz pesquisa direta quando não existe um único “melhor” ponto?

É essa a pergunta a que o DMS responde.

Pesquisa direta (um objetivo)

1. escolher $\mathbf{x}_k$;
2. sondar $\mathbf{x}_k + \alpha_k \mathbf{d}$, $\mathbf{d} \in D_k$;
3. um ponto entra se tiver **menor** f .

Sucesso = encontrar um ponto com menor f .

DMS (vários objetivos)


1. escolher um centro $\mathbf{x}_k$ **da lista**;
2. sondar $\mathbf{x}_k + \alpha_k \mathbf{d}$, $\mathbf{d} \in D_k$;
3. um ponto entra se **sobreviver ao filtro de dominância**.

Sucesso = **a lista mudou**, $L_{k+1} \neq L_k$.

Nada é agregado: não há pesos nem limites — só dominância (6.2).


Com $m = 1$ o DMS é exatamente a pesquisa direta direcional.

Uma sondagem: quem entra na lista?



Exemplo não convexo da UC, $\alpha_k = 0,25$. O ponto fora de X nem é avaliado. O que fazemos com cada ponto novo?

Uma sondagem: quem entra na lista?



Exemplo não convexo da UC, $\alpha_k = 0,25$. O ponto fora de X nem é avaliado. O que fazemos com cada ponto novo?

dominado



eliminar

não dominado



entra na lista


domina pontos da lista



entra, e esses saem

É praticamente todo o mecanismo do DMS.

Uma iteração em quatro passos



Sucesso

$L_{k+1} \neq L_k$: a lista mudou. O passo mantém-se (ou aumenta).

Insucesso

$L_{k+1} = L_k$: a lista não mudou. α_k **diminui** — só o do centro sondado.

A lista: $L_k = \{(\mathbf{x}; \alpha)\}$

Cada elemento da lista guarda

- uma **solução** $\mathbf{x}$, admissível;
- o seu **passo** α — cada ponto tem o seu.

Os pontos da lista são **não dominados entre si**: a lista é, em cada iteração, a **aproximação não dominada corrente**.

O centro é escolhido da lista e fica nela enquanto não for dominado.

Porquê um passo por ponto?

Numa região já bem explorada, o passo desse ponto já diminuiu; um ponto novo, noutra zona da frente, começa com um passo maior. A lista refina umas zonas sem parar a exploração de outras.

- **filter**: juntar à lista os pontos sondados e **manter só os não dominados**.
- **select**: decidir quanto da lista filtrada guardar. Nesta UC, tudo: $L_{\text{tent}} = L_{\text{filt}}$, porque queremos aproximar a frente inteira.
- **order**: escolher quem é sondado a seguir. Regra simples (FIFO): o centro sondado vai para o fim da lista — todos acabam sondados.

Outras opções (artigo)

- ordenar pela maior lacuna Γ entre vizinhos na frente;
- começar com vários pontos ($\text{DMS}(n, \text{line})$);
- *cache*: não reavaliar pontos já avaliados.

O algoritmo DMS (Algoritmo 2.1 do artigo)

DMS — dados $\mathbf{x}_0 \in X$, $\alpha_0 > 0$, $0 < \beta_1 \leq \beta_2 < 1$, $\gamma \geq 1$, $\mathcal{D}$; $L_0 = \{(\mathbf{x}_0; \alpha_0)\}$

- 1: **for** $k = 0, 1, 2, \dots$ **do**
- 2: **Seleção**: ordenar L_k ; $(\mathbf{x}_k; \alpha_k) \leftarrow$ primeiro elemento
- 3: **Pesquisa** (opcional): avaliar $\mathbf{f}_X$ num conjunto finito; se sucesso, saltar 4–5
- 4: **Sondagem**: avaliar $\mathbf{f}_X$ em $\{\mathbf{x}_k + \alpha_k \mathbf{d} : \mathbf{d} \in D_k\}$; $L_{\text{add}} \leftarrow \{(\mathbf{x}_k + \alpha_k \mathbf{d}; \alpha_k)\}$
- 5: $L_{\text{filt}} \leftarrow \text{filter}(L_k, L_{\text{add}})$; $L_{\text{tent}} \leftarrow \text{select}(L_{\text{filt}})$
- 6: **se** $L_{\text{tent}} \neq L_k$: **sucesso**, $L_{k+1} \leftarrow L_{\text{tent}}$; **senão insucesso**, $L_{k+1} \leftarrow L_k$
- 7: **Passo**: sucesso $\Rightarrow \alpha_{\text{novo}} \in [\alpha_k, \gamma \alpha_k]$ nos pontos novos e em $\mathbf{x}_k$, se continuar na lista; insucesso $\Rightarrow \alpha_{\text{novo}} \in [\beta_1 \alpha_k, \beta_2 \alpha_k]$ em $\mathbf{x}_k$
- 8: **end for**

Essencial

seleção + **sondagem** + filter

Search: opcional (espalhar, modelos). **A sondagem sustenta a teoria** — como no GLODS (5.1).

Custo: até $|D_k|$ avaliações do vetor $\mathbf{f}$ por sondagem ($2n$ com $[I - I]$); paralelizável. Paragem: $\alpha < \alpha_{\min}$ em toda a lista, ou orçamento $N_{\max}$.

SP1: uma iteração à mão

$$\min \left((x_1 - 1)^2 + (x_1 - x_2)^2, (x_1 - x_2)^2 + (x_2 - 3)^2 \right), -1 \leq x_1, x_2 \leq 5; \quad L_0 = \{(1,5; 1,5)\}, \quad \alpha_0 = 1, \\ D = [I \quad -I].$$

Centro (1,5; 1,5): $\mathbf{f} = (0,25; 2,25)$.

Sondados $\mathbf{x}_k \pm \mathbf{e}_i$:

ponto	$\mathbf{f}$
(2,5; 1,5)	(3,25; 3,25)
(1,5; 2,5)	(1,25; 1,25)
(0,5; 1,5)	(1,25; 3,25)
(1,5; 0,5)	(1,25; 7,25)

As iterações 1 e 2 à mão estão no artigo (secção 3). O código MATLAB original do DMS (www.mat.uc.pt/dms) é distribuído na aula.

SP1: uma iteração à mão

$$\min \left((x_1 - 1)^2 + (x_1 - x_2)^2, (x_1 - x_2)^2 + (x_2 - 3)^2 \right), -1 \leq x_1, x_2 \leq 5; \quad L_0 = \{(1,5; 1,5)\}, \quad \alpha_0 = 1, \\ D = [I \quad -I].$$

Centro $(1,5; 1,5)$: $\mathbf{f} = (0,25; 2,25)$.

Sondados $\mathbf{x}_k \pm \mathbf{e}_i$:

ponto	$\mathbf{f}$
$(2,5; 1,5)$	$(3,25; 3,25)$
$(1,5; 2,5)$	$(1,25; 2,25)$
$(0,5; 1,5)$	$(1,25; 3,25)$
$(1,5; 0,5)$	$(1,25; 7,25)$

Filtro. $(1,25; 1,25)$ e $(0,25; 2,25)$ são incomparáveis: **entra**. Os outros três são dominados por $(1,25; 1,25)$: **eliminados**.

As iterações 1 e 2 à mão estão no artigo (secção 3). O código MATLAB original do DMS (www.mat.uc.pt/dms) é distribuído na aula.

SP1: uma iteração à mão

$$\min \left((x_1 - 1)^2 + (x_1 - x_2)^2, (x_1 - x_2)^2 + (x_2 - 3)^2 \right), -1 \leq x_1, x_2 \leq 5; L_0 = \{(1,5; 1,5)\}, \alpha_0 = 1, D = [I \quad -I].$$

Centro (1,5; 1,5): $\mathbf{f} = (0,25; 2,25)$.

Sondados $\mathbf{x}_k \pm \mathbf{e}_i$:

ponto	$\mathbf{f}$
(2,5; 1,5)	(3,25; 3,25)
(1,5; 2,5)	(1,25; 1,25)
(0,5; 1,5)	(1,25; 3,25)
(1,5; 0,5)	(1,25; 7,25)


Filtro. (1,25; 1,25) e (0,25; 2,25) são incomparáveis: **entra**. Os outros três são dominados por (1,25; 1,25): **eliminados**.

Resultado. $L_1 = \{(1,5; 2,5), (1,5; 1,5)\}$: a lista passou de **1 para 2** pontos. **Sucesso**; $\alpha = 1$ mantém-se. $n_f = 1 + 4 = 5$.

As iterações 1 e 2 à mão estão no artigo (secção 3). O código MATLAB original do DMS (www.mat.uc.pt/dms) é distribuído na aula.


SP1: a frente emerge

Fim da iteração 0: $|L_1| = 2$ (a página anterior).



SP1: a frente emerge


Fim da iteração 1: entra mais um ponto, $|L_2| = 3$.



SP1: a frente emerge


Fim da iteração 2: a lista não muda

— **insucesso**: $|L_3| = 3$ e o passo do centro passa a $\frac{1}{2}$.




SP1: a frente emerge

Ao fim de 10 iterações: $|L_{10}| = 5$,
 $n_f = 41$.



SP1: a frente emerge


Ao fim de 20: $|L_{20}| = 12$, $n_f = 81$.



SP1: a frente emerge

Ao fim de 100: $|L_{100}| = 63$, $n_f = 401$.

Uma aproximação da frente
emerge da própria pesquisa direta
— sem pesos nem limites.



Sucesso: $L_{k+1} \neq L_k$

Não é preciso que um ponto domine o centro: basta **melhorar a aproximação não dominada** (na iteração 0 do SP1, o ponto novo não dominava o centro — era incomparável).

Insucesso: $L_{k+1} = L_k$

Nenhum ponto sondado altera a lista. Então α diminui **apenas para o centro sondado** (SP1, iteração 2: $\alpha = 1 \rightarrow \frac{1}{2}$ só em $(1,5; 1,5)$).

Restrições: barreira extrema (5.1)

$$f_X(\mathbf{x}) = \begin{cases} f(\mathbf{x}), & \mathbf{x} \in X \\ (+\infty, \dots, +\infty), & \mathbf{x} \notin X \end{cases}$$

Fora de X **nem se avaliam os objetivos**: basta saber “admissível ou não”. Serve para restrições de caixa negra.

O que significa estacionariedade com vários objetivos?

Um objetivo: não existe direção admissível que faça f descer.

Vários objetivos: não existe direção admissível que faça **todos os objetivos** **descerem ao mesmo tempo**.

Ponto crítico de Pareto–Clarke

$$\forall \mathbf{d} \in T_X^{Cl}(\mathbf{x}^*) \quad \exists i : f_i^\circ(\mathbf{x}^*; \mathbf{d}) \geq 0.$$

Se as f_i são estritamente diferenciáveis (p. ex. C^1):

$$\forall \mathbf{d} \in T_X^{Cl}(\mathbf{x}^*) \quad \exists i : \nabla f_i(\mathbf{x}^*)^T \mathbf{d} \geq 0.$$

T_X^{Cl} : cone tangente de Clarke; f_i° : derivada direcional generalizada (Clarke–Jahn), para f_i só L -Lipschitz (R). Definição em 5.1.

O que significa estacionariedade com vários objetivos?

Um objetivo: não existe direção admissível que faça f descer.

Vários objetivos: não existe direção admissível que faça **todos os objetivos** **descerem ao mesmo tempo**.

Não significa $\nabla f_i = \mathbf{0}$ para todo o i : basta que, em cada direção, *algum* objetivo não desça.

Ponto crítico de Pareto–Clarke

$$\forall \mathbf{d} \in T_X^{Cl}(\mathbf{x}^*) \quad \exists i : f_i^\circ(\mathbf{x}^*; \mathbf{d}) \geq 0.$$

Se as f_i são estritamente diferenciáveis (p. ex. C^1):

$$\forall \mathbf{d} \in T_X^{Cl}(\mathbf{x}^*) \quad \exists i : \nabla f_i(\mathbf{x}^*)^T \mathbf{d} \geq 0.$$

T_X^{Cl} : cone tangente de Clarke; f_i° : derivada direcional generalizada (Clarke–Jahn), para f_i só L -Lipschitz (R). Definição em 5.1.

O que o DMS garante — e o que não garante

Com iterandos num compacto (aqui, X limitado) e malha racional ou decréscimo suficiente $\Rightarrow \alpha_k \rightarrow 0$ numa subsucessão de insucessos $\Rightarrow$ ponto limite $\mathbf{x}_*$

$\Rightarrow f_i$ Lipschitz perto de $\mathbf{x}_*$ e direções refinantes densas: $\mathbf{x}_*$ é crítico de Pareto–Clarke

Com D fixo (como aqui, $D = [I \ -I]$): para cada $\mathbf{d} \in D$, $\exists i : f_i^\circ(\mathbf{x}_*; \mathbf{d}) \geq 0$ (só nessas direções).

Garante

- um ponto limite com a estacionariedade adequada;
- sem derivadas (só Lipschitz local), com restrições por barreira extrema;
- com $m = 1$, a teoria da pesquisa direta.


Não garante

- que a *lista inteira* converge para a frente;
- que esse ponto seja eficiente (nem sequer localmente);
- boa distribuição ao longo da frente.

“Convergência global”: não é preciso começar perto da solução — **não** significa ótimo global.

Condição **necessária local**.

DMS nos dois exemplos da UC



DMS(1) do centro da caixa, $\alpha_0 = 1$, $D = [I \ -I]$, FIFO, sem cache, $N_{\max} = 300$ (a sondagem em curso completa-se: $n_f \leq N_{\max} + 2n - 1$, contando a avaliação inicial). Convexo: **55 pontos**, HV 1,641 (exata 1,648); não convexo: **38 pontos**, HV 1,116 (exata 1,148), com $\mathbf{r} = (1,1; 1,65)$.

Uma execução constrói uma aproximação inteira. Em 6.3/6.4, cada ponto era uma otimização completa.

(Uma execução com centenas de avaliações: não é automaticamente mais barata. Comparação a sério: HV vs. n_f , 6.6.)

A implementação importa

Variantes, no exemplo não convexo (resultados nossos), $N_{\max} = 300$:

variante	it.	n_f	$ L $	HV
DMS(1), FIFO	98	301	38	1,116
DMS(n ,line), FIFO	108	302	50	1,136
DMS(1), espalhamento Γ	97	301	40	1,118
DMS(1), FIFO, <i>cache</i>	232	303	79	1,138

Não reavaliar o que já sabemos

Sem *cache*, mais de metade das avaliações repetia pontos já avaliados (cerca de um terço, pontos da própria lista). Com ela, o mesmo orçamento dá mais iterações e o dobro dos pontos.

Começar com vários pontos (segmento) também ajuda; o espalhamento pouco muda *aqui*.

O artigo de 2011 e uma aplicação real

Testes: 100 problemas com limites, $1 \leq n \leq 30$, $2 \leq m \leq 4$, orçamento comum de 20 000 avaliações; comparação com AMOSA, BIMADS e NSGA-II.

- o DMS foi **competitivo** na qualidade das frentes;
- muito bom **espalhamento**;
- o NSGA-II foi ligeiramente mais eficiente numa das métricas de distribuição.

Neste conjunto de problemas, com estes parâmetros e este orçamento. O detalhe (métricas, perfis) está no artigo.

Nota. O material foi codificado por subintervalos (alumínio [1, 2], GFRP [2, 3], CFRP [3, 4]): isto impõe uma **ordem artificial** a uma variável *categórica* — um passo pequeno pode “trocar de material” só por atravessar um limite arbitrário. Tratar as categóricas nativamente é o que faz o DMS-SI-Mix.

OTIMIZAÇÃO NA PRÁTICA

Painéis sanduíche viscoelásticos: maximizar o amortecimento, minimizar massa e custo; modelo de elementos finitos. **O DMS usado trabalha só com variáveis reais:** as escolhas discretas (material e espessura de cada camada, orientação, espessura do núcleo) foram *codificadas* em 25 variáveis reais em $[0, 4]$. Com massa $\leq 1,5$ kg, o DMS devolveu **14 579** soluções não dominadas.

Madeira et al., Compos. Part B 77:391–401, 2015.

O QUE DEVE FICAR — 6.5

1. O DMS é **pesquisa direta multiobjetivo**: em vez de um iterando, mantém uma **lista** de soluções não dominadas.
2. Sonda um centro da lista e usa a **dominância** para a atualizar; nada é agregado.
3. **Sucesso** = a lista mudou; **insucesso** reduz o passo do centro sondado.
4. Uma execução pode construir uma **aproximação** com muitos pontos não dominados, mesmo para frentes não convexas.
5. A teoria garante estacionariedade de Pareto–Clarke de um ponto limite, sob hipóteses — uma condição necessária local, não convergência da lista para a frente global.

E se, em vez de uma lista construída por sondagem, mantivermos uma população que evolui?

→ **6.6 NSGA-II**

Referências e recursos

Referências Lista completa: *Bibliografia da UC*, no fim do PDF da UC.

- Custódio, A. L., Madeira, J. F. A., Vaz, A. I. F., Vicente, L. N., *Direct multisearch for multiobjective optimization*, SIAM Journal on Optimization 21(3):1109–1140, 2011 — o artigo do DMS.
- Custódio, A. L., Madeira, J. F. A., *MultiGLODS: global and local multiobjective optimization using direct search*, Journal of Global Optimization 72(2):323–345, 2018 — MultiGLODS.
- Madeira, J. F. A., *Multiobjective and global optimization with directional direct search*, Tese de Doutoramento em Matemática, IST, Universidade de Lisboa, 2019.

Recursos

- Para além da UC: *DMS-SI-Mix*, com invariância de escala e variáveis contínuas, *discretas* (valores com ordem: número de camadas, espessuras de catálogo) e *categóricas* (opções sem ordem: o material) tratadas nativamente.
- Código MATLAB original do DMS, distribuído na aula: www.mat.uc.pt/dms (nenhuma função da UC).
- MATLAB: `paretosearch` (Global Optimization Toolbox, desde a R2018b), pesquisa em padrão multiobjetivo; a documentação remete para o artigo do DMS na análise de convergência.
- Dissertações no IST com DMS: Santos (2017), Dionísio (2019), Pereira (2024), Costa (2025) — lista completa na *Bibliografia da UC*.