

# Otimização

## 6.5 *Direct MultiSearch* (DMS)

---

José Firmino Aguilar Madeira

# De um ponto para uma lista

O 6.4 terminou com a pergunta: **podemos construir uma aproximação da frente numa única execução?**

**Pesquisa direta (3.2.5; 5.1):** um iterando

$$x_k$$

**DMS** (*Direct MultiSearch*): uma **lista** de pontos não dominados

$$L_k = \{x^1, \dots, x^q\}$$

# De um ponto para uma lista

O 6.4 terminou com a pergunta: **podemos construir uma aproximação da frente numa única execução?**

**Pesquisa direta (3.2.5; 5.1):** um iterando

$$x_k$$

**DMS** (*Direct MultiSearch*): uma **lista** de pontos não dominados

$$L_k = \{x^1, \dots, x^q\}$$

Como se faz pesquisa direta quando não existe um único “melhor” ponto?

É essa a pergunta a que o DMS responde.

## Pesquisa direta (um objetivo)

1. escolher  $x_k$ ;
2. sondar  $x_k + \alpha_k d$ ,  $d \in D_k$ ;
3. um ponto entra se tiver **menor  $f$** .

**Sucesso** = encontrar um ponto com menor  $f$ .

## DMS (vários objetivos)


1. escolher um centro  $x_k$  **da lista**;
2. sondar  $x_k + \alpha_k d$ ,  $d \in D_k$ ;
3. um ponto entra se **sobreviver ao filtro de dominância**.

**Sucesso** = a lista mudou,  $L_{k+1} \neq L_k$ .

Nada é agregado: não há pesos nem limites — só dominância (6.2).


Com  $m = 1$  o DMS é exatamente a pesquisa direta direcional.

# Uma sondagem: quem entra na lista?



Exemplo não convexo da UC,  $\alpha_k = 0,25$ . O ponto fora de  $X$  nem é avaliado. O que fazemos com cada ponto novo?

# Uma sondagem: quem entra na lista?



Exemplo não convexo da UC,  $\alpha_k = 0,25$ . O ponto fora de  $X$  nem é avaliado. O que fazemos com cada ponto novo?

dominado



eliminar

não dominado



entra na lista


domina pontos da lista



entra, e esses saem

É praticamente todo o mecanismo do DMS.

# Uma iteração em quatro passos



## Sucesso

$L_{k+1} \neq L_k$ : a lista mudou. O passo mantém-se (ou aumenta).

## Insucesso

$L_{k+1} = L_k$ : a lista não mudou.  $\alpha_k$  diminui — só o do centro sondado.

## A lista: $L_k = \{(x; \alpha)\}$

Cada elemento da lista guarda

- uma **solução**  $x$ , admissível;
- o seu **passo**  $\alpha$  — cada ponto tem o seu.

Os pontos da lista são **não dominados entre si**: a lista é, em cada iteração, a **aproximação não dominada corrente**.

O centro é escolhido da lista e fica nela enquanto não for dominado.

### Porquê um passo por ponto?

Numa região já bem explorada, o passo desse ponto já diminuiu; um ponto novo, noutra zona da frente, começa com um passo maior. A lista refina umas zonas sem parar a exploração de outras.

- **filter**: juntar à lista os pontos sondados e **manter só os não dominados**.
- **select**: decidir quanto da lista filtrada guardar. Nesta UC, tudo:  $L_{\text{tent}} = L_{\text{filt}}$ , porque queremos aproximar a frente inteira.
- **order**: escolher quem é sondado a seguir. Regra simples (FIFO): o centro sondado vai para o fim da lista — todos acabam sondados.

## Outras opções (artigo)

- ordenar pela maior lacuna  $\Gamma$  entre vizinhos na frente;
- começar com vários pontos ( $\text{DMS}(n, \text{line})$ );
- *cache*: não reavaliar pontos já avaliados.

# O algoritmo DMS (Algoritmo 2.1 do artigo)

**DMS** — dados  $x_0 \in X$ ,  $\alpha_0 > 0$ ,  $0 < \beta_1 \leq \beta_2 < 1$ ,  
 $\gamma \geq 1$ ,  $\mathcal{D}$ ;  $L_0 = \{(x_0; \alpha_0)\}$

```
1: for  $k = 0, 1, 2, \dots$  do  
2:   Seleção: ordenar  $L_k$ ;  $(x_k; \alpha_k) \leftarrow$  primeiro elemento  
3:   Pesquisa (opcional): avaliar  $f_X$  num conjunto finito; se  
    sucesso, saltar 4–5  
4:   Sondagem: avaliar  $f_X$  em  $\{x_k + \alpha_k d : d \in D_k\}$ ;  $L_{\text{add}} \leftarrow$   
     $\{(x_k + \alpha_k d; \alpha_k)\}$   
5:    $L_{\text{filt}} \leftarrow \text{filter}(L_k, L_{\text{add}})$ ;  $L_{\text{tent}} \leftarrow \text{select}(L_{\text{filt}})$   
6:   se  $L_{\text{tent}} \neq L_k$ : sucesso,  $L_{k+1} \leftarrow L_{\text{tent}}$ ; senão insucesso,  
     $L_{k+1} \leftarrow L_k$   
7:   Passo: sucesso  $\Rightarrow \alpha_{\text{novo}} \in [\alpha_k, \gamma \alpha_k]$  nos pontos novos e em  
     $x_k$ , se continuar na lista; insucesso  $\Rightarrow \alpha_{\text{novo}} \in [\beta_1 \alpha_k, \beta_2 \alpha_k]$  em  
     $x_k$   
8: end for
```

## Essencial

seleção + **sondagem** + filter

*Search*: opcional (espalhar, modelos). **A sondagem sustenta a teoria** — como no GLODS (5.1).

Custo: até  $|D_k|$  avaliações do vetor  $f$  por sondagem ( $2n$  com  $[I - I]$ ); paralelizável. Paragem:  $\alpha < \alpha_{\min}$  em toda a lista, ou orçamento  $N_{\max}$ .

## SP1: uma iteração à mão

$$\min ((x_1 - 1)^2 + (x_1 - x_2)^2, (x_1 - x_2)^2 + (x_2 - 3)^2), -1 \leq x_1, x_2 \leq 5; \quad L_0 = \{(1,5; 1,5)\}, \quad \alpha_0 = 1, \\ D = [I \quad -I].$$

Centro (1,5; 1,5):  $f = (0,25; 2,25)$ .

Sondados  $x_k \pm e_i$ :

| ponto      | f            |
|------------|--------------|
| (2,5; 1,5) | (3,25; 3,25) |
| (1,5; 2,5) | (1,25; 7,25) |
| (0,5; 1,5) | (1,25; 3,25) |
| (1,5; 0,5) | (1,25; 7,25) |

As iterações 1 e 2 à mão estão no artigo (secção 3). O código MATLAB original do DMS ([www.mat.uc.pt/dms](http://www.mat.uc.pt/dms)) é distribuído na aula.

## SP1: uma iteração à mão

$$\min ((x_1 - 1)^2 + (x_1 - x_2)^2, (x_1 - x_2)^2 + (x_2 - 3)^2), -1 \leq x_1, x_2 \leq 5; \quad L_0 = \{(1,5; 1,5)\}, \quad \alpha_0 = 1, \\ D = [I \quad -I].$$

Centro (1,5; 1,5):  $f = (0,25; 2,25)$ .

Sondados  $x_k \pm e_i$ :

| ponto      | f            |
|------------|--------------|
| (2,5; 1,5) | (3,25; 3,25) |
| (1,5; 2,5) | (1,25; 3,25) |
| (0,5; 1,5) | (1,25; 3,25) |
| (1,5; 0,5) | (1,25; 7,25) |

**Filtro.** (1,25; 1,25) e (0,25; 2,25) são incomparáveis: **entra**. Os outros três são dominados por (1,25; 1,25): **eliminados**.

As iterações 1 e 2 à mão estão no artigo (secção 3). O código MATLAB original do DMS ([www.mat.uc.pt/dms](http://www.mat.uc.pt/dms)) é distribuído na aula.

## SP1: uma iteração à mão

$$\min ((x_1 - 1)^2 + (x_1 - x_2)^2, (x_1 - x_2)^2 + (x_2 - 3)^2), -1 \leq x_1, x_2 \leq 5; \quad L_0 = \{(1,5; 1,5)\}, \quad \alpha_0 = 1, \\ D = [I \quad -I].$$

Centro  $(1,5; 1,5)$ :  $f = (0,25; 2,25)$ .

Sondados  $x_k \pm e_i$ :

| ponto        | f              |
|--------------|----------------|
| $(2,5; 1,5)$ | $(3,25; 3,25)$ |
| $(1,5; 2,5)$ | $(1,25; 1,25)$ |
| $(0,5; 1,5)$ | $(1,25; 3,25)$ |
| $(1,5; 0,5)$ | $(1,25; 7,25)$ |


**Filtro.**  $(1,25; 1,25)$  e  $(0,25; 2,25)$  são incomparáveis: **entra**. Os outros três são dominados por  $(1,25; 1,25)$ : **eliminados**.

**Resultado.**  $L_1 = \{(1,5; 2,5), (1,5; 1,5)\}$ : a lista passou de **1 para 2** pontos. **Sucesso**;  $\alpha = 1$  mantém-se.  $n_f = 1 + 4 = 5$ .

As iterações 1 e 2 à mão estão no artigo (secção 3). O código MATLAB original do DMS ([www.mat.uc.pt/dms](http://www.mat.uc.pt/dms)) é distribuído na aula.


## SP1: a frente emerge

Fim da iteração 0:  $|L_1| = 2$  (a página anterior).



## SP1: a frente emerge


Fim da iteração 1: entra mais um ponto,  $|L_2| = 3$ .



## SP1: a frente emerge


Fim da iteração 2: a lista não muda

— **insucesso**:  $|L_3| = 3$  e o passo do centro passa a  $\frac{1}{2}$ .




## SP1: a frente emerge

Ao fim de 10 iterações:  $|L_{10}| = 5$ ,  
 $n_f = 41$ .



## SP1: a frente emerge


Ao fim de 20:  $|L_{20}| = 12$ ,  $n_f = 81$ .



# SP1: a frente emerge

Ao fim de 100:  $|L_{100}| = 63$ ,  $n_f = 401$ .

Uma aproximação da frente  
emerge da própria pesquisa direta  
— sem pesos nem limites.



## Sucesso: $L_{k+1} \neq L_k$

Não é preciso que um ponto domine o centro: basta **melhorar a aproximação não dominada** (na iteração 0 do SP1, o ponto novo não dominava o centro — era incomparável).

## Insucesso: $L_{k+1} = L_k$

Nenhum ponto sondado altera a lista. Então  $\alpha$  diminui **apenas para o centro sondado** (SP1, iteração 2:  $\alpha = 1 \rightarrow \frac{1}{2}$  só em  $(1,5; 1,5)$ ).

## Restrições: barreira extrema (5.1)

$$f_X(x) = \begin{cases} f(x), & x \in X \\ (+\infty, \dots, +\infty), & x \notin X \end{cases}$$

Fora de  $X$  **nem se avaliam os objetivos**: basta saber “admissível ou não”. Serve para restrições de caixa negra.

# O que significa estacionariedade com vários objetivos?

**Um objetivo:** não existe direção admissível que faça  $f$  descer.

**Vários objetivos:** não existe direção admissível que faça **todos os objetivos** **descerem ao mesmo tempo**.

## Ponto crítico de Pareto–Clarke

$$\forall d \in T_X^{Cl}(x^*) \quad \exists i : f_i^\circ(x^*; d) \geq 0.$$

Se as  $f_i$  são estritamente diferenciáveis (p. ex.  $C^1$ ):

$$\forall d \in T_X^{Cl}(x^*) \quad \exists i : \nabla f_i(x^*)^T d \geq 0.$$

$T_X^{Cl}$ : cone tangente de Clarke;  $f_i^\circ$ : derivada direcional generalizada (Clarke–Jahn), para  $f_i$  só  $L$ -Lipschitz (R). Definição em 5.1.

# O que significa estacionariedade com vários objetivos?

**Um objetivo:** não existe direção admissível que faça  $f$  descer.

**Vários objetivos:** não existe direção admissível que faça **todos os objetivos** **descerem ao mesmo tempo**.

**Não** significa  $\nabla f_i = 0$  para todo o  $i$ : basta que, em cada direção, *algum* objetivo não desça.

## Ponto crítico de Pareto–Clarke

$$\forall d \in T_X^{Cl}(x^*) \quad \exists i : f_i^\circ(x^*; d) \geq 0.$$

Se as  $f_i$  são estritamente diferenciáveis (p. ex.  $C^1$ ):

$$\forall d \in T_X^{Cl}(x^*) \quad \exists i : \nabla f_i(x^*)^T d \geq 0.$$

$T_X^{Cl}$ : cone tangente de Clarke;  $f_i^\circ$ : derivada direcional generalizada (Clarke–Jahn), para  $f_i$  só  $L$ -Lipschitz (R). Definição em 5.1.

# O que o DMS garante — e o que não garante

Com iterandos num compacto (aqui,  $X$  limitado) e malha racional ou decréscimo suficiente  $\Rightarrow \alpha_k \rightarrow 0$  numa subsucessão de insucessos  $\Rightarrow$  ponto limite  $x_*$

$\Rightarrow f_i$  Lipschitz perto de  $x_*$  e direções refinantes densas:  $x_*$  é crítico de Pareto–Clarke

Com  $D$  fixo (como aqui,  $D = [I \ -I]$ ): para cada  $d \in D$ ,  $\exists i : f_i^\circ(x_*; d) \geq 0$  (só nessas direções).

## Garante


- um ponto limite com a estacionariedade adequada;
- sem derivadas (só Lipschitz local), com restrições por barreira extrema;
- com  $m = 1$ , a teoria da pesquisa direta.

## Não garante

- que a *lista inteira* converge para a frente;
- que esse ponto seja eficiente (nem sequer localmente);
- boa distribuição ao longo da frente.

“Convergência global”: não é preciso começar perto da solução — **não** significa ótimo global. Condição **necessária local**.

# DMS nos dois exemplos da UC



DMS(1) do centro da caixa,  $\alpha_0 = 1$ ,  $D = [I \ -I]$ , FIFO, sem cache,  $N_{\max} = 300$  (a sondagem em curso completa-se:  $n_f \leq N_{\max} + 2n - 1$ , contando a avaliação inicial). Convexo: **55 pontos**, HV 1,641 (exata 1,648); não convexo: **38 pontos**, HV 1,116 (exata 1,148), com  $r = (1,1; 1,65)$ .

Uma execução constrói uma aproximação inteira. Em 6.3/6.4, cada ponto era uma otimização completa.

(Uma execução com centenas de avaliações: não é automaticamente mais barata. Comparação a sério: HV vs.  $n_f$ , 6.6.)

# A implementação importa

Variantes, no exemplo não convexo (resultados nossos),  $N_{\max} = 300$ :

| variante                      | it. | $n_f$ | $ L $ | HV    |
|-------------------------------|-----|-------|-------|-------|
| DMS(1), FIFO                  | 98  | 301   | 38    | 1,116 |
| DMS( $n$ ,line), FIFO         | 108 | 302   | 50    | 1,136 |
| DMS(1), espalhamento $\Gamma$ | 97  | 301   | 40    | 1,118 |
| DMS(1), FIFO, <i>cache</i>    | 232 | 303   | 79    | 1,138 |

## Não reavaliar o que já sabemos

Sem *cache*, **mais de metade** das avaliações repetia pontos já avaliados (cerca de um terço, pontos da própria lista). Com ela, o mesmo orçamento dá mais iterações e o dobro dos pontos.

Começar com vários pontos (segmento) também ajuda; o espalhamento pouco muda *aqui*.

# O artigo de 2011 e uma aplicação real

**Testes:** 100 problemas com limites,  $1 \leq n \leq 30$ ,  $2 \leq m \leq 4$ , orçamento comum de 20 000 avaliações; comparação com AMOSA, BIMADS e NSGA-II.

- o DMS foi **competitivo** na qualidade das frentes;
- muito bom **espalhamento**;
- o NSGA-II foi ligeiramente mais eficiente numa das métricas de distribuição.

Neste conjunto de problemas, com estes parâmetros e este orçamento. O detalhe (métricas, perfis) está no artigo.

## OTIMIZAÇÃO NA PRÁTICA

Painéis sanduíche viscoelásticos: maximizar o amortecimento, minimizar massa e custo; modelo de elementos finitos. O DMS usado **trabalha só com variáveis reais**: as escolhas discretas (material e espessura de cada camada, orientação, espessura do núcleo) foram *codificadas* em 25 variáveis reais em  $[0, 4]$ . Com massa  $\leq 1,5$  kg, o DMS devolveu **14 579** soluções não dominadas.

Madeira et al., Compos. Part B 77:391–401, 2015.

**Nota.** O material foi codificado por subintervalos (alumínio  $[1, 2]$ , GFRP  $[2, 3]$ , CFRP  $[3, 4]$ ): isto impõe uma **ordem artificial** a uma variável *categórica* — um passo pequeno pode “trocar de material” só por atravessar um limite arbitrário. Tratar as categóricas nativamente é o que faz o DMS-SI-Mix.

## O QUE DEVE FICAR — 6.5

1. O DMS é **pesquisa direta multiobjetivo**: em vez de um iterando, mantém uma **lista** de soluções não dominadas.
2. Sonda um centro da lista e usa a **dominância** para a atualizar; nada é agregado.
3. **Sucesso** = a lista mudou; **insucesso** reduz o passo do centro sondado.
4. Uma execução pode construir uma **aproximação** com muitos pontos não dominados, mesmo para frentes não convexas.
5. A teoria garante estacionariedade de Pareto–Clarke de um ponto limite, sob hipóteses — uma condição necessária local, não convergência da lista para a frente global.

E se, em vez de uma lista construída por sondagem, mantivermos uma população que evolui?

→ **6.6 NSGA-II**

**Referências**    Lista completa: *Bibliografia da UC*, no fim do PDF da UC.

- Custódio, A. L., Madeira, J. F. A., Vaz, A. I. F., Vicente, L. N., *Direct multisearch for multiobjective optimization*, SIAM Journal on Optimization 21(3):1109–1140, 2011 — o artigo do DMS.
- Custódio, A. L., Madeira, J. F. A., *MultiGLODS: global and local multiobjective optimization using direct search*, Journal of Global Optimization 72(2):323–345, 2018 — MultiGLODS.
- Madeira, J. F. A., *Multiobjective and global optimization with directional direct search*, Tese de Doutoramento em Matemática, IST, Universidade de Lisboa, 2019.

## Recursos

- Para além da UC: *DMS-SI-Mix*, com invariância de escala e variáveis contínuas, *discretas* (valores com ordem: número de camadas, espessuras de catálogo) e *categóricas* (opções sem ordem: o material) tratadas nativamente.
- Código MATLAB original do DMS, distribuído na aula: [www.mat.uc.pt/dms](http://www.mat.uc.pt/dms) (nenhuma função da UC).