

Otimização

6.6 NSGA-II (algoritmos genéticos multiobjetivo)

José Firmino Aguilar Madeira

Do AG ao NSGA-II: quem ganha o torneio?

6.5: uma lista construída por sondagem.

6.6: uma **população que evolui**.

No AG do 5.3, $f(\mathbf{x}_a) < f(\mathbf{x}_b)$ decidia o torneio.

Agora $\mathbf{f}(\mathbf{x}) = (f_1(\mathbf{x}), \dots, f_m(\mathbf{x}))$ e muitas vezes

$$\mathbf{x}_a \not\prec \mathbf{x}_b \quad \text{e} \quad \mathbf{x}_b \not\prec \mathbf{x}_a.$$

Do AG ao NSGA-II: quem ganha o torneio?

6.5: uma lista construída por sondagem.

6.6: uma população que evolui.

No AG do 5.3, $f(\mathbf{x}_a) < f(\mathbf{x}_b)$ decidia o torneio.

Agora $\mathbf{f}(\mathbf{x}) = (f_1(\mathbf{x}), \dots, f_m(\mathbf{x}))$ e muitas vezes

$$\mathbf{x}_a \not\prec \mathbf{x}_b \quad \text{e} \quad \mathbf{x}_b \not\prec \mathbf{x}_a.$$

Quem ganha o torneio?

Como se faz seleção num AG quando não há uma aptidão escalar?

(Deb, Pratap, Agarwal e Meyarivan, 2002)

A resposta tem dois ingredientes

1. Convergência

Preferir quem está numa **frente melhor** da população:

rank de dominância

2. Diversidade

Entre soluções igualmente boas por dominância, preferir as de **regiões menos ocupadas**:


distância de aglomeração (*crowding*)

$$\text{NSGA-II} = \textit{rank} + \textit{crowding}$$

As duas metas do 6.2 tornaram-se os **dois critérios de seleção**.

Ordenação não dominada: o *rank*


Oito soluções. Quais são não dominadas?



Ordenação não dominada: o *rank*

Oito soluções. Ninguém domina 1, 2, 4 e 8:

$$F_1 = \{1, 2, 4, 8\} \quad (\text{rank } 1).$$



Ordenação não dominada: o *rank*

Oito soluções. Ninguém domina 1, 2, 4 e 8:

$$F_1 = \{1, 2, 4, 8\} \quad (\text{rank } 1).$$


Retiradas estas, repete-se nas restantes:

$$F_2 = \{3, 5, 6, 7\} \quad (\text{rank } 2).$$

rank 1 é melhor do que rank 2


Atenção

F_1 é a primeira frente da população atual
— não é necessariamente a frente de Pareto Y_N (6.2).



Distância de aglomeração: o *crowding*

Só há lugar para 3 dos 4 pontos de F_1 . Por dominância, 1, 2, 4 e 8 são indistinguíveis. Qual sai?



Distância de aglomeração: o *crowding*

Só há lugar para 3 dos 4 pontos de F_1 . Por dominância, 1, 2, 4 e 8 são indistinguíveis. Qual sai?


Queremos preservar a **diversidade**: sai o que está numa região mais povoada. Os extremos recebem $d = \infty$; para os outros, ordenando por cada objetivo,

$$d_p = \sum_i \frac{f_i(\text{seguinte}) - f_i(\text{anterior})}{f_i^{\max} - f_i^{\min}}.$$

Ponto 2 (vizinhos 1 e 4):

$$d_2 = \frac{4-1}{7-1} + \frac{6-1,5}{6-1} = 0,5 + 0,9 = 1,4.$$

Ponto 4: $d_4 = 1,233$.



Distância de aglomeração: o *crowding*

Só há lugar para 3 dos 4 pontos de F_1 . Por dominância, 1, 2, 4 e 8 são indistinguíveis. Qual sai?

Queremos preservar a **diversidade**: sai o que está numa região mais povoada. Os extremos recebem $d = \infty$; para os outros, ordenando por cada objetivo,

$$d_p = \sum_i \frac{f_i(\text{seguinte}) - f_i(\text{anterior})}{f_i^{\max} - f_i^{\min}}.$$


Ponto 2 (vizinhos 1 e 4):

$$d_2 = \frac{4-1}{7-1} + \frac{6-1,5}{6-1} = 0,5 + 0,9 = 1,4.$$

Ponto 4: $d_4 = 1,233$.

Ficam 1, 2 e 8; sai o 4.

maior d = região menos povoada = maior prioridade



Operador $\prec_n$ (*crowded comparison*)


$$p \prec_n q \text{ se } \text{rank}(p) < \text{rank}(q) \text{ ou } (\text{rank}(p) = \text{rank}(q) \text{ e } d_p > d_q).$$

Primeiro convergência; em empate, diversidade.

É assim que se decide o torneio binário.

Não é uma nova relação de dominância: é uma regra de desempate para seleccionar.


Elitismo: pais e filhos competem



1. Os N pais P_t geram N filhos Q_t .
2. Junta-se tudo: $R_t = P_t \cup Q_t$, com $2N$ soluções.
3. Ordena-se R_t em frentes $F_1, F_2, \dots$.
4. Enche-se P_{t+1} frente a frente, enquanto couberem inteiras.
5. A primeira que não cabe é cortada por *crowding*.

Os melhores pais podem sobreviver diretamente: **elitismo**.

Uma geração do NSGA-II



Seleção para reprodução

Quem gera filhos? Torneio: **estocástica**.

Seleção ambiental

Quem sobrevive? Truncagem de $P_t \cup Q_t$: **determinística**, dados P_t e Q_t .

O elitismo está na segunda.

NSGA-II: $N, G, p_c, p_m \leftarrow P_0 \leftarrow N$ pontos aleatórios na caixa $[x^{(L)}, x^{(U)}]$

```
1: avaliar  $f$  em  $P_0$ 
2: for  $t = 0, \dots, G - 1$  do
3:   ordenar  $P_t$  em frentes; calcular  $d_p$  em cada frente
4:    $Q_t \leftarrow N$  filhos: torneio binário por  $\prec_n$ , SBX, mutação polinomial; avaliar
5:    $R_t \leftarrow P_t \cup Q_t$ ; nova ordenação em frentes e novo  $d_p$ 
6:    $P_{t+1} \leftarrow F_1 \cup F_2 \cup \dots$  enquanto couberem; truncar a primeira que não
      cabe pelos maiores  $d_p$ 
7: end for
8: return  $F_1$  de  $P_G$ 
```


SBX e mutação polinomial: operadores reais de Deb ($\eta_c \approx 15\text{--}20$, $\eta_m \approx 20$, $p_m = 1/n$), no lugar do BLX e da mutação gaussiana do 5.3: filhos perto dos pais, dispersão controlada por η_c, η_m .

Custo: N avaliações por geração + $O(mN^2)$ na ordenação. Se avaliar f exige uma simulação (elementos finitos, CFD), são normalmente as avaliações que dominam — e as N de uma geração são **paralelizáveis**.

E se houver restrições?

Regra de Deb: admissível vence inadmissível; entre inadmissíveis, menor violação; entre admissíveis, dominância normal. **Sem penalização a calibrar** (4.3.1).


NSGA-II em ação: gerações 0 a 50



Exemplo convexo da UC, $N = 40$. Geração 0: população aleatória, 6 não dominados. Geração 5: quase todos perto da frente, mal distribuídos. Geração 20: boa cobertura. Geração 50: refinamento — HV 1,637 (exata 1,648; $r = (1,1; 1,65)$), 2040 avaliações.

Implementação didática nossa; a restrição $x_1^2 + x_2^2 \leq 1$ tratada pela regra de Deb, como acima.

NSGA-II em ação: gerações 0 a 50




Exemplo convexo da UC, $N = 40$. Geração 0: população aleatória, 6 não dominados. Geração 5: quase todos perto da frente, mal distribuídos. Geração 20: boa cobertura. Geração 50: refinamento — HV 1,637 (exata 1,648; $r = (1,1; 1,65)$), 2040 avaliações.

Implementação didática nossa; a restrição $x_1^2 + x_2^2 \leq 1$ tratada pela regra de Deb, como acima.

O que está a fazer o *rank*? Aproximar a população da frente.

E o *crowding*? Distribuí-la ao longo dela.

NSGA-II em ação: gerações 0 a 50



Exemplo convexo da UC, $N = 40$. Geração 0: população aleatória, 6 não dominados. Geração 5: quase todos perto da frente, mal distribuídos. Geração 20: boa cobertura. Geração 50: refinamento — HV 1,637 (exata 1,648; $r = (1,1; 1,65)$), 2040 avaliações.

Implementação didática nossa; a restrição $x_1^2 + x_2^2 \leq 1$ tratada pela regra de Deb, como acima.

O que está a fazer o *rank*? Aproximar a população da frente.

E o *crowding*? Distribuí-la ao longo dela.

Primeiro *chegar à frente*, depois *espalhar-se nela*: as duas metas do 6.2.

No computador: MATLAB e Python

MATLAB (Global Optimization Toolbox)

```
[x,fval] = gamultiobj(fun, nvars, ...  
    [],[],[],[], lb, ub, nonlcon);
```

gamultiobj é uma **variante** da família NSGA-II: não é preciso implementar ordenação, *crowding* ou SBX para resolver um problema.

Python (pymoo)


```
from pymoo.algorithms.moo.nsga2 import NSGA2  
from pymoo.optimize import minimize  
  
algorithm = NSGA2(pop_size=40)  
res = minimize(problem, algorithm,  
               ('n_gen', 50), seed=1)  
res.X, res.F      # decisoes e objetivos da aproximacao final
```

pop_size = N n_gen = G
res.X: soluções res.F: objetivos

Aqui pede-se explicitamente o NSGA-II. Trocar NSGA2 por NSGA3 ou MOEAD: o problema fica igual; muda a estratégia para obter convergência + diversidade. seed=1: reprodutível (3.2.1, 5.2, 5.3).

Código complementar da UC: nsga2_exemplo_uc.py (exemplo convexo da UC). O script imprime: 40 pontos, n_eval = 2000 (no pymoo a população inicial conta como 1.ª das 50 gerações), HV 1,636 ($r = (1,1; 1,65)$). A nossa implementação (inicial + 50 gerações): 2040 avaliações, HV 1,637.

DMS vs. NSGA-II, no mesmo problema



orçamento n_f	DMS	NSGA-II med.	[Q1; Q3]
100	1,064	0,986	[0,968; 1,006]
200	1,094	1,083	[1,066; 1,096]
400	1,123	1,125	[1,117; 1,129]
800	1,139	1,132	[1,131; 1,133]
2000	1,144	1,132	[1,132; 1,133]

- Exemplo não convexo: também o NSGA-II apanha pontos *non-supported* — usa dominância, não pesos.
- Mesmo indicador, referência e orçamento:** DMS numa curva (determinístico); NSGA-II em 20 corridas, mediana e quartis. Frente exata: 1,148 ($r = (1,1; 1,65)$). Cada orçamento usa a última geração completa do NSGA-II que não o excede.
- A 100 avaliações o DMS(1) está à frente; a 200–400 empatam; depois o NSGA-II estabiliza perto de 1,132 e o DMS continua (1,144).
- Neste problema, com estes parâmetros e este orçamento.** Noutros problemas (rugosos, frentes em vários troços) a população pode ser vantajosa.

NSGA-II

$$|P_t| = N$$

A aproximação final tem no máximo N pontos: a **resolução** da representação da frente fica limitada pela população (aqui, $N = 40$: estabiliza perto de HV 1,132).

DMS

$|L_k|$ pode crescer

A lista vai ganhando pontos à medida que a sondagem refina: a resolução **aumenta com o orçamento**.

Uma diferença **estrutural** — mais interessante do que “qual ganhou”.

Vantagens

- muitos pontos numa corrida;
- *supported* e *non-supported*;
- não requer derivadas;
- flexível: diferentes representações e operadores permitem tratar variáveis contínuas, discretas, permutações e restrições;
- avaliações paralelizáveis;
- bibliotecas maduras.

Limitações

- muitas avaliações;
- estocástico $\rightarrow$ várias corridas;
- vários parâmetros ($N, p_c, p_m, \eta_c, \eta_m$);
- população fixa limita a resolução;
- sem garantia de frente global com orçamento finito;
- com muitos objetivos, a dominância perde poder de discriminação.

O problema é sempre o mesmo: como criar pressão para convergir e, ao mesmo tempo, manter diversidade?

NSGA-II (2002) *rank + crowding*

MOEA/D (2007) decomposição em subproblemas escalares (Tchebycheff, 6.3)

NSGA-III (2014) pontos de referência — pensado para muitos objetivos

Outro clássico: SPEA2 (2001), com aptidão por “força” de dominância e arquivo externo.

Quadro de consulta — capítulo 6

	soma ponderada	ε -constrang.	DMS	NSGA-II
um ponto ou uma frente?	um (por $\mathbf{w}$)	um (por ε)	frente	frente
precisa de derivadas?	as do solver	as do solver	não	não
frente não convexa?	só <i>supported</i>	sim*	sim	sim
custo	uma otimização completa por ponto	uma otimização completa por ponto	até $2n$ avaliações de $\mathbf{f}$ por sondagem	N avaliações por geração
determinístico?	se o solver o for	se o solver o for	na versão apresentada	não (várias corridas)
controlo da posição	fraco	direto	—	—
garantia	eficiente ($w_i > 0$, minimizante global)	única $\Rightarrow$ eficiente; qualquer eficiente recuperável*	ponto limite Pareto–Clarke crítico (Lipschitz, direcções densas)	nenhuma com orçamento finito

* com ε adequado e solução global do subproblema. Para estudo. Na aula: as duas páginas seguintes.

O QUE DEVE FICAR — 6.6

1. O NSGA-II é um AG multiobjetivo: *rank* de dominância + *crowding* substituem a aptidão escalar.
2. *Rank* → **convergência**; *crowding* → **diversidade**.
3. O **elitismo** vem de $P_t \cup Q_t$ e da escolha dos N sobreviventes.
4. Uma corrida dá muitos pontos, incluindo *non-supported*, mas é estocástica: **várias corridas, mediana e quartis** para comparar.
5. Custo: N avaliações por geração; a população fixa limita a resolução e, com muitos objetivos, a dominância perde poder seletivo.

vários objetivos $\Rightarrow$ em geral, **não há uma única melhor solução**

dominância $\Rightarrow$ um **conjunto de compromissos** (a frente de Pareto)

boa aproximação = **convergência** + **diversidade**

um ponto de cada vez (6.3, 6.4) ou muitos pontos numa execução (6.5, 6.6)

otimização $\rightarrow$ **compromissos** $\rightarrow$ **decisão**

E fecha-se a UC: de um mínimo de uma função de uma variável (cap. 2) a um conjunto de compromissos entre vários objetivos (cap. 6) — sempre com as mesmas perguntas: que informação sobre **f** temos, quanto custa, o que se garante.

Referências e recursos

Referências Lista completa: *Bibliografia da UC*, no fim do PDF da UC.

- Deb, K., Pratap, A., Agarwal, S., Meyarivan, T., *A fast and elitist multiobjective genetic algorithm: NSGA-II*, IEEE Transactions on Evolutionary Computation 6(2):182–197, 2002 — o artigo do NSGA-II.
- Deb, K., *Multi-Objective Optimization Using Evolutionary Algorithms*, Wiley, 2001.
- Madeira, J. F. A., *Optimização multi-objectivo da topologia de estruturas com algoritmos genéticos*, Tese de Doutoramento em Engenharia Mecânica, IST, Universidade Técnica de Lisboa, 2004 — AG multiobjetivo, em português.
- Deb, K., *An efficient constraint handling method for genetic algorithms*, Computer Methods in Applied Mechanics and Engineering 186(2–4):311–338, 2000 — regra de Deb.

Recursos

- Código complementar: `nsga2_exemplo_uc.py` (pymoo). MATLAB: `gamultiobj` (Global Optimization Toolbox).
- Python (pymoo): `NSGA2(pop_size=...), minimize(problem, algorithm, ('n_gen', G), seed=1), res.X, res.F`; alternativas NSGA3, MOEAD.