

Otimização

R. Pré-requisitos e revisão: geometria, cálculo diferencial e álgebra linear

José Firmino Aguilar Madeira

Porquê estas revisões?

Os métodos de otimização que vamos estudar assentam em quatro ferramentas:

- **Vetores e retas** — cada iteração de um método é um passo $x_{k+1} = x_k + \alpha_k d_k$ ao longo de uma reta (esquema iterativo: ver 1.1).
- **Gradiente** — quando $\nabla f \neq 0$, dá a direção de maior crescimento de f ; $-\nabla f$ é a direção de descida mais rápida.
- **Hessiana e valores próprios** — ajudam a classificar os pontos estacionários.
- **Convexidade** — relaciona mínimos locais e globais (ver 1.1).

Vetores, retas e hiperplanos

Ângulo entre dois vetores


Para $u, v \in \mathbb{R}^n$, ambos não nulos, o **produto interno** é

$$\langle u, v \rangle = u^T v = \sum_{i=1}^n u_i v_i = \|u\| \|v\| \cos \theta.$$

Logo o ângulo $\theta \in [0, \pi]$ entre u e v é

$$\theta = \arccos\left(\frac{\langle u, v \rangle}{\|u\| \|v\|}\right).$$

- $\langle u, v \rangle = 0 \iff u \perp v$
- $\langle u, v \rangle > 0 \iff \theta < 90^\circ$ (“mesmo sentido”)




Equação paramétrica da reta

A reta R que passa por x_0 com a direção de $v \neq 0$ é

$$r(t) = x_0 + t v, \quad t \in \mathbb{R}.$$

- x_0 — ponto inicial
- v — vetor diretor
- t — parâmetro escalar

Cada ponto do espaço é identificado com o seu vetor de posição.



Exemplo 1

Reta que passa por $x_0 = (1, 1, 1)^T$ na direção de $v = (1, 1, 0)^T$:

$$r(t) = (1, 1, 1)^T + t(1, 1, 0)^T = (1 + t, 1 + t, 1)^T, \quad t \in \mathbb{R}.$$

Exemplo 2 — da forma paramétrica para a cartesiana

Seja $r(t) = (4 - 2t, 3 + 6t)^T$ em $\mathbb{R}^2$. De $x = 4 - 2t$ vem $t = \frac{4 - x}{2}$ e

$$y = 3 + 6 \cdot \frac{4 - x}{2} = 15 - 3x.$$

Dados dois pontos $u \neq s$, o **segmento** que os une é

$$r(t) = u + t(s - u) = (1 - t)u + ts, \quad 0 \leq t \leq 1.$$

($t = 0$ dá u , $t = 1$ dá s .)

Exemplo 3

Segmento entre $(0, 2)$ e $(2, 0)$:

$$r(t) = (1 - t)(0, 2) + t(2, 0) = (2t, 2 - 2t), \quad 0 \leq t \leq 1.$$

Esta expressão reaparece na definição de **conjunto convexo**.

Hiperplano

Um hiperplano generaliza a reta e o plano para n dimensões:

Espaço	Equação	Objeto
$\mathbb{R}^2$	$a_1x_1 + a_2x_2 = b$	reta (dimensão 1)
$\mathbb{R}^3$	$a_1x_1 + a_2x_2 + a_3x_3 = b$	plano (dimensão 2)
$\mathbb{R}^n$	$a_1x_1 + \cdots + a_nx_n = a^T x = b, \quad a \neq 0$	hiperplano (dimensão $n - 1$)

- Um hiperplano de $\mathbb{R}^n$ é o conjunto $\{x : a^T x = b\}$ com $a \neq 0$; o vetor a é **normal** ao hiperplano.
- Um hiperplano divide $\mathbb{R}^n$ em dois semiespaços: $a^T x \leq b$ e $a^T x \geq b$.
- Restrições lineares de um problema de otimização definem hiperplanos e semiespaços.

Funções de várias variáveis


Gráfico de uma função

Dada $f: S \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$, o **gráfico** de f é o subconjunto de $\mathbb{R}^{n+1}$

$$\{(x, x_{n+1}) \in \mathbb{R}^n \times \mathbb{R} : x \in S, x_{n+1} = f(x)\}.$$

- $n = 1$: curva $y = f(x)$ no plano.
- $n = 2$: superfície $z = f(x, y)$ no espaço.

Exemplo. $f(x, y) = x^2 + 2y^2$ está definida em $\mathbb{R}^2$; o gráfico é uma superfície em $\mathbb{R}^3$.



Conjuntos de nível


Seja $f: D \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ e $c \in \mathbb{R}$. O **conjunto de nível** c é

$$\{x \in D : f(x) = c\},$$



isto é, os pontos do domínio onde f vale c . Em $\mathbb{R}^2$ é, em geral, uma **curva de nível**; em $\mathbb{R}^3$, uma **superfície de nível**.

Exemplo. Para $f(x, y) = x^2 + 2y^2$ e $c > 0$, as curvas de nível $x^2 + 2y^2 = c$ são elipses concêntricas (c cresce para fora). Para $c = 0$ o conjunto de nível reduz-se a $\{(0, 0)\}$; para $c < 0$ é vazio.

Em otimização desenham-se curvas de nível para visualizar o percurso dos métodos iterativos.



Curvas de nível — interpretação topográfica



As curvas de nível são as “cotas” de um mapa topográfico: a projeção no plano xy das interseções do gráfico com planos horizontais $z = c$.

Queremos a taxa de variação de $z = f(x)$ no ponto a na direção de um vetor **unitário** u ($\|u\| = 1$).

Definição

Seja $f: D \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$, a interior a D e $\|u\| = 1$. A derivada direcional de f em a na direção u é

$$D_u f(a) = \lim_{h \rightarrow 0} \frac{f(a + hu) - f(a)}{h},$$

se o limite existir.

- A distância entre a e $a + hu$ é $|h|$; o quociente é a taxa média de variação por unidade de comprimento no segmento de a a $a + hu$.
- Depende do ponto a e da direção u .

Exemplo

Seja $f(a)$ a temperatura no ponto a de uma sala com um radiador e a porta aberta. Movendo-nos em direção à porta, a temperatura desce; em direção ao radiador, sobe. A taxa a que varia depende de onde estamos e para onde vamos.

Se $u = e_i$ (vetor da base canónica), $D_{e_i} f(a) = \frac{\partial f}{\partial x_i}(a)$: as derivadas parciais são casos particulares da derivada direcional.

Definição

O gradiente de f , denotado ∇f ou $\text{grad } f$, é o vetor das derivadas parciais:

$$\nabla f(\mathbf{x}) = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right)^T.$$

Se f é diferenciável, a derivada direcional é um produto interno:

$$D_{\mathbf{u}}f(\mathbf{x}) = \sum_{j=1}^n \frac{\partial f}{\partial x_j}(\mathbf{x}) u_j = \nabla f(\mathbf{x})^T \mathbf{u} = \|\nabla f(\mathbf{x})\| \cos \theta,$$

onde θ é o ângulo entre $\nabla f(\mathbf{x})$ e $\mathbf{u}$.

Lipschitz. f é **L-Lipschitz** em S se $|f(\mathbf{x}) - f(\mathbf{y})| \leq L \|\mathbf{x} - \mathbf{y}\|$ para todos $\mathbf{x}, \mathbf{y} \in S$ (gradiente Lipschitz: $\|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\| \leq L \|\mathbf{x} - \mathbf{y}\|$).

Teorema

Se f é diferenciável em x e $\nabla f(x) \neq 0$, o valor máximo de $D_u f(x)$ é $\|\nabla f(x)\|$ e ocorre quando u tem a direção e o sentido de $\nabla f(x)$.


- ∇f aponta para onde f cresce mais depressa; $-\nabla f$ aponta para onde f decresce mais depressa.
- Uma direção d é de **descida** em x se $\nabla f(x)^T d < 0$ (ângulo com o gradiente superior a 90°).
- É a base do método do gradiente (*steepest descent*).

Gradiente e curvas de nível em $\mathbb{R}^2$

Se $\nabla f(x_0, y_0) \neq 0$, o gradiente, além de dar a direção de maior crescimento, é perpendicular à curva de nível $f(x, y) = c$ que passa por (x_0, y_0) .

Ao longo da curva de nível f é constante, logo a derivada direcional na direção tangente é zero: $\nabla f^T u_{\text{tang}} = 0$.


Exemplo. $f = x^2 + 2y^2$, $\nabla f = (2x, 4y)^T$: as setas cruzam as elipses em ângulo reto e apontam para fora (onde c cresce).



Gradiente e superfícies de nível em $\mathbb{R}^3$

Se $\nabla F(P) \neq 0$, o gradiente $\nabla F(x_0, y_0, z_0)$ é perpendicular ao plano tangente à superfície de nível $F(x, y, z) = c$ que passa por $P = (x_0, y_0, z_0)$.

Se $r(t)$ é uma curva na superfície com $r(t_0) = P$, então $F(r(t)) = c$ e, derivando, $\nabla F(P)^T r'(t_0) = 0$: o gradiente é ortogonal a todos os vetores tangentes.



Plano tangente e reta normal a uma superfície

Seja $F(x, y, z) = c$ e $P = (x_0, y_0, z_0)$ um ponto da superfície com $\nabla F(P) \neq 0$.

- **Plano tangente** — vetores que partem de P e são ortogonais a $\nabla F(P)$:

$$\nabla F(P)^T (x - x_0, y - y_0, z - z_0) = 0.$$

- **Reta normal** — passa por P com a direção de $\nabla F(P)$:

$$(x - x_0, y - y_0, z - z_0) = s \nabla F(P), \quad s \in \mathbb{R},$$


ou, em equações simétricas (quando as derivadas parciais são não nulas),

$$\frac{x - x_0}{F_x(P)} = \frac{y - y_0}{F_y(P)} = \frac{z - z_0}{F_z(P)}.$$

Visualizar gradientes em MATLAB

```
[X,Y] = meshgrid(-2:.2:2);  
Z = X.*exp(-X.^2 - Y.^2);  
[DX,DY] = gradient(Z,.2,.2);  
subplot(1,2,1); surf(X,Y,Z)  
subplot(1,2,2); contour(X,Y,Z)  
hold on; quiver(X,Y,DX,DY)
```

Superfície $z = x e^{-x^2 - y^2}$ e o campo de gradientes sobre as curvas de nível.



Matriz Hessiana e valores próprios

Matriz Hessiana

Seja $f: A \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ de classe C^2 numa vizinhança de $a \in A$. A **matriz Hessiana** de f em a (também $\nabla^2 f(a)$; nos métodos, $H_k = \nabla^2 f(x_k)$) é

$$Hf(a) = \left[\frac{\partial^2 f}{\partial x_i \partial x_j}(a) \right]_{i,j=1}^n = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}.$$

Como $f \in C^2$, é uma matriz $n \times n$ **simétrica real** (Schwarz). Veremos a seguir que isso garante valores próprios reais, e que o seu sinal ajuda a classificar pontos estacionários.

Definição

Dada $A \in \mathbb{R}^{n \times n}$, um escalar λ e um vetor $x \neq 0$ tais que


$$Ax = \lambda x$$

dizem-se, respetivamente, **valor próprio** e **vetor próprio** de A .

- λ pode ser complexo mesmo com A real (mas não se A for simétrica).
- **Espectro:** $\lambda(A) = \{\lambda_1, \dots, \lambda_n\}$, o conjunto dos valores próprios.
- **Raio espectral:** $\rho(A) = \max\{|\lambda_1|, \dots, |\lambda_n|\}$.



- $Ax = \lambda x$
- Ax tem a direção de x
- comprimento e sentido de Ax dependem de λ



- $Ay \neq \lambda y$ para todo o λ
- Ay não tem a direção de y
- y não é vetor próprio de A

$$Ax = \lambda x \iff Ax - \lambda Ix = 0 \iff (A - \lambda I)x = 0.$$

Queremos soluções **não triviais** ($x \neq 0$) do sistema homogéneo, o que exige que a matriz dos coeficientes seja singular:

$$\det(A - \lambda I) = 0.$$

- $\det(A - \lambda I)$ é o **polinómio característico**, de grau n em λ ; as suas raízes são os valores próprios.
- Para cada λ_i , os vetores próprios são as soluções não nulas de $(A - \lambda_i I)x = 0$.

Exemplo 1

$$A = \begin{bmatrix} 2 & 1 & 0 & 0 \\ 0 & 2 & 0 & 0 \\ 0 & 0 & -1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \quad \det(A - \lambda I) = (2 - \lambda)^2(-1 - \lambda)(1 - \lambda).$$

Valores próprios: 2 (multiplicidade algébrica 2), -1 e 1 (multiplicidade 1).

Exemplo 2

$$A = \begin{bmatrix} 2 & 2 & -1 \\ 1 & -1 & 0 \\ 3 & 1 & -1 \end{bmatrix}, \quad \det(A - \lambda I) = 2\lambda - \lambda^3 = -\lambda(\lambda - \sqrt{2})(\lambda + \sqrt{2}).$$

Valores próprios: $\lambda_1 = 0$, $\lambda_2 = \sqrt{2}$, $\lambda_3 = -\sqrt{2}$.

Matriz definida positiva

Definição

Uma matriz simétrica $A \in \mathbb{R}^{n \times n}$ é **definida positiva** se

$$x^T A x > 0 \quad \text{para todo o } x \neq 0,$$

e **semidefinida positiva** se $x^T A x \geq 0$ para todo o x .

- A é definida positiva $\iff$ todos os valores próprios são positivos.
- A é semidefinida positiva $\iff$ todos os valores próprios são ≥ 0 .

Exemplo

$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$: $\det(A - \lambda I) = \begin{vmatrix} 2 - \lambda & 1 \\ 1 & 2 - \lambda \end{vmatrix} = \lambda^2 - 4\lambda + 3 = 0 \Rightarrow \lambda_1 = 3, \lambda_2 = 1$. Logo A é definida positiva.

Cr terio de Sylvester

Seja A sim trica. A   definida positiva se e s  se todos os **menores principais l deres** s o positivos:

$$\det[a_{11}] > 0, \quad \det \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} > 0, \quad \det \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} > 0, \quad \dots, \quad \det A > 0.$$

Com Δ_k o menor l der de ordem k : A   **definida negativa** se e s  se $(-1)^k \Delta_k > 0$, $k = 1, \dots, n$.

Aten  o

Para *semidefinida* positiva n o basta olhar para os menores l deres:   preciso que *todos* os menores principais (n o s  os l deres) sejam ≥ 0 . Exemplo: $\begin{bmatrix} 0 & 0 \\ 0 & -1 \end{bmatrix}$ tem menores l deres 0 e 0, mas n o   semidefinida positiva ($\lambda = -1$).

Classificação de pontos estacionários

Seja a um ponto estacionário ($\nabla f(a) = 0$) e sejam $\lambda_{\min}$, $\lambda_{\max}$ o menor e o maior valor próprio de $Hf(a)$. Uma matriz A é (semi)definida negativa se $-A$ for (semi)definida positiva; indefinida se $x^T Ax$ toma os dois sinais. O teste da segunda derivada:

Valores próprios de $Hf(a)$	$Hf(a)$	Conclusão
todos positivos	definida positiva	a é mínimo local estrito
todos negativos	definida negativa	a é máximo local estrito
$\lambda_{\min} = 0$, $\lambda_{\max} > 0$	semidefinida positiva	a não é máximo
$\lambda_{\min} < 0$, $\lambda_{\max} = 0$	semidefinida negativa	a não é mínimo
$\lambda_{\min} < 0$, $\lambda_{\max} > 0$	indefinida	a é ponto de sela
todos nulos	—	inconclusivo


Nos casos semidefinidos e nulo o teste não decide; é preciso analisar termos de ordem superior.
(Mínimo local estrito: ver 1.1.)

Convexidade


Definição 1

Um conjunto $S \subseteq \mathbb{R}^n$ é **convexo** se, para quaisquer $x_1, x_2 \in S$, o segmento que os une está contido em S :

$$(1 - t)x_1 + tx_2 \in S \quad \text{para todo o } t \in [0, 1].$$



convexo





não convexo

Definição 2

$f: S \rightarrow \mathbb{R}$, com S convexo, é **convexa** se o segmento que une dois pontos quaisquer do gráfico nunca fica abaixo do gráfico:

$$f((1-t)x_1 + tx_2) \leq (1-t)f(x_1) + tf(x_2), \quad t \in [0, 1].$$

É **côncava** se a desigualdade vale com $\geq$ (isto é, $-f$ é convexa).



Teorema 1

Num problema de otimização convexo (função objetivo e conjunto admissível convexos; ver 1.1), **qualquer mínimo local é mínimo global**.


Teorema 2

Se f é convexa, o conjunto de nível inferior $L_c = \{x : f(x) \leq c\}$ é convexo para todo o $c \in \mathbb{R}$.

Teorema 3

A interseção de conjuntos convexos é convexa.

Consequência: $\{g_j(x) \geq 0, h_\ell(x) = 0\}$ com g_j côncavas e h_ℓ afins é convexo (convenção $g_j \geq 0$ da UC: ver 1.1).




Teorema 4

Seja f de classe C^2 num conjunto aberto convexo S . São equivalentes:

- (a) f é convexa em S ;
- (b) $f(x_1) \geq f(x_2) + \nabla f(x_2)^T(x_1 - x_2)$ para todos $x_1, x_2 \in S$ (o gráfico fica acima de qualquer plano tangente);
- (c) a Hessiana $Hf(x)$ é **semidefinida positiva** para todo o $x \in S$.

- Hf definida positiva em $S \Rightarrow f$ *estritamente* convexa (recíproca falsa: $f(x) = x^4$ é estritamente convexa mas $f''(0) = 0$).
- f convexa $\Rightarrow \nabla f(x^*) = 0$ é condição necessária e *suficiente* de mínimo global (sem restrições; x^* interior a S).

Caracterizações de convexidade (cont.)



Teorema 4(b): o gráfico fica acima da tangente.

Teorema 5

Uma forma quadrática $q(x) = x^T A x$ com A semidefinida positiva é convexa.

Teorema 6

Uma combinação linear com coeficientes não negativos de funções convexas é convexa.

Teorema 7

f é convexa em S se e só se, para todos $x \in S$ e d , a função de uma variável $\varphi(\alpha) = f(x + \alpha d)$ (a do 2.1) é convexa no intervalo $\{\alpha : x + \alpha d \in S\}$.

- **Reta** $r(t) = x_0 + tv$: cada iteração de um método é um passo ao longo de uma reta.
- **Gradiente** ∇f : direção de maior crescimento, perpendicular às curvas de nível; $\nabla f^T d < 0$ define uma direção de descida.
- **Hessiana** Hf : simétrica; o sinal dos valores próprios ajuda a classificar os pontos estacionários (casos semidefinidos: inconclusivo).
- **Definida positiva** (A simétrica): $x^T A x > 0 \iff$ valores próprios $> 0 \iff$ menores líderes > 0 .
- **Convexidade** ($f \in C^2$ num aberto convexo): Hessiana semidefinida positiva $\iff f$ convexa $\Rightarrow$ mínimo local é global.

Referências Lista completa: *Bibliografia da UC*, no fim do PDF da UC.

- Nocedal, J., Wright, S. J., *Numerical Optimization*, 2.^a ed., Springer, 2006 — cap. 2.
- Dennis, J. E., Jr., Schnabel, R. B., *Numerical Methods for Unconstrained Optimization and Nonlinear Equations*, SIAM (Classics in Applied Mathematics 16), 1996.

Recursos

- MATLAB: `meshgrid`, `gradient`, `surf`, `contour`, `quiver` (visualizar gradientes).