

Otimização

R. Pré-requisitos e revisão: geometria, cálculo diferencial e álgebra linear

José Firmino Aguilar Madeira

Porquê estas revisões?

Os métodos de otimização que vamos estudar assentam em quatro ferramentas:

- **Vetores e retas** — cada iteração de um método é um passo $\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$ ao longo de uma reta (esquema iterativo: ver 1.1).
- **Gradiente** — quando $\nabla f \neq \mathbf{0}$, dá a direção de maior crescimento de f ; $-\nabla f$ é a direção de descida mais rápida.
- **Hessiana e valores próprios** — ajudam a classificar os pontos estacionários.
- **Convexidade** — relaciona mínimos locais e globais (ver 1.1).

Vetores, retas e hiperplanos

Ângulo entre dois vetores


Para $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$, ambos não nulos, o **produto interno** é

$$\langle \mathbf{u}, \mathbf{v} \rangle = \mathbf{u}^T \mathbf{v} = \sum_{i=1}^n u_i v_i = \|\mathbf{u}\| \|\mathbf{v}\| \cos \theta.$$

Logo o ângulo $\theta \in [0, \pi]$ entre $\mathbf{u}$ e $\mathbf{v}$ é

$$\theta = \arccos\left(\frac{\langle \mathbf{u}, \mathbf{v} \rangle}{\|\mathbf{u}\| \|\mathbf{v}\|}\right).$$

- $\langle \mathbf{u}, \mathbf{v} \rangle = 0 \iff \mathbf{u} \perp \mathbf{v}$
- $\langle \mathbf{u}, \mathbf{v} \rangle > 0 \iff \theta < 90^\circ$ (“mesmo sentido”)




Equação paramétrica da reta

A reta R que passa por $\mathbf{x}_0$ com a direção de $\mathbf{v} \neq \mathbf{0}$ é

$$\mathbf{r}(t) = \mathbf{x}_0 + t \mathbf{v}, \quad t \in \mathbb{R}.$$

- $\mathbf{x}_0$ — ponto inicial
- $\mathbf{v}$ — vetor diretor
- t — parâmetro escalar

Cada ponto do espaço é identificado com o seu vetor de posição.



Exemplo 1

Reta que passa por $\mathbf{x}_0 = (1, 1, 1)^T$ na direção de $\mathbf{v} = (1, 1, 0)^T$:

$$\mathbf{r}(t) = (1, 1, 1)^T + t(1, 1, 0)^T = (1 + t, 1 + t, 1)^T, \quad t \in \mathbb{R}.$$

Exemplo 2 — da forma paramétrica para a cartesiana

Seja $\mathbf{r}(t) = (4 - 2t, 3 + 6t)^T$ em $\mathbb{R}^2$. De $x = 4 - 2t$ vem $t = \frac{4 - x}{2}$ e

$$y = 3 + 6 \cdot \frac{4 - x}{2} = 15 - 3x.$$

Dados dois pontos $\mathbf{u} \neq \mathbf{s}$, o **segmento** que os une é

$$\mathbf{r}(t) = \mathbf{u} + t(\mathbf{s} - \mathbf{u}) = (1 - t)\mathbf{u} + t\mathbf{s}, \quad 0 \leq t \leq 1.$$

($t = 0$ dá $\mathbf{u}$, $t = 1$ dá $\mathbf{s}$.)

Exemplo 3

Segmento entre $(0, 2)$ e $(2, 0)$:

$$\mathbf{r}(t) = (1 - t)(0, 2) + t(2, 0) = (2t, 2 - 2t), \quad 0 \leq t \leq 1.$$

Esta expressão reaparece na definição de **conjunto convexo**.

Um hiperplano generaliza a reta e o plano para n dimensões:

Espaço	Equação	Objeto
$\mathbb{R}^2$	$a_1x_1 + a_2x_2 = b$	reta (dimensão 1)
$\mathbb{R}^3$	$a_1x_1 + a_2x_2 + a_3x_3 = b$	plano (dimensão 2)
$\mathbb{R}^n$	$a_1x_1 + \cdots + a_nx_n = \mathbf{a}^T \mathbf{x} = b, \mathbf{a} \neq \mathbf{0}$	hiperplano (dimensão $n - 1$)

- Um hiperplano de $\mathbb{R}^n$ é o conjunto $\{\mathbf{x} : \mathbf{a}^T \mathbf{x} = b\}$ com $\mathbf{a} \neq \mathbf{0}$; o vetor $\mathbf{a}$ é **normal** ao hiperplano.
- Um hiperplano divide $\mathbb{R}^n$ em dois semiespaços: $\mathbf{a}^T \mathbf{x} \leq b$ e $\mathbf{a}^T \mathbf{x} \geq b$.
- Restrições lineares de um problema de otimização definem hiperplanos e semiespaços.

Funções de várias variáveis


Gráfico de uma função

Dada $f: S \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$, o **gráfico** de f é o subconjunto de $\mathbb{R}^{n+1}$

$$\{(\mathbf{x}, x_{n+1}) \in \mathbb{R}^n \times \mathbb{R} : \mathbf{x} \in S, x_{n+1} = f(\mathbf{x})\}.$$

- $n = 1$: curva $y = f(x)$ no plano.
- $n = 2$: superfície $z = f(x, y)$ no espaço.

Exemplo. $f(x, y) = x^2 + 2y^2$ está definida em $\mathbb{R}^2$; o gráfico é uma superfície em $\mathbb{R}^3$.



Conjuntos de nível


Seja $f: D \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ e $c \in \mathbb{R}$. O **conjunto de nível** c é

$$\{\mathbf{x} \in D : f(\mathbf{x}) = c\},$$



isto é, os pontos do domínio onde f vale c . Em $\mathbb{R}^2$ é, em geral, uma **curva de nível**; em $\mathbb{R}^3$, uma **superfície de nível**.

Exemplo. Para $f(x, y) = x^2 + 2y^2$ e $c > 0$, as curvas de nível $x^2 + 2y^2 = c$ são elipses concêntricas (c cresce para fora). Para $c = 0$ o conjunto de nível reduz-se a $\{(0, 0)\}$; para $c < 0$ é vazio.

Em otimização desenham-se curvas de nível para visualizar o percurso dos métodos iterativos.



Curvas de nível — interpretação topográfica



As curvas de nível são as “cotas” de um mapa topográfico: a projeção no plano xy das interseções do gráfico com planos horizontais $z = c$.

Derivada direcional

Queremos a taxa de variação de $z = f(\mathbf{x})$ no ponto $\mathbf{a}$ na direção de um vetor **unitário** $\mathbf{u}$ ($\|\mathbf{u}\| = 1$).

Definição

Seja $f: D \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$, $\mathbf{a}$ interior a D e $\|\mathbf{u}\| = 1$. A derivada direcional de f em $\mathbf{a}$ na direção $\mathbf{u}$ é

$$D_{\mathbf{u}}f(\mathbf{a}) = \lim_{h \rightarrow 0} \frac{f(\mathbf{a} + h\mathbf{u}) - f(\mathbf{a})}{h},$$

se o limite existir.

- A distância entre $\mathbf{a}$ e $\mathbf{a} + h\mathbf{u}$ é $|h|$; o quociente é a taxa média de variação por unidade de comprimento no segmento de $\mathbf{a}$ a $\mathbf{a} + h\mathbf{u}$.
- Depende do ponto $\mathbf{a}$ e da direção $\mathbf{u}$.

Exemplo

Seja $f(\mathbf{a})$ a temperatura no ponto $\mathbf{a}$ de uma sala com um radiador e a porta aberta. Movendo-nos em direção à porta, a temperatura desce; em direção ao radiador, sobe. A taxa a que varia depende de onde estamos e para onde vamos.

Se $\mathbf{u} = \mathbf{e}_i$ (vetor da base canónica), $D_{\mathbf{e}_i} f(\mathbf{a}) = \frac{\partial f}{\partial x_i}(\mathbf{a})$: as derivadas parciais são casos particulares da derivada direcional.

Definição

O gradiente de f , denotado ∇f ou $\text{grad } f$, é o vetor das derivadas parciais:

$$\nabla f(\mathbf{x}) = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right)^T.$$

Se f é diferenciável, a derivada direcional é um produto interno:

$$D_{\mathbf{u}}f(\mathbf{x}) = \sum_{j=1}^n \frac{\partial f}{\partial x_j}(\mathbf{x}) u_j = \nabla f(\mathbf{x})^T \mathbf{u} = \|\nabla f(\mathbf{x})\| \cos \theta,$$

onde θ é o ângulo entre $\nabla f(\mathbf{x})$ e $\mathbf{u}$.

Lipschitz. f é **L-Lipschitz** em S se $|f(\mathbf{x}) - f(\mathbf{y})| \leq L \|\mathbf{x} - \mathbf{y}\|$ para todos $\mathbf{x}, \mathbf{y} \in S$ (gradiente Lipschitz: $\|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\| \leq L \|\mathbf{x} - \mathbf{y}\|$).

Teorema

Se f é diferenciável em $\mathbf{x}$ e $\nabla f(\mathbf{x}) \neq \mathbf{0}$, o valor máximo de $D_{\mathbf{u}}f(\mathbf{x})$ é $\|\nabla f(\mathbf{x})\|$ e ocorre quando $\mathbf{u}$ tem a direção e o sentido de $\nabla f(\mathbf{x})$.


- ∇f aponta para onde f cresce mais depressa; $-\nabla f$ aponta para onde f decresce mais depressa.
- Uma direção $\mathbf{d}$ é de **descida** em $\mathbf{x}$ se $\nabla f(\mathbf{x})^T \mathbf{d} < 0$ (ângulo com o gradiente superior a 90°).
- É a base do método do gradiente (*steepest descent*).

Gradiente e curvas de nível em $\mathbb{R}^2$

Se $\nabla f(x_0, y_0) \neq \mathbf{0}$, o gradiente, além de dar a direção de maior crescimento, é **perpendicular à curva de nível** $f(x, y) = c$ que passa por (x_0, y_0) .

Ao longo da curva de nível f é constante, logo a derivada direcional na direção tangente é zero: $\nabla f^T \mathbf{u}_{\text{tang}} = 0$.


Exemplo. $f = x^2 + 2y^2$, $\nabla f = (2x, 4y)^T$: as setas cruzam as elipses em ângulo reto e apontam para fora (onde c cresce).



Gradiente e superfícies de nível em $\mathbb{R}^3$

Se $\nabla F(P) \neq \mathbf{0}$, o gradiente $\nabla F(x_0, y_0, z_0)$ é **perpendicular ao plano tangente** à superfície de nível $F(x, y, z) = c$ que passa por $P = (x_0, y_0, z_0)$.

Se $\mathbf{r}(t)$ é uma curva na superfície com $\mathbf{r}(t_0) = P$, então $F(\mathbf{r}(t)) = c$ e, derivando, $\nabla F(P)^T \mathbf{r}'(t_0) = 0$: o gradiente é ortogonal a todos os vetores tangentes.



Plano tangente e reta normal a uma superfície

Seja $F(x, y, z) = c$ e $P = (x_0, y_0, z_0)$ um ponto da superfície com $\nabla F(P) \neq \mathbf{0}$.

- **Plano tangente** — vetores que partem de P e são ortogonais a $\nabla F(P)$:

$$\nabla F(P)^T (x - x_0, y - y_0, z - z_0) = 0.$$

- **Reta normal** — passa por P com a direção de $\nabla F(P)$:

$$(x - x_0, y - y_0, z - z_0) = s \nabla F(P), \quad s \in \mathbb{R},$$


ou, em equações simétricas (quando as derivadas parciais são não nulas),

$$\frac{x - x_0}{F_x(P)} = \frac{y - y_0}{F_y(P)} = \frac{z - z_0}{F_z(P)}.$$

Visualizar gradientes em MATLAB

```
[X,Y] = meshgrid(-2:.2:2);  
Z = X.*exp(-X.^2 - Y.^2);  
[DX,DY] = gradient(Z,.2,.2);  
subplot(1,2,1); surf(X,Y,Z)  
subplot(1,2,2); contour(X,Y,Z)  
hold on; quiver(X,Y,DX,DY)
```

Superfície $z = x e^{-x^2 - y^2}$ e o campo de gradientes sobre as curvas de nível.



Matriz Hessiana e valores próprios

Matriz Hessiana

Seja $f: A \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ de classe C^2 numa vizinhança de $\mathbf{a} \in A$. A **matriz Hessiana** de f em $\mathbf{a}$ (também $\nabla^2 f(\mathbf{a})$; nos métodos, $H_k = \nabla^2 f(\mathbf{x}_k)$) é

$$Hf(\mathbf{a}) = \left[\frac{\partial^2 f}{\partial x_i \partial x_j}(\mathbf{a}) \right]_{i,j=1}^n = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}.$$

Como $f \in C^2$, é uma matriz $n \times n$ **simétrica real** (Schwarz). Veremos a seguir que isso garante valores próprios reais, e que o seu sinal ajuda a classificar pontos estacionários.


Definição

Dada $A \in \mathbb{R}^{n \times n}$, um escalar λ e um vetor $\mathbf{x} \neq \mathbf{0}$ tais que


$$A\mathbf{x} = \lambda\mathbf{x}$$

dizem-se, respetivamente, **valor próprio** e **vetor próprio** de A .

- λ pode ser complexo mesmo com A real (mas não se A for simétrica).
- **Espectro:** $\lambda(A) = \{\lambda_1, \dots, \lambda_n\}$, o conjunto dos valores próprios.
- **Raio espectral:** $\rho(A) = \max\{|\lambda_1|, \dots, |\lambda_n|\}$.



- $Ax = \lambda x$
- Ax tem a direção de x
- comprimento e sentido de Ax dependem de λ



- $Ay \neq \lambda y$ para todo o λ
- Ay não tem a direção de y
- y não é vetor próprio de A

$$A\mathbf{x} = \lambda\mathbf{x} \iff A\mathbf{x} - \lambda\mathbf{x} = \mathbf{0} \iff (A - \lambda I)\mathbf{x} = \mathbf{0}.$$

Queremos soluções **não triviais** ($\mathbf{x} \neq \mathbf{0}$) do sistema homogéneo, o que exige que a matriz dos coeficientes seja singular:

$$\det(A - \lambda I) = 0.$$

- $\det(A - \lambda I)$ é o **polinómio característico**, de grau n em λ ; as suas raízes são os valores próprios.
- Para cada λ_i , os vetores próprios são as soluções não nulas de $(A - \lambda_i I)\mathbf{x} = \mathbf{0}$.

Exemplo 1

$$A = \begin{bmatrix} 2 & 1 & 0 & 0 \\ 0 & 2 & 0 & 0 \\ 0 & 0 & -1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \quad \det(A - \lambda I) = (2 - \lambda)^2(-1 - \lambda)(1 - \lambda).$$

Valores próprios: 2 (multiplicidade algébrica 2), -1 e 1 (multiplicidade 1).

Exemplo 2

$$A = \begin{bmatrix} 2 & 2 & -1 \\ 1 & -1 & 0 \\ 3 & 1 & -1 \end{bmatrix}, \quad \det(A - \lambda I) = 2\lambda - \lambda^3 = -\lambda(\lambda - \sqrt{2})(\lambda + \sqrt{2}).$$

Valores próprios: $\lambda_1 = 0$, $\lambda_2 = \sqrt{2}$, $\lambda_3 = -\sqrt{2}$.

Matriz definida positiva

Definição

Uma matriz simétrica $A \in \mathbb{R}^{n \times n}$ é **definida positiva** se

$$\mathbf{x}^T A \mathbf{x} > 0 \quad \text{para todo o } \mathbf{x} \neq \mathbf{0},$$

e **semidefinida positiva** se $\mathbf{x}^T A \mathbf{x} \geq 0$ para todo o $\mathbf{x}$.

- A é definida positiva $\iff$ todos os valores próprios são positivos.
- A é semidefinida positiva $\iff$ todos os valores próprios são ≥ 0 .

Exemplo

$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$: $\det(A - \lambda I) = \begin{vmatrix} 2 - \lambda & 1 \\ 1 & 2 - \lambda \end{vmatrix} = \lambda^2 - 4\lambda + 3 = 0 \Rightarrow \lambda_1 = 3, \lambda_2 = 1$. Logo A é definida positiva.

Cr terio de Sylvester

Seja A sim trica. A   definida positiva se e s  se todos os **menores principais l deres** s o positivos:

$$\det[a_{11}] > 0, \quad \det \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} > 0, \quad \det \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} > 0, \quad \dots, \quad \det A > 0.$$

Com Δ_k o menor l der de ordem k : A   **definida negativa** se e s  se $(-1)^k \Delta_k > 0$, $k = 1, \dots, n$.

Aten o

Para *semidefinida* positiva n o basta olhar para os menores l deres:   preciso que *todos* os menores principais (n o s  os l deres) sejam ≥ 0 . Exemplo: $\begin{bmatrix} 0 & 0 \\ 0 & -1 \end{bmatrix}$ tem menores l deres 0 e 0, mas n o   semidefinida positiva ($\lambda = -1$).

Classificação de pontos estacionários

Seja $\mathbf{a}$ um ponto estacionário ($\nabla f(\mathbf{a}) = \mathbf{0}$) e sejam $\lambda_{\min}$, $\lambda_{\max}$ o menor e o maior valor próprio de $Hf(\mathbf{a})$. Uma matriz A é (semi)definida negativa se $-A$ for (semi)definida positiva; indefinida se $\mathbf{x}^T A \mathbf{x}$ toma os dois sinais. O teste da segunda derivada:

Valores próprios de $Hf(\mathbf{a})$	$Hf(\mathbf{a})$	Conclusão
todos positivos	definida positiva	$\mathbf{a}$ é mínimo local estrito
todos negativos	definida negativa	$\mathbf{a}$ é máximo local estrito
$\lambda_{\min} = 0$, $\lambda_{\max} > 0$	semidefinida positiva	$\mathbf{a}$ não é máximo
$\lambda_{\min} < 0$, $\lambda_{\max} = 0$	semidefinida negativa	$\mathbf{a}$ não é mínimo
$\lambda_{\min} < 0$, $\lambda_{\max} > 0$	indefinida	$\mathbf{a}$ é ponto de sela
todos nulos	—	inconclusivo


Nos casos semidefinidos e nulo o teste não decide; é preciso analisar termos de ordem superior. (Mínimo local estrito: ver 1.1.)

Convexidade


Definição 1

Um conjunto $S \subseteq \mathbb{R}^n$ é **convexo** se, para quaisquer $\mathbf{x}_1, \mathbf{x}_2 \in S$, o segmento que os une está contido em S :

$$(1 - t)\mathbf{x}_1 + t\mathbf{x}_2 \in S \quad \text{para todo o } t \in [0, 1].$$



convexo





não convexo

Definição 2

$f: S \rightarrow \mathbb{R}$, com S convexo, é **convexa** se o segmento que une dois pontos quaisquer do gráfico nunca fica abaixo do gráfico:

$$f((1-t)\mathbf{x}_1 + t\mathbf{x}_2) \leq (1-t)f(\mathbf{x}_1) + tf(\mathbf{x}_2), \quad t \in [0, 1].$$

É **côncava** se a desigualdade vale com $\geq$ (isto é, $-f$ é convexa).



Teorema 1

Num problema de otimização convexo (função objetivo e conjunto admissível convexos; ver 1.1), **qualquer mínimo local é mínimo global**.


Teorema 2

Se f é convexa, o conjunto de nível inferior $L_c = \{\mathbf{x} : f(\mathbf{x}) \leq c\}$ é convexo para todo o $c \in \mathbb{R}$.

Teorema 3

A interseção de conjuntos convexos é convexa.

Consequência: $\{g_j(\mathbf{x}) \geq 0, h_\ell(\mathbf{x}) = 0\}$ com g_j côncavas e h_ℓ afins é convexo (convenção $g_j \geq 0$ da UC: ver 1.1).




Teorema 4

Seja f de classe C^2 num conjunto aberto convexo S . São equivalentes:

- (a) f é convexa em S ;
- (b) $f(\mathbf{x}_1) \geq f(\mathbf{x}_2) + \nabla f(\mathbf{x}_2)^T (\mathbf{x}_1 - \mathbf{x}_2)$ para todos $\mathbf{x}_1, \mathbf{x}_2 \in S$ (o gráfico fica acima de qualquer plano tangente);
- (c) a Hessiana $Hf(\mathbf{x})$ é **semidefinida positiva** para todo o $\mathbf{x} \in S$.

- Hf definida positiva em $S \Rightarrow f$ *estritamente* convexa (recíproca falsa: $f(x) = x^4$ é estritamente convexa mas $f''(0) = 0$).
- f convexa $\Rightarrow \nabla f(\mathbf{x}^*) = \mathbf{0}$ é condição necessária e *suficiente* de mínimo global (sem restrições; $\mathbf{x}^*$ interior a S).

Caracterizações de convexidade (cont.)



Teorema 4(b): o gráfico fica acima da tangente.

Teorema 5

Uma forma quadrática $q(\mathbf{x}) = \mathbf{x}^T A \mathbf{x}$ com A semidefinida positiva é convexa.

Teorema 6

Uma combinação linear com coeficientes não negativos de funções convexas é convexa.

Teorema 7

f é convexa em S se e só se, para todos $\mathbf{x} \in S$ e $\mathbf{d}$, a função de uma variável $\varphi(\alpha) = f(\mathbf{x} + \alpha \mathbf{d})$ (a do 2.1) é convexa no intervalo $\{\alpha : \mathbf{x} + \alpha \mathbf{d} \in S\}$.

- **Reta** $\mathbf{r}(t) = \mathbf{x}_0 + t\mathbf{v}$: cada iteração de um método é um passo ao longo de uma reta.
- **Gradiente** ∇f : direção de maior crescimento, perpendicular às curvas de nível;
 $\nabla f^T \mathbf{d} < 0$ define uma direção de descida.
- **Hessiana** Hf : simétrica; o sinal dos valores próprios ajuda a classificar os pontos estacionários (casos semidefinidos: inconclusivo).
- **Definida positiva** (A simétrica): $\mathbf{x}^T A \mathbf{x} > 0 \iff$ valores próprios $> 0 \iff$ menores líderes > 0 .
- **Convexidade** ($f \in C^2$ num aberto convexo): Hessiana semidefinida positiva $\iff f$ convexa $\Rightarrow$ mínimo local é global.

Referências Lista completa: *Bibliografia da UC*, no fim do PDF da UC.

- Nocedal, J., Wright, S. J., *Numerical Optimization*, 2.^a ed., Springer, 2006 — cap. 2.
- Dennis, J. E., Jr., Schnabel, R. B., *Numerical Methods for Unconstrained Optimization and Nonlinear Equations*, SIAM (Classics in Applied Mathematics 16), 1996.

Recursos

- MATLAB: `meshgrid`, `gradient`, `surf`, `contour`, `quiver` (visualizar gradientes).