Otimização

R. Pré-requisitos e revisão: geometria, cálculo diferencial e álgebra linear

---

José Firmino Aguilar Madeira

Porquê estas revisões?

Os métodos de otimização que vamos estudar assentam em quatro ferramentas:

- Vetores e retas — cada iteração de um método é um passo $\mathbf{x}_{k+1} = \mathbf{x}_k + \lambda_k \mathbf{S}_k$ ao longo de uma reta (esquema iterativo: ver 1.1).
- Gradiente — quando $\nabla f \neq \mathbf{0}$, dá a direção de maior crescimento de f; $-\nabla f$ é a direção de descida mais rápida.
- Hessiana e valores próprios — ajudam a classificar os pontos estacionários.
- Convexidade — relaciona mínimos locais e globais (ver 1.1).

Vetores, retas e hiperplanos

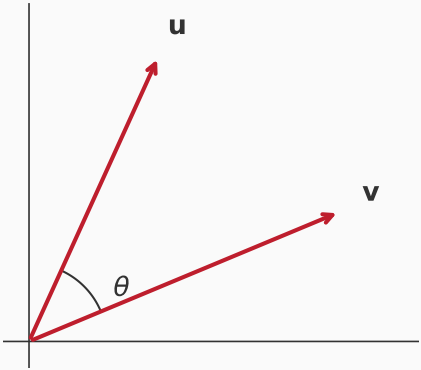
Ângulo entre dois vetores

Para $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$, ambos não nulos, o produto interno é

$$\langle \mathbf{u}, \mathbf{v} \rangle = \mathbf{u}^T \mathbf{v} = \sum_{i=1}^{n} u_i v_i = \|\mathbf{u}\| \, \|\mathbf{v}\| \cos\theta.$$

Logo o ângulo $\theta \in [0, \pi]$ entre $\mathbf{u}$ e $\mathbf{v}$ é

$$\theta = \arccos\left(\frac{\langle \mathbf{u}, \mathbf{v} \rangle}{\|\mathbf{u}\| \, \|\mathbf{v}\|} \right).$$

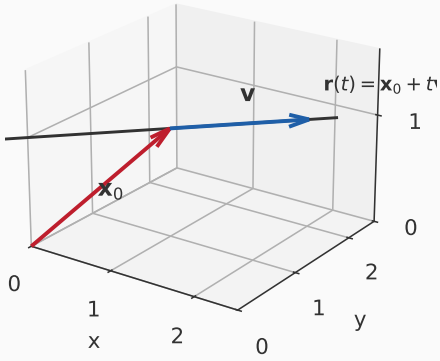


- $\langle \mathbf{u}, \mathbf{v} \rangle = 0 \iff \mathbf{u} \perp \mathbf{v}$
- $\langle \mathbf{u}, \mathbf{v} \rangle > 0 \iff \theta < 90^\circ$ ("mesmo sentido")

Equação paramétrica da reta

A reta R que passa por $\mathbf{x}_0$ com a direção de $\mathbf{v} \neq \mathbf{0}$ é

$$\mathbf{r}(t) = \mathbf{x}_0 + t\,\mathbf{v}, \qquad t \in \mathbb{R}.$$



- $\mathbf{x}_0$ — ponto inicial
- $\mathbf{v}$ — vetor diretor
- t — parâmetro escalar

Cada ponto do espaço é identificado com o seu vetor de posição.

Equação paramétrica da reta — exemplos

Exemplo 1

Reta que passa por $\mathbf{x}_0 = (1;1;1)^T$ na direção de $\mathbf{v} = (1;1;0)^T$:

$$\mathbf{r}(t) = (1;1;1)^T + t\,(1;1;0)^T = (1+t,\ 1+t,\ 1)^T, \quad t \in \mathbb{R}.$$

Exemplo 2 — da forma paramétrica para a cartesiana

Seja $\mathbf{r}(t) = (4-2t,\ 3+6t)^T$ em $\mathbb{R}^2$. De $x = 4-2t$ vem $t = \dfrac{4-x}{2}$ e

$$y = 3 + 6 \cdot \frac{4-x}{2} = 15 - 3x.$$

Segmento de reta

Dados dois pontos $\mathbf{u} \neq \mathbf{s}$, o segmento que os une é

$$\mathbf{r}(t) = \mathbf{u} + t\,(\mathbf{s} - \mathbf{u}) = (1 - t)\,\mathbf{u} + t\,\mathbf{s}, \qquad 0 \leq t \leq 1.$$

($t = 0$ dá $\mathbf{u}$, $t = 1$ dá $\mathbf{s}$.)

Exemplo 3

Segmento entre $(0; 2)$ e $(2; 0)$:

$$\mathbf{r}(t) = (1 - t)(0; 2) + t(2, 0) = (2t,\ 2 - 2t), \qquad 0 \leq t \leq 1.$$

Esta expressão reaparece na definição de conjunto convexo.

Hiperplano

Um hiperplano generaliza a reta e o plano para n dimensões:

Espaço	Equação	Objeto
$\mathbb{R}^2$	$a_1x_1 + a_2x_2 = b$	reta (dimensão 1)
$\mathbb{R}^3$	$a_1x_1 + a_2x_2 + a_3x_3 = b$	plano (dimensão 2)
$\mathbb{R}^n$	$a_1x_1 + \cdots + a_nx_n = \mathbf{a}^T\mathbf{x} = b, \quad \mathbf{a} \neq \mathbf{0}$	hiperplano (dimensão $n-1$)

- Um hiperplano de $\mathbb{R}^n$ é o conjunto $\{\mathbf{x} : \mathbf{a}^T\mathbf{x} = b\}$ com $\mathbf{a} \neq \mathbf{0}$; o vetor $\mathbf{a}$ é normal ao hiperplano.
- Um hiperplano divide $\mathbb{R}^n$ em dois semiespaços: $\mathbf{a}^T\mathbf{x} \leq b$ e $\mathbf{a}^T\mathbf{x} \geq b$.
- Restrições lineares de um problema de otimização definem hiperplanos e semiespaços.

Funções de várias variáveis

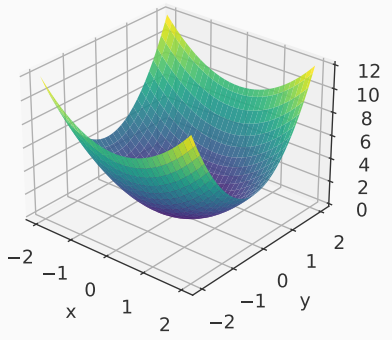
Gráfico de uma função

Dada $f : S \subseteq \mathbb{R}^n \to \mathbb{R}$, o gráfico de f é o subconjunto de $\mathbb{R}^{n+1}$

$$\{(\mathbf{x}, x_{n+1}) \in \mathbb{R}^n \times \mathbb{R} \ : \ \mathbf{x} \in S, \ x_{n+1} = f(\mathbf{x})\}.$$

- $n = 1$: curva $y = f(x)$ no plano.
- $n = 2$: superfície $z = f(x, y)$ no espaço.

Exemplo. $f(x, y) = x^2 + 2y^2$ está definida em $\mathbb{R}^2$; o gráfico é uma superfície em $\mathbb{R}^3$.



Conjuntos de nível

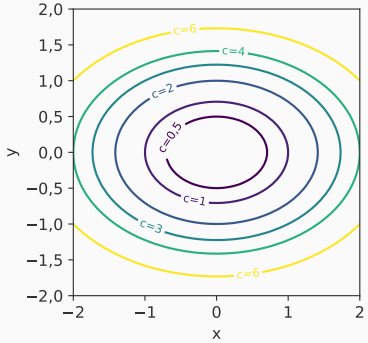
Seja $f\colon D \subseteq \mathbb{R}^n \to \mathbb{R}$ e $c \in \mathbb{R}$. O conjunto de nível c é

$$\{\mathbf{x} \in D \ : \ f(\mathbf{x}) = c\},$$

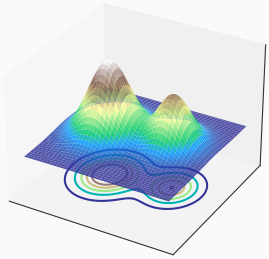
isto é, os pontos do domínio onde f vale c. Em $\mathbb{R}^2$ é, em geral, uma curva de nível; em $\mathbb{R}^3$, uma superfície de nível.

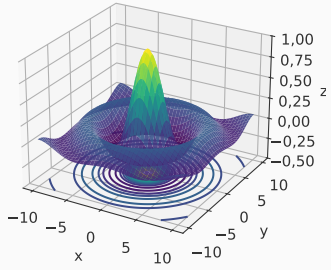
Exemplo. Para $f(x, y) = x^2 + 2y^2$ e $c > 0$, as curvas de nível $x^2 + 2y^2 = c$ são elipses concêntricas (c cresce para fora). Para $c = 0$ o conjunto de nível reduz-se a $\{(0; 0)\}$; para $c < 0$ é vazio.

Em otimização desenham-se curvas de nível para visualizar o percurso dos métodos iterativos.



Curvas de nível — interpretação topográfica





As curvas de nível são as "cotas" de um mapa topográfico: a projeção no plano xy das interseções do gráfico com planos horizontais $z = c$.

Derivada direcional

Queremos a taxa de variação de $z = f(\mathbf{x})$ no ponto $\mathbf{a}$ na direção de um vetor unitário $\mathbf{u}$ ($\|\mathbf{u}\| = 1$).

Definição

Seja $f : D \subseteq \mathbb{R}^n \to \mathbb{R}$, $\mathbf{a}$ interior a D e $\|\mathbf{u}\| = 1$. A derivada direcional de f em $\mathbf{a}$ na direção $\mathbf{u}$ é

$$D_{\mathbf{u}} f(\mathbf{a}) = \lim_{h \to 0} \frac{f(\mathbf{a} + h\mathbf{u}) - f(\mathbf{a})}{h},$$

se o limite existir.

- A distância entre $\mathbf{a}$ e $\mathbf{a} + h\mathbf{u}$ é $|h|$; o quociente é a taxa média de variação por unidade de comprimento no segmento de $\mathbf{a}$ a $\mathbf{a} + h\mathbf{u}$.
- Depende do ponto $\mathbf{a}$ *e* da direção $\mathbf{u}$.

Derivada direcional — intuição

Exemplo

Seja $f(\mathbf{a})$ a temperatura no ponto $\mathbf{a}$ de uma sala com um radiador e a porta aberta. Movendo-nos em direção à porta, a temperatura desce; em direção ao radiador, sobe. A taxa a que varia depende de onde estamos e para onde vamos.

Se $\mathbf{u} = \mathbf{e}_i$ (vetor da base canónica), $D_{\mathbf{e}_i} f(\mathbf{a}) = \dfrac{\partial f}{\partial x_i}(\mathbf{a})$: as derivadas parciais são casos particulares da derivada direcional.

Vetor gradiente

Definição

O gradiente de f, denotado ∇f ou $\operatorname{grad} f$, é o vetor das derivadas parciais:

$$\nabla f(\mathbf{x}) = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \ldots, \frac{\partial f}{\partial x_n} \right)^T.$$

Se f é diferenciável, a derivada direcional é um produto interno:

$$D_{\mathbf{u}} f(\mathbf{x}) = \sum_{j=1}^{n} \frac{\partial f}{\partial x_j}(\mathbf{x})\, u_j = \nabla f(\mathbf{x})^T \mathbf{u} = \|\nabla f(\mathbf{x})\| \cos\theta,$$

onde θ é o ângulo entre $\nabla f(\mathbf{x})$ e $\mathbf{u}$.

Lipschitz. f é L-Lipschitz em S se $|f(\mathbf{x}) - f(\mathbf{y})| \leq L \|\mathbf{x} - \mathbf{y}\|$ para todos $\mathbf{x}, \mathbf{y} \in S$ (gradiente Lipschitz: $\|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\| \leq L \|\mathbf{x} - \mathbf{y}\|$).

Direção de maior crescimento

Teorema

Se f é diferenciável em $\mathbf{x}$ e $\nabla f(\mathbf{x}) \neq \mathbf{0}$, o valor máximo de $D_{\mathbf{u}} f(\mathbf{x})$ é $\|\nabla f(\mathbf{x})\|$ e ocorre quando $\mathbf{u}$ tem a direção e o sentido de $\nabla f(\mathbf{x})$.

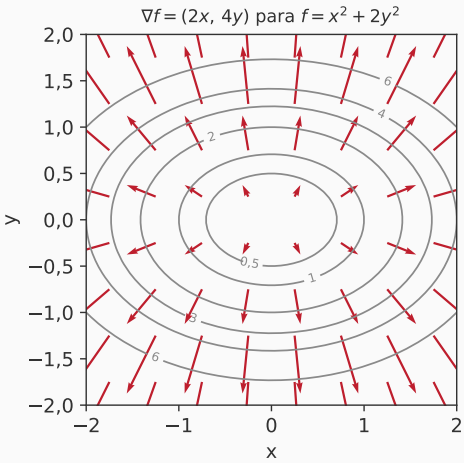
- ∇f aponta para onde f cresce mais depressa; $-\nabla f$ aponta para onde f decresce mais depressa.
- Uma direção $\mathbf{d}$ é de descida em $\mathbf{x}$ se $\nabla f(\mathbf{x})^T \mathbf{d} < 0$ (ângulo com o gradiente superior a 90°).
- É a base do método do gradiente (*steepest descent*).

Gradiente e curvas de nível em $\mathbb{R}^2$

Se $\nabla f(x_0, y_0) \neq \mathbf{0}$, o gradiente, além de dar a direção de maior crescimento, é perpendicular à curva de nível $f(x, y) = c$ que passa por (x_0, y_0).

Ao longo da curva de nível f é constante, logo a derivada direcional na direção tangente é zero: $\nabla f^T \mathbf{u}_{\text{tang}} = 0$.

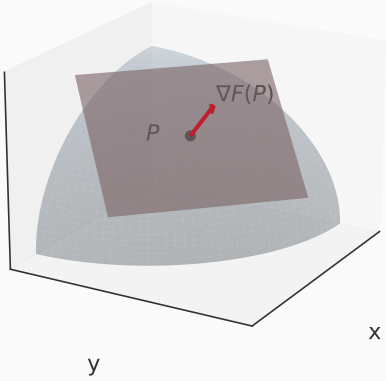
Exemplo. $f = x^2 + 2y^2$, $\nabla f = (2x, 4y)^T$: as setas cruzam as elipses em ângulo reto e apontam para fora (onde c cresce).



Gradiente e superfícies de nível em $\mathbb{R}^3$

Se $\nabla F(P) \neq \mathbf{0}$, o gradiente $\nabla F(x_0, y_0, z_0)$ é perpendicular ao plano tangente à superfície de nível $F(x, y, z) = c$ que passa por $P = (x_0, y_0, z_0)$.

Se $\mathbf{r}(t)$ é uma curva na superfície com $\mathbf{r}(t_0) = P$, então $F(\mathbf{r}(t)) = c$ e, derivando, $\nabla F(P)^T \mathbf{r}'(t_0) = 0$: o gradiente é ortogonal a todos os vetores tangentes.



Plano tangente e reta normal a uma superfície

Seja $F(x, y, z) = c$ e $P = (x_0, y_0, z_0)$ um ponto da superfície com $\nabla F(P) \neq \mathbf{0}$.

- **Plano tangente** — vetores que partem de P e são ortogonais a $\nabla F(P)$:

$$\nabla F(P)^T \, (x - x_0,\ y - y_0,\ z - z_0) = 0.$$

- **Reta normal** — passa por P com a direção de $\nabla F(P)$:

$$(x - x_0,\ y - y_0,\ z - z_0) = s \, \nabla F(P), \qquad s \in \mathbb{R},$$

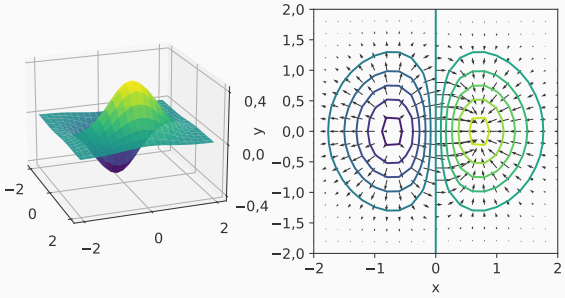
ou, em equações simétricas (quando as derivadas parciais são não nulas),

$$\frac{x - x_0}{F_x(P)} = \frac{y - y_0}{F_y(P)} = \frac{z - z_0}{F_z(P)}.$$

Visualizar gradientes em MATLAB

```
[X,Y] = meshgrid(-2:.2:2);
Z = X.*exp(-X.^2 - Y.^2);
[DX,DY] = gradient(Z,.2,.2);
subplot(1,2,1); surf(X,Y,Z)
subplot(1,2,2); contour(X,Y,Z)
hold on; quiver(X,Y,DX,DY)
```

Superfície $z = x\, e^{-x^2-y^2}$ e o campo de gradientes sobre as curvas de nível.



Matriz Hessiana e valores próprios

Matriz Hessiana

Seja $f\colon A \subseteq \mathbb{R}^n \to \mathbb{R}$ de classe C^2 numa vizinhança de $\mathbf{a} \in A$. A matriz Hessiana de f em $\mathbf{a}$ (também $\nabla^2 f(\mathbf{a})$; nos métodos, $H_k = \nabla^2 f(\mathbf{x}_k)$) é

$$Hf(\mathbf{a}) = \left[\frac{\partial^2 f}{\partial x_i\,\partial x_j}(\mathbf{a})\right]_{i,j=1}^{n} = \begin{bmatrix} \dfrac{\partial^2 f}{\partial x_1^2} & \dfrac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \dfrac{\partial^2 f}{\partial x_1 \partial x_n} \\ \dfrac{\partial^2 f}{\partial x_2 \partial x_1} & \dfrac{\partial^2 f}{\partial x_2^2} & \cdots & \dfrac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \dfrac{\partial^2 f}{\partial x_n \partial x_1} & \dfrac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \dfrac{\partial^2 f}{\partial x_n^2} \end{bmatrix}.$$

Como $f \in C^2$, é uma matriz $n \times n$ simétrica real (Schwarz). Veremos a seguir que isso garante valores próprios reais, e que o seu sinal ajuda a classificar pontos estacionários.

Funções quadráticas na forma matricial

Toda a quadrática em $\mathbb{R}^n$ escreve-se $f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T A\mathbf{x} - \mathbf{b}^T\mathbf{x} + c$, com A simétrica (a forma usada nos caps. 3 e 4). Então $\nabla f(\mathbf{x}) = A\mathbf{x} - \mathbf{b}$, $Hf(\mathbf{x}) = A$ (constante), e os pontos estacionários resolvem $A\mathbf{x} = \mathbf{b}$.

Como ler A, $\mathbf{b}$ e c

$A_{ii} = 2\times$(coeficiente de x_i^2); $A_{ij} = A_{ji} =$ coeficiente de $x_i x_j$ $(i \neq j)$; $b_i = -$(coeficiente de x_i); c = termo constante.

1. $f = \frac{1}{2}(x_1^2 + 9x_2^2)$: $A = \begin{bmatrix} 1 & 0 \\ 0 & 9 \end{bmatrix}$, $\mathbf{b} = \mathbf{0}$ (3.3.1).
2. $f = 3x_1^2 + x_2^2 - 12x_1 - 8x_2$: $A = \begin{bmatrix} 6 & 0 \\ 0 & 2 \end{bmatrix}$, $\mathbf{b} = (12;\, 8)^T$; $\mathbf{x}^* = A^{-1}\mathbf{b} = (2;\, 4)$ (3.2.5).
3. $f = x_1^2 + x_1x_2 + 2x_2^2 - x_1$: $A = \begin{bmatrix} 2 & 1 \\ 1 & 4 \end{bmatrix}$, $\mathbf{b} = (1;\, 0)^T$; $\mathbf{x}^* = A^{-1}\mathbf{b} = \left(\frac{4}{7};\, -\frac{1}{7}\right)$.

Erro típico: esquecer o $\frac{1}{2}$ (pôr A_{ii} igual ao coeficiente de x_i^2) ou dividir o termo cruzado por dois.

Definição

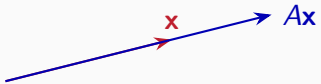
Dada $A \in \mathbb{R}^{n \times n}$, um escalar λ e um vetor $\mathbf{x} \neq \mathbf{0}$ tais que

$$A\mathbf{x} = \lambda\mathbf{x}$$

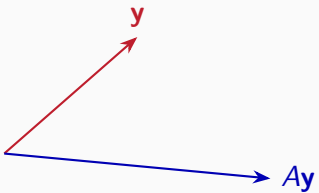
dizem-se, respetivamente, valor próprio e vetor próprio de A.

- λ pode ser complexo mesmo com A real (mas não se A for simétrica).
- **Espectro:** $\lambda(A) = \{\lambda_1, \ldots, \lambda_n\}$, o conjunto dos valores próprios.
- **Raio espectral:** $\rho(A) = \max\{|\lambda_1|, \ldots, |\lambda_n|\}$.

Interpretação geométrica



- $A\mathbf{x} = \lambda\mathbf{x}$
- $A\mathbf{x}$ tem a direção de $\mathbf{x}$
- comprimento e sentido de $A\mathbf{x}$ dependem de λ



- $A\mathbf{y} \neq \lambda\mathbf{y}$ para todo o λ
- $A\mathbf{y}$ não tem a direção de $\mathbf{y}$
- $\mathbf{y}$ não é vetor próprio de A

Cálculo dos valores e vetores próprios

$$A\mathbf{x} = \lambda\mathbf{x} \iff A\mathbf{x} - \lambda I\mathbf{x} = \mathbf{0} \iff (A - \lambda I)\,\mathbf{x} = \mathbf{0}.$$

Queremos soluções não triviais ($\mathbf{x} \neq \mathbf{0}$) do sistema homogéneo, o que exige que a matriz dos coeficientes seja singular:

$$\det(A - \lambda I) = 0.$$

- $\det(A - \lambda I)$ é o polinómio característico, de grau n em λ; as suas raízes são os valores próprios.
- Para cada λ_i, os vetores próprios são as soluções não nulas de $(A - \lambda_i I)\mathbf{x} = \mathbf{0}$.

Valores próprios — exemplos

Exemplo 1

$$A = \begin{bmatrix} 2 & 1 & 0 & 0 \\ 0 & 2 & 0 & 0 \\ 0 & 0 & -1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \quad \det(A - \lambda I) = (2-\lambda)^2(-1-\lambda)(1-\lambda).$$

Valores próprios: 2 (multiplicidade algébrica 2), -1 e 1 (multiplicidade 1).

Exemplo 2

$$A = \begin{bmatrix} 2 & 2 & -1 \\ 1 & -1 & 0 \\ 3 & 1 & -1 \end{bmatrix}, \quad \det(A - \lambda I) = 2\lambda - \lambda^3 = -\lambda(\lambda - \sqrt{2})(\lambda + \sqrt{2}).$$

Valores próprios: $\lambda_1 = 0$, $\lambda_2 = \sqrt{2}$, $\lambda_3 = -\sqrt{2}$.

Matriz definida positiva

Definição

Uma matriz simétrica $A \in \mathbb{R}^{n \times n}$ é definida positiva se

$$\mathbf{x}^T A \mathbf{x} > 0 \quad \text{para todo o } \mathbf{x} \neq \mathbf{0},$$

e semidefinida positiva se $\mathbf{x}^T A \mathbf{x} \geq 0$ para todo o $\mathbf{x}$.

- A é definida positiva $\iff$ todos os valores próprios são positivos.
- A é semidefinida positiva $\iff$ todos os valores próprios são ≥ 0.

Exemplo

$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$: $\det(A - \lambda I) = \begin{vmatrix} 2-\lambda & 1 \\ 1 & 2-\lambda \end{vmatrix} = \lambda^2 - 4\lambda + 3 = 0 \Rightarrow \lambda_1 = 3,\ \lambda_2 = 1$. Logo A é definida positiva.

Critério de Sylvester

Seja A simétrica. A é definida positiva se e só se todos os menores principais líderes são positivos:

$$\det\begin{bmatrix} a_{11} \end{bmatrix} > 0, \quad \det\begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} > 0, \quad \det\begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} > 0, \ \ldots, \ \det A > 0.$$

Com Δ_k o menor líder de ordem k: A é definida negativa se e só se $(-1)^k \Delta_k > 0$, $k = 1, \ldots, n$.

Atenção

Para *semidefinida* positiva não basta olhar para os menores líderes: é preciso que *todos* os menores principais (não só os líderes) sejam ≥ 0. Exemplo: $\begin{bmatrix} 0 & 0 \\ 0 & -1 \end{bmatrix}$ tem menores líderes 0 e 0, mas não é semidefinida positiva ($\lambda = -1$).

Classificação de pontos estacionários

Seja $\mathbf{a}$ um ponto estacionário ($\nabla f(\mathbf{a}) = \mathbf{0}$) e sejam $\lambda_{\min}$, $\lambda_{\max}$ o menor e o maior valor próprio de $Hf(\mathbf{a})$. Uma matriz A é (semi)definida negativa se $-A$ for (semi)definida positiva; indefinida se $\mathbf{x}^T A\mathbf{x}$ toma os dois sinais. O teste da segunda derivada:

Valores próprios de $Hf(\mathbf{a})$	$Hf(\mathbf{a})$	Conclusão
todos positivos	definida positiva	$\mathbf{a}$ é mínimo local estrito
todos negativos	definida negativa	$\mathbf{a}$ é máximo local estrito
$\lambda_{\min} = 0,\ \lambda_{\max} > 0$	semidefinida positiva	$\mathbf{a}$ não é máximo
$\lambda_{\min} < 0,\ \lambda_{\max} = 0$	semidefinida negativa	$\mathbf{a}$ não é mínimo
$\lambda_{\min} < 0,\ \lambda_{\max} > 0$	indefinida	$\mathbf{a}$ é ponto de sela
todos nulos	—	inconclusivo

Nos casos semidefinidos e nulo o teste não decide; é preciso analisar termos de ordem superior. (Mínimo local estrito: ver 1.1.)

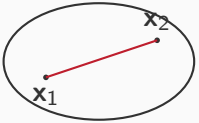
Convexidade

Conjunto convexo

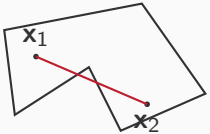
Definição 1

Um conjunto $S \subseteq \mathbb{R}^n$ é convexo se, para quaisquer $\mathbf{x}_1, \mathbf{x}_2 \in S$, o segmento que os une está contido em S:

$$(1-t)\,\mathbf{x}_1 + t\,\mathbf{x}_2 \in S \qquad \text{para todo o } t \in [0,1].$$



convexo



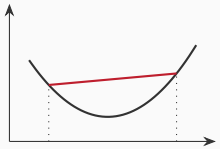
não convexo

Definição 2

$f : S \to \mathbb{R}$, com S convexo, é convexa se o segmento que une dois pontos quaisquer do gráfico nunca fica abaixo do gráfico:

$$f\big((1-t)\,\mathbf{x}_1 + t\,\mathbf{x}_2\big) \leq (1-t)\,f(\mathbf{x}_1) + t\,f(\mathbf{x}_2), \qquad t \in [0,1].$$

É côncava se a desigualdade vale com $\geq$ (isto é, $-f$ é convexa).



convexa


côncava

Convexidade e otimização

Teorema 1

Num problema de otimização convexo (função objetivo e conjunto admissível convexos; ver 1.1), qualquer mínimo local é mínimo global.

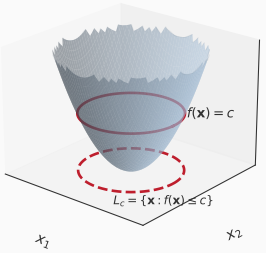
Teorema 2

Se f é convexa, o conjunto de nível inferior $L_c = \{\mathbf{x} : f(\mathbf{x}) \leq c\}$ é convexo para todo o $c \in \mathbb{R}$.

Teorema 3

A interseção de conjuntos convexos é convexa.

Consequência: $\{g_j(\mathbf{x}) \geq 0,\ h_\ell(\mathbf{x}) = 0\}$ com g_j côncavas e h_ℓ afins é convexo (convenção $g_j \geq 0$ da UC: ver 1.1).



Teorema 4

Seja f de classe C^2 num conjunto aberto convexo S. São equivalentes:

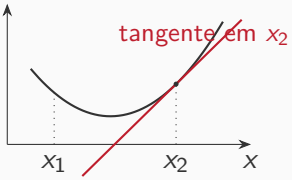
(a) f é convexa em S;

(b) $f(\mathbf{x}_1) \geq f(\mathbf{x}_2) + \nabla f(\mathbf{x}_2)^T(\mathbf{x}_1 - \mathbf{x}_2)$ para todos $\mathbf{x}_1, \mathbf{x}_2 \in S$ (o gráfico fica acima de qualquer plano tangente);

(c) a Hessiana $Hf(\mathbf{x})$ é semidefinida positiva para todo o $\mathbf{x} \in S$.

- Hf definida positiva em $S \Rightarrow f$ *estritamente* convexa (recíproca falsa: $f(x) = x^4$ é estritamente convexa mas $f''(0) = 0$).
- f convexa $\Rightarrow \nabla f(\mathbf{x}^*) = \mathbf{0}$ é condição necessária *e suficiente* de mínimo global (sem restrições; $\mathbf{x}^*$ interior a S).

Caracterizações de convexidade (cont.)



Teorema 4(b): o gráfico fica acima da tangente.

Teorema 5

Uma forma quadrática $q(\mathbf{x}) = \mathbf{x}^T A\mathbf{x}$ com A semidefinida positiva é convexa.

Teorema 6

Uma combinação linear com coeficientes não negativos de funções convexas é convexa.

Teorema 7

f é convexa em S se e só se, para todos $\mathbf{x} \in S$ e $\mathbf{d}$, a função de uma variável $\varphi(\alpha) = f(\mathbf{x} + \alpha\mathbf{d})$ (a do 2.1) é convexa no intervalo $\{\alpha : \mathbf{x} + \alpha\mathbf{d} \in S\}$.

O QUE DEVE FICAR — R

- **Reta** $\mathbf{r}(t) = \mathbf{x}_0 + t\mathbf{v}$: cada iteração de um método é um passo ao longo de uma reta.
- **Gradiente** ∇f: direção de maior crescimento, perpendicular às curvas de nível; $\nabla f^T \mathbf{d} < 0$ define uma direção de descida.
- **Hessiana** Hf: simétrica; o sinal dos valores próprios ajuda a classificar os pontos estacionários (casos semidefinidos: inconclusivo).
- **Definida positiva** (A simétrica): $\mathbf{x}^T A\mathbf{x} > 0 \iff$ valores próprios $> 0 \iff$ menores líderes > 0.
- **Convexidade** ($f \in C^2$ num aberto convexo): Hessiana semidefinida positiva $\iff f$ convexa $\Rightarrow$ mínimo local é global.

Referências e recursos

Referências Lista completa: *Bibliografia da UC*, no fim do PDF da UC.

- Nocedal, J., Wright, S. J., *Numerical Optimization*, 2.ª ed., Springer, 2006 — cap. 2.
- Dennis, J. E., Jr., Schnabel, R. B., *Numerical Methods for Unconstrained Optimization and Nonlinear Equations*, SIAM (Classics in Applied Mathematics 16), 1996.

Recursos

- MATLAB: `meshgrid`, `gradient`, `surf`, `contour`, `quiver` (visualizar gradientes).